2026-2학기 데이터사이언스

6강. 기술통계량과 시각화

2026. 10. 12.

자료를 처음 열었다. 무엇부터 보나

- 세종 아파트 실거래 15,486건. 그대로는 아무도 못 읽음
- 줄이는 방법은 여럿이고 무엇을 고르느냐에 따라 다른 것이 보임
- 오늘은 일곱 가지를 목록으로 펼치고 언제 무엇을 고르는지까지

오늘의 방법 일곱

	방법	무엇을 답하나	필요한 자료
1	도수분포표와 히스토그램	값이 어디에 몰려 있나	연속변수 1개
2	대표값 — 평균·중앙값·최빈값	가운데를 하나의 숫자로	연속변수 1개
3	산포 — 범위·사분위수범위·표준편차	얼마나 흩어져 있나	연속변수 1개
4	박스플롯	분포를 다섯 숫자로 압축	연속변수 1개 (+집단)
5	산점도와 상관계수	두 변수가 함께 움직이나, 얼마나 직선적인가	연속변수 2개
6	K-means 군집분석	대상을 정한 개수의 그룹으로 묶음	연속변수 여럿
7	계층적 군집분석	대상을 가까운 순서대로 묶어 나무로	연속변수 여럿

→ 1~4 는 **변수 하나**를, 5 는 **둘**을, 6~7 은 **여럿**을 다룸

오늘의 실습자료와 자료 정리

세종시 아파트 매매 실거래가

- **파일:** `06강–세종아파트실거래가.zip`
- **기간:** 2017년 1월 ~ 2020년 12월 계약분
- **규모:** 23,597건
- **열:** 계약년월 · 시군구 · 단지명 · 전용면적(m²) · 거래금액(만원) · 건축년도 · 해제사유발생일 등 11개
- **함께 든 것:** 열 설명(README) · 방법별 프롬프트 · 로직 문서 본보기

→ 정리 기준이 결과를 바꿈. **무엇을 왜 뺐는지**를 남김

자료: COMPAS 「주택 시장 특성분석」(세종, SBJ_2102_001)

자료 정리 프롬프트

세종시_아파트매매_실거래가_2017-2020.csv 를 읽고 행 수, 열 이름, 열마다 빈 값의 개수를 보여 줘.

거래금액(만원)은 "8,600" 같은 문자열이야. 숫자로 바꿔 줘.

해제사유발생일이 있는 거래(취소)와 전용면적 60m² 이하는 빼 줘. 기준마다 몇 건이 빠졌는지 따로 알려 줘.

시군구의 마지막 단어로 「동」 열을, 거래금액 ÷ 전용면적으로 「m²당 가격」 열을 만들어 줘.

무엇을 왜 뺐는지 로직 문서로 정리해 줘.

확인할 값: 23,597건 → 취소 537건 제외 23,060건 → 60m² 이하 7,574건 제외 **15,486건**

도수분포표와 히스토그램: 목적과 정의

값의 범위를 계급으로 나누고 계급마다 몇 개가 들어가는지 센 것

- **계급:** 값의 범위를 일정한 폭으로 나눈 구간
- **도수(빈도):** 한 계급에 들어간 관측치의 개수
- **상대도수:** 도수를 전체 관측치 수로 나눈 비율
- **도수분포표:** 계급별 도수를 표로 정리한 것
- **히스토그램:** 계급을 가로축에, 도수를 막대 높이로 그린 그림. 막대를 붙여 그림

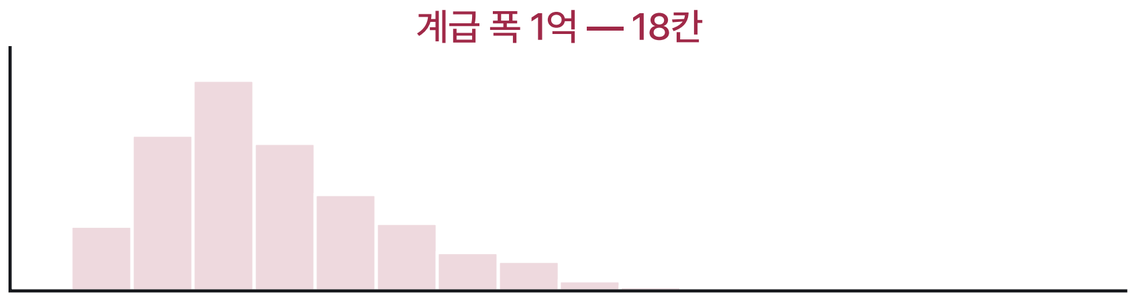
필요한 자료: 연속변수 1개

→ 자료를 처음 열었을 때 **가장 먼저 하는 일**. 가운데가 어디고 꼬리가 어느 쪽으로 늘어지는지가 한눈에 들어옴

도수분포표와 히스토그램: 어떻게 작동하나

1. 계급 폭을 정함
   세종은 1억 단위로 잘랐음
2. 값을 계급에 떨어뜨림
   39,000만원 → 3~4억 계급
3. 계급마다 셈
   그것이 빈도
4. 막대 높이로 세움
   붙여 그림. 막대 사이를 띄우지 않음

→ 계급 폭이 결과를 바꿈. 넓으면 뭉개지고 좁으면 들쭉날쭉함





같은 자료 15,486건. 계급 폭만 다름

도수분포표와 히스토그램: 적용 사례

거래 15,486건을 1억 단위 18개 계급으로 나눔

봉우리가 **3~4억**에 있고 오른쪽으로 길게 늘어짐

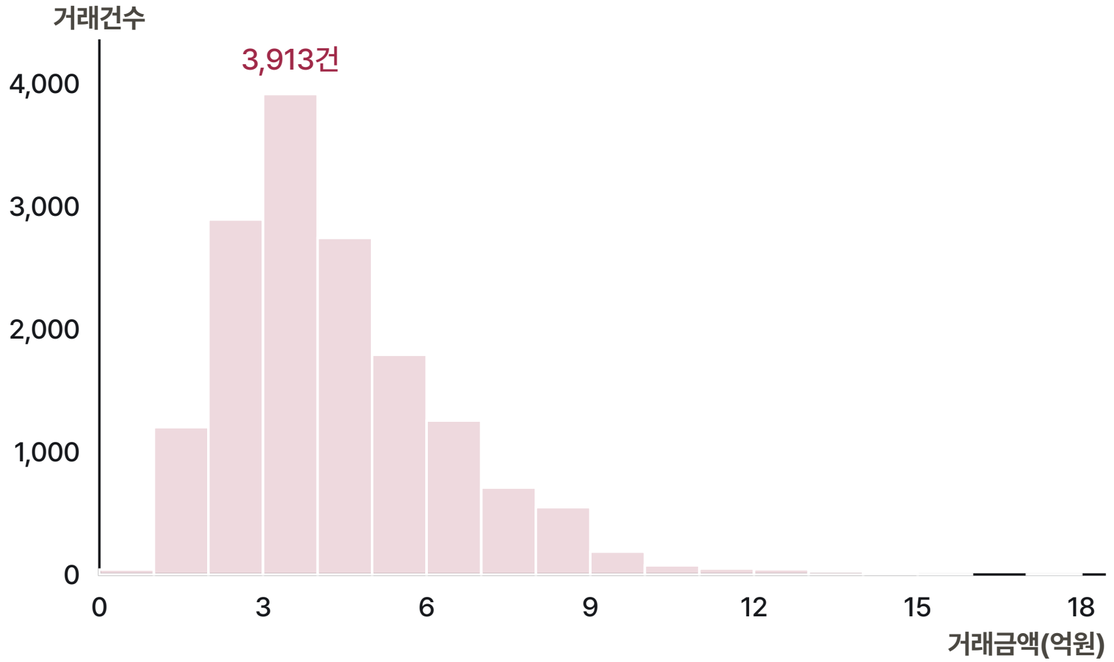
왼쪽에는 더 갈 데가 없고 오른쪽은 17억까지 열려 있음

→ 이 모양이면 평균이 중앙값보다 큼

→ 다음 방법에서 확인함

자료: COMPAS 「주택 시장 특성분석」(세종, SBJ_2102_001)

계산: analysis/07-기술적분석/07-세종주택시장.py



대표값: 목적과 정의

흩어진 값들의 가운데를 숫자 하나로 나타낸 것

- **평균:** 모든 값을 더해 값의 개수로 나눈 것
- **중앙값:** 값을 크기순으로 늘어놓았을 때 한가운데에 오는 값. 개수가 짝수이면 가운데 두 값의 평균
- **최빈값:** 가장 자주 나타나는 값. 연속변수는 계급으로 묶은 뒤 도수가 가장 큰 계급을 씀

필요한 자료: 연속변수 1개 (최빈값은 범주도 가능)

→ 셋은 **서로 다른 가운데**. 어느 것을 쓰느냐로 결론이 달라짐

대표값: 어떻게 작동하나

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \quad \cdot \quad \text{중앙값} = x_{((n+1)/2)} \text{ (크기순으로 세운 뒤)}$$

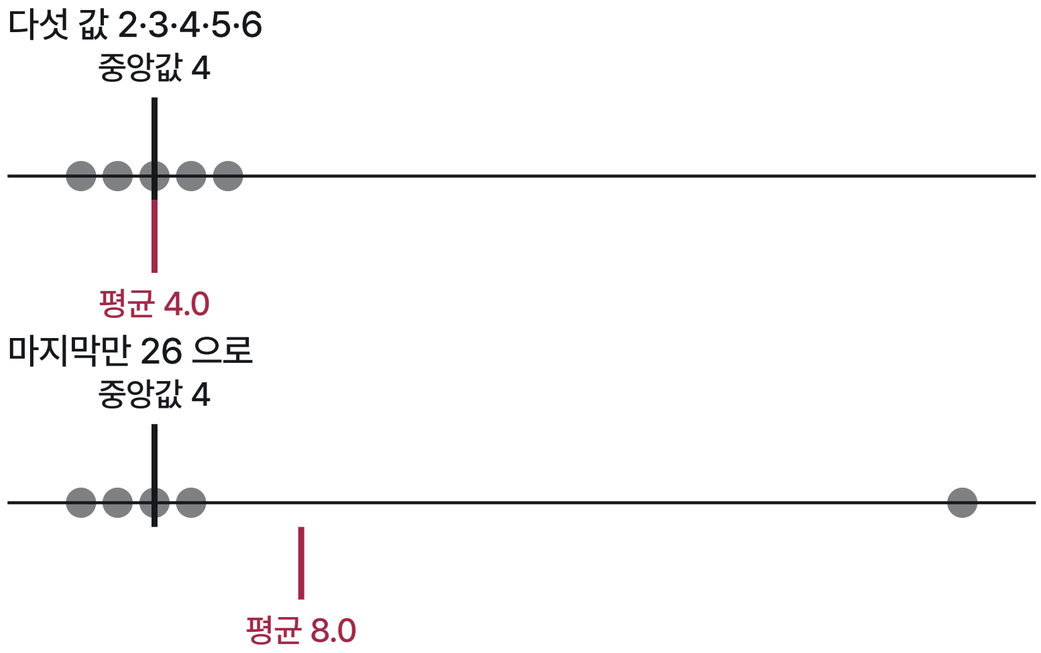
평균은 무게중심

값 하나가 멀리 있으면 **그쪽으로 끌려감**

중앙값은 순위

얼마나 먼지는 보지 않고 **몇 번째인지만** 봄

→ 그래서 한쪽 꼬리가 긴 자료에서 **평균 > 중앙값**



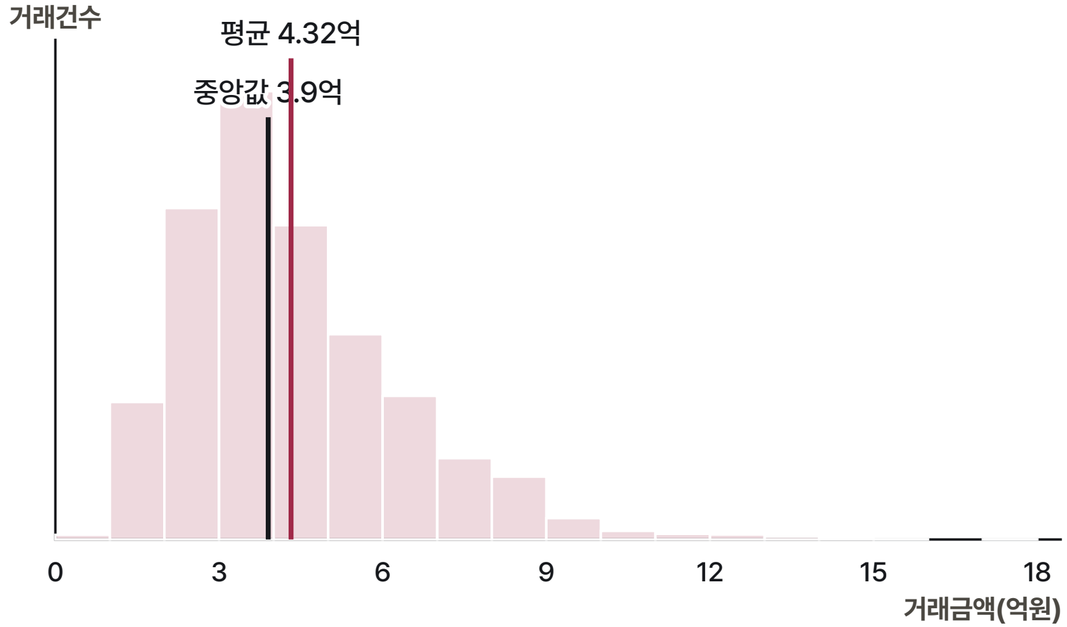
대표값: 적용 사례

평균	43,199만원
중앙값	39,000만원
차이	**4,199만원**

앞의 히스토그램에서 본 **오른쪽 긴 꼬리**가 평균을 위로 끌어올림

→ 세종 집값을 하나로 말해야 한다면 **중앙값**. 평균은 소수의 고가 거래를 담고 있음

계산: analysis/07-기술적분석/07-세종주택시장.py



산포: 목적과 정의

값들이 가운데에서 얼마나 멀리 흩어져 있는지를 측정한 것

- **범위:** 최댓값에서 최솟값을 뺀 것
- **사분위수:** 크기순으로 늘어놓은 값을 네 등분하는 세 값. Q1 은 아래에서 25%, Q3 은 75% 지점
- **사분위수범위(IQR):** Q3 − Q1. 가운데 50% 가 퍼진 폭
- **분산:** 각 값과 평균의 차이를 제곱해 평균 낸 것
- **표준편차:** 분산의 제곱근. 퍼짐을 원래 단위로 나타냄

필요한 자료: 연속변수 1개

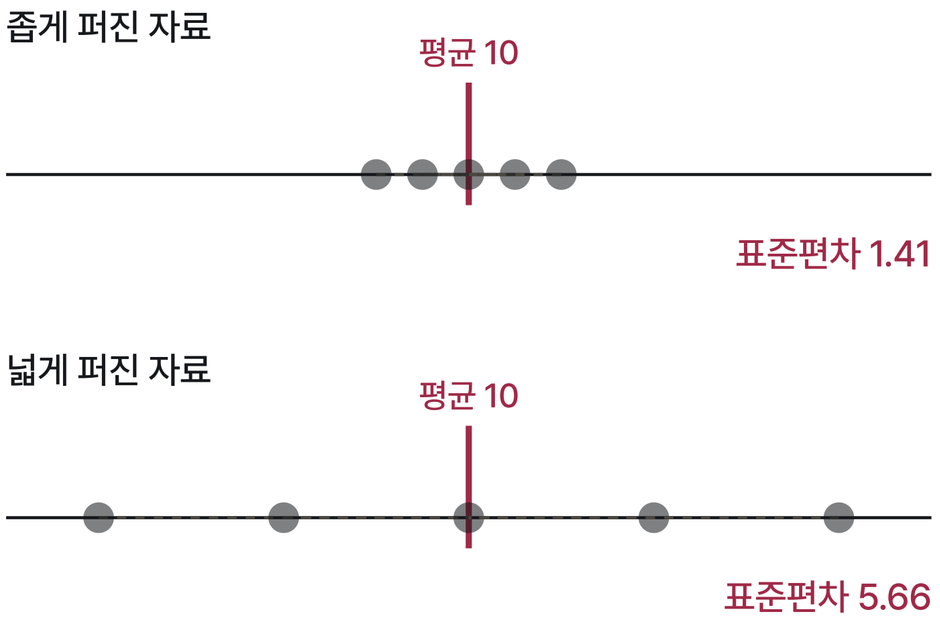
→ 대표값만으로는 **같은 가운데, 다른 분포**를 구별하지 못함

산포: 어떻게 작동하나

$$s = \sqrt{\frac{1}{n}\sum (x_i - \bar{x})^2} \quad \cdot \quad \mathrm{IQR} = Q_3 - Q_1$$

1. 평균에서 얼마나 떨어졌나를 각 값마다 측정함
2. 제곱함 — 양쪽 방향을 같게 만들고 먼 값을 키움
3. 평균 냄 — 그것이 분산
4. 제곱근 — 원래 단위로 돌아옴

→ 표준편차는 **제곱**을 거치므로 먼 값 하나에 민감함. IQR 은 가운데 절반만 보므로 둔감함



산포: 적용 사례

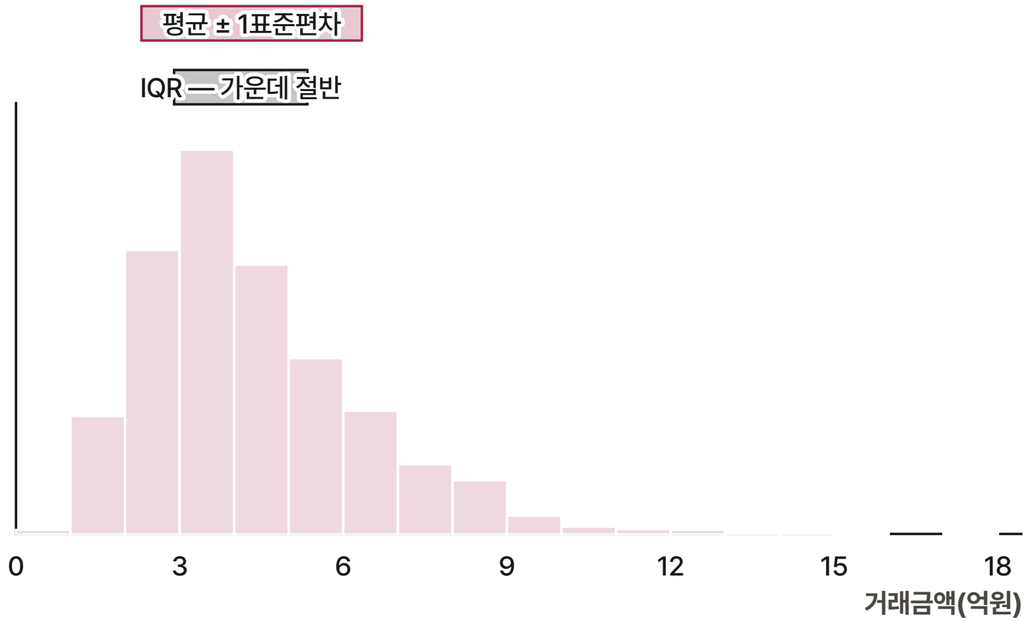
범위 (최대−최소)	16.62억
사분위수범위 (Q3−Q1)	2.44억
표준편차	2.02억

가운데 절반은 **2.9억~5.34억** 안에 있음

범위는 16.62억으로 IQR 의 **일곱 배 가까움**

→ 양 끝의 몇 건이 범위를 혼자 정함. 퍼짐을 말할 때 **범위보다 IQR** 이 안전함

계산: analysis/07-기술적분석/07-세종주택시장.py



박스플롯: 목적과 정의

분포를 다섯 숫자로 압축해 그린 그림

- **다섯 숫자 요약:** 최솟값 · Q1 · 중앙값 · Q3 · 최댓값
- **상자:** Q1 에서 Q3 까지의 직사각형. 안의 선이 중앙값
- **울타리:** Q1 − 1.5×IQR 과 Q3 + 1.5×IQR. 이상치를 가르는 경계
- **수염:** 상자에서 울타리 안의 가장 먼 값까지 뻗은 선
- **이상치:** 울타리 밖에 있는 값. 점으로 따로 찍음

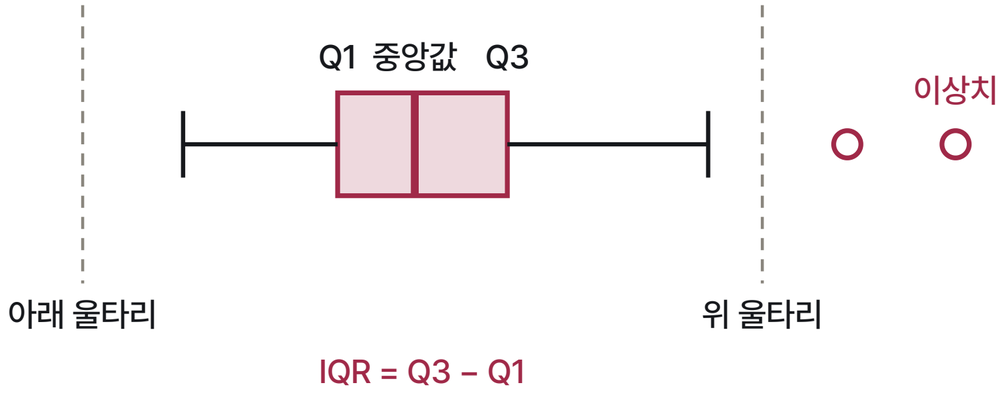
필요한 자료: 연속변수 1개. 집단이 있으면 나란히 놓고 견줌

→ 히스토그램보다 **자리를 덜 먹음**. 여러 집단을 한 화면에서 비교할 때 씀

박스플롯: 어떻게 작동하나

1. 크기순으로 세움
2. Q1 · 중앙값 · Q3 를 찾아 상자를 그림
3. 울타리를 침 — Q1−1.5×IQR 과 Q3+1.5×IQR
4. 수염은 울타리 안의 마지막 값까지만 뻗음
5. 울타리 밖의 값은 점으로 따로 찍음

→ 1.5 는 약속된 관습이지 법칙이 아님. **「이상치」로 찍혔다고 잘못된 값은 아님**



박스플롯: 적용 사례

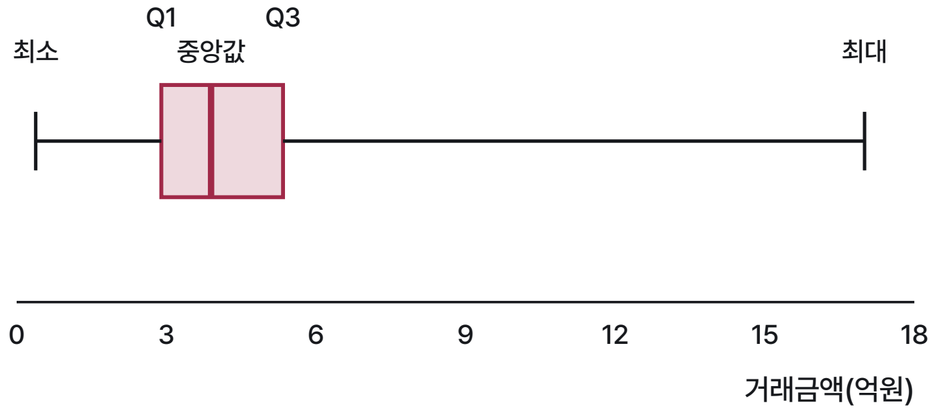
세종 거래금액의 다섯 숫자

최소	0.38억
Q1	2.90억
중앙값	3.90억
Q3	5.34억
최대	17.00억

상자가 **왼쪽으로 치우쳐** 있고 위쪽 수염이 훨씬 김

→ 히스토그램이 보여 준 **오른쪽 긴 꼬리**가 다섯 숫자만으로도 드러남

계산: analysis/07-기술적분석/07-세종주택시장.py



실습: 계약 연도별 박스플롯을 그린다

박스플롯은 집단을 **나란히 놓을 때** 쓸모가 드러남

프롬프트

정리한 15,486건으로 계약 연도(2017~2020)별 거래금액 박스플롯을 나란히 그려 줘.

수염의 끝과 이상치를 어떤 기준으로 정했는지 밝히고, 연도별 최소·Q1·중앙값·Q3·최대를 표로 보여 줘.

해마다 무엇이 달라졌는지 설명해 줘.

그림에서 볼 것

- **중앙선:** 해마다 올라가는가
- **상자 폭:** 넓어지는가, 좁아지는가
- **위쪽 이상치:** 고가 거래가 늘어나는가

확인할 값 (만원)

연도	Q1	중앙값	Q3
2017	25,000	30,900	36,700
2018	28,000	35,000	44,000
2019	32,700	42,000	52,800
2020	34,000	51,000	69,000

사분위수 계산법에 따라 Q1·Q3 가 조금 다르게 나올 수 있음. 어떤 방법을 썼는지 적으면 됨

산점도와 상관계수: 목적과 정의

두 변수가 함께 움직이는지를 그림(산점도)과 숫자(상관계수)로 보는 것

- **산점도:** 두 변수를 가로·세로 축에 놓고 관측치 하나를 점 하나로 찍은 그림
- **상관계수(피어슨 r):** 두 변수의 직선 관계를 −1 에서 1 사이의 숫자 하나로 나타낸 것
- **r 의 부호:** + 이면 함께 늘고, − 이면 하나가 늘 때 다른 하나가 줆
- **r 의 크기:** ±1 에 가까울수록 점이 직선에 몰리고, 0 에 가까우면 직선 관계가 약함

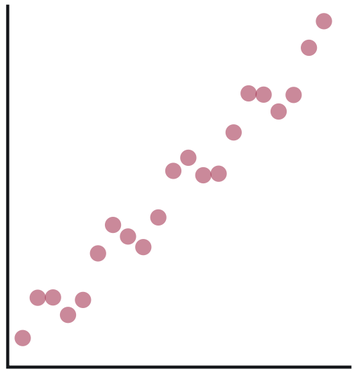
필요한 자료: 연속변수 2개

→ 그림으로 **모양**을 보고, 숫자로 **직선 관계의 세기**를 측정함

산점도와 상관계수: 어떻게 작동하나

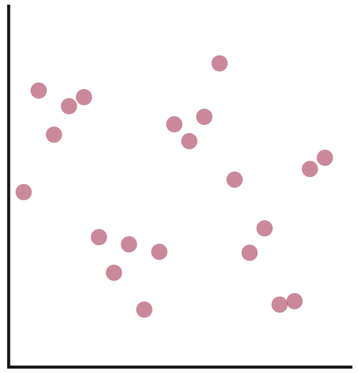
$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\,\sqrt{\sum (y_i - \bar{y})^2}}$$

1. 방향 — 오른쪽 위로 가나, 아래로 가나
2. 세기 — 선 주위에 촘촘한가, 흩어졌나
3. 모양 — 직선인가, 굽었나
4. 동떨어진 점 — 혼자 멀리 있는 것이 있나
5. r 을 계산함 — 그림 아래 숫자가 각 모양의 r



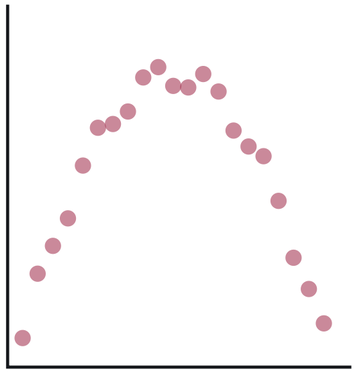
강한 양의 관계

r = 0.98



약한 관계

r = -0.26



굽은 관계

r = 0.00

→ 상관계수 하나로 줄이기 전에 **반드시 그림을 먼저 봄**. 굽은 관계는 계수가 0 에 가깝게 나옴 (9주차에서 다시)

산점도와 상관계수: 적용 사례

전용면적 ↔ 거래금액 · 상관계수 **r = 0.206**

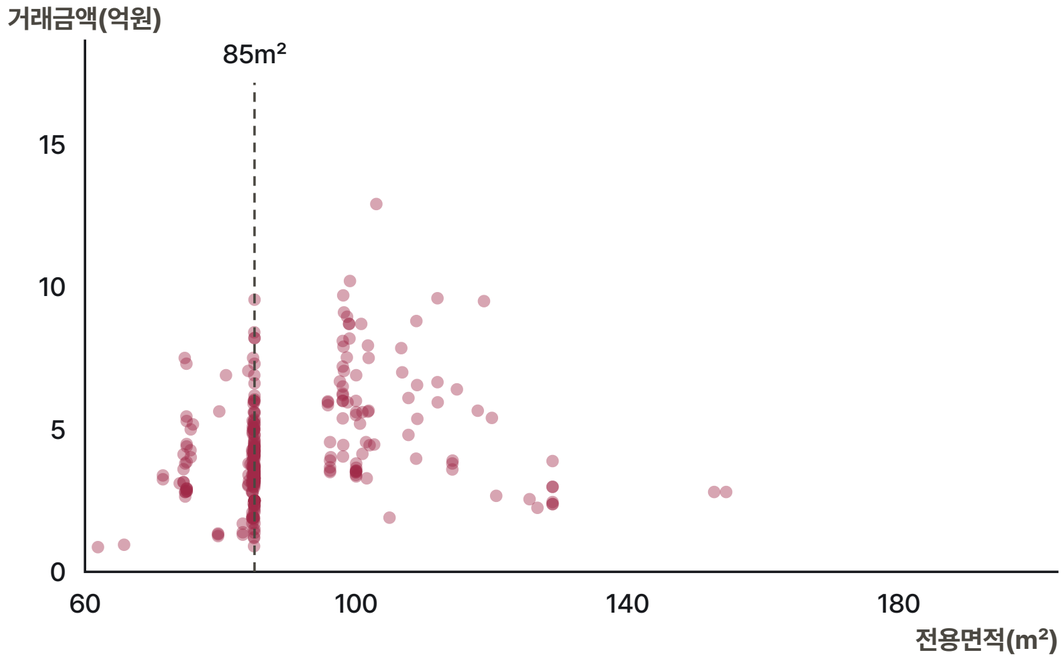
넓으면 비쌀 듯하나 점구름이 **세로로 두껍게** 퍼져 있음

같은 85m² 라도 **2억대부터 10억대까지** 있음

→ 면적만으로는 금액을 못 정함. **어느 동인지, 언제인지**가 더 크게 작용함 (10주차 회귀에서 다시)

r 은 15,486건 전체로 계산 · 그림은 51건마다 하나씩 뽑은 300건

계산: analysis/07-기술적분석/07-세종군집.py



K-means 군집분석: 목적과 정의

군집분석은 대상을 비슷한 것끼리 몇 개의 그룹으로 묶는 일

K-means 는 그 가운데 대상을 **정해 둔 k 개의 그룹**으로 나누는 방법

- **군집:** 서로 가까운 대상끼리 묶인 그룹
- **거리:** 속성값의 차이로 측정한 두 대상 사이의 떨어진 정도 (보통 유클리드 거리)
- **중심(centroid):** 한 군집에 속한 대상들의 평균 위치
- **k:** 나눌 군집의 개수. 분석자가 정하며, 엘보우 기법·실루엣 계수로 고름

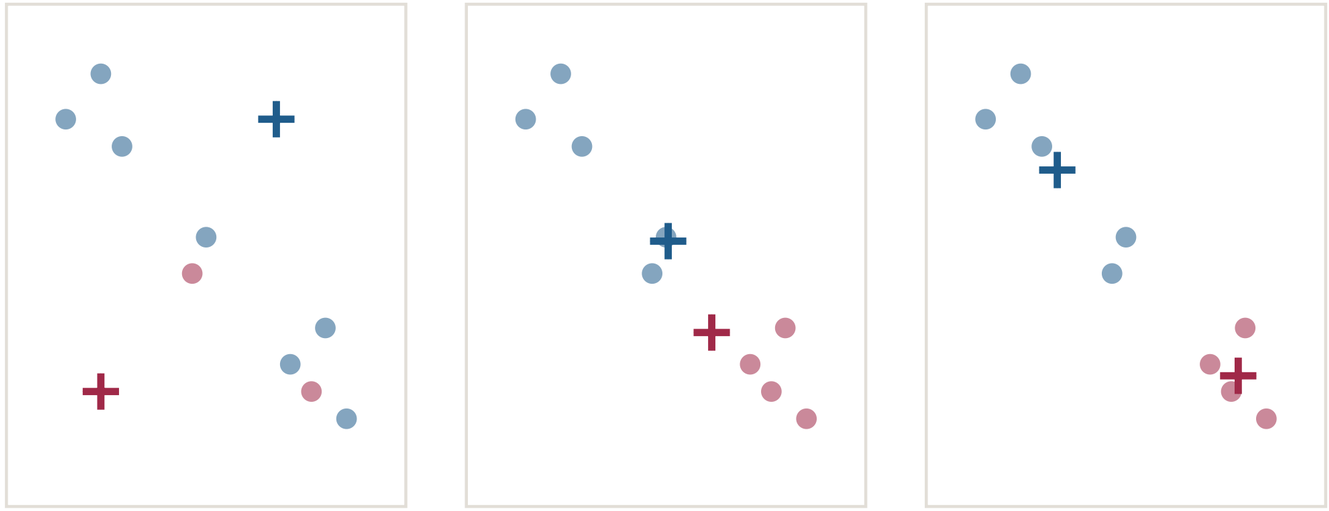
필요한 자료: 연속변수 여럿 · 군집 개수 k

→ 맞힐 답이 없음. 자료 안의 **유형**을 스스로 찾음. 위치로 묶는 것은 7주차 DBSCAN 에서 다룸

K-means: 어떻게 작동하나

1. 표준화 — 단위가 다르면 큰 수가 거리를 독차지
2. 중심 k 개를 놓음
3. 배정 — 각 점을 가장 가까운 중심에
4. 갱신 — 중심을 그 묶음의 평균으로 옮김
5. 움직이지 않을 때까지 3·4 를 되풀이

→ 시작 위치가 답을 바꿈. 이 강의 스크립트는 **서로 가장 먼 점**부터 골라 난수를 쓰지 않음



배정 → 갱신 → 되풀이

K-means: 군집 개수 k 를 정하는 법

엘보우(팔꿈치) 기법

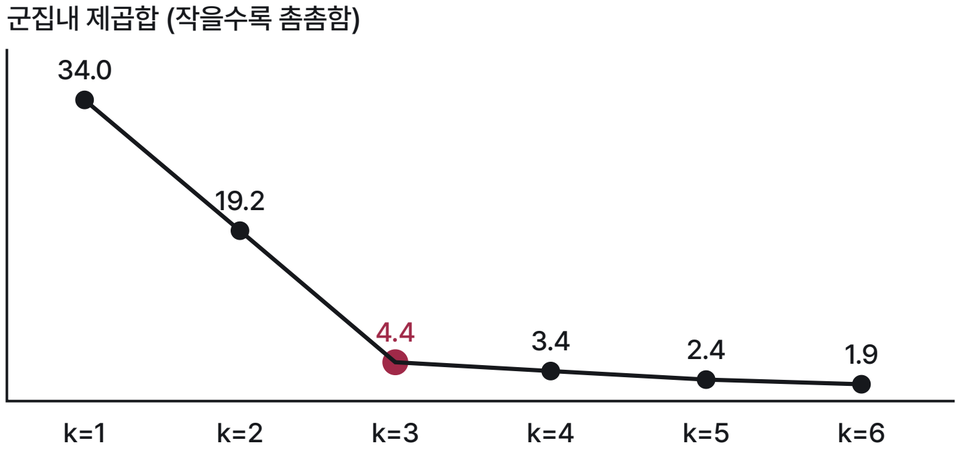
k 를 하나씩 늘리며 **군집내 제곱합(WSS)**을 구함. 줄어드는 폭이 갑자기 작아지는 **꺾인 점**의 k 를 고름

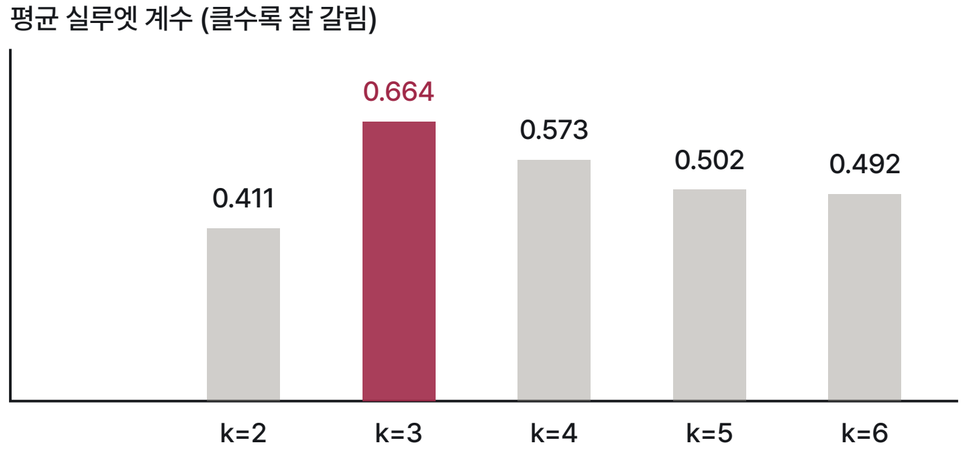
실루엣 계수

대상마다 자기 군집에 얼마나 잘 붙어 있는지를 −1~1 로 측정함. 평균이 **가장 큰 k** 를 고름

$$s = \frac{b - a}{\max(a,\, b)}$$

a: 자기 군집 안 평균거리 · b: 가장 가까운 다른 군집까지 평균거리





→ 세종 17개 동은 두 방법 모두 **k = 3**. 둘이 다르게 가리키면 군집을 해석해 보고 정함

K-means: 적용 사례

17개 동을 **거래건수**와 **m²당 중앙값**으로 묶음

군집 1 — 거래 많고 중간 가격 5개 · 평균 1,919건 · 442만원

도담동 · 종촌동 · 한솔동 · 아름동 · 고운동

군집 2 — 거래 적고 높은 가격 7개 · 평균 453건 · 688만원

대평동 · 새롬동 · 다정동 · 보람동 · 소담동 · 어진동 · 반곡동

군집 3 — 읍면 「리」 5개 · 평균 489건 · 199만원

신흥리 · 신안리 · 죽림리 · 침산리 · 남리

→ 군집 3 은 전부 「리」. 찾아낸 것은 유형이라기보다 **신도시와 편입 읍면의 경계**임

k = 3 은 엘보우(34.0 → 19.2 → 4.4 → 3.4)와 실루엣(0.664, 최대)으로 골랐음

계산: analysis/07-기술적분석/07-세종군집.py



계층적 군집분석: 목적과 정의

가장 가까운 둘을 차례로 합쳐 나가 대상 전체를 하나의 나무로 묶는 군집분석

- **덴드로그램:** 합쳐진 순서와 그때의 거리를 나무 모양으로 그린 그림
- **연결법:** 묶음과 묶음 사이의 거리를 측정하는 규칙. 최단·최장·평균연결
- **자르는 높이:** 덴드로그램을 가로로 자르는 거리. 자른 선과 만나는 가지 수가 군집 개수

필요한 자료: 연속변수 여럿. **군집 개수를 미리 정하지 않아도 됨**

→ K-means 가 「어떤 묶음으로 나뉘나」라면 계층군집은 **「어떤 순서로 가까운가」**까지 보여 줌

계층적 군집분석: 어떻게 작동하나

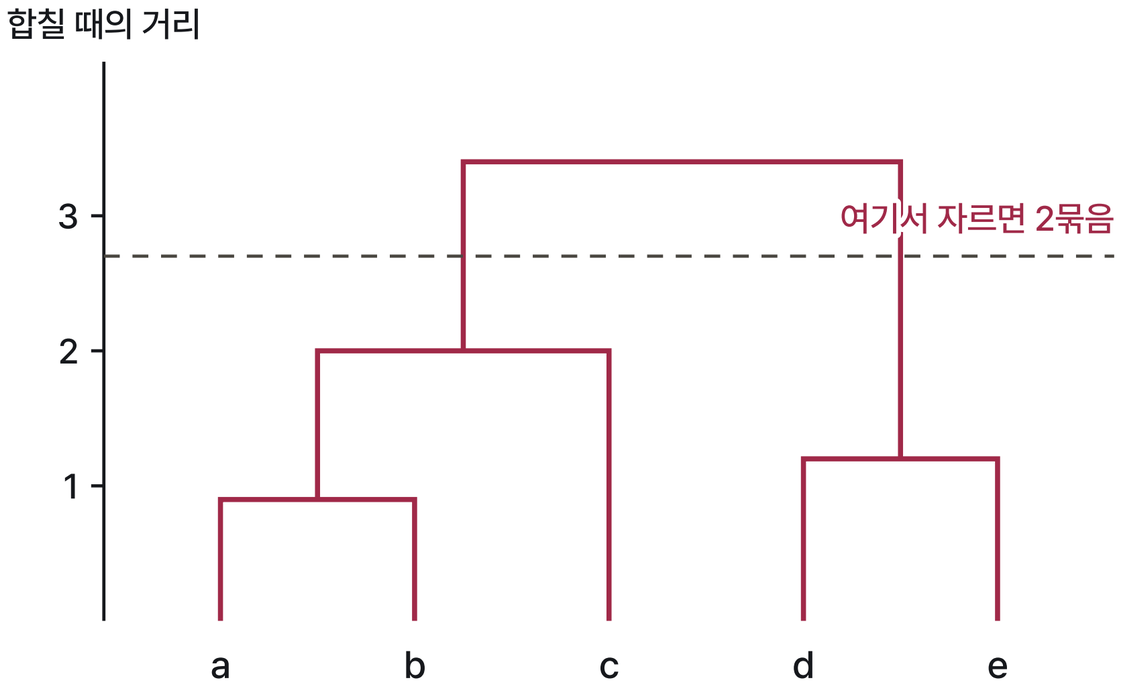
1. 각자 하나의 묶음에서 시작함
2. 모든 짝의 거리를 측정해 가장 가까운 둘을 합침
3. 합친 묶음과 나머지의 거리를 다시 측정함
4. 하나가 남을 때까지 되풀이함

묶음끼리의 거리를 어떻게 측정하나

최단연결 가장 가까운 한 쌍 · **최장연결** 가장 먼 한 쌍 · **평균연결** 모든 쌍의 평균

→ 이 강의는 **평균연결**

→ 사슬처럼 늘어지는 것과 이상치에 덜 흔들림



계층적 군집분석: 적용 사례

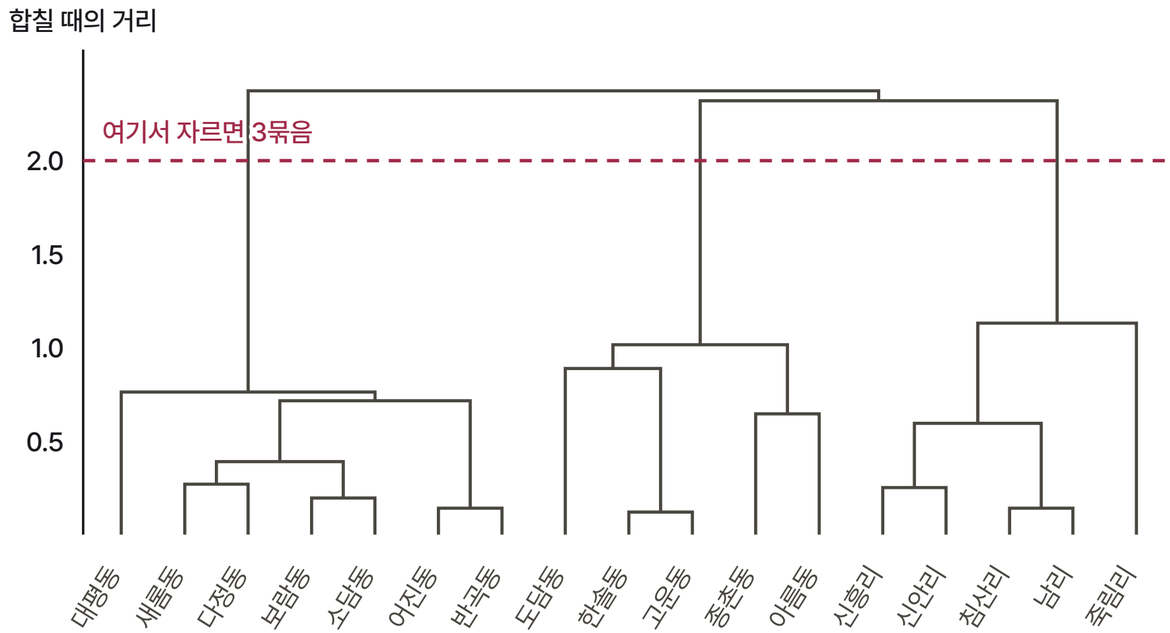
앞과 같은 17개 동, 같은 두 축

평균연결로 합쳐 나감

마지막 두 묶음이 **거리 2.374** 에서 합쳐짐. 그 앞이 크게 벌어져 있음

→ 거기서 자르면 **세 덩어리**. K-means 가 k=3 으로 찾은 것과 같은 묶음임

계산: analysis/07-기술적분석/07-세종군집.py



함께 해 보기: 2020년 아파트 단지를 군집으로 묶는다

프롬프트

정리한 자료에서 2020년 계약분만 골라 줘.

단지(동 + 단지명)마다 거래건수, m²당 가격의 중앙값, 건축년도를 구하고, 2020년 거래가 10건 이상인 단지만 남겨 줘.

세 변수를 표준화한 뒤 K-means 로 군집해 줘. k 를 2부터 7까지 바꾸며 군집내 제곱합과 평균 실루엣 계수를 구하고, k 를 고른 이유를 말해 줘.

군집마다 단지 수, 세 변수의 평균, 대표 단지 이름을 표로 보여 줘. 건축년도와 m²당 가격의 산점도에 군집을 색으로 표시해 줘.

프롬프트에 담은 판단

- **2020년만:** 한 해로 묶어야 가격이 시점에 끌려가지 않음
- **동 + 단지명:** 같은 이름의 단지가 다른 동에 있을 수 있음
- **10건 이상:** 거래가 적은 단지의 중앙값은 우연에 흔들림
- **표준화:** 거래건수·가격·연도는 단위가 모두 다름

→ 답을 받기 전에 **군집이 몇 개로, 무엇끼리 나뉠지** 먼저 예상해 적어 둠

함께 해 보기: 결과를 함께 해석한다

2020년 거래 10건 이상인 106개 단지 · k = 3

군집 1: 신도시의 새 단지 88개

m²당 691만원 · 건축 2016년 · 거래 41.9건

군집 2: 거래가 아주 많은 단지 5개

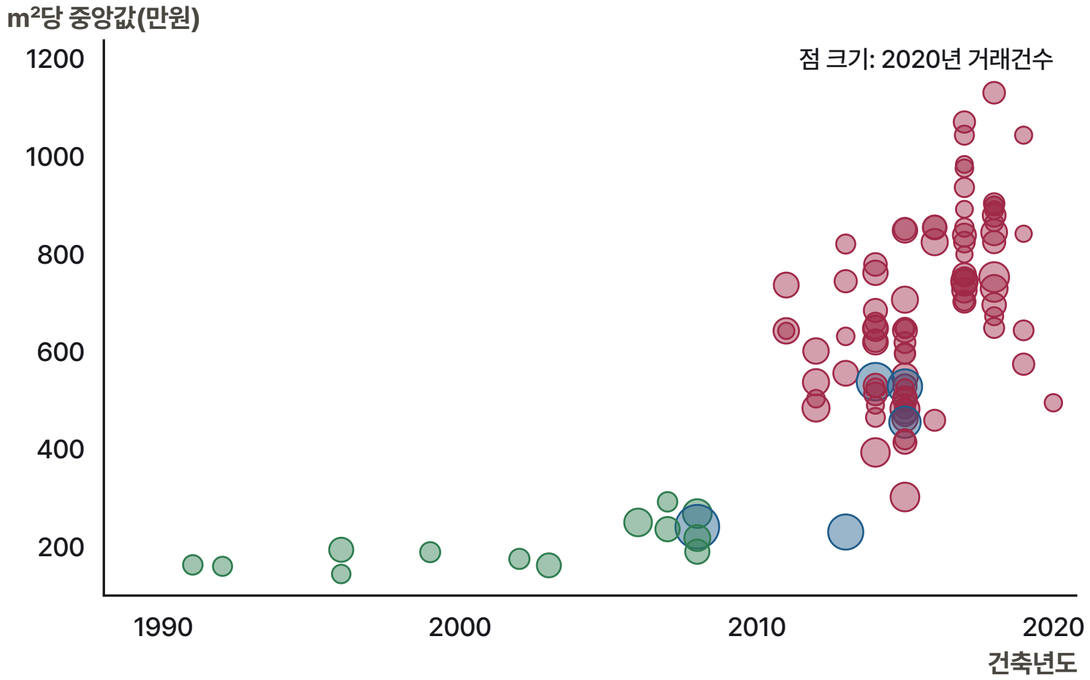
m²당 398만원 · 건축 2013년 · 거래 206.6건

군집 3: 읍면의 오래된 단지 13개

m²당 203만원 · 건축 2002년 · 거래 48.0건

- **k:** 실루엣이 k=3 (0.593) 과 k=2 (0.586) 에서 거의 같음. 무엇으로 고르나
- **군집 2:** m²당 538만원(아름동)과 230만원(신안리) 단지가 한 묶음. 무엇이 묶었나

→ **넣은 변수가 군집을 정함.** 거래건수를 빼고 다시 돌려 봄



계산: analysis/07-기술적분석/07-세종단지군집.py

어떤 조건에서 무엇을 고르나



두 군집분석 모두 개수를 몰라도 됨: K-means 는 엘보우·실루엣으로 k 를 고르고, 계층군집은 덴드로그램을 자르는 높이로 정함

K-means: 대상이 많아도 빠름 · 결과는 묶음 하나 · 시작 위치에 따라 답이 달라질 수 있음

계층군집: 대상 사이의 순서와 위계가 보임 · 한 번 합친 것은 되돌리지 않음 · 대상이 많으면 계산과 그림이 무거움

과제: 일곱 방법을 조사하고 자기 데이터에 적용한다

1. 일곱 방법을 모두 조사한다

방법마다 AI 에게 묻고 확인해 세 가지를 정리함

- **쓰는 경우:** 어떤 목적과 자료에서 쓰나
- **다른 방법과의 차이:** 같은 목적의 다른 방법과 무엇이 다른가
- **장점과 단점:** 무엇을 잘 보여 주고 무엇을 놓치나

2. 자기 데이터에 적용해 보고서로 정리한다

1. 목적을 한 문장으로 적음: 무엇을 알고 싶은가
2. 방법을 고르고 이유를 적음: 순서도의 어느 갈림을 탔나
3. 적용하고 결과를 봄: AI 에게 로직을 요구하고 사람이 검증함
4. 판단을 남김: 무엇을 걸러 냈고 무엇을 정했나

본보기: 배포 자료의 「분석 프롬프트.md」와 「로직 문서 본보기.md」

제출물

두 과제를 각각 별도 파일로 낸다

- `방법조사.md` : 1번의 조사내용: 쓰는 경우, 다른 방법과의 차이, 장점과 단점
- `분석보고서.md` : 2번의 자기 데이터에 적용한 결과

제출기한: 10월 31일(토) 23시 59분 59초

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

2주차와 같은 주소다. 주차 선택에서 **6주차**를 고르고, 학번 열 자리와 이름을 띄어쓰기 없이 적는다.

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr