



2026-2학기 데이터사이언스

6강. 기술통계량과 시각화

2026. 10. 12.

자료를 처음 열었다. 무엇부터 보나

- 세종 아파트 실거래 15,486건. 그대로는 아무도 못 읽음
- 줄이는 방법은 여럿이고 무엇을 고르느냐에 따라 다른 것이 보임
- 오늘은 일곱 가지를 목록으로 펼치고 언제 무엇을 고르는지까지

오늘의 방법 일곱

	방법	무엇을 답하나	필요한 자료
1	도수분포표와 히스토그램	값이 어디에 몰려 있나	연속변수 1개
2	대표값 — 평균·중앙값·최빈값	가운데를 하나의 숫자로	연속변수 1개
3	산포 — 범위·사분위수범위·표준편차	얼마나 흩어져 있나	연속변수 1개
4	박스플롯	분포를 다섯 숫자로 압축	연속변수 1개 (+집단)
5	산점도	두 변수가 함께 움직이나	연속변수 2개
6	K-means 군집분석	속성으로 몇 개의 유형이 있나	연속변수 여럿
7	계층적 군집분석	유형을 나무 모양으로	연속변수 여럿

→ 1~4 는 변수 하나를, 5 는 둘을, 6~7 은 여럿을 다룸

도수분포표와 히스토그램: 목적과 정의

값의 범위를 계급으로 나누고 계급마다 몇 개가 들어가는지 센 것

표로 적으면 도수분포표, 막대로 그리면 히스토그램

필요한 자료 — 연속변수 1개

→ 자료를 처음 열었을 때 가장 먼저 하는 일. 가운데가 어디고 꼬리가 어느 쪽으로 늘어지는지가 한눈에 들어옴

도수분포표와 히스토그램: 어떻게 작동하나

- 1 계급 폭을 정함
세종은 1억 단위로 잘랐음
- 2 값을 계급에 떨어뜨림
39,000만원 → 3~4억 계급
- 3 계급마다 셈
그것이 빈도
- 4 막대 높이로 세움
붙여 그림. 막대 사이를 띄우지 않음

→ 계급 폭이 결과를 바꿈. 넓으면 뭉개지고 좁으면 들쭉날쭉함

계급 폭 1억 — 18칸



계급 폭 2억 — 9칸



같은 자료 15,486건. 계급 폭만 다름

도수분포표와 히스토그램: 적용 사례

거래 15,486건을 1억 단위 18개 계급으로 나눔

봉우리가 3~4억에 있고 오른쪽으로 길게 늘어짐


왼쪽에는 더 갈 데가 없고 오른쪽은 17억까지 열려 있음

→ 이 모양이면 평균이 중앙값보다 큼

→ 다음 방법에서 확인함

자료: COMPAS 「주택 시장 특성분석」(세종, SBJ_2102_001)

계산: analysis/07-기술적분석/07-세종주택시장.py



대표값: 목적과 정의

흩어진 값들의 가운데를 숫자 하나로 나타낸 것

평균 다 더해 개수로 나눔 · 중앙값 크기순 한가운데 · 최빈값 가장 자주 나온 값

필요한 자료 — 연속변수 1개 (최빈값은 범주도 가능)

→ 셋은 서로 다른 가운데. 어느 것을 쓰느냐로 결론이 달라짐

대표값: 어떻게 작동하나

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \cdot \quad \text{중앙값} = x_{((n+1)/2)} \text{ (크기순으로 세운 뒤)}$$


평균은 무게중심

값 하나가 멀리 있으면 그쪽으로 끌려감

중앙값은 순위

얼마나 먼지는 보지 않고 몇 번째인지만 봄

→ 그래서 한쪽 꼬리가 긴 자료에서 평균 > 중앙값




대표값: 적용 사례

평균	43,199만원
중앙값	39,000만원
차이	4,199만원

앞의 히스토그램에서 본 오른쪽 긴 꼬리가 평균을 위로 끌어올림

→ 세종 집값을 하나로 말해야 한다면 **중앙값**. 평균은 소수의 고가 거래를 담고 있음

계산: analysis/07-기술적분석/07-세종주택시장.py



산포: 목적과 정의

값들이 가운데에서 얼마나 멀리 흩어져 있는지를 잴 것

범위 최대-최소 · 사분위수범위(IQR) $Q3-Q1$ · 표준편차 평균에서 떨어진 거리의 평균적 크기

필요한 자료 — 연속변수 1개

→ 대표값만으로는 같은 가운데, 다른 분포를 구별하지 못함


산포: 어떻게 작동하나

$$s = \sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2} \cdot \text{IQR} = Q_3 - Q_1$$

- 1 평균에서 얼마나 떨어졌나 를 각 값마다 잴
- 2 제곱함 — 양쪽 방향을 같게 만들고 먼 값을 키움
- 3 평균 났 — 그것이 분산
- 4 제곱근 — 원래 단위로 돌아옴

→ 표준편차는 제곱을 거치므로 먼 값 하나에 민감함. IQR 은 가운데 절반만 보므로 둔감함

좁게 퍼진 자료



넓게 퍼진 자료



산포: 적용 사례


범위 (최대-최소)	16.62억
사분위수범위 (Q3-Q1)	2.44억
표준편차	2.02억

가운데 절반은 2.9억~5.34억 안에 있음

범위는 16.62억으로 IQR 의 일곱 배 가까움

→ 양 끝의 몇 건이 범위를 혼자 정함. 퍼짐을 말할 때 범위보다 IQR 이 안전함

계산: analysis/07-기술적분석/07-세종주택시장.py



박스플롯: 목적과 정의

분포를 다섯 숫자로 압축해 그린 그림

최소 · Q1 · 중앙값 · Q3 · 최대. 상자가 가운데 절반, 수염이 나머지


필요한 자료 — 연속변수 1개. 집단이 있으면 나란히 놓고 견줄

→ 히스토그램보다 자리를 덜 먹음. 여러 집단을 한 화면에서 비교할 때 씀

박스플롯: 어떻게 작동하나

- 1 크기순으로 세움
- 2 $Q1$ · 중앙값 · $Q3$ 를 찾아 상자를 그림
- 3 울타리를 침 — $Q1 - 1.5 \times IQR$ 과 $Q3 + 1.5 \times IQR$
- 4 수염은 울타리 안의 마지막 값까지만 뺌
- 5 울타리 밖의 값은 점으로 따로 찍음

→ 1.5 는 약속된 관습이지 법칙이 아님. 「이상치」로 찍혔다고 잘못된 값은 아님




박스플롯: 적용 사례

세종 거래금액의 다섯 숫자

최소	0.38억
Q1	2.90억
중앙값	3.90억
Q3	5.34억
최대	17.00억

상자가 왼쪽으로 치우쳐 있고 위쪽 수염이 훨씬 김
→ 히스토그램이 보여 준 오른쪽 긴 꼬리가 다섯 숫자만으로도 드러남

계산: analysis/07-기술적분석/07-세종주택시장.py



산점도: 목적과 정의

두 변수를 가로·세로 축에 놓고 관측치 하나를 점 하나로 찍은 그림

점들이 어떤 모양을 이루는지로 함께 움직이는지를 봄


필요한 자료 — 연속변수 2개

→ 관계의 세기·방향·모양을 한 번에 봄. 직선인지 굽었는지, 이상치가 있는지도 여기서 드러남


산점도: 어떻게 작동하나

점을 찍는 일은 간단함. 어려운 것은 무엇이 보이는지 읽는 일


- 1 방향 — 오른쪽 위로 가나, 아래로 가나
- 2 세기 — 선 주위에 촘촘한가, 흩어졌나
- 3 모양 — 직선인가, 굽었나
- 4 동떨어진 점 — 혼자 멀리 있는 것이 있나



강한 양의 관계



약한 관계



굽은 관계

→ 상관계수 하나로 줄이기 전에 반드시 그림을 먼저 봄. 굽은 관계는 계수가 0에 가깝게 나옴 (9주차에서 다시)

산점도: 적용 사례

전용면적 ↔ 거래금액


넓으면 비쌀 듯하나 점구름이 세로로 두껍게 퍼져 있음

같은 85m² 라도 2억대부터 10억대까지 있음

→ 면적만으로는 금액을 못 정함. 어느 동인지, 언제인지
가 더 크게 작용함 (10주차 회귀에서 다시)

표본 300건 — 15,486건에서 51건마다 하나씩 규칙적으로 뽑음

계산: `analysis/07-기술적분석/07-세종군집.py`



K-means 군집분석: 목적과 정의

여러 속성으로 켜 거리가 가까운 것끼리 미리 정한 개수 k 개의 묶음으로 나누는 일

맞힐 답이 없음. 자료 안에 어떤 유형이 있는지 스스로 찾음


필요한 자료 — 연속변수 여럿 · 묶음 개수 k

→ 6주차의 군집은 속성으로 묶음. 위치로 묶는 것은 7주차 DBSCAN 에서 다룸

K-means: 어떻게 작동하나

- 1 표준화 — 단위가 다르면 큰 수가 거리를 독차지
- 2 중심 k 개를 놓음
- 3 배정 — 각 점을 가장 가까운 중심에
- 4 갱신 — 중심을 그 묶음의 평균으로 옮김
- 5 움직이지 않을 때까지 3·4 를 되풀이

→ 시작 위치가 답을 바꿈. 이 강의 스크립트는 서로 가장 먼 점부터 골라 난수를 쓰지 않음



배정 → 갱신 → 되풀이

K-means: 적용 사례

17개 동을 거래건수와 m²당 중앙값으로 묶음

군집 1 — 거래 많고 중간 가격 5개 · 평균 1,919건 · 442만원

도담동 · 종촌동 · 한솔동 · 아름동 · 고운동

군집 2 — 거래 적고 높은 가격 7개 · 평균 453건 · 688만원

대평동 · 새롬동 · 다정동 · 보람동 · 소담동 · 어진동 · 반곡동


군집 3 — 읍면 '리' 5개 · 평균 489건 · 199만원

신흥리 · 신안리 · 죽림리 · 침산리 · 남리

→ 군집 3은 전부 '리'. 찾아낸 것은 유형이라기보다 신도시와 편입 읍면의 경계임

k = 3은 팔꿈치에서 골랐음 — 34.0 → 19.2 → 4.4 → 3.4

계산: analysis/07-기술적분석/07-세종군집.py



계층적 군집분석: 목적과 정의

가장 가까운 둘을 차례로 합쳐 나가 전체를 하나의 나무로 만드는 일

그 나무를 덴드로그램이라 함. 어느 높이에서 자르느냐로 묶음 개수가 정해짐

필요한 자료 — 연속변수 여럿. k 를 미리 정하지 않아도 됨

→ K-means 가 「몇 개로 나눌까」라면 계층군집은 「어떤 순서로 가까운가」를 보여 줌

계층적 군집분석: 어떻게 작동하나

- 1 각자 하나의 묶음에서 시작함
- 2 모든 짝의 거리를 재 가장 가까운 둘을 합침
- 3 합친 묶음과 나머지의 거리를 다시 잴
- 4 하나가 남을 때까지 되풀이함


묶음끼리의 거리를 어떻게 재나

최단연결 가장 가까운 한 쌍 · 최장연결 가장 먼 한 쌍 · 평균연결
모든 쌍의 평균

→ 이 강의는 **평균연결**

→ 사슬처럼 늘어지는 것과 이상치에 덜 흔들림

합칠 때의 거리



계층적 군집분석: 적용 사례


앞과 같은 17개 동, 같은 두 축

평균연결로 합쳐 나감

마지막 두 묶음이 거리 **2.374** 에서 합쳐짐. 그 앞이 크게 벌어져 있음

→ 거기서 자르면 세 덩어리. K-means 가 $k=3$ 으로
찾은 것과 같은 묶음임

계산: analysis/07-기술적분석/07-세종군집.py



어떤 조건에서 무엇을 고르나



→ 갈림은 자료의 성격으로 정해짐

→ 목적이 같아도 변수가 몇 개인지에 따라 쓸 수 있는 것이 달라짐

실습 ①－방법을 조사해 위키에 적는다 25분

오늘 일곱 중 자기가 쓸 두세 개를 고름

AI에게 물을 것

이 방법은 언제 쓰고 언제 쓰면 안 되나

같은 목적의 다른 방법과 무엇이 다른가

흔히 저지르는 잘못은 무엇인가

→ 산출물은 wiki/topics/ 페이지. 2주차에 만든 위키에 이어 붙임

위키에 적을 것

한 문장 정의와 필요한 자료

고를 조건 · 피할 조건

확인하지 못한 것은 「확인 필요」로 표시

실습 ② – 자기 데이터에 적용한다 40분

- 1 목적을 한 문장으로 — 「무엇을 알고 싶은가」를 먼저 적음
- 2 방법을 고르고 이유를 적음 — 순서도의 갈림 중 어디를 탔는지
- 3 적용하고 결과를 봄 — AI 에게 로직을 요구하고 사람이 검증함
- 4 로직 문서를 남김 — 무엇을 걸러 냈고 무엇을 정했는지

본보기는 analysis/07-기술적분석/07-세종주택시장-로직.md

→ 코드가 아니라 판단을 적음. 같은 자료로 다른 사람이 같은 값을 얻을 수 있어야 함

실습 ③ – 아쉬운 점을 공개 논의한다 ^{25분}

내는 것

고른 방법과 그 이유

결과 그림 한 장

스스로 아쉬운 점 한 가지

서로 볼 것

이 목적에 이 방법이 맞나

걸러 낸 기준이 결과를 바꾸지 않나

그림이 결론을 과장하지 않나

→ 받은 지적과 고친 내용을 위키에 남김. 고치지 않기로 한 것도 이유와 함께 적음

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr