



2026-2학기 데이터사이언스

7강. 기술적 분석 무슨 일이 일어났는가

2026. 10. 19.

세종시 집값에 무슨 일이 있었나?

- 거래 15,486건의 숫자가 있다
- 이걸 그대로 보여 주면 아무도 못 읽는다
- 무엇으로 줄여야 뜻이 생기는가

기술적 분석 descriptive

있는 그대로를 줄여서 보여 주는 일.

왜 그런지, 앞으로 어떻게 될지는 아직 묻지 않는다


→ 모든 분석의 첫 단계다. 여기서 잘못 줄이면 뒤의 진단·예측이 전부 어긋난다

오늘 배울 세 가지

방법	답하는 질문	줄이는 방식
① 대표값과 산포	대체로 얼마인가	수천 개를 숫자 두세 개 로
② 분포	어떻게 퍼져 있나	수천 개를 하나의 모양 으로
③ 비교	어디가·언제가 다른가	수천 개를 몇 개의 덩어리 로

셋 다 "줄이는" 일이다. 줄이면 반드시 **무언가 사라진다** — 무엇이 사라지는지 아는 것이 이 강의의 핵심이다.

가운데를 가리키는 두 가지 방법



꼬리가 한쪽으로 길면 **평균이 그 꼬리 쪽으로 끌려간다**. 중앙값은 순서만 보므로 끌리지 않는다.


가운데만으로는 모자란다

평균이 같아도 **퍼진 정도**가 다르면 전혀 다른 시장이다.

표준편차는 각 값이 평균에서 얼마나 떨어져 있는지를 평균 낸 것이다.

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$$

사분위(Q1·Q3)는 순서로 자른다. **이상값에 끌리지 않는다.**



어느 것을 쓸 것인가

이럴 때	이것을 쓴다	도시 데이터의 예
좌우 대칭이다	평균 · 표준편차	통근 시간, 기온
꼬리가 길다	중앙값 · 사분위	집값, 소득, 상가 매출
극단값이 중요하다	최대·최소도 함께	미세먼지 농도, 강우량
단위가 다른 것을 비교	비율로 바꾼다	m ² 당 가격, 1인당 면적

도시·부동산·소득 자료는 **거의 언제나 꼬리가 길다**. 기본은 중앙값이고, 평균은 함께 보는 참고값이다.

세종 아파트 실거래가

거래금액	만원
평균	43,199
중앙값	39,000
표준편차	20,194
Q1 (하위 25%)	29,000
Q3 (상위 25%)	53,400
최소 — 최대	3,800 — 170,000

COMPAS 세종 주택시장 · 2017~2020 · 전용 60m² 초과 15,486건 (취소 제외)

여기서 읽어야 할 것

- 평균이 중앙값보다 **4,199만원** 높다 — 고가 거래가 평균을 끌었다
- 표준편차가 중앙값의 절반이 넘는다 — "**대체로 4억**" 이라는 말이 위태롭다
- 최대가 최소의 45배다. 같은 "아파트" 로 묶어도 되는가


숫자 여섯 개가 **15,486건보다 많은 것을 말한다.**

주의 — 평균 하나로 말하지 않는다

함정	무슨 일이 벌어지나
평균의 함정	고가 거래 몇 건이 "평균 집값" 을 올린다. 대부분의 시민이 겪는 값이 아니다
단위를 안 맞춤	면적이 다른 집의 가격을 그냥 비교한다. m ² 당으로 바꿔야 뜻이 생긴다
표본이 적은 집단	거래 3건인 동의 "중앙값" 은 그냥 가운데 한 건이다
기간을 안 나눔	4년치를 한 덩어리로 요약하면 오른 것도 내린 것도 안 보인다

마지막 줄이 다음 방법으로 이어진다 — **한 덩어리로 줄이면 변화가 사라진다.**

모양으로 보면 대표값이 못 보여 준 것이 보인다



세종 아파트 거래금액 분포 (2017~2020 · 전용 60m² 초과 15,486건) — 막대 위는 건수


박스플롯 — 다섯 숫자로 그린 분포

히스토그램은 한 집단의 모양을 잘 보여 주지만 **여러 집단을 나란히 놓기**는 어렵다.

박스플롯은 최소·Q1·중앙값·Q3·최대 **다섯 숫자**만으로 그린다. 좁아서 여럿을 붙여 놓을 수 있다.

상자의 길이가 **가운데 절반**이 퍼진 정도다. 이것을 사분위범위(IQR)라 한다.

$$IQR = Q_3 - Q_1$$



언제 쓰고, 무엇을 조심하나


이럴 때 분포를 본다

- 대표값 하나로 설명이 안 될 때 — **봉우리가 둘인지** 확인한다
- 이상값이 있는지 봐야 할 때
- 여러 지역·시점을 나란히 견줄 때 (박스플롯)

주의


함정	무슨 일이 벌어지나
구간 폭을 바꾸면 모양이 바뀐다	같은 자료도 구간을 넓게 잡으면 봉우리가 하나로 뭉친다. 폭을 몇 개로 바꿔 보고 결론이 유지되는지 확인한다
이상값을 그냥 지운다	이상값이 오류인지 실제인지 먼저 본다. <u>진짜 비싼 집은 오류가 아니다</u>
세로축을 0에서 시작하지 않는다	차이가 실제보다 커 보인다

시간으로 나누면 변화가 보인다



세종 아파트 거래금액 **중양값** (전용 60m² 초과) — 8쪽의 "39,000만원" 은 이 넷을 뭉친 값이다

공간으로 나누면 격차가 보인다



동별 m²당 가격 중앙값 (거래 100건 이상 17개 동 중 발체) — 최고 대평동 790, 최저 남리 148만원, **5.33배**

주의 — 비교는 기준을 맞춰야 성립한다

함정	세종 자료에서라면
구성이 다르다	비싼 동은 새 아파트가 많다. "위치가 비싼 것" 과 "새것이 비싼 것" 이 섞여 있다
기간이 겹치지 않는다	신도시 동은 2019년부터, 편입 지역은 2017년부터 거래가 있다. 같은 기간으로 잘라야 한다
표본 수가 다르다	남리 122건과 죽림리 1,145건을 같은 무게로 볼 수 없다
축을 자른다	세로축을 140부터 그리면 5.33배가 20배처럼 보인다

5.33배는 사실이지만 그 자체로는 아무것도 설명하지 못한다. 왜 그런지는 9주차 진단적 분석에서 따진다.

이 숫자들은 어떻게 나왔나

오늘 슬라이드의 모든 수치는 이 판단 위에 있다

정한 것	어떻게	왜
취소 거래	뺀다	성사되지 않은 거래는 시장 가격이 아니다
전용면적	60m ² 초과만	소형은 임대 목적이 섞여 성격이 다르다
대표값	중앙값 위주	고가 거래가 평균을 끈다
동별 최소 건수	100건 이상	적은 거래로 순위가 뒤집히는 것을 막는다

판단을 바꾸면 숫자가 바뀐다. 그래서 숫자보다 이 표를 먼저 보여 준다.

전체 로직과 스크립트: `analysis/07-세종주택시장-로직.md` · `analysis/07-세종주택시장.py`

실습

세종 주택시장 요약 리포트 — 약 1시간 30분

실습 ① — 데이터를 받는다 20분

- 1 COMPAS 에서 「주택 시장 특성분석」(세종시) 과제를 찾는다
- 2 데이터 탭에서 전체를 내려받는다. 공개 데이터만 들어 있다
- 3 3. 세종시_아파트(매매)_실거래가.csv 를 작업 폴더에 둔다
- 4 CLAUDE.md 에 이 데이터의 출처·기간·단위를 적는다 (5주차에 만든 것을 이어 쓴다)

3~6주차에는 청주 실거래가로 연습했다. 같은 종류의 자료라 규칙이 거의 그대로 옮겨진다 — 무엇을 고쳐야 하는지 확인해 본다.

실습 ② — 로직을 먼저 정한다 25분

프롬프트

"세종 아파트 실거래가로 기술적 분석 요약 리포트를 만들 거야. 답을 것은 ① 대표값과 산포 ② 금액 분포 ③ 연도별 추이 ④ 동별 비교.

코드는 아직 쓰지 마. CLAUDE.md 규칙을 적용했을 때 각 항목을 어떻게 계산할지 로직으로 먼저 보여 주고, 규칙만으로 정해지지 않는 자리를 짚어 줘."

정해지지 않을 자리 (미리 생각해 둘 것)

- 히스토그램 구간을 몇 개로 자를 것인가
- 연도별로 나눌 것인가 분기별로 나눌 것인가
- 동별 비교에서 최소 건수를 몇으로 둘 것인가

실습 ③ — 만들고 대조한다 30분

- 1 정한 대로 실행시켜 표와 그래프 넷을 받는다
- 2 **오늘 슬라이드의 숫자와 맞춰 본다.** 강의에서 쓴 규칙(60m² 초과·취소 제외·100건 이상)을 그대로 쓰면 같아야 한다
- 3 다르면 어디서 갈렸는지 찾는다 — 이것이 오늘의 진짜 연습이다
- 4 규칙을 하나 바꿔 본다 (예: 하한을 85m² 로) 그리고 결과가 얼마나 달라지는지 본다

같은 데이터로 다른 그림을 만들 수 있다는 것을 직접 확인한다. **그래서 로직을 적어 두는 것이다.**

실습 ④ — 한 문단으로 쓴다 ^{15분}

표와 그래프만 내지 않는다. 읽은 것을 문장으로 옮긴다

이런 꼴로

"세종시 아파트 거래금액 중앙값은 2017년 ○○만원에서 2020년 ○○만원으로 ○% 올랐다. 다만 동별 격차가 커서 ○○동과 ○○동의 m²당 가격은 ○배 차이가 난다. 이 차이가 위치 때문인지 건축 연한 때문인지는 이 분석으로 알 수 없다."

마지막 문장이 중요하다. **기술적 분석이 말할 수 없는 것을 함께 적는다** — 그 자리가 9주차의 출발점이다.

제출: 요약 리포트(표 + 그래프 4종 + 한 문단) + 로직 문서

가정 과제: 자기 문제정의서 데이터로도 기술적 분석을 해 본다

자료 출처

- 모든 수치 — COMPAS 「주택 시장 특성분석」(세종시, SBJ_2102_001) 공개 데이터
3. 세종시_아파트(매매)_실거래가.csv · 2017-01 ~ 2020-12 계약분 · 2026. 8. 26. 내려받음
- 산출 방법 — analysis/07-세종주택시장.py, 판단 근거는 analysis/07-세종주택시장-로직.md
- 5·6·11쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr