



2026-2학기 데이터사이언스

9강. 진단적 분석 I

상관과 인과

2026. 11. 2.

아산의 어느 동네는 왜 병원이 멀까?

- 7주차에는 "어디가 다르다" 까지만 말했다
- 이제 왜 그런가를 묻는다
- 그런데 "왜" 는 데이터가 저절로 말해 주지 않는다

진단적 분석 diagnostic

두 가지가 함께 움직이는지 보고,
그것이 원인 때문인지 따져 보는 일

→ 기술적 분석이 "무엇" 이라면 진단적 분석은 "왜" 다.
그리고 "왜" 는 대부분 **틀린다** — 틀리는 방식을 배우는 것이 오늘이다

오늘 배울 세 가지

방법	답하는 질문	한계
① 상관	둘이 함께 움직이나	움직임의 방향을 말하지 못한다
② 집단 비교	어느 집단이 다른가	다른 조건이 섞여 있다
③ 접근성 지표	얼마나 닿기 어려운가	무엇을 "가깝다" 로 볼지 사람이 정한다

셋 다 **인과를 증명하지 못한다**. 인과에 다가가는 방법은 10주차에서 다룬다. 오늘은 증거를 모으고 그 한계를 정확히 말하는 데까지 간다.


함께 움직이는 정도를 하나의 숫자로

두 변수가 같은 방향으로 움직이면 **양(+)**, 반대로 움직이면 **음(-)**이다.

각자의 평균에서 떨어진 정도를 곱해 더한 뒤, 단위를 없애려고 각자의 산포로 나눈다.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

단위가 없어졌으므로 **-1에서 +1 사이**다. 인구(명)와 병원(개)처럼 단위가 달라도 견줄 수 있다.



$r \approx +0.9$



$r \approx +0.3$



$r \approx -0.8$



$r \approx 0$

상관이 답해 주는 것과 아닌 것

이런 질문에 쓴다

인구가 많은 곳에 병원도 많은가

노령인구 비율이 높은 곳이 의료 이용도 많은가

어떤 변수를 다음 분석에 넣어 볼 만한가

이런 질문에는 못 쓴다


인구가 많아서 병원이 생긴 것인가

고령화가 의료 수요를 늘린 것인가

그 변수를 바꾸면 결과가 바뀌는가

상관은 **탐색의 도구**다. 무엇을 더 볼지 정하는 데 쓰고, 결론을 내리는 데 쓰지 않는다.

같은 자료에서 두 개의 상관이 나온다



무엇과 무엇	r
인구 — 병원 수	0.972
인구 — 10만명당 병원	0.297

위는 "사람 많은 데 병원 많다" 는 말이다. 거의 아무것도 알려 주지 않는다.


아래는 **인구 대비**로 바꾼 것이다. 관계가 흐려진다 — 인구가 적어도 병원 밀도가 높은 곳이 있다는 뜻이다.

분모를 무엇으로 두느냐가 **결론을 바꾼다**.

아산시 12개 지역 · 인구 2023.12 · 병원 358곳


주의 – 상관이 인과가 아닌 네 가지 이유

정방향




X가 Y를 낳는다

역인과



Y가 X를 낳는다

제3의 변수



Z가 둘 다 낳는다

우연




아무 관계 없다

상관계수는 네 경우를 구별하지 못한다. 넷 다 같은 r 이 나올 수 있다.

나눠서 전주면 차이가 드러난다

아산시 12개 지역 · 인구 10만명당 병원 수



최고 온양 시가지 133.2, 최저 염치읍 33.1 — **4.0배**. 7주차 세종의 5.33배와 같은 종류의 숫자다.

이 표를 만들다가 실제로 겪은 일

인구 파일과 병원 파일을 읍면동 이름으로 그냥 이었더니

지역	인구	병원	결론
온양1~6동	122,384	0	아산 최대의 의료 사막
배방읍	86,711	74	정상

인구 파일은 행정동(온양1~6동), 병원 파일은 법정동(온천동·모종동·용화동...)을 쓴다.

읍·면은 두 파일에서 이름이 같아 아무 경고 없이 붙는다. 그래서 더 위험하다 — 표는 그럴듯하게 만들어지고 숫자만 틀린다.

3주차에 "행정동과 법정동은 다르다" 고 말했던 그 함정이다. 법정동 12개를 온양 시가지로 묶어 고쳤다.


집단의 평균은 개인의 사정이 아니다

"염치읍은 10만명당 병원이 33개다" 는 **지역의 값**이다.

염치읍 주민 개인이 병원에 못 간다는 뜻이 아니다. 경계 너머 온양 시가지로 가면 된다.

집단 수준의 관계를 개인에게 그대로 옮기는 것을 **생태학적 오류**라 한다.

행정경계로 자른 지표는 **경계에서 가장 많이 틀린다.**



“가깝다”를 숫자로 만든다


가장 단순한 것부터

- **최근접 거리** — 가장 가까운 병원까지 몇 m
- **일정 반경 안의 개수** — 1km 안에 몇 개
- **공급 대비 수요** — 그 병원을 몇 명이 나눠 쓰나

셋째가 중요하다. 가까워도 그 병원을 쓰는 사람이 많으면 실제로는 접근하기 어렵다.

$$R_j = \frac{S_j}{\sum_{k \in d_{kj} \leq d_0} P_k}$$

병원 j 의 공급 S_j 를, 그 병원에 닿을 수 있는 인구 P_k 의 합으로 나눈다. 이것을 지역마다 다시 더하면 2SFCA라 부르는 지표가 된다.



지표를 만들 때 사람이 정해야 하는 것

정할 것	선택지	바꾸면
거리를 무엇으로	직선 · 도로 · 이동시간	산·강이 있으면 직선거리가 크게 틀린다
기준 거리 d_0	500m · 1km · 30분	기준을 늘리면 취약지역이 사라진다
공급을 무엇으로	병원 수 · 의사 수 · 병상 수	엄치읍은 병원 2곳에 의사 0명이다
수요를 무엇으로	총인구 · 노령인구 · 유동인구	대상이 누구냐에 따라 취약지가 달라진다

여기서 정한 것이 결론을 만든다. 그래서 지표는 결과가 아니라 판단의 묶음이다 — CLAUDE.md 에 적어 두어야 하는 이유다.

오늘 숫자의 판단 목록

정한 것	어떻게	왜
지역 단위	읍·면 11 + 온양 시가지	행정동·법정동이 어긋나 그대로는 이을 수 없다
인구 시점	2023. 12.	자료에 있는 가장 최근 시점
병원 범위	358곳 전부	의원·치과·한의원·보건지소를 나누면 표본이 너무 작아진다
이름 없는 병원	4건 제외	지역을 알 수 없어 어디에도 넣을 수 없다

세 번째 줄은 **타협이다**. 의원 하나와 종합병원 하나가 같은 1로 세어진다 — 그래서 의사 수를 함께 봤다.

전체 로직: `analysis/09-진단적분석1/09-아산의료접근성-로직.md` · 스크립트: `analysis/09-진단적분석1/09-아산의료접근성.py`

실습

아산 의료 취약지역 ① 현황 진단 — 약 1시간 30분

실습 ① – 데이터를 잇는다 30분

- 1 COMPAS 「보건의료 불균형 — 의료 취약지역 도출」(아산시) 를 받는다
- 2 인구·병원·약국 세 파일을 읍면동으로 잇는다
- 3 **이었던니 이상한 곳이 없는지 반드시 확인한다** — 인구는 많은데 시설이 0인 지역이 있으면 멈춘다

프롬프트

"세 파일을 읍면동 기준으로 이어 줘. 잇기 전에 양쪽의 지역 이름 목록을 각각 보여 주고, 한쪽에만 있는 이름을 알려 줘. 그다음에 어떻게 맞출지 상의하자."

시키기 전에 **양쪽 이름을 먼저 대조하는 습관**을 들인다. 이 한 문장이 오늘 강의에서 본 사고를 막는다.

실습 ② – 지표를 만들고 비교한다 35분

- 1 지역별 **인구 10만명당 병원 수**와 **의사 수**를 낸다
- 2 인구와 병원 수의 상관계수, 인구와 10만명당 병원의 상관계수를 각각 구한다
- 3 둘이 왜 다른지 한 문장으로 설명해 본다
- 4 공급을 병원 수 대신 **의사 수**로 바꿔 다시 낸다. 순위가 바뀌는 지역을 찾는다

4번이 오늘의 핵심 연습이다. **지표를 바꾸면 취약지역이 바뀐다** — 그 사실을 직접 보고 나면 지표를 함부로 고르지 않게 된다.

실습 ③ — 말할 수 있는 것까지만 ^{25분}

세 문장으로 쓴다

- 1 **확인한 것** — 어느 지역이 어떤 지표에서 낮은가 (숫자와 함께)
- 2 **짐작하는 것** — 왜 그럴 것 같은가. "~로 보인다" 로 쓴다
- 3 **이 분석으로 알 수 없는 것** — 무엇을 더 봐야 확인되는가

제출: 취약지역 후보 표 + 세 문장 + 로직 문서

다음 주에는 3번에 적은 것을 실제로 따진다 — 회귀로 다른 조건을 통제한다.

가정 과제: 자기 문제정의서 데이터에서도 두 변수의 상관을 구해 본다.

자료 출처

- 모든 수치 — COMPAS 「보건의료 불균형 해소를 위한 의료 취약지역 도출 분석」
(아산시, SBJ_2405_001) 공개 데이터 · 2026. 8. 26. 내려받음
인구 2023. 12. 기준 345,796명 · 병원 358곳 · 약국 126곳
- 산출 방법 — `analysis/09-진단적분석1/09-아산의료접근성.py` , 판단 근거는 `analysis/09-진단적분석1/09-아산의료접근성-로직.md`
- 5·8·11·12쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다
- 12쪽의 지표는 2SFCA(2-step floating catchment area) 의 1단계다. 이 과제 최우수작도 같은 방법을 썼다 — COMPAS 분석 결과 탭에서 볼 수 있다

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr