2026-2학기 데이터사이언스

9강. 진단적 분석 I
상관과 인과

2026. 11. 2.

아산의 어느 동네는 왜 병원이 멀까?

- 7주차에는 "어디가 다르다" 까지만 말했다
- 이제 왜 그런가를 묻는다
- 그런데 "왜" 는 데이터가 저절로 말해 주지 않는다

진단적 분석 diagnostic

두 가지가 함께 움직이는지 보고,
그것이 원인 때문인지 따져 보는 일

→ 기술적 분석이 "무엇" 이라면 진단적 분석은 "왜" 다.

그리고 "왜" 는 대부분 틀린다 — 틀리는 방식을 배우는 것이 오늘이다

오늘 배울 세 가지

방법	답하는 질문	한계
① 상관	둘이 함께 움직이나	움직임의 **방향을 말하지 못한다**
② 집단 비교	어느 집단이 다른가	다른 조건이 섞여 있다
③ 접근성 지표	얼마나 닿기 어려운가	무엇을 "가깝다" 로 볼지 **사람이 정한다**

셋 다 **인과를 증명하지 못한다.** 인과에 다가가는 방법은 10주차에서 다룬다. 오늘은 증거를 모으고 그 한계를 정확히 말하는 데까지 간다.

오늘의 실습자료와 자료 정리

아산시 주민등록인구와 병원

- **파일:** `09강–아산의료접근성.zip`
- **인구:** 행정동 17개 × 2021년 1월 ~ 2023년 12월 월별, 612행. 열은 adm_nm(행정동) · year · m_pop · fm_pop
- **병원:** 358곳 (의원·보건지소 포함). 열은 기관명 · 종별 · emd_nm(법정동) · 주소 · 의사 수 · 경위도 등 8개
- **함께 든 것:** 열 설명(README) · 방법별 프롬프트 · 로직 문서 본보기

→ 두 파일은 **지역 이름 체계가 다름**. 잇기 전에 이름부터 대조함

자료: COMPAS 「보건의료 불균형 해소를 위한 의료 취약지역 도출 분석」 (아산시, SBJ_2405_001)

자료 정리 프롬프트

아산시_주민등록인구_2021-2023.csv 와 아산시_병원정보.csv 를 읽고 행 수, 열 이름, 열마다 빈 값의 개수를 보여 줘.

인구는 가장 최근 달만 쓰고, 남녀 인구를 더해 총인구를 만들어 줘.

두 파일을 읍면동으로 잇기 전에 **양쪽의 지역 이름 목록을 각각 보여 주고, 한쪽에만 있는 이름을 알려 줘.** 어떻게 맞출지는 그다음에 상의하자.

읍면동 이름이 빈 병원이 몇 곳인지 알려 줘.

무엇을 왜 뺐고 이름을 어떻게 맞췄는지 로직 문서로 정리해 줘.

확인할 값: 2023년 12월 총인구 345,796명 · 이름이 빈 병원 4곳 제외 · 그대로 이으면 온양1~6동 122,384명에 병원 0곳 → 법정동 12개를 묶어 **12개 지역**

함께 움직이는 정도를 하나의 숫자로

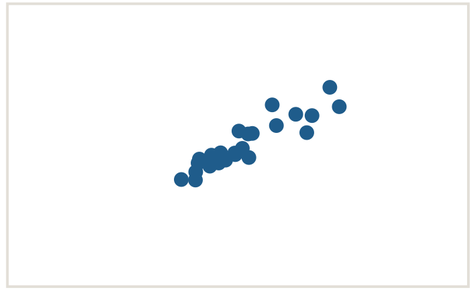
두 변수가 함께 움직이는 정도를 나타낸 숫자

- **상관계수(피어슨 r):** 두 변수의 직선 관계의 방향과 세기를 −1에서 +1 사이의 숫자로 나타낸 것
- **양(+)의 상관:** 한 변수가 클 때 다른 변수도 큰 관계
- **음(−)의 상관:** 한 변수가 클 때 다른 변수는 작은 관계
- **편차:** 관측치에서 평균을 뺀 값

각자의 편차를 곱해 더한 뒤, 단위를 없애려고 각자의 산포로 나눈다.

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\sqrt{\sum (y_i - \bar{y})^2}}$$

단위가 없어졌으므로 **−1 에서 +1 사이**다. 인구(명)와 병원(개)처럼 단위가 달라도 견줄 수 있다.



r ≈ +0.9



r ≈ +0.3



r ≈ −0.8



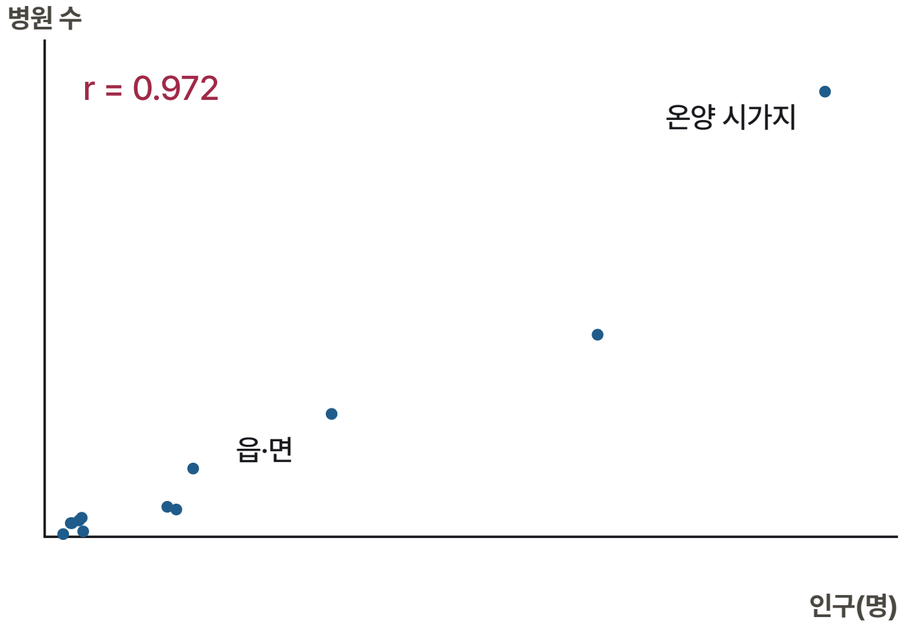
r ≈ 0

상관이 답해 주는 것과 아닌 것

이런 질문에 쓴다	이런 질문에는 못 쓴다
인구가 많은 곳에 병원도 많은가	인구가 많아서 병원이 생긴 것인가
노령인구 비율이 높은 곳이 의료 이용도 많은가	고령화가 의료 수요를 늘린 것인가
어떤 변수를 다음 분석에 넣어 볼 만한가	그 변수를 바꾸면 결과가 바뀌는가

상관은 **탐색의 도구**다. 무엇을 더 볼지 정하는 데 쓰고, 결론을 내리는 데 쓰지 않는다.

같은 자료에서 두 개의 상관이 나온다



무엇과 무엇	r
인구 — 병원 수	**0.972**
인구 — 10만명당 병원	0.297

위는 **"사람 많은 데 병원 많다"** 는 말이다. 거의 아무것도 알려 주지 않는다.

아래는 **인구 대비**로 바꾼 것이다. 관계가 흐려진다 — 인구가 적어도 병원 밀도가 높은 곳이 있다는 뜻이다.

분모를 무엇으로 두느냐가 결론을 바꾼다.

아산시 12개 지역 · 인구 2023.12 · 병원 358곳

주의: 상관이 인과가 아닌 네 가지 이유

정방향



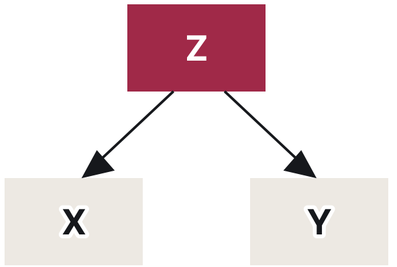
X가 Y를 낳는다

역인과



Y가 X를 낳는다

제3의 변수



Z가 둘 다 낳는다

우연



아무 관계 없다

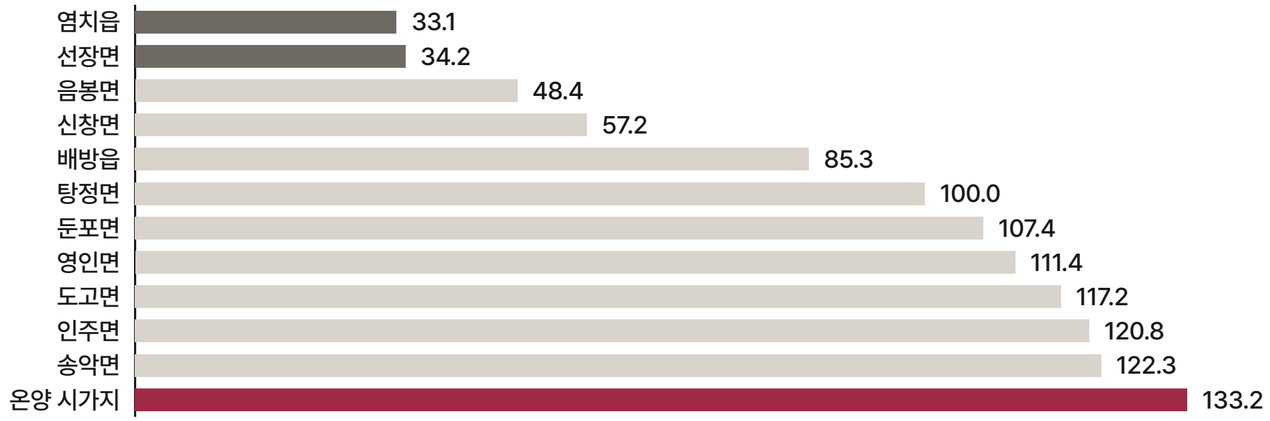
상관계수는 네 경우를 구별하지 못한다. 넷 다 같은 r 이 나올 수 있다.

나눠서 견주면 차이가 드러난다

자료를 집단으로 나누고 집단마다 같은 지표를 계산해 견주는 것

- **집단:** 같은 기준(여기서는 지역)에 속하는 관측치의 묶음
- **인구 10만명당 지표:** 개수를 인구로 나누고 10만을 곱한 값. 인구가 다른 집단끼리 견줄 수 있게 함
- **배율:** 가장 큰 값을 가장 작은 값으로 나눈 것

아산시 12개 지역 · 인구 10만명당 병원 수



최고 온양 시가지 133.2, 최저 염치읍 33.1 — **4.0배**. 7주차 세종의 5.33배와 같은 종류의 숫자다.

이 표를 만들다가 실제로 겪은 일

인구 파일과 병원 파일을 읍면동 이름으로 그냥 이었더니

지역	인구	병원	결론
온양1~6동	122,384	0	아산 최대의 의료 사막
배방읍	86,711	74	정상

인구 파일은 **행정동**(온양1~6동), 병원 파일은 **법정동**(온천동·모종동·용화동…)을 쓴다.

읍·면은 두 파일에서 이름이 같아 아무 경고 없이 붙는다. **그래서 더 위험하다** — 표는 그럴듯하게 만들어지고 숫자만 틀린다.

3주차에 "행정동과 법정동은 다르다" 고 말했던 그 함정이다. 법정동 12개를 온양 시가지로 묶어 고쳤다.

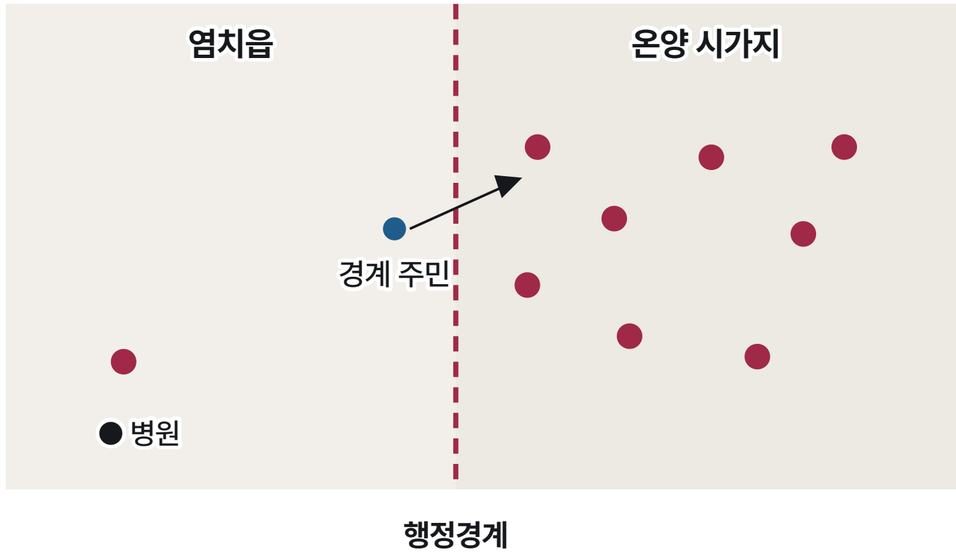
집단의 평균은 개인의 사정이 아니다

"염치읍은 10만명당 병원이 33개다" 는 **지역의 값**이다.

염치읍 주민 개인이 병원에 못 간다는 뜻이 아니다. **경계 너머 온양 시가지로 가면 된다.**

집단 수준의 관계를 개인에게 그대로 옮기는 것을 **생태학적 오류**라 한다.

행정경계로 자른 지표는 경계에서 가장 많이 틀린다.



"가깝다"를 숫자로 만든다

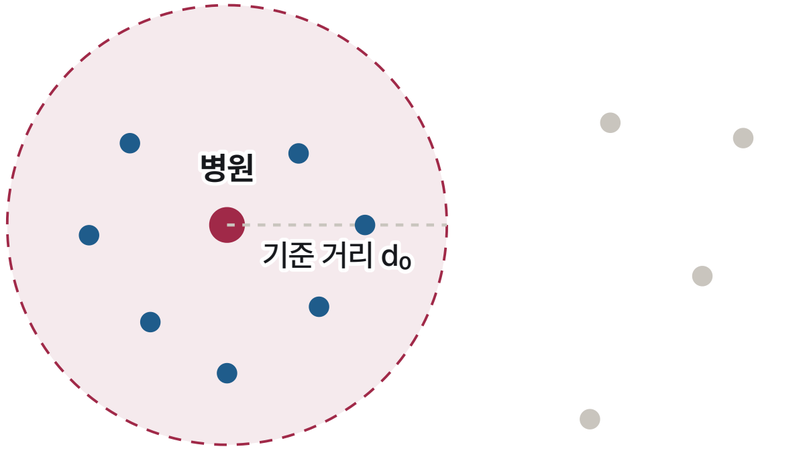
시설에 얼마나 쉽게 닿는지를 나타낸 숫자

- **최근접 거리:** 가장 가까운 병원까지의 거리 (몇 m)
- **기준 거리(d_0):** 「닿을 수 있다」로 볼 최대 거리
- **반경 안의 개수:** 기준 거리 안의 병원 수 (1km 안에 몇 개)
- **공급 대비 수요:** 병원의 공급을 그 병원에 닿을 수 있는 인구의 합으로 나눈 값

마지막이 중요하다. 가까워도 **그 병원을 쓰는 사람이 많으면** 실제로는 접근하기 어렵다.

$$R_j = \frac{S_j}{\sum_{k \in d_{kj} \le d_0} P_k}$$

병원 j 의 공급 S_j 를, 그 병원에 닿을 수 있는 인구 P_k 의 합으로 나눈다. 이것을 지역마다 다시 더하면 2SFCA 라 부르는 지표가 된다.



안의 인구 7명이 이 병원 하나를 나눠 쓴다

밖의 인구는 세지 않는다

지표를 만들 때 사람이 정해야 하는 것

정할 것	선택지	바꾸면
거리를 무엇으로	직선 · 도로 · 이동시간	산·강이 있으면 직선거리가 크게 틀린다
기준 거리 d_0	500m · 1km · 30분	**기준을 늘리면 취약지역이 사라진다**
공급을 무엇으로	병원 수 · 의사 수 · 병상 수	염치읍은 병원 2곳에 **의사 0명**이다
수요를 무엇으로	총인구 · 노령인구 · 유동인구	대상이 누구냐에 따라 취약지가 달라진다

여기서 정한 것이 결론을 만든다. 그래서 지표는 결과가 아니라 판단의 묶음이다 — CLAUDE.md 에 적어 두어야 하는 이유다.

오늘 숫자의 판단 목록

정한 것	어떻게	왜
지역 단위	**읍·면 11 + 온양 시가지**	행정동·법정동이 어긋나 그대로는 이을 수 없다
인구 시점	2023. 12.	자료에 있는 가장 최근 시점
병원 범위	358곳 전부	의원·치과·한의원·보건지소를 나누면 표본이 너무 작아진다
이름 없는 병원	4건 제외	지역을 알 수 없어 어디에도 넣을 수 없다

세 번째 줄은 **타협이다.** 의원 하나와 종합병원 하나가 같은 1로 세어진다 — 그래서 의사 수를 함께 봤다.

전체 로직: `analysis/09-진단적분석1/09-아산의료접근성-로직.md` · 스크립트: `analysis/09-진단적분석1/09-아산의료접근성.py`

과제: 아산 의료 취약지역을 진단하고 자기 데이터에 적용한다

1. 아산 자료로 의료 취약지역을 진단한다

1. 자료를 잇는다: 「오늘의 실습자료와 자료 정리」 프롬프트로 두 파일을 이음. 인구는 많은데 병원이 0인 지역이 있으면 멈춤
2. 지표를 만든다: 지역별 인구 10만명당 병원 수와 의사 수를 냄. 인구와 병원 수, 인구와 10만명당 병원의 상관계수를 각각 구하고 둘이 왜 다른지 한 문장으로 설명함
3. 지표를 바꿔 본다: 공급을 병원 수 대신 **의사 수**로 바꿔 다시 냄. 순위가 바뀌는 지역을 찾음
4. 표와 세 문장으로 쓴다: 취약지역 후보 표와 오른쪽의 세 가지

→ 3번이 핵심. **지표를 바꾸면 취약지역이 바뀜**

세 문장

- **확인한 것:** 어느 지역이 어떤 지표에서 낮은가 (숫자와 함께)
- **짐작하는 것:** 왜 그럴 것 같은가. 「~로 보인다」로 씀
- **이 분석으로 알 수 없는 것:** 무엇을 더 봐야 확인되는가

2. 자기 데이터에 적용한다

문제정의서 데이터에서 두 변수의 상관을 구하고, 집단을 나눠 견줌. 결과를 같은 세 문장으로 정리함

다음 주에는 「알 수 없는 것」에 적은 것을 실제로 따진다. 회귀로 다른 조건을 통제한다.

본보기: 배포 자료의 「분석 프롬프트.md」와 「로직 문서 본보기.md」

제출물

두 과제를 각각 별도 파일로 낸다

- `의료취약지역진단.md` : 1번의 취약지역 후보 표, 세 문장, 무엇을 걸러 내고 정했는지
- `분석보고서.md` : 2번의 자기 데이터에 적용한 결과

제출기한: 11월 7일(토) 23시 59분 59초

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

2주차와 같은 주소다. 주차 선택에서 **9주차**를 고르고, 학번 열 자리와 이름을 띄어쓰기 없이 적는다.

자료 출처

- **모든 수치:** COMPAS 「보건의료 불균형 해소를 위한 의료 취약지역 도출 분석」
  (아산시, SBJ_2405_001) 공개 데이터 · 2026. 8. 26. 내려받음
  인구 2023. 12. 기준 345,796명 · 병원 358곳 · 약국 126곳
- **산출 방법:** `analysis/09-진단적분석1/09-아산의료접근성.py` , 판단 근거는 `analysis/09-진단적분석1/09-아산의료접근성-로직.md`
- 6·9·12·13쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다
- 13쪽의 지표는 2SFCA(2-step floating catchment area) 의 1단계다. 이 과제 최우수작도 같은 방법을 썼다 — COMPAS 분석 결과 탭에서 볼 수 있다

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr