2026-2학기 데이터사이언스

10강. 예측적 분석 머신러닝

2026. 11. 9.

지난 시간: 회귀분석으로 「왜」를 물었다

선형회귀

- 세종 m²당 가격 ~ 다섯 변수 · R^2 .548
- 계수 · 유의성 · 여섯 가지 가정 진단

로지스틱 회귀

- 「비싼 집인가」(0/1) · 승산비로 해석
- 정분류율 79.4% · 종속변수별 모형 선택

오늘: 같은 자료로 「처음 보는 거래의 가격을 얼마나 맞히는가」

설명을 잘하는 모형이 예측도 잘하는가?

- 9강 회귀식: 계수 하나하나를 읽을 수 있음
- 그러나 가격 변동의 45%는 식 밖에 남음
- 해석을 조금 내주고 예측을 얻는 방법 → 머신러닝

예측적 분석 predictive

과거에서 찾은 규칙을 아직 없는 자료에 적용하는 일

- **진단:** 지금 자료로 맞는지 확인 가능
- **예측:** 그 값이 생겨야 확인 가능

→ 그래서 **미리 채점하는 법**(홀드아웃 검증)이 예측의 출발점

출처: 옛 11강 「예측적 분석 I」

머신러닝: 목적과 정의

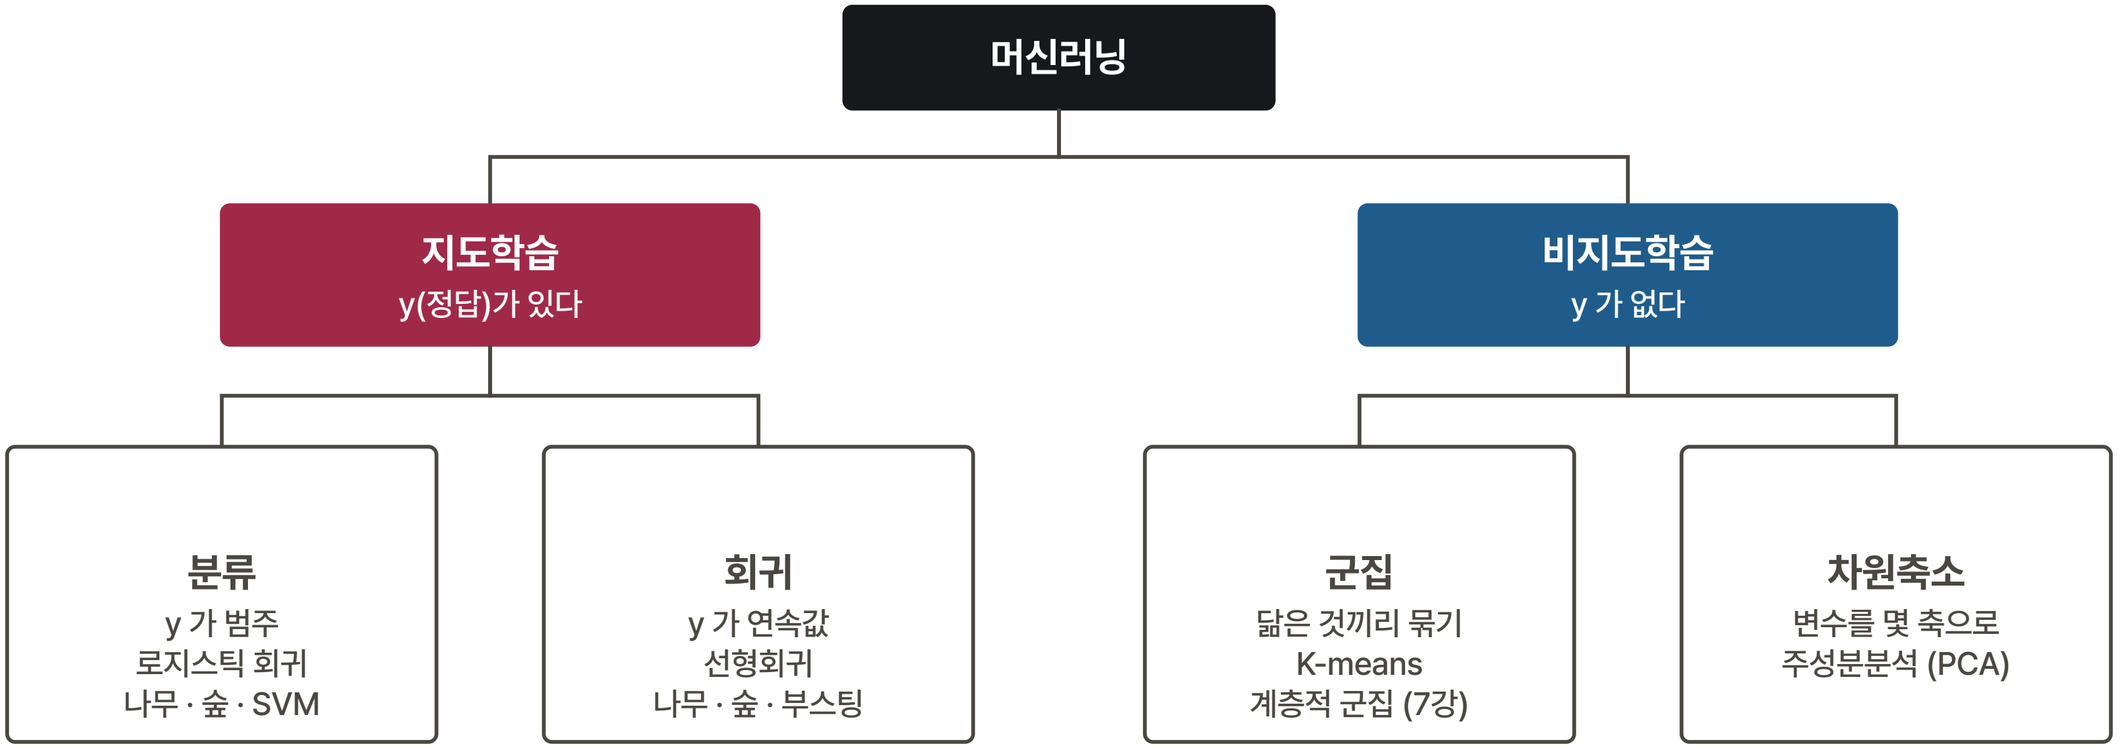
사람이 규칙을 적지 않아도 자료에서 규칙을 배워 새 자료를 예측하는 방법

- **학습:** 답을 아는 자료(훈련 자료)로 모형을 맞춤
- **예측:** 답을 모르는 새 자료에 적용
- **평가:** 학습에 쓰지 않은 자료(시험 자료)에서 얼마나 맞히나

→ 데이터마이닝(좁은 뜻): 대규모 자료에서 자동으로 규칙 탐색 · 사전 가설 X · 머신러닝 활용

출처: 데이터마이닝(2022-1) 1강 p.5. 머신러닝 정의는 이 강의에서 씀

머신러닝의 네 갈래


머신러닝
지도학습
y(정답)가 있다
비지도학습
y 가 없다
분류
y 가 범주
로지스틱 회귀
나무 · 숲 · SVM
회귀
y 가 연속값
선형회귀
나무 · 숲 · 부스팅
군집
닮은 것끼리 묶기
K-means
계층적 군집 (7강)
차원축소
변수를 몇 축으로
주성분분석 (PCA)

지도학습: 분류와 회귀

회귀 (regression)

- **y:** 연속값 → 얼마인지 맞힘
- **세종:** m^2당 가격
- **대표 모형:** 선형회귀
- **평가:** RMSE · MAE · MAPE · R^2

분류 (classification)

- **y:** 범주 → 어디에 속하는지 맞힘
- **세종:** 중앙값보다 비싼 집인가
- **대표 모형:** 로지스틱 회귀
- **평가:** 정분류율 · 민감도 · 특이도 · AUC

→ 9강의 두 모형 = 두 갈래의 대표 (로지스틱: 「회귀라기보다는 분류의 문제」)

출처: 고급도시교통통계분석 10강 p.3·28~31

통계 모형과 머신러닝 모형은 묻는 것이 다르다

	통계 모형 (9강)	머신러닝 모형 (오늘)
목적	X 가 Y 에 얼마나, 왜	**새 자료의 Y 를 얼마나 맞히나**
식의 모양	사람이 정함 (직선, 로짓)	자료가 정함 (나무, 숲, 신경망)
가정	선형성 · 등분산 · 독립 · 정규	거의 없음
판단 기준	계수 · 표준오차 · p 값	시험 자료의 오차
얻는 것	해석 가능한 계수	예측값 · 변수 중요도
위험	가정 위배 → p 값 불신	훈련 자료를 외움 (과적합)

→ 대립 X. 「왜」 → 통계 모형 · 「얼마」 → 머신러닝

언제 머신러닝을, 언제 회귀를 쓰나

머신러닝이 낫다	회귀가 낫다
관측이 많음 (수천~수만)	관측이 적음 (수십~수백)
변수가 많고 관계가 뒤엉킴	변수가 몇 개뿐
맞히는 것 자체가 목적	**왜 그런지 설명해야 함**
규칙을 미리 알기 어려움	이론이 꼴을 알려 줌

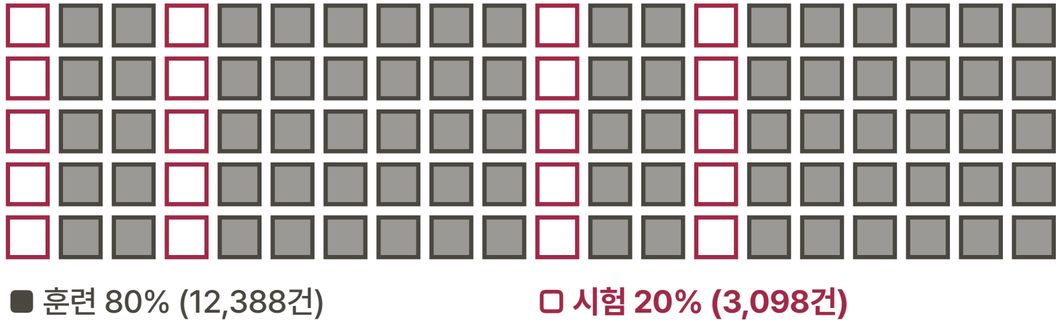
→ 세종 15,486건 · 신도시×나이×시점이 얽힘 → 예측에는 머신러닝이 유리

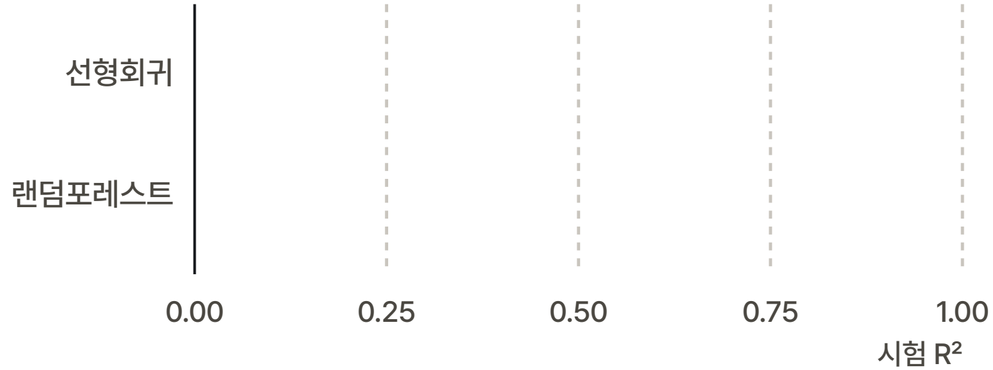
정책 근거를 만드는 일: 「왜 이 지역인가」를 설명 못 하면 예산 X → 오른쪽 셋째 줄이 자주 결정적

출처: 옛 12강 「예측적 분석 II」

홀드아웃 검증: 숨겨 둔 자료로 채점한다

- **훈련 자료(80%):** 모형을 만듦
- **시험 자료(20%):** 답을 가리고 채점에만 씀
- **지표:**
  - RMSE · MAE: 평균적으로 빗나간 크기 (원 단위)
  - MAPE: 빗나간 크기 ÷ 실제값 (%)

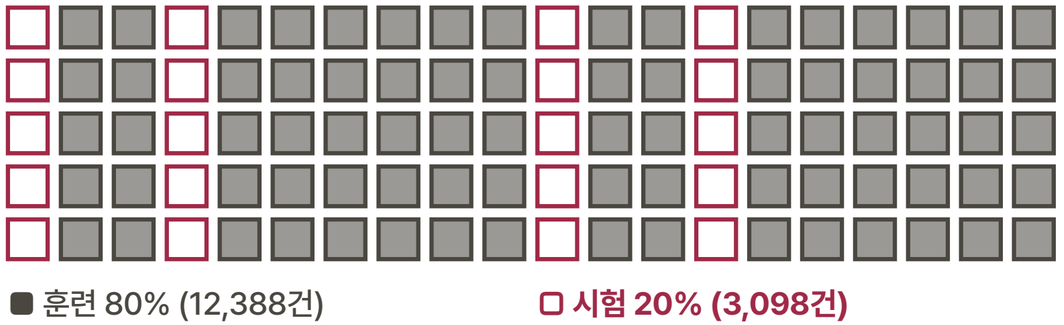


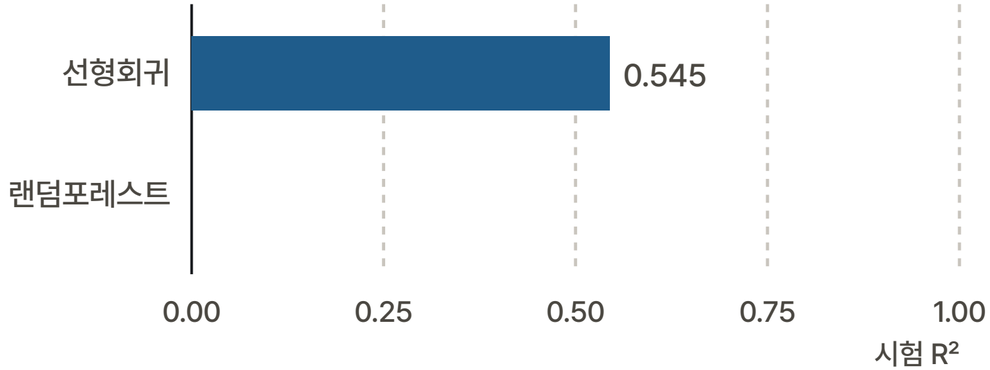


홀드아웃 검증: 숨겨 둔 자료로 채점한다

- **훈련 자료(80%):** 모형을 만듦
- **시험 자료(20%):** 답을 가리고 채점에만 씀
- **지표:**
  - RMSE · MAE: 평균적으로 빗나간 크기 (원 단위)
  - MAPE: 빗나간 크기 ÷ 실제값 (%)

→ 선형회귀: 시험 R^2 .545 · MAPE 26.1%



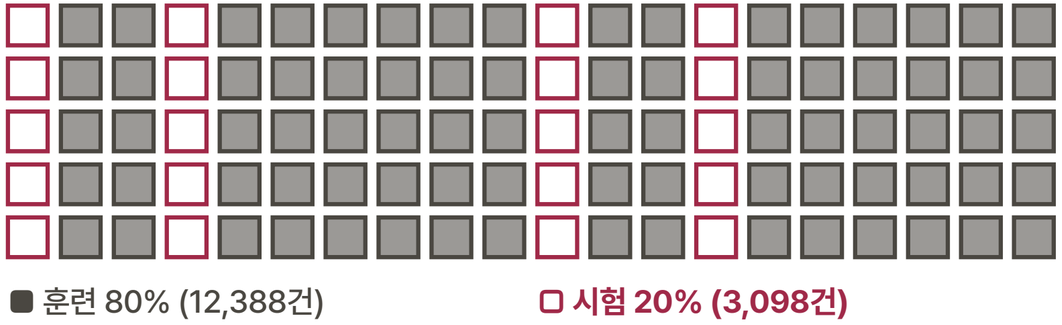


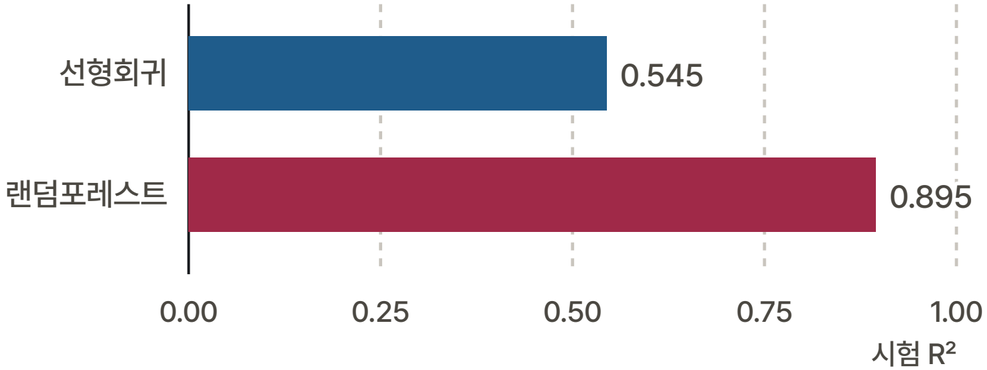
홀드아웃 검증: 숨겨 둔 자료로 채점한다

- **훈련 자료(80%):** 모형을 만듦
- **시험 자료(20%):** 답을 가리고 채점에만 씀
- **지표:**
  - RMSE · MAE: 평균적으로 빗나간 크기 (원 단위)
  - MAPE: 빗나간 크기 ÷ 실제값 (%)

→ 선형회귀: 시험 R^2 .545 · MAPE 26.1%

→ 랜덤포레스트: 시험 R^2 **.895** · MAPE **8.4%**





주의: 검증을 망치는 방법들

이렇게 하면	왜 안 되나
같은 묶음을 양쪽에 나눔	같은 단지 · 같은 사람의 다른 관측을 외워서 맞힘 → **성적 부풀림**
시계열을 무작위로 나눔	미래를 보고 과거를 맞힘 → 반드시 뒤쪽을 뗌
시험 성적을 보며 모형을 고침	시험 자료에 맞춰짐 → 더는 시험이 아님
학습에 미래 정보가 섞임	전체 평균 같은 값을 미리 계산해 넣음 → 시험 자료가 새어 듦

세종 시험 R^2	거래 무작위	단지 단위
선형회귀	.545	.445
랜덤포레스트	.895	**.728**

출처: 옛 11강 「검증을 망치는 방법들」에 세종 결과를 더함

→ 네 가지 모두 성적을 **실제보다 좋게** 만듦

단지 단위: 133개 단지 중 27개(4,672건)를 통째로 시험 자료로. 「새 단지는 얼마일까」에 맞는 점수

분류와 회귀에 쓰는 모형들

모형	회귀	분류	한 줄 설명
선형회귀	●		회귀의 대표. 직선(평면)으로 맞춤
로지스틱 회귀		●	분류의 대표. 로짓을 직선으로 맞춤
릿지 · 라쏘	●	●	계수에 벌점 · 라쏘는 쓸모없는 변수를 0으로
K-최근접 이웃	●	●	가장 닮은 K 개 사례의 평균 · 다수결
서포트 벡터 머신	●	●	두 범주 사이 여백이 가장 넓은 경계
의사결정나무	●	●	**예/아니오 질문을 이어 붙여 자료를 나눔**
랜덤포레스트	●	●	**나무 여러 그루의 평균 · 다수결**
그래디언트 부스팅	●	●	앞 나무가 틀린 만큼을 다음 나무가 고침 (XGBoost · LightGBM)
신경망	●	●	층을 쌓아 복잡한 관계 학습 · 자료가 아주 많을 때

→ 실습: 회귀 · 분류 모두 되고 손질이 적은 **랜덤포레스트**

비지도학습 ①: 군집 (7강에서 실습)

y 없이 닮은 것끼리 묶어 자료의 구조를 찾음

K-means

- 묶음 수 K 를 먼저 정함
- 중심과의 거리가 최소가 되도록 나눔

계층적 군집

- 가장 가까운 둘부터 차례로 합침
- 덴드로그램을 잘라 묶음 수 결정

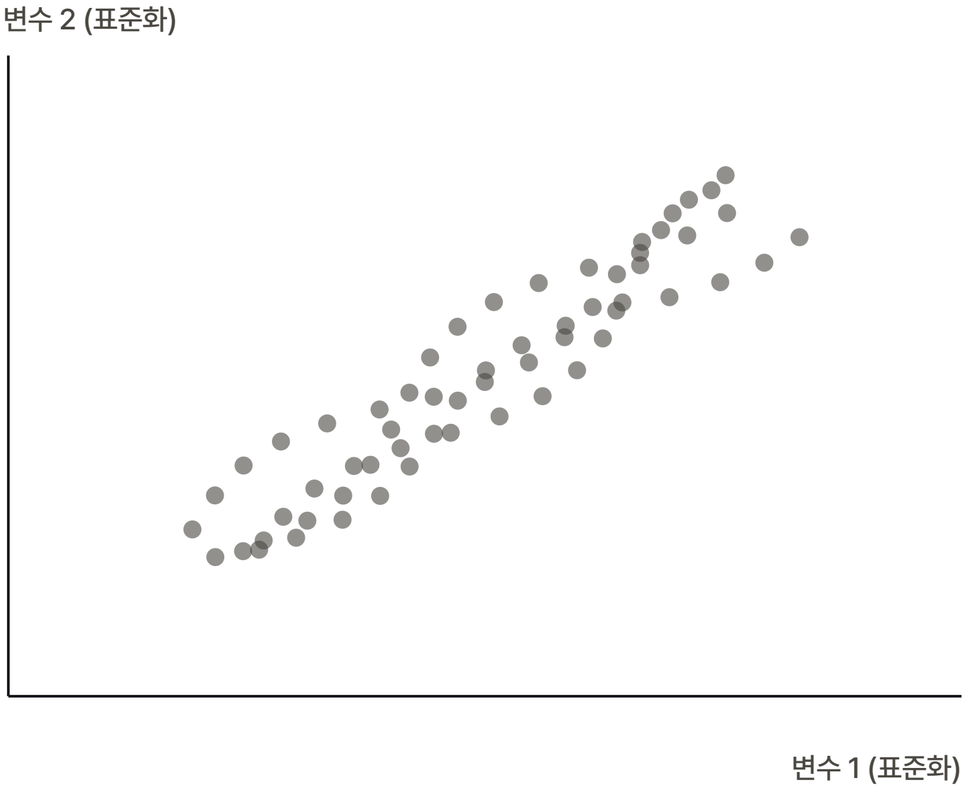
→ 분류: 정답 범주가 있음 · 군집: 범주 자체를 자료에서 만듦

비지도학습 ②: 주성분분석으로 차원을 줄인다

겹친 정보를 담은 여러 변수 → 적은 수의 새 축

- **설명분산:** 주성분마다 원래 분산의 몇 % 를 담나 → 남길 개수 결정

→ 쓰임: 예측 전 변수 줄이기 · 지수 만들기 (예: 쇠퇴지수)



개념도 · 실제 자료 아님

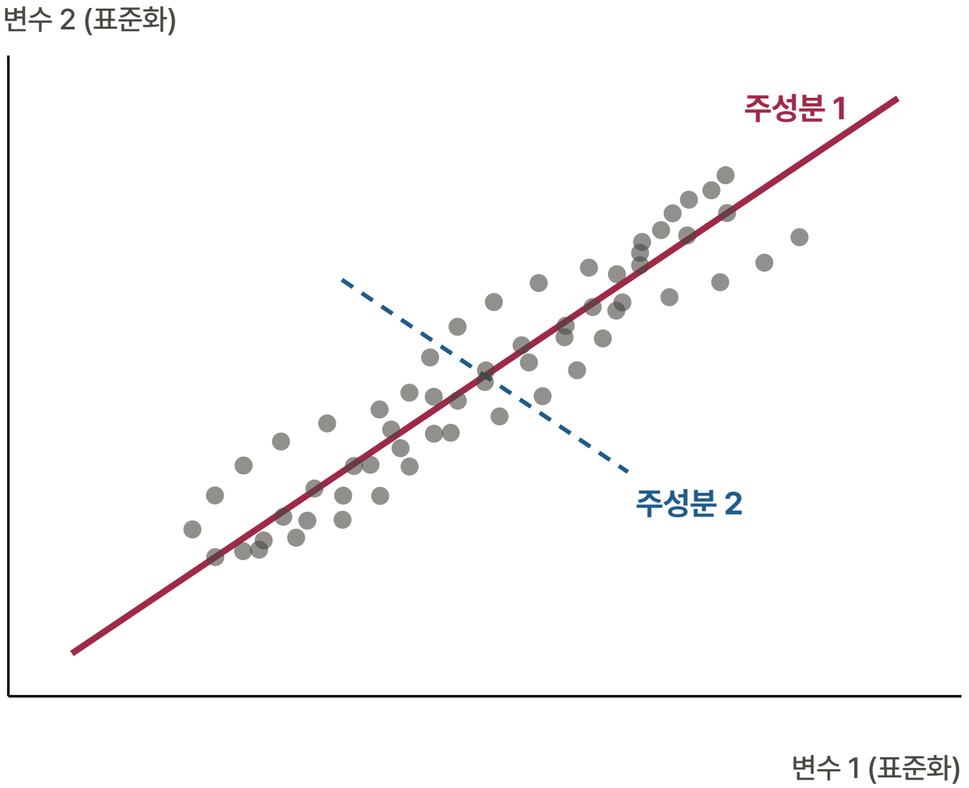
비지도학습 ②: 주성분분석으로 차원을 줄인다

겹친 정보를 담은 여러 변수 → 적은 수의 새 축

- **주성분 1:** 점이 가장 길게 퍼진 방향

- **설명분산:** 주성분마다 원래 분산의 몇 % 를 담나 → 남길 개수 결정

→ 쓰임: 예측 전 변수 줄이기 · 지수 만들기 (예: 쇠퇴지수)



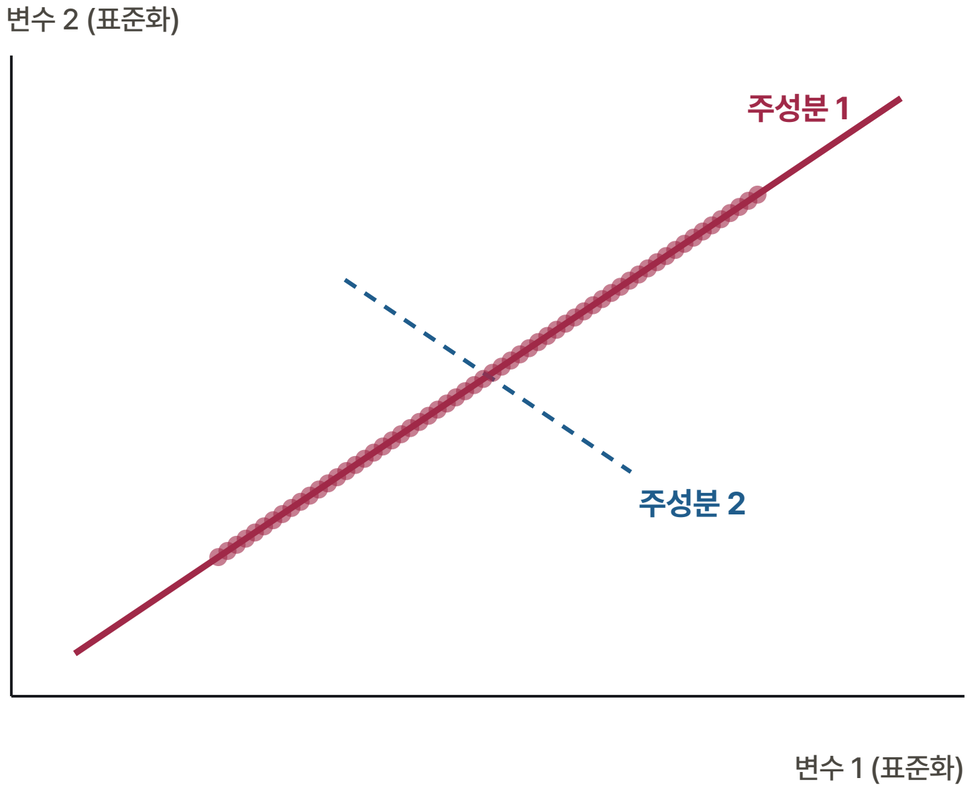
개념도 · 실제 자료 아님

비지도학습 ②: 주성분분석으로 차원을 줄인다

겹친 정보를 담은 여러 변수 → 적은 수의 새 축

- **주성분 1:** 점이 가장 길게 퍼진 방향
- **투영:** 점을 그 축에 내림 → 두 변수가 하나로 (축과 수직인 짧은 퍼짐만 잃음)
- **설명분산:** 주성분마다 원래 분산의 몇 % 를 담나 → 남길 개수 결정

→ 쓰임: 예측 전 변수 줄이기 · 지수 만들기 (예: 쇠퇴지수)



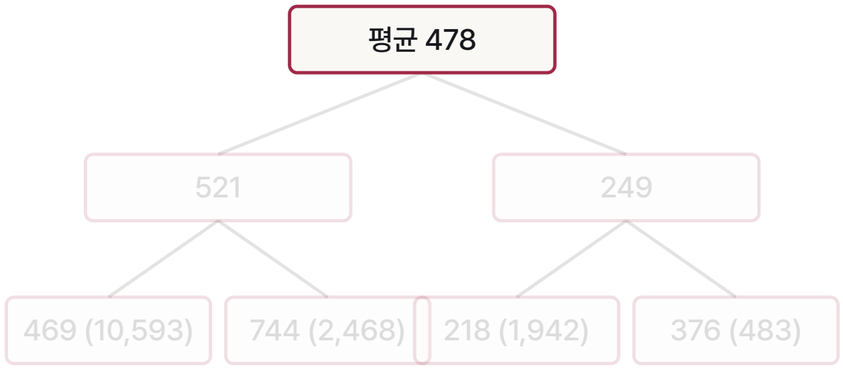
개념도 · 실제 자료 아님

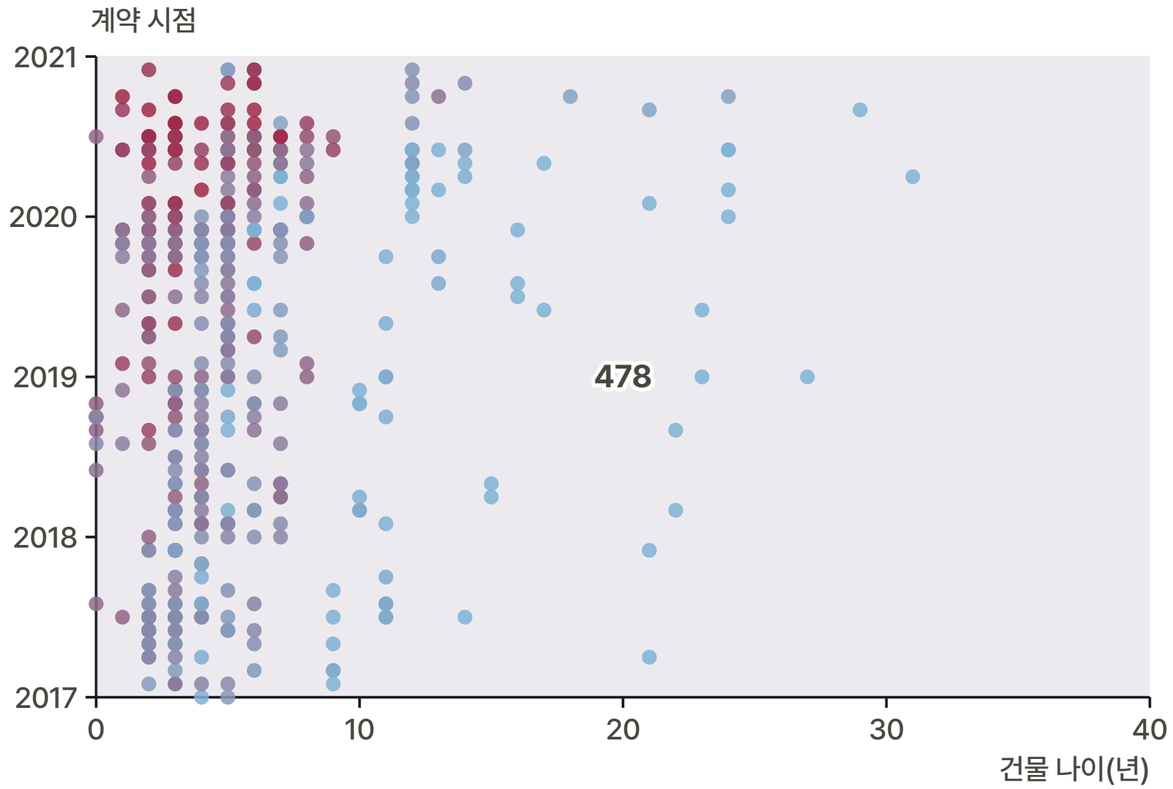
나무에서 숲으로

회귀와 분류를 모두 하는 모형. 의사결정나무부터

의사결정나무: 질문을 이어 붙인다

질문 하나로 둘로 나누고, 칸마다 평균을 예측값으로



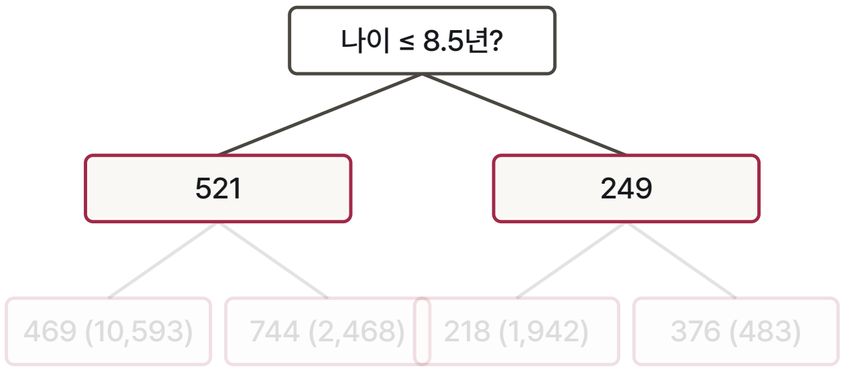


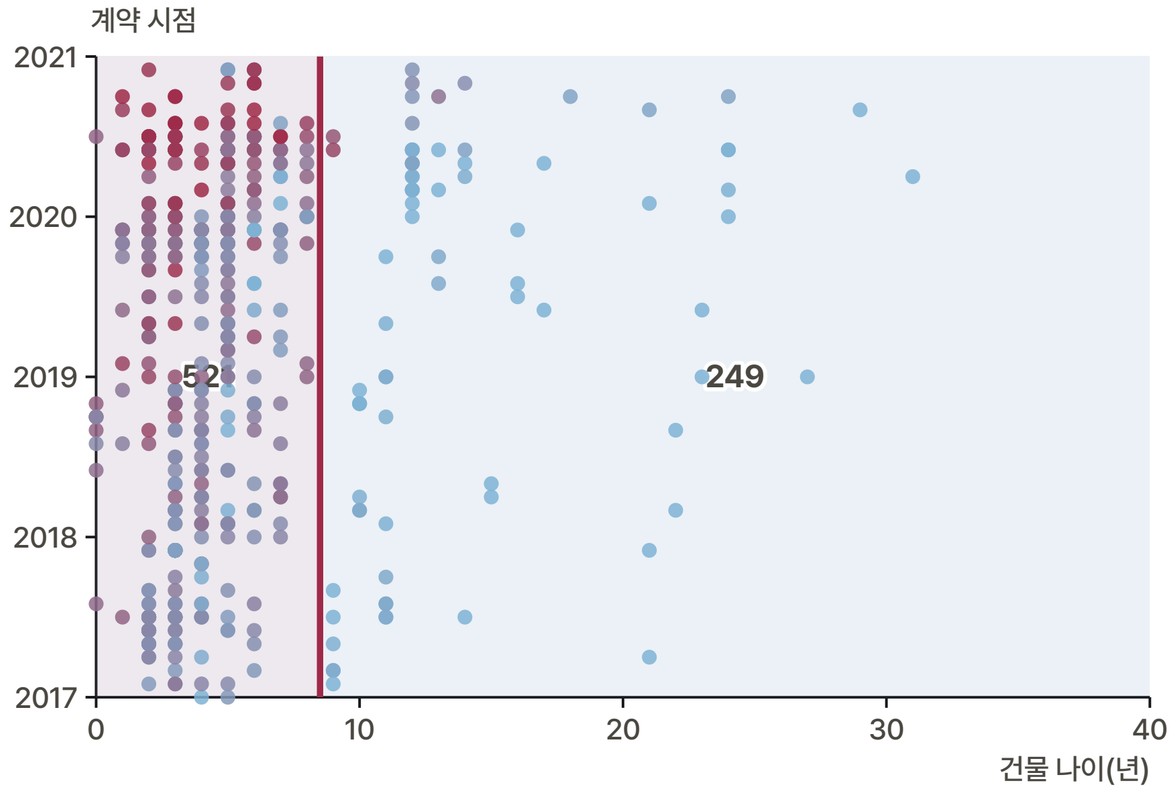
점 500건 · 색이 진할수록 m²당 가격 높음 · 칸의 숫자 = 예측값

의사결정나무: 질문을 이어 붙인다

질문 하나로 둘로 나누고, 칸마다 평균을 예측값으로

- 질문 1: 건물 나이 ≤ 8.5년?



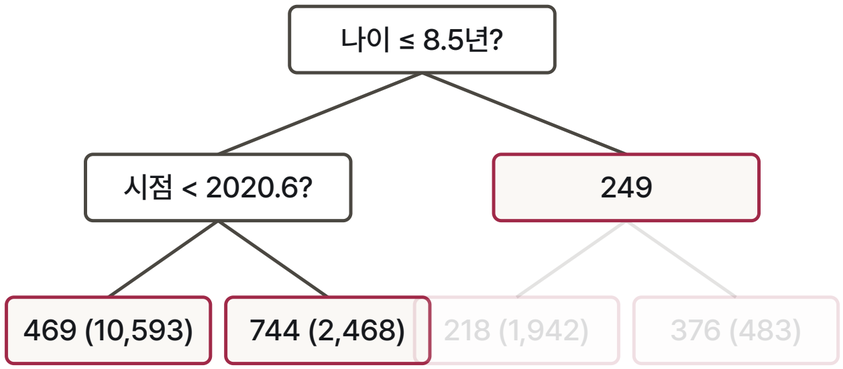


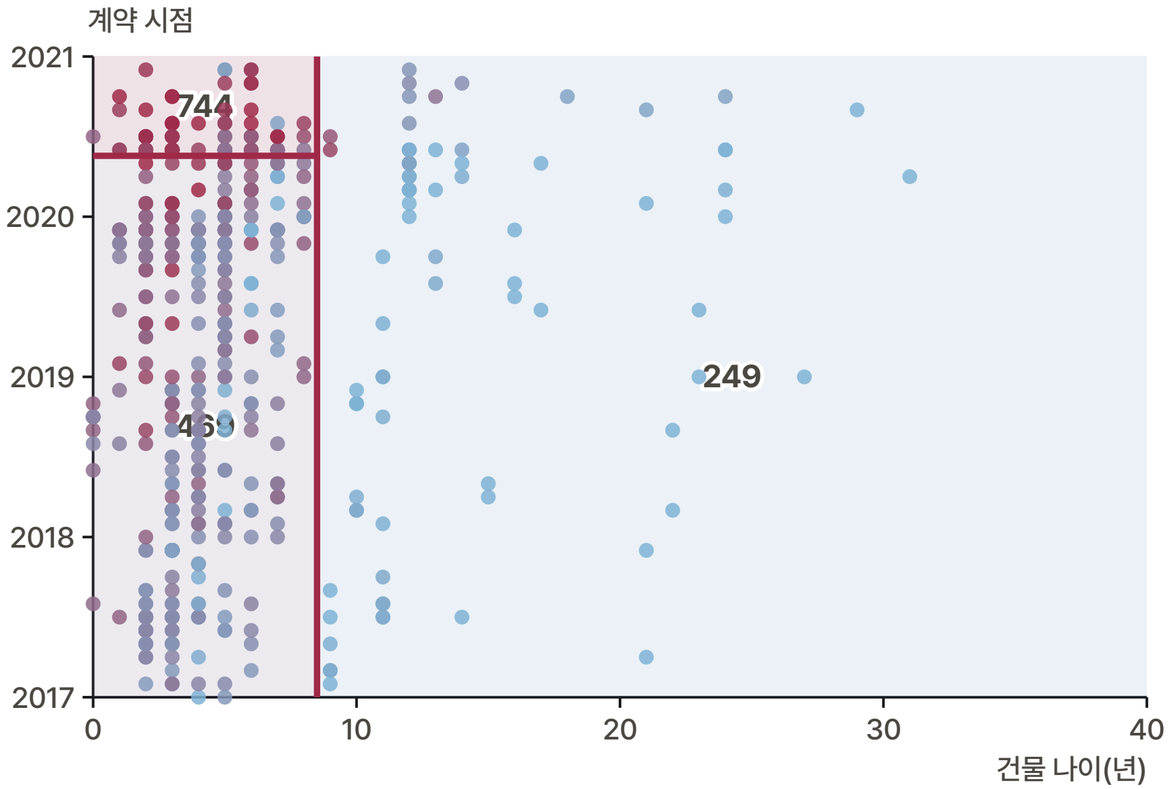
점 500건 · 색이 진할수록 m²당 가격 높음 · 칸의 숫자 = 예측값

의사결정나무: 질문을 이어 붙인다

질문 하나로 둘로 나누고, 칸마다 평균을 예측값으로

- 질문 1: 건물 나이 ≤ 8.5년?
- 질문 2: (새 아파트) 2020년 6월 이후 계약?



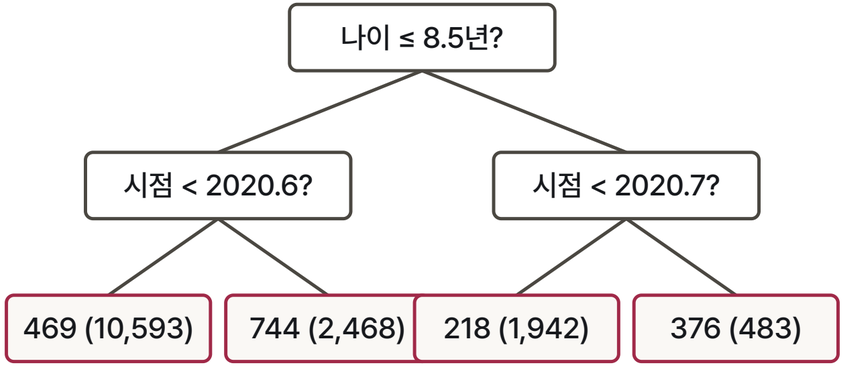


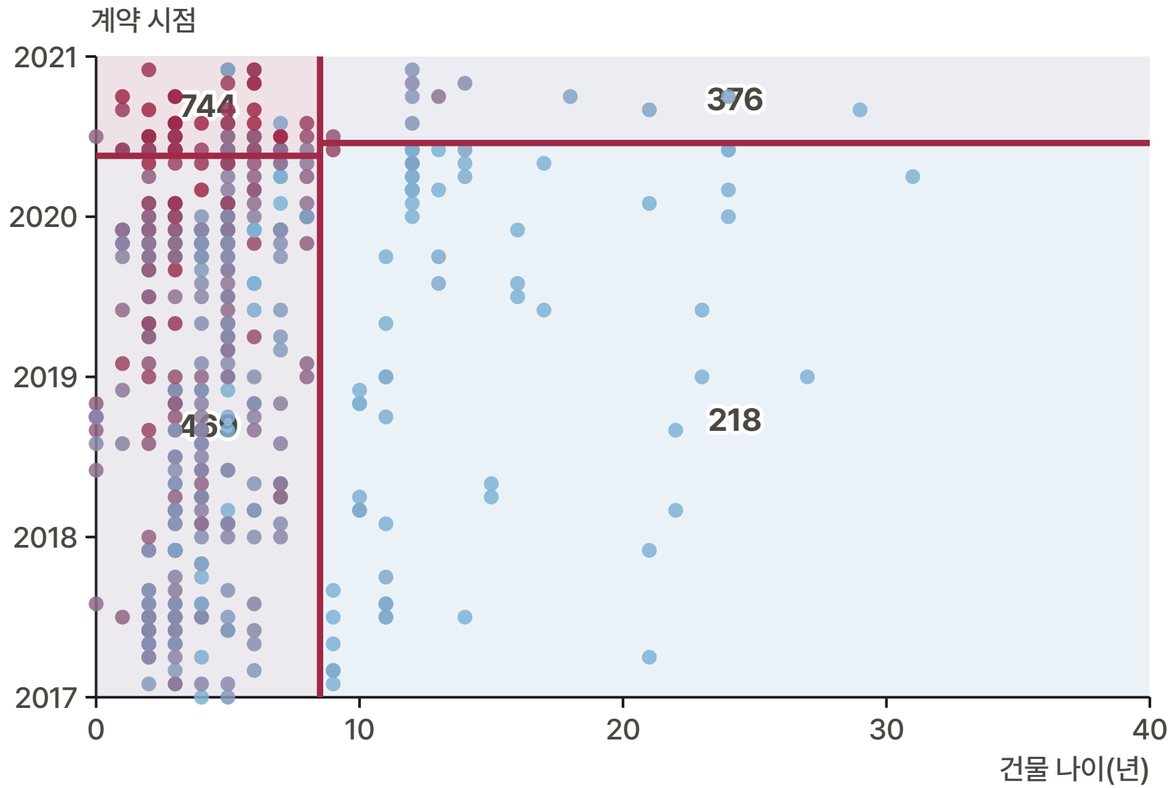
점 500건 · 색이 진할수록 m²당 가격 높음 · 칸의 숫자 = 예측값

의사결정나무: 질문을 이어 붙인다

질문 하나로 둘로 나누고, 칸마다 평균을 예측값으로

- 질문 1: 건물 나이 ≤ 8.5년?
- 질문 2: (새 아파트) 2020년 6월 이후 계약?
- 질문 3: (오래된 쪽) 2020년 7월 이후 계약?



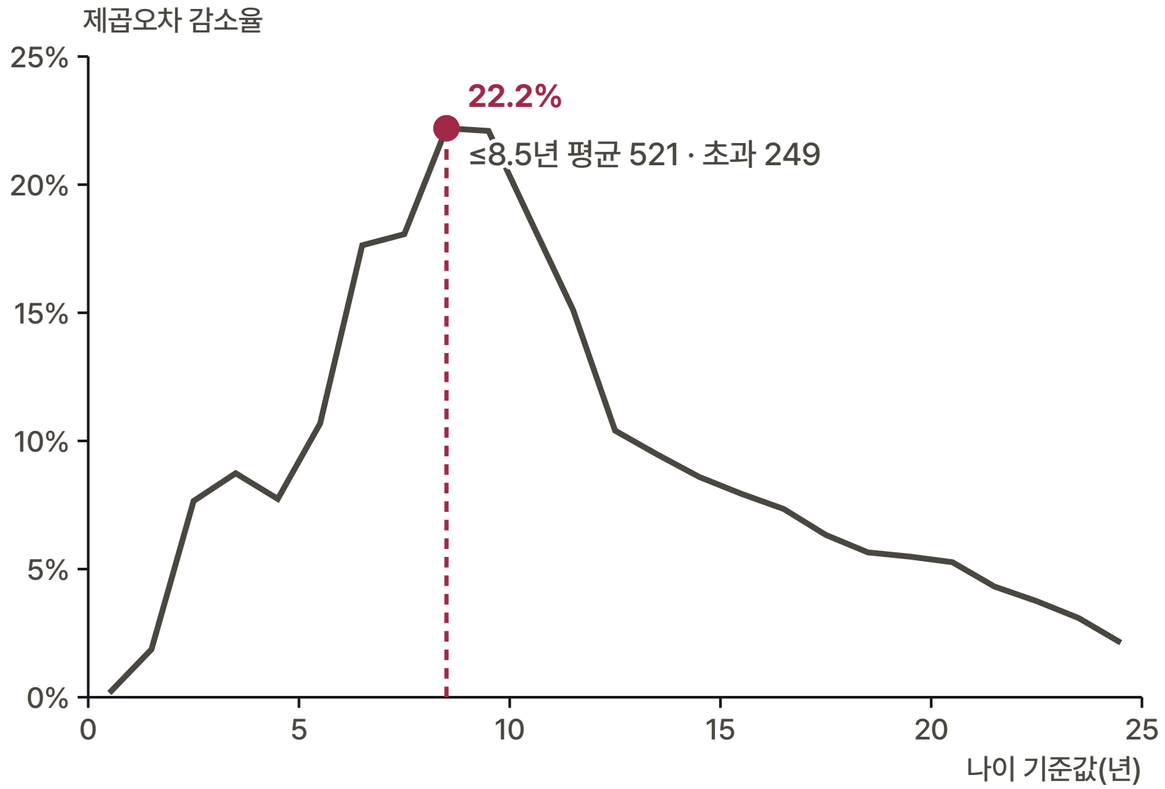


점 500건 · 색이 진할수록 m²당 가격 높음 · 칸의 숫자 = 예측값

나무는 오차가 가장 많이 줄어드는 질문을 고른다

- **후보:** 모든 변수 × 모든 기준값
- **기준:**
  - 회귀 나무: 두 묶음의 제곱오차 합 감소
  - 분류 나무: 지니 불순도 감소
- **반복:** 나뉜 칸마다 같은 방법으로 다음 질문

→ 세종: 나이 8.5년에서 감소율 최대 (22.2%) → 첫 질문



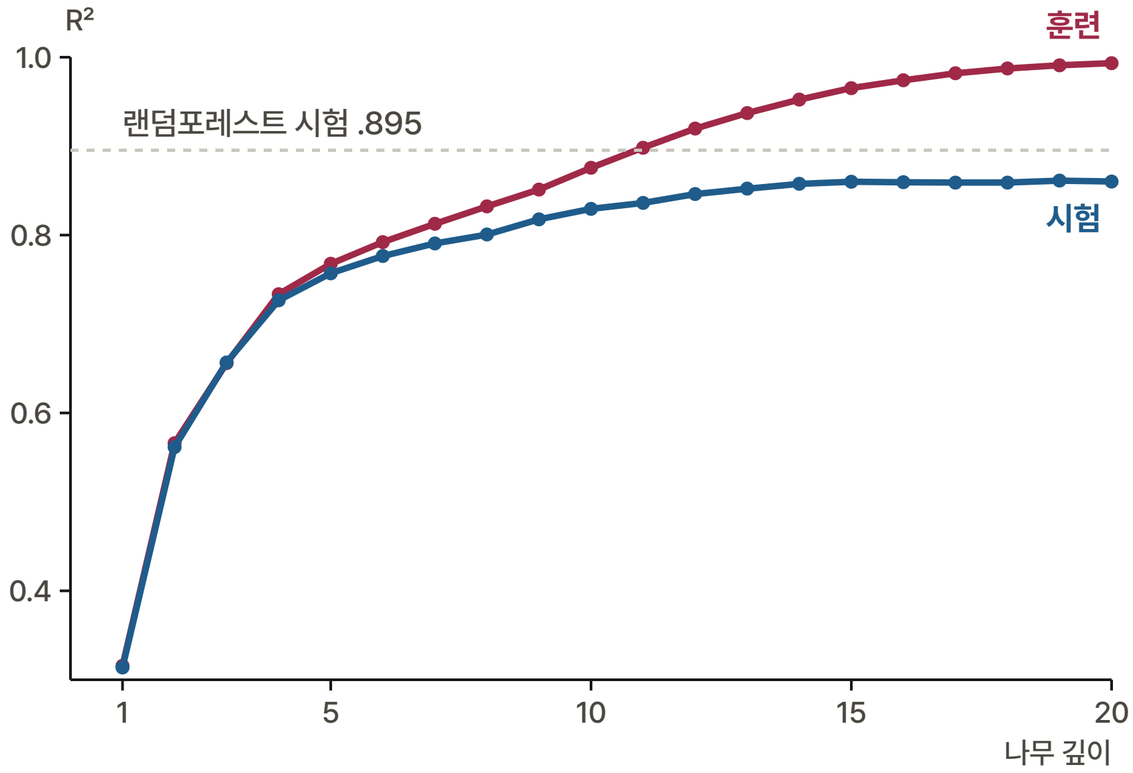
과적합: 복잡해지면 훈련 자료를 외운다

자료의 규칙뿐 아니라 우연까지 따라 그려 새 자료에서 빗나가는 것

- **복잡도:** 모형이 자료에 맞춰 조정할 수 있는 정도 (나무의 깊이 · 변수 수 · 다항식 차수)
- **훈련 오차:** 복잡도↑ → 계속 감소
- **시험 오차:** 어느 지점부터 감소 멈춤 · 다시 증가

→ 세종 나무: 훈련 R^2 → .996 · 시험 R^2 는 깊이 15 근처 .86에서 멈춤

→ 복잡도는 **시험(검증) 오차로** 고름. 훈련 R^2 로 고르면 과적합 모형이 뽑힘



랜덤포레스트: 다르게 자란 나무들의 평균

예시 거래: 신도시 · 나이 5년 · 85m² · 10층 · 2020년 7월 계약 · 나무는 깊이 2, 변수 후보 둘 (실제 숲은 300그루, 깊게)

랜덤포레스트: 다르게 자란 나무들의 평균

① 부트스트랩: 표본을 복원추출로 다시 뽑음 (한 그루가 보는 거래 ≈ 63%)

나무 1



거래 9,760건이 한 번 이상 뽑힘

나무 2



거래 9,756건이 한 번 이상 뽑힘

나무 3



거래 9,762건이 한 번 이상 뽑힘

예시 거래: 신도시 · 나이 5년 · 85m² · 10층 · 2020년 7월 계약 · 나무는 깊이 2, 변수 후보 둘 (실제 숲은 300그루, 깊게)

랜덤포레스트: 다르게 자란 나무들의 평균

① 부트스트랩: 표본을 복원추출로 다시 뽑음 (한 그루가 보는 거래 ≈ 63%) ② 질문마다 변수 일부만 후보로



예시 거래: 신도시 · 나이 5년 · 85m² · 10층 · 2020년 7월 계약 · 나무는 깊이 2, 변수 후보 둘 (실제 숲은 300그루, 깊게)

랜덤포레스트: 다르게 자란 나무들의 평균

① 부트스트랩: 표본을 복원추출로 다시 뽑음 (한 그루가 보는 거래 ≈ 63%) ② 질문마다 변수 일부만 후보로 ③ 예측을 평균



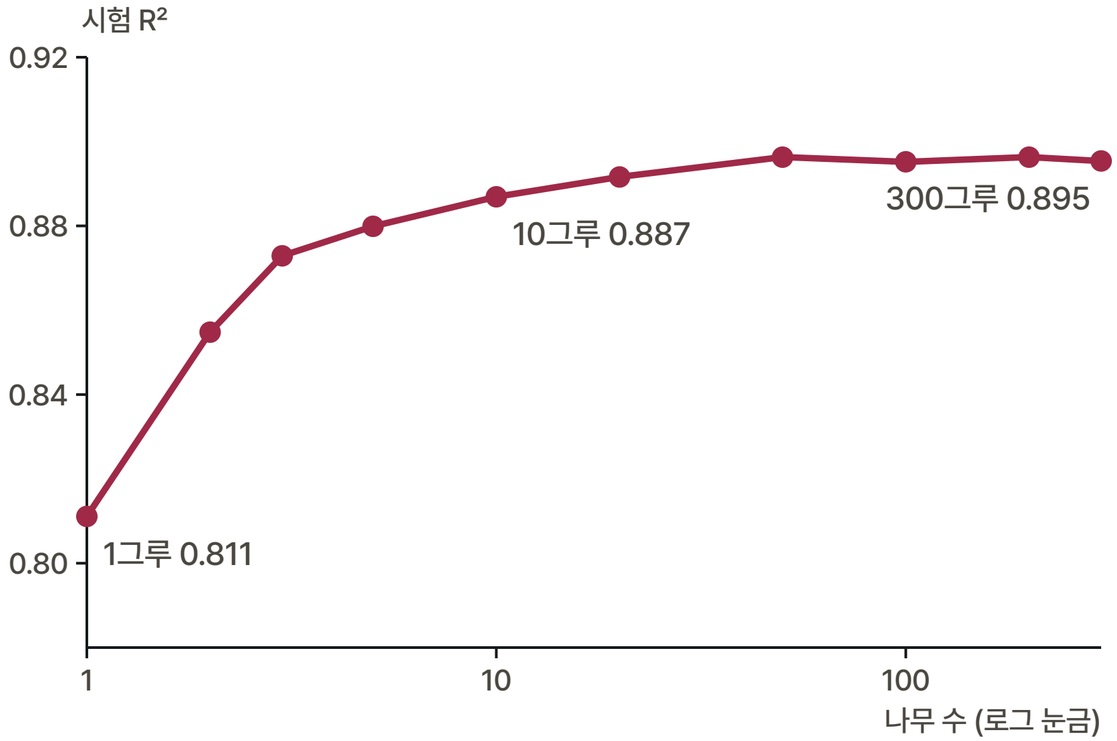
예시 거래: 신도시 · 나이 5년 · 85m² · 10층 · 2020년 7월 계약 · 나무는 깊이 2, 변수 후보 둘 (실제 숲은 300그루, 깊게)

나무를 늘리면 예측이 안정된다

- **1그루:** 시험 R^2 .811
- **10그루:** .887
- **50그루 이후:** .896 에서 멈춤

→ 나무마다 틀리는 방향이 다름 → 평균하면 오차가 상쇄

OOB: 부트스트랩에서 빠진 37% 로 각 나무를 채점 → 시험 자료 없이 성능 가늠 (R^2 .897)



회귀와 분류에서 숲과 통계 모형을 견준다

회귀: m²당 가격

모형	훈련 R^2	시험 R^2	시험 RMSE
선형회귀	.558	.545	142.5
나무 (깊이 4)	.734	.727	110.4
나무 (끝까지)	.996	.856	80.2
랜덤포레스트	.933	**.895**	**68.3**

→ 같은 다섯 변수 · 같은 분할에서 숲이 회귀·분류 모두 우세

시험 자료 3,098건 · 거래 무작위 분할 기준

분류: 중앙값보다 비싼가

모형	정분류율	AUC
로지스틱 회귀	78.2%	.875
랜덤포레스트	**93.1%**	**.982**

AUC: ROC 곡선(1−특이도 대 민감도) 아래 넓이 · 0.7 이상 수용 가능

숲 안을 들여다본다

숲에는 계수가 없음. 어떤 변수가 얼마나 작용했는지 어떻게 아는가

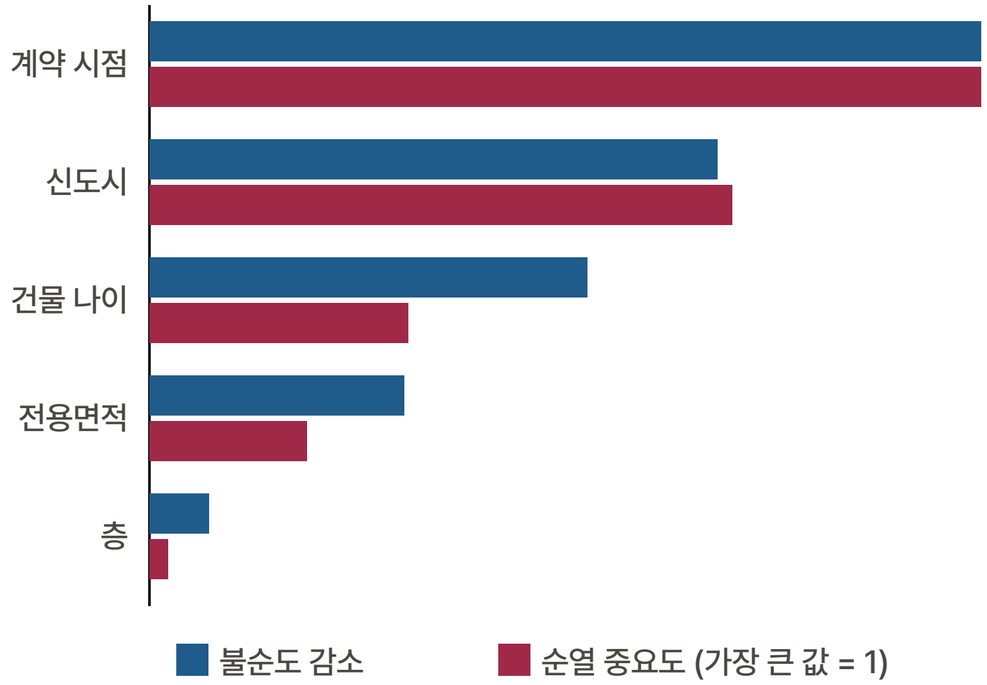
변수 중요도: 어느 변수가 많이 쓰였나

- **불순도 감소(MDI):** 그 변수로 나눌 때 줄어든 오차를 모든 나무에서 합산
- **순열 중요도:** 그 변수 값만 섞었을 때 예측이 나빠지는 정도

→ 세종: 계약 시점 > 신도시 > 건물 나이 > 면적 > 층

- **한계:**
  - 방향을 알려 주지 않음 (나이가 많으면 비싼가 싼가?)
  - 상관이 높은 변수가 들어오면 크게 흔들림

출처: 설명가능한 AI p.5, 발제논문 1 p.8 (2024-2 머신러닝 이론과 실습)

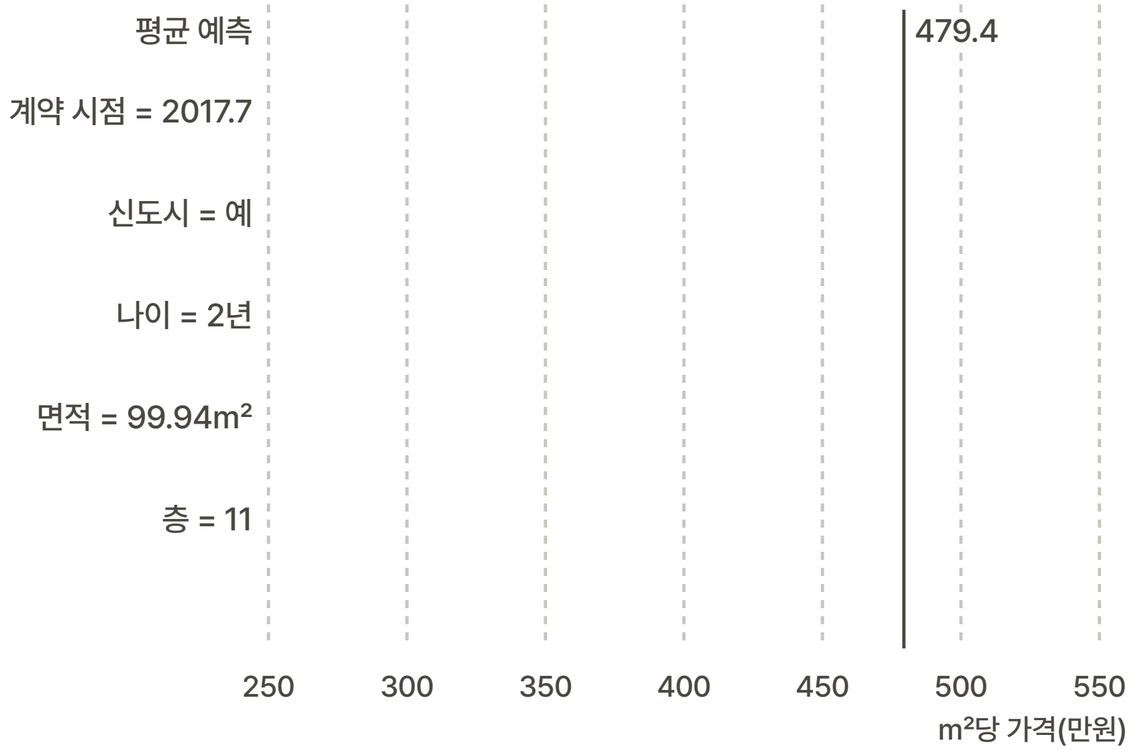


섀플리 값: 예측을 변수마다 공정하게 나눈다

예측값 = 평균 예측 + 변수별 몫(SHAP 값)

- **출발:** 게임이론 · 함께 번 이익을 기여만큼 배분
- **효율성:** 몫의 합 = 예측값
- **더미:** 기여하지 않은 변수의 몫 = 0
- **대칭성:** 기여가 같으면 몫도 같음

출처: 설명가능한 AI p.17·19



시험 자료의 거래 한 건. 몫을 모두 더하면 예측값이 된다

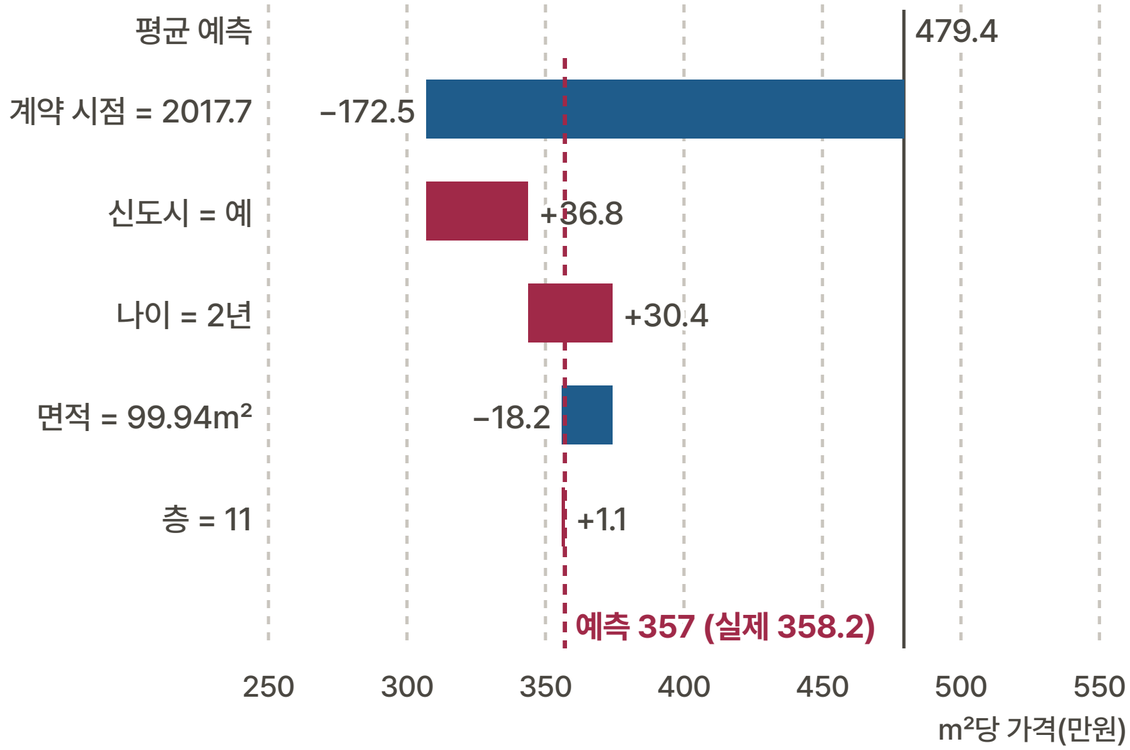
섀플리 값: 예측을 변수마다 공정하게 나눈다

예측값 = 평균 예측 + 변수별 몫(SHAP 값)

- **출발:** 게임이론 · 함께 번 이익을 기여만큼 배분
- **효율성:** 몫의 합 = 예측값
- **더미:** 기여하지 않은 변수의 몫 = 0
- **대칭성:** 기여가 같으면 몫도 같음

→ 이 거래: 평균 479 → 계약 시점 **−173** (2017년 7월, 상승 전 계약) → 예측 357

출처: 설명가능한 AI p.17·19



시험 자료의 거래 한 건. 몫을 모두 더하면 예측값이 된다

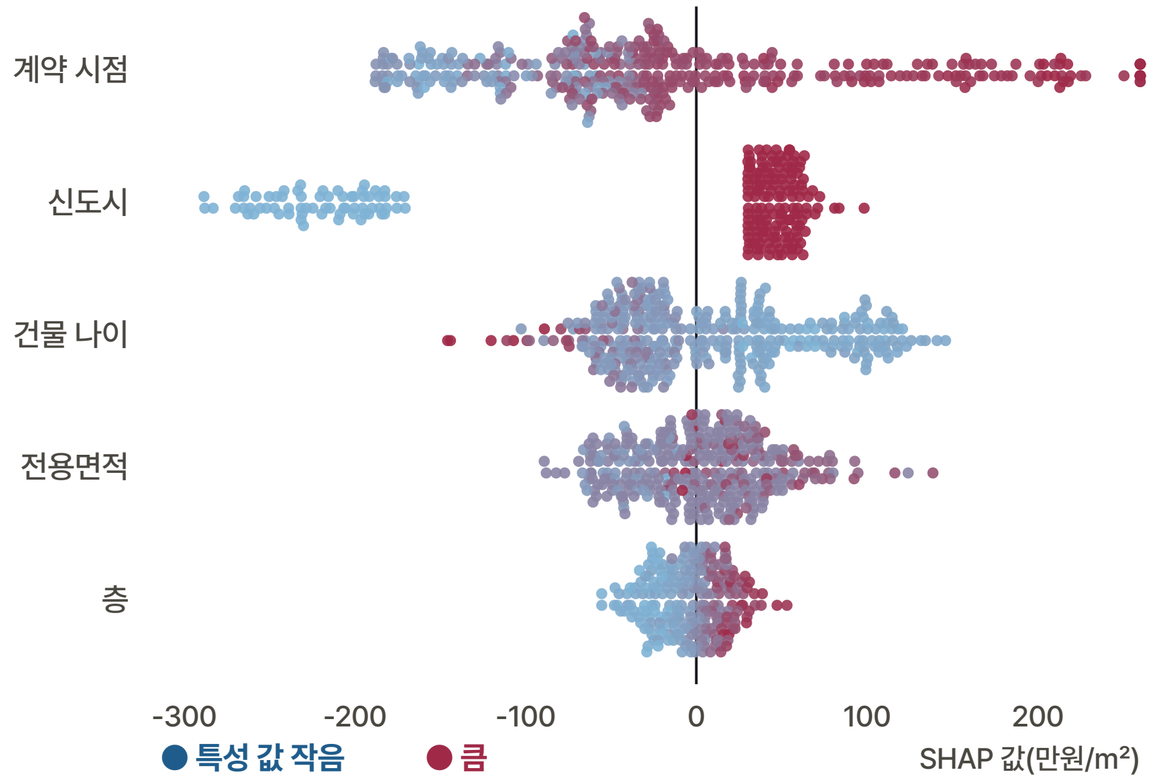
SHAP 요약 그림: 모든 거래의 몫을 한 장에

- **점:** 거래 하나의 한 변수 몫
- **색:** 특성 값 큼 = 붉은색 · 작음 = 푸른색
- **위치:** 0 오른쪽 = 가격↑ · 왼쪽 = 가격↓
- **순서:** 평균 |SHAP| 큰 변수부터

→ 계약 시점: 늦을수록(붉음) 가격↑

→ 건물 나이: 새것일수록(푸름) 가격↑

읽는 법 출처: 설명가능한 AI p.20

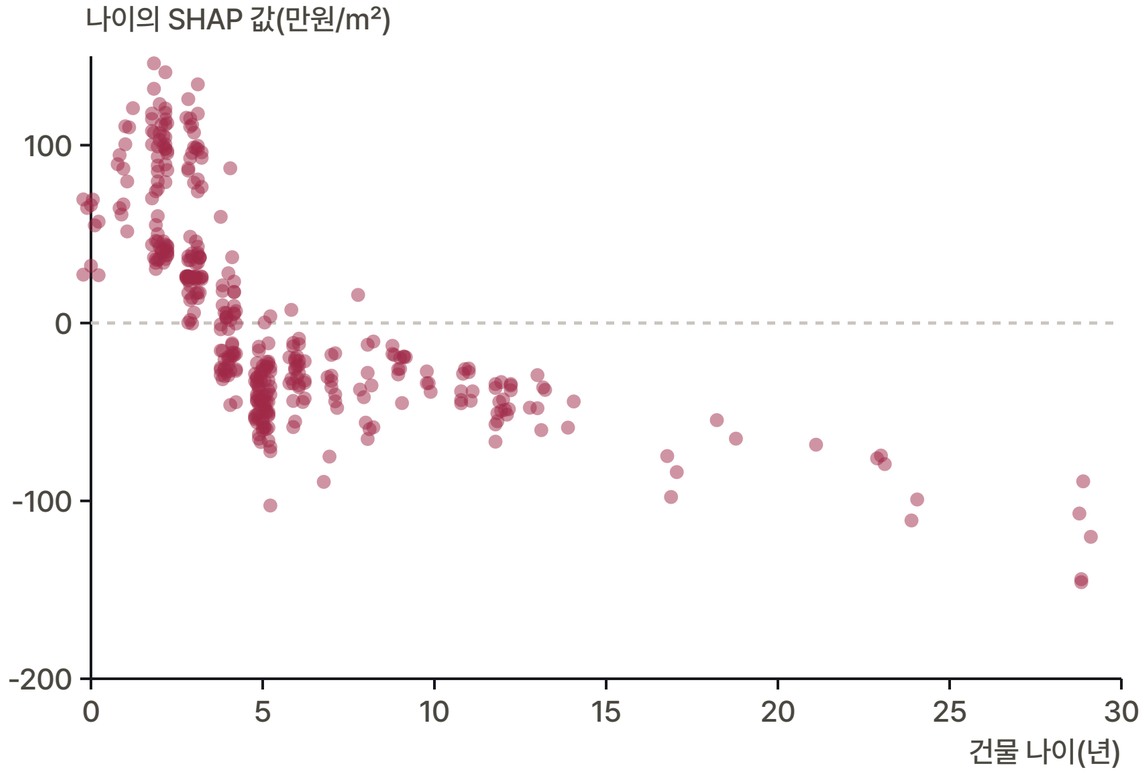


SHAP 의존 그림: 회귀계수가 보여 주지 못한 모양

- **x 축:** 건물 나이 · **y 축:** 나이의 몫
- 3년 이하 +100 안팎 → 4~5년에 급락 → 이후 완만히 감소

→ 숲은 계단 모양을 자료에서 찾음 · 직선은 그 모양을 놓침

갓 지은 아파트 = 대부분 신도시 · 늦은 거래 → 계단에 지역·시점 차이가 섞임

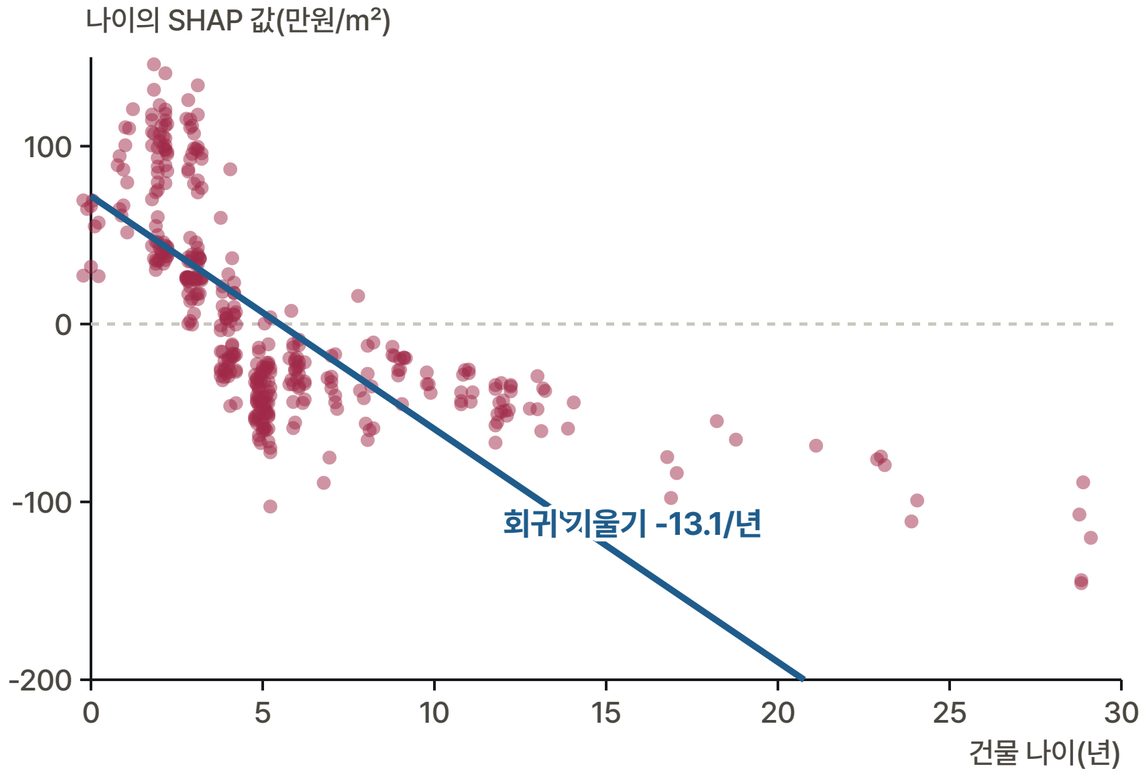


SHAP 의존 그림: 회귀계수가 보여 주지 못한 모양

- **x 축:** 건물 나이 · **y 축:** 나이의 몫
- 3년 이하 +100 안팎 → 4~5년에 급락 → 이후 완만히 감소
- 선형회귀: 「1년에 −13.1만원」 직선 하나로 요약

→ 숲은 계단 모양을 자료에서 찾음 · 직선은 그 모양을 놓침

갓 지은 아파트 = 대부분 신도시 · 늦은 거래 → 계단에 지역·시점 차이가 섞임



SHAP 값이 뜻하는 것과 뜻하지 않는 것

뜻하는 것

- 이 **모형**이 이 예측에서 각 변수에 기댄 정도
- 거래 하나(지역) · 전체(전역)를 같은 단위로
- 방향과 모양

뜻하지 않는 것

- **인과 X:** 나이를 바꾸면 값이 그만큼 바뀐다는 뜻 아님
- 변수끼리 상관 ↑ → 몫이 쏠리거나 나뉨
- 모형이 틀리면 설명도 틀림 → 시험 점수 먼저

→ 예측은 숲 · 「왜」의 단서는 SHAP · 확인은 9강의 회귀

출처: 설명가능한 AI p.21

예측을 증거로 쓰려면

점 하나가 아니라 범위로, 그리고 틀릴 조건까지

예측구간: 숫자 하나 대신 범위를 낸다

새로 관측될 값이 정한 확률로 들어갈 범위

- **점 예측:** 예측값 하나
- **신뢰구간과의 차이:** 신뢰구간 = 평균·계수의 범위 · 예측구간 = 값 하나의 범위 (더 넓음)
- **간단한 방법:** 시험 잔차의 5% · 95% 분위를 예측값에 더함

→ 세종 숲: 예측 −91 ~ +119 만원/m^2 가 90% 범위

같은 예측을 두 가지로 쓰면

- ㉠ 「이 거래는 m^2당 357만원이다」
- ㉡ 「m^2당 357만원으로 예측. 시험 오차로 보면 266~476 만원 범위가 90%」

→ ㉠ 반박당하면 무너짐 · ㉡ 틀릴 수 있음까지 포함

틀: 옛 12강 「예측구간」

구간이 담지 못하는 불확실성

종류	구간에 들어가나
자료의 흩어짐	들어감 (예측구간이 측정하는 것)
계수·나무를 잘못 추정한 정도	들어감
모형을 잘못 고른 것	**안 들어감 · 모형이 틀리면 구간도 틀림**
자료 밖의 대상 · 구조 변화	**안 들어감 · 새 단지, 정책 변화, 시장 급변**

→ 세종: 90% 범위를 새 단지(단지 단위 시험)에 대 보면 **70.2%**만 들어감

아래 둘은 시나리오로 다룸 → 13강 처방적 분석

예측을 증거로 쓰는 조건

1. 학습에 쓰지 않은 자료로 채점했는가 (묶음 · 시간 누수 없이)

2. 복잡도를 시험(검증) 오차로 골랐는가

3. 점이 아니라 범위로 말했는가

4. 무엇이 어긋나면 틀리는지 적었는가

→ 하나라도 빠지면 정책 근거로 쓸 수 없음

출처: 옛 12강 「예측을 증거로 쓰는 조건」

실습: 랜덤포레스트와 SHAP

1. 회귀 숲

9강에서 정리한 세종 자료로 m²당 가격을 예측해 줘. 변수는 신도시 여부·건물 나이·전용면적·층·계약 시점(2017년 1월 = 0, 연 단위)이야.

거래를 80:20 으로 나누고(random_state 10), 선형회귀와 랜덤포레스트(나무 300, min_samples_leaf 5, max_features 0.6)의 훈련·시험 R^2·RMSE·MAE·MAPE 를 표로 비교해 줘.

확인할 값: 시험 R^2 선형 .545 · 숲 .895 · MAPE 26.1% · 8.4%

2. 분류 숲

m²당 가격이 중앙값을 넘는지를 같은 변수로 로지스틱 회귀와 랜덤포레스트로 맞히고 정분류율과 AUC 를 비교해 줘.

확인할 값: AUC 로지스틱 .875 · 숲 .982

3. 들여다보기

회귀 숲의 불순도 중요도와 순열 중요도를 그려 줘. 시험 자료 400건으로 SHAP 요약 그림, 건물 나이의 의존 그림, 거래 하나의 폭포 그림을 그리고 그림마다 무엇이 보이는지 세 줄로 설명해 줘.

4. 단지 단위 검증과 예측구간

같은 단지(시군구 + 단지명)가 훈련과 시험에 나뉘지 않게 단지 단위로 80:20 을 나눠 다시 채점해 줘. 무작위 분할의 시험 잔차로 90% 예측구간을 만들고, 그 구간에 단지 분할 시험 자료가 몇 % 들어가는지 알려 줘.

확인할 값: 숲 시험 R^2 .7 근처 · 구간 적중 약 70%

값의 출처: `analysis/10-머신러닝/10-세종랜덤포레스트.py` · 숲은 무작위라 셋째 자리가 다를 수 있음

과제: 숲으로 예측하고 SHAP 으로 읽는다

1. 세종 실습 정리

- 네 프롬프트 결과 ↔ 확인할 값 대조
- SHAP 의존 그림 하나 ↔ 9강 회귀계수 비교
- 무작위 분할 vs 단지 분할 점수 차이 설명

2. 자기 연구질문에 적용

- 9강의 종속변수를 랜덤포레스트로 예측
- 통계 모형과 시험 점수 비교 (누수 없는 분할)
- SHAP 요약 그림 · 예측구간 · 틀릴 조건

제출물

두 과제를 각각 별도 파일로 제출

- `세종랜덤포레스트.md` : 1번의 비교표 · 그림 · 설명
- `자기데이터머신러닝.md` : 2번의 비교표 · SHAP 그림 · 예측구간 · 단서

제출기한: (미정)

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

주차 선택에서 **10주차** 선택 · 학번 열 자리와 이름을 띄어쓰기 없이

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr