



2026-2학기 데이터사이언스

# 10강. 진단적 분석 II

## 회귀와 혼란변수

---

2026. 11. 9.

# 비싼 것은 위치 때문인가, 새것이기 때문인가?

---

- 7주차에 세종 동별 m<sup>2</sup>당 가격이 5.33배 차이 난다고 했다
- 비싼 동은 새 아파트가 많은 동이기도 하다
- 둘이 섞여 있는데 어떻게 떼어 내는가

# 오늘 배울 세 가지

| 방법         | 하는 일            | 얻는 것               |
|------------|-----------------|--------------------|
| ① 단순회귀     | 관계를 직선 하나로 요약한다 | "하나 늘면 얼마 변하나"     |
| ② 다중회귀와 통제 | 다른 조건을 같게 맞춘다   | <b>섞인 것을 떼어 낸다</b> |
| ③ 혼란변수·역인과 | 남은 함정을 찾는다      | 어디까지 말할 수 있는지      |

②까지 가면 상관보다 훨씬 나아진다. 그래도 **인과는 증명되지 않는다** — ③이 그 이유를 다룬다.

# 흩어진 점을 직선 하나로


모든 점에서 직선까지의 **세로 거리를 제공해 더한 값**이 가장 작아지는 직선을 고른다. 최소제곱법이다.

$$\hat{y} = b_0 + b_1x$$

$b_1$  이 **기울기**다. " $x$ 가 1 늘 때  $y$ 가 평균적으로 얼마 변하는가"를 뜻한다.

$R^2$  은 **이 직선이 설명하는 몫**이다. 0.32 면  $y$ 가 흩어진 정도의 32%만 설명한다는 뜻이다.

나머지 68%는 모형 밖에 있다 — 그것을 잊으면 과신하게 된다.




# 상관 대신 회귀를 쓰는 이유

|         | 상관계수                | 회귀                          |
|---------|---------------------|-----------------------------|
| 말해 주는 것 | 함께 움직이는 <b>정도</b>   | 얼마나 <b>변하는지</b>             |
| 단위      | 없다 (-1~+1)          | 있다 (m <sup>2</sup> 당 만원 등)  |
| 방향      | 대칭이다 — x와 y를 바꿔도 같다 | <b>비대칭이다 — 무엇을 설명할지 정한다</b> |
| 변수 개수   | 둘                   | <b>여럿을 한꺼번에</b>             |

마지막 줄이 오늘의 핵심이다. **변수를 여럿 넣을 수 있다는 것**이 "다른 조건을 같게 맞추는" 길을 연다.



# “다른 조건이 같다면”을 계산으로 만든다



신도시일수록 건물이 새것이고, 새것일수록 비싸다. 그래서 **신도시의 효과에 나이의 효과가 섞여 들어온다.**

# 통제란 식에 함께 넣는 것이다

---

$$\hat{y} = b_0 + b_1(\text{신도시}) + b_2(\text{나이})$$

→  $b_1$  은 이제 "나이가 같은 집끼리 비교했을 때"의 신도시 효과다.

나이가 설명하는 몫을  $b_2$  가 가져가고 남은 것이  $b_1$  이다

# 7주차의 질문에 답한다

세종 아파트 m²당 가격 (만원) · 15,486건 · 신도시(동) 12,779 · 편입(리) 2,707

| 모형        | 신도시  | 나이   | 면적    | R²    |
|-----------|------|------|-------|-------|
| ① 신도시만    | +310 | —    | —     | 0.315 |
| ② + 건물 나이 | +263 | -5.5 | —     | 0.321 |
| ③ + 전용면적  | +277 | -4.8 | +1.03 | 0.325 |


나이를 통제하니 신도시 계수가 **310 → 263** 으로 **15% 줄었다**.

차이의 일부는 건물이 새것이어서였다. 그러나 대부분은 남는다 — 나이를 같게 맞춰도 신도시가 m²당 263만원 비싸다.

건물나이 중앙값: 신도시 4년 · 편입 12년. 혼란변수가 실재했다는 증거다.



## 통제 전후를 그림으로



줄어든 47만원이 **건물 나이가 설명하던 몫**이다. 남은 263만원은 아직 설명되지 않았다.

# 주의 — 통제했다고 끝난 것이 아니다

| 아직 남은 것                 | 왜 문제인가                                                                                                                                                   |
|-------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 놓지 않은 변수<br>시점을 통제하지 않음 | 역과의 거리, 학군, 단지 규모, 층·향. <b><math>R^2</math>이 0.32 라는 것이 그 증거다</b> — 3분의 2는 모형 밖에 있다<br>2017~2020 에 가격이 계속 올랐고 신도시 거래가 뒤로 갈수록 많다. 그 상승분이 신도시 계수에<br>섞여 있다 |
| 묵음으로 들어온 것              | 신도시는 새것일 뿐 아니라 계획도시다. 도로·학교·상가가 함께 들어왔다 — <b>"신도시 계수" 는 그 묵<br/>음 전체다</b>                                                                                |
| 역인과                     | 비싸질 곳에 좋은 시설이 들어오기도 한다. 어느 쪽이 먼저인지 자료만으로는 모른다                                                                                                            |

말할 수 있는 것은 "건물 나이만으로는 설명되지 않는다" 까지다. **263만원을 "위치의 값" 이라고 부르면 안 된다.**


# 나누면 방향이 뒤집히기도 한다

전체로 보면 **오른쪽 위로** 가는데, 집단마다 나눠 보면 **전부 오른쪽 아래로** 가는 일이 있다.

집단이 서로 다른 위치에 놓여 있어서 집단 간 차이가 집단 내 관계를 덮어 버린 것이다.

이것을 **심슨의 역설**이라 한다. 통제해야 할 변수를 빠뜨리면 결론의 부호 까지 바뀐다.

그래서 "나눠 보면 어떨까" 를 항상 묻는다.



# 어디까지 말할 수 있나

---

회귀는 "다른 조건이 같다면" 을 계산해 준다.  
다만 식에 넣은 조건에 한해서다

→ 넣지 않은 조건은 계수 안에 그대로 남아 있다.  
그래서 결론은 언제나 "...를 통제했을 때" 라는 단서와 함께 쓴다

---

# 실습

아산 의료 취약지역 ② 원인 분석 — 약 1시간 30분



## 실습 ① — 무엇을 통제할지 정한다 25분

---

지난주에 "10만명당 병원이 적다" 고 찾은 지역들. 왜 그럴까

- 1 원인 후보를 **먼저 종이에 적는다** — 인구밀도, 도시화 정도, 노령인구 비율, 온양 시가지와의 거리
- 2 후보마다 **"이것이 병원 수와 지역 특성 둘 다에 영향을 주는가"** 를 따진다. 둘 다면 혼란변수다
- 3 데이터로 만들 수 있는 것과 없는 것을 나눈다

**이 순서를 지킨다.** 데이터를 먼저 보고 변수를 고르면 눈에 띄는 것만 넣게 된다.

## 실습 ② — 통제 전후를 비교한다 40분

### 프롬프트

"아산 12개 지역 자료로 회귀를 해 줘. 종속변수는 인구 10만명당 병원 수야.

모형을 단계적으로 보여 줘 — ① 도시화 여부만 ② + 인구밀도 ③ + 노령인구 비율. 각 단계에서 계수가 어떻게 변하는지 표로 정리해 줘.

표본이 12개뿐인데 이 회귀를 믿어도 되는지도 같이 말해 줘."

마지막 문장이 중요하다.  **$n = 12$  는 회귀를 돌리기에 매우 작다** — 변수를 셋만 넣어도 자유도가 거의 남지 않는다.

읍면동보다 잘게 나눈 격자 자료를 쓰면 표본이 늘어난다. 그 방법도 물어본다.

## 실습 ③ — 단서와 함께 쓴다 25분

---

### 네 문장으로 쓴다

- 1 통제 전 — 무엇이 얼마나 차이 났나
- 2 통제 후 — 그 차이가 얼마나 줄었나. 숫자로
- 3 남은 것의 해석 — 줄지 않은 부분은 무엇으로 볼 수 있나
- 4 단서 — 무엇을 통제하지 못했나. 표본은 충분했나

제출: 모형 비교표 + 네 문장 + 로직 문서

가정 과제 (10주차) — 도로교통공단 TAAS 공개 데이터로 어린이 교통사고 위험지역을 집에서 분석해 제출한다. 절차는 별도로 배부한다.



# 자료 출처

---

- 8·9쪽 회귀 결과 — COMPAS 「주택 시장 특성분석」(세종시, SBJ\_2102\_001) 공개 데이터  
2017~2020 계약분 · 전용 60m<sup>2</sup> 초과 · 취소 제외 15,486건  
신도시/편입 구분은 지역명이 **동** 으로 끝나는지 **리** 로 끝나는지로 나눴다
- 산출 방법 — `analysis/10-세종회귀.py` (외부 라이브러리 없이 정규방정식을 직접 푼다), 판단 근거는 `analysis/10-세종회귀-로직.md`
- 4·6·11쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

# Q & A

---

권규상 Kyusang Kwon  
kyusang.kwon@chungbuk.ac.kr