



2026-2학기 데이터사이언스

10강. 진단적 분석 II

회귀와 혼란변수

2026. 11. 9.

비싼 것은 위치 때문인가, 새것이기 때문인가?

- 7주차에 세종 동별 m²당 가격이 5.33배 차이 난다고 했다
- 비싼 동은 새 아파트가 많은 동이기도 하다
- 둘이 섞여 있는데 어떻게 떼어 내는가

오늘 배울 세 가지

방법	하는 일	얻는 것
① 단순회귀	관계를 직선 하나로 요약한다	"하나 늘면 얼마 변하나"
② 다중회귀와 통제	다른 조건을 같게 맞춘다	섞인 것을 떼어 낸다
③ 혼란변수·역인과	남은 함정을 찾는다	어디까지 말할 수 있는지

②까지 가면 상관보다 훨씬 나아진다. 그래도 **인과는 증명되지 않는다** — ③이 그 이유를 다룬다.

흩어진 점을 직선 하나로


모든 점에서 직선까지의 **세로 거리를 제공해 더한 값**이 가장 작아지는 직선을 고른다. 최소제곱법이다.

$$\hat{y} = b_0 + b_1x$$

b_1 이 **기울기**다. " x 가 1 늘 때 y 가 평균적으로 얼마 변하는가"를 뜻한다.

R^2 은 **이 직선이 설명하는 몫**이다. 0.32 면 y 가 흩어진 정도의 32%만 설명한다는 뜻이다.

나머지 68%는 모형 밖에 있다 — 그것을 잊으면 과신하게 된다.




상관 대신 회귀를 쓰는 이유

	상관계수	회귀
말해 주는 것	함께 움직이는 정도	얼마나 변하는지
단위	없다 (-1~+1)	있다 (m ² 당 만원 등)
방향	대칭이다 — x와 y를 바꿔도 같다	비대칭이다 — 무엇을 설명할지 정한다
변수 개수	둘	여럿을 한꺼번에

마지막 줄이 오늘의 핵심이다. **변수를 여럿 넣을 수 있다는 것**이 "다른 조건을 같게 맞추는" 길을 연다.

“다른 조건이 같다면” 을 계산으로 만든다



신도시일수록 건물이 새것이고, 새것일수록 비싸다. 그래서 **신도시의 효과에 나이의 효과가 섞여 들어온다.**

통제란 식에 함께 넣는 것이다

$$\hat{y} = b_0 + b_1(\text{신도시}) + b_2(\text{나이})$$

→ b_1 은 이제 "나이가 같은 집끼리 비교했을 때"의 신도시 효과다.

나이가 설명하는 몫을 b_2 가 가져가고 남은 것이 b_1 이다

7주차의 질문에 답한다

세종 아파트 m²당 가격 (만원) · 15,486건 · 신도시(동) 12,779 · 편입(리) 2,707


모형	신도시	나이	면적	R ²
① 신도시만	+310	—	—	0.315
② + 건물 나이	+263	-5.5	—	0.321
③ + 전용면적	+277	-4.8	+1.03	0.325

나이를 통제하니 신도시 계수가 **310 → 263** 으로 **15% 줄었다**.

차이의 일부는 건물이 새것이어서였다. 그러나 대부분은 남는다 — 나이를 같게 맞춰도 신도시가 m²당 263만원 비싸다.

건물나이 중앙값: 신도시 4년 · 편입 12년. 혼란변수가 실재했다는 증거다.

통제 전후를 그림으로



줄어든 47만원이 **건물 나이가 설명하던 몫**이다. 남은 263만원은 아직 설명되지 않았다.

주의 — 통제했다고 끝난 것이 아니다

아직 남은 것	왜 문제인가
놓지 않은 변수 시점을 통제하지 않음	역과의 거리, 학군, 단지 규모, 층·향. R^2이 0.32 라는 것이 그 증거다 — 3분의 2는 모형 밖에 있다 2017~2020 에 가격이 계속 올랐고 신도시 거래가 뒤로 갈수록 많다. 그 상승분이 신도시 계수에 섞여 있다
묵음으로 들어온 것	신도시는 새것일 뿐 아니라 계획도시다. 도로·학교·상가가 함께 들어왔다 — "신도시 계수" 는 그 묵 음 전체다
역인과	비싸질 곳에 좋은 시설이 들어오기도 한다. 어느 쪽이 먼저인지 자료만으로는 모른다

말할 수 있는 것은 "건물 나이만으로는 설명되지 않는다" 까지다. **263만원을 "위치의 값" 이라고 부르면 안 된다.**


나누면 방향이 뒤집히기도 한다

전체로 보면 **오른쪽 위로** 가는데, 집단마다 나눠 보면 **전부 오른쪽 아래로** 가는 일이 있다.

집단이 서로 다른 위치에 놓여 있어서 집단 간 차이가 집단 내 관계를 덮어 버린 것이다.

이것을 **심슨의 역설**이라 한다. 통제해야 할 변수를 빠뜨리면 결론의 부호 까지 바뀐다.

그래서 "나눠 보면 어떨까" 를 항상 묻는다.



어디까지 말할 수 있나

회귀는 "다른 조건이 같다면" 을 계산해 준다.
다만 식에 넣은 조건에 한해서다

→ 넣지 않은 조건은 계수 안에 그대로 남아 있다.
그래서 결론은 언제나 "...를 통제했을 때" 라는 단서와 함께 쓴다

실습

아산 의료 취약지역 ② 원인 분석 — 약 1시간 30분

실습 ① — 무엇을 통제할지 정한다 25분

지난주에 "10만명당 병원이 적다" 고 찾은 지역들. 왜 그럴까

- 1 원인 후보를 **먼저 종이에 적는다** — 인구밀도, 도시화 정도, 노령인구 비율, 온양 시가지와의 거리
- 2 후보마다 **"이것이 병원 수와 지역 특성 둘 다에 영향을 주는가"** 를 따진다. 둘 다면 혼란변수다
- 3 데이터로 만들 수 있는 것과 없는 것을 나눈다

이 순서를 지킨다. 데이터를 먼저 보고 변수를 고르면 눈에 띄는 것만 넣게 된다.

실습 ② — 통제 전후를 비교한다 40분

프롬프트

"아산 12개 지역 자료로 회귀를 해 줘. 종속변수는 인구 10만명당 병원 수야.

모형을 단계적으로 보여 줘 — ① 도시화 여부만 ② + 인구밀도 ③ + 노령인구 비율. 각 단계에서 계수가 어떻게 변하는지 표로 정리해 줘.

표본이 12개뿐인데 이 회귀를 믿어도 되는지도 같이 말해 줘."

마지막 문장이 중요하다. **$n = 12$ 는 회귀를 돌리기에 매우 작다** — 변수를 셋만 넣어도 자유도가 거의 남지 않는다.

읍면동보다 잘게 나눈 격자 자료를 쓰면 표본이 늘어난다. 그 방법도 물어본다.

실습 ③ — 단서와 함께 쓴다 25분

네 문장으로 쓴다

- 1 통제 전 — 무엇이 얼마나 차이 났나
- 2 통제 후 — 그 차이가 얼마나 줄었나. 숫자로
- 3 남은 것의 해석 — 줄지 않은 부분은 무엇으로 볼 수 있나
- 4 단서 — 무엇을 통제하지 못했나. 표본은 충분했나

제출: 모형 비교표 + 네 문장 + 로직 문서

가정 과제 (10주차) — 도로교통공단 TAAS 공개 데이터로 어린이 교통사고 위험지역을 집에서 분석해 제출한다. 절차는 별도로 배부한다.

자료 출처

- 8·9쪽 회귀 결과 — COMPAS 「주택 시장 특성분석」(세종시, SBJ_2102_001) 공개 데이터
2017~2020 계약분 · 전용 60m² 초과 · 취소 제외 15,486건
신도시/편입 구분은 지역명이 **동** 으로 끝나는지 **리** 로 끝나는지로 나눴다
- 산출 방법 — `analysis/10-진단적분석2/10-세종회귀.py` (외부 라이브러리 없이 정규방정식을 직접 푼다), 판단 근거는 `analysis/10-진단적분석2/10-세종회귀-로직.md`
- 4·6·11쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr