2026-2학기 데이터사이언스

10강. 진단적 분석 II
회귀와 혼란변수

2026. 11. 9.

비싼 것은 위치 때문인가, 새것이기 때문인가?

- 6주차에 세종 동별 m^2당 가격이 5.33배 차이 난다고 했다
- 비싼 동은 새 아파트가 많은 동이기도 하다
- 둘이 섞여 있는데 어떻게 떼어 내는가

오늘 배울 세 가지

방법	하는 일	얻는 것
① 단순회귀	관계를 직선 하나로 요약한다	"하나 늘면 얼마 변하나"
② 다중회귀와 통제	다른 조건을 같게 맞춘다	**섞인 것을 떼어 낸다**
③ 혼란변수·역인과	남은 함정을 찾는다	어디까지 말할 수 있는지

②까지 가면 상관보다 훨씬 나아진다. 그래도 **인과는 증명되지 않는다** — ③이 그 이유를 다룬다.

오늘의 실습자료와 자료 정리

세종시 아파트 매매 실거래가

- **파일:** `10강–세종아파트회귀.zip`
- **기간:** 2017년 1월 ~ 2020년 12월 계약분
- **규모:** 23,597건
- **열:** 계약년월 · 시군구 · 단지명 · 전용면적(m²) · 거래금액(만원) · 건축년도 · 해제사유발생일 등 11개
- **함께 든 것:** 열 설명(README) · 방법별 프롬프트 · 로직 문서 본보기

→ 6강과 같은 자료. 오늘은 **건물 나이와 신도시 여부**를 더함

자료: COMPAS 「주택 시장 특성분석」(세종, SBJ_2102_001)

자료 정리 프롬프트

세종시_아파트매매_실거래가_2017-2020.csv 를 읽고 행 수, 열 이름, 열마다 빈 값의 개수를 보여 줘.

거래금액(만원)은 "8,600" 같은 문자열이야. 숫자로 바꿔 줘.

해제사유발생일이 있는 거래(취소)와 전용면적 60m² 이하는 빼 줘. 기준마다 몇 건이 빠졌는지 따로 알려 줘.

m²당 가격, 건물 나이(계약연도 − 건축년도), 신도시 여부(시군구가 「동」으로 끝나면 1, 「리」로 끝나면 0) 열을 만들어 줘.

무엇을 왜 뺐는지 로직 문서로 정리해 줘.

확인할 값: 23,597건 → 취소 537건 제외 23,060건 → 60m² 이하 7,574건 제외 **15,486건** (신도시 12,779 · 편입 2,707)

단순회귀: 목적과 정의

한 변수가 변할 때 다른 변수가 평균적으로 얼마나 변하는지를 직선 하나로 나타낸 것

- **종속변수(y):** 설명하려는 변수. 오늘은 m^2당 가격
- **독립변수(x):** y 를 설명하는 데 쓰는 변수
- **회귀계수(기울기, b_1):** x 가 1 늘 때 y 의 평균 변화량
- **절편(b_0):** x 가 0 일 때 직선이 예측하는 y 값
- **잔차:** 실제 y 값에서 직선이 예측한 값을 뺀 것
- **최소제곱법:** 잔차를 제곱해 더한 값이 가장 작아지게 계수를 정하는 방법
- **결정계수(R^2):** y 의 변동 가운데 직선이 설명하는 비율. 0 에서 1 사이

필요한 자료: 종속변수 1개 + 독립변수 1개

흩어진 점을 직선 하나로

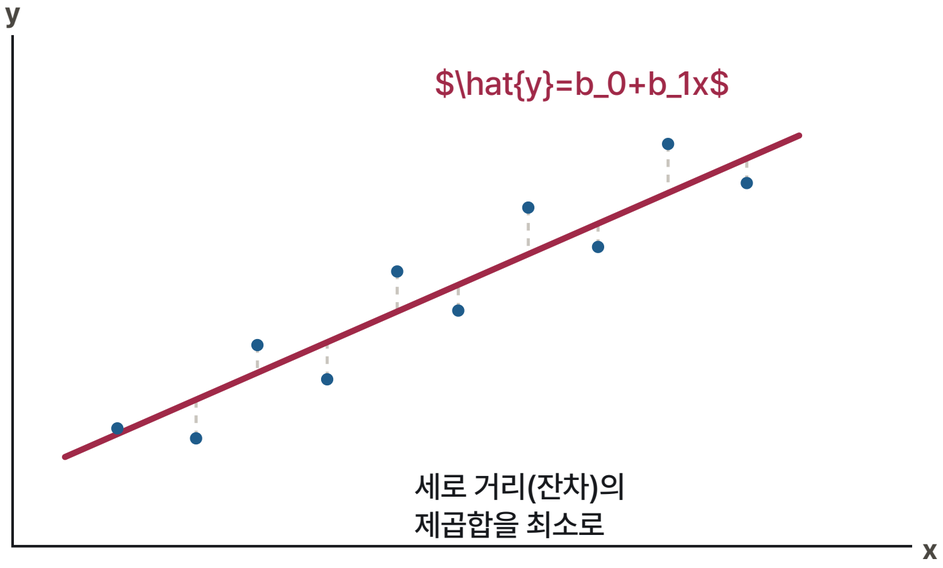
모든 점에서 직선까지의 **세로 거리를 제곱해 더한 값**이 가장 작아지는 직선을 고른다. 최소제곱법이다.

$$\hat{y} = b_0 + b_1 x$$

b_1 이 **기울기**다. "x 가 1 늘 때 y 가 평균적으로 얼마 변하는가" 를 뜻한다.

R^2 은 **이 직선이 설명하는 몫**이다. 0.32 면 y 가 흩어진 정도의 32%만 설명한다는 뜻이다.

나머지 68%는 모형 밖에 있다 — 그것을 잊으면 과신하게 된다.



상관 대신 회귀를 쓰는 이유

	상관계수	회귀
말해 주는 것	함께 움직이는 **정도**	얼마나 **변하는지**
단위	없다 (−1~+1)	있다 (m^2당 만원 등)
방향	대칭이다: x와 y를 바꿔도 같다	**비대칭이다: 무엇을 설명할지 정한다**
변수 개수	둘	**여럿을 한꺼번에**

마지막 줄이 오늘의 핵심이다. **변수를 여럿 넣을 수 있다는 것**이 "다른 조건을 같게 맞추는" 길을 연다.

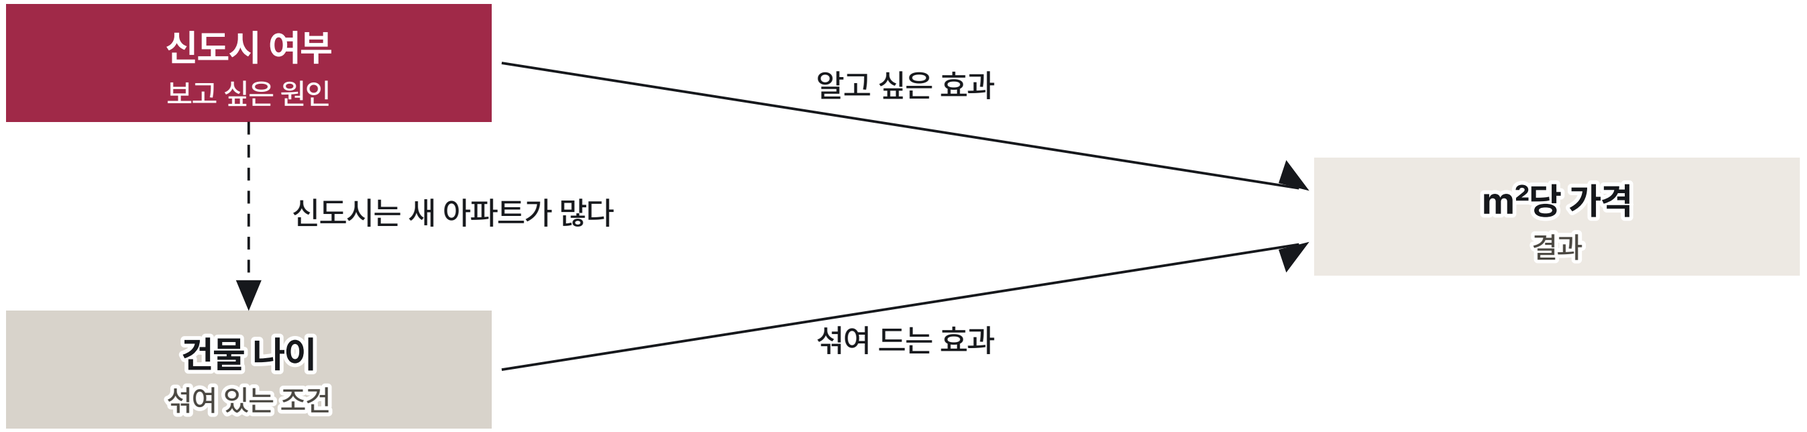
다중회귀와 통제: 목적과 정의

독립변수 여럿을 한 식에 넣어 다른 변수를 같게 맞춘 채 한 변수의 효과를 구하는 것

- **다중회귀:** 독립변수가 둘 이상인 회귀
- **통제변수:** 관심 변수의 효과를 보려고 식에 함께 넣는 변수
- **편회귀계수:** 다른 독립변수를 고정했을 때 그 변수가 1 늘면 y 가 평균적으로 변하는 양
- **더미변수:** 범주를 0 과 1 로 바꾼 변수. 오늘은 신도시 = 1, 편입 = 0
- **더미변수의 계수:** 다른 변수가 같을 때 1 인 집단과 0 인 집단의 평균 차이

필요한 자료: 종속변수 1개 + 독립변수 여럿 (범주는 더미로 바꿈)

"다른 조건이 같다면"을 계산으로 만든다



신도시일수록 건물이 새것이고, 새것일수록 비싸다. 그래서 **신도시의 효과에 나이의 효과가 섞여 들어온다.**

통제란 식에 함께 넣는 것이다

$$\hat{y} = b_0 + b_1(\text{신도시}) + b_2(\text{나이})$$

→ b_1 은 이제 "나이가 같은 집끼리 비교했을 때"의 신도시 효과다.
나이가 설명하는 몫을 b_2 가 가져가고 남은 것이 b_1 이다

6주차의 질문에 답한다

세종 아파트 m²당 가격 (만원) · 15,486건 · 신도시(동) 12,779 · 편입(리) 2,707

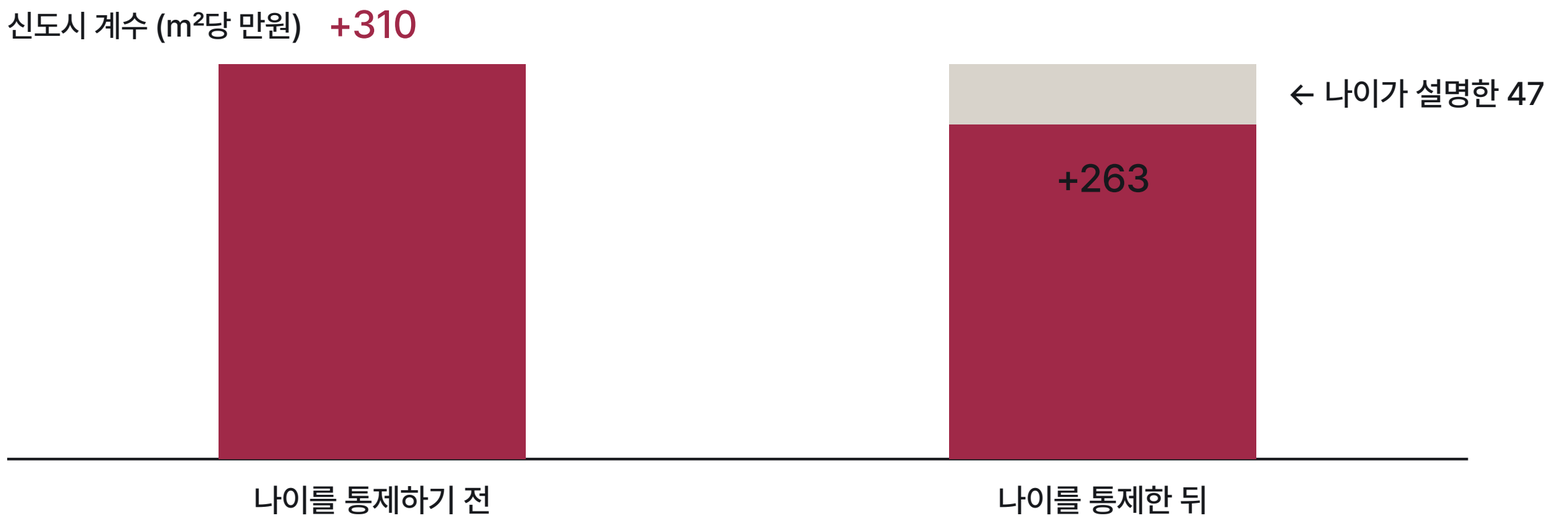
모형	신도시	나이	면적	R^2
① 신도시만	**+310**	—	—	0.315
② + 건물 나이	**+263**	−5.5	—	0.321
③ + 전용면적	+277	−4.8	+1.03	0.325

나이를 통제하니 신도시 계수가 **310 → 263** 으로 **15% 줄었다.**

차이의 일부는 **건물이 새것이어서**였다. 그러나 **대부분은 남는다** — 나이를 같게 맞춰도 신도시가 m²당 263만원 비싸다.

건물나이 중앙값: 신도시 4년 · 편입 12년. 혼란변수가 실재했다는 증거다.

통제 전후를 그림으로



줄어든 47만원이 **건물 나이가 설명하던 몫**이다. 남은 263만원은 아직 설명되지 않았다.

혼란변수·역인과: 목적과 정의

회귀 계수를 원인의 효과로 읽지 못하게 하는 것을 찾아 결론이 어디까지인지 정하는 일

- **혼란변수:** 원인 후보와 결과 양쪽에 영향을 주는 변수
- **누락변수 편의:** 혼란변수를 식에 넣지 않아 그 효과가 남은 계수에 섞이는 것
- **역인과:** 결과로 본 변수가 실제로는 원인 쪽에 영향을 주는 경우
- **심슨의 역설:** 전체에서 본 관계의 방향이 집단별로 나누면 뒤집히는 현상

필요한 자료: 회귀 결과 + 넣지 않은 변수와 시간 순서에 대한 지식

주의: 통제했다고 끝난 것이 아니다

아직 남은 것	왜 문제인가
넣지 않은 변수	역과의 거리, 학군, 단지 규모, 층·향. **R^2이 0.32 라는 것이 그 증거다** — 3분의 2는 모형 밖에 있다
시점을 통제하지 않음	2017~2020 에 가격이 계속 올랐고 신도시 거래가 뒤로 갈수록 많다. 그 상승분이 신도시 계수에 섞여 있다
묶음으로 들어온 것	신도시는 새것일 뿐 아니라 계획도시다. 도로·학교·상가가 함께 들어왔다 — **"신도시 계수" 는 그 묶음 전체다**
역인과	비싸질 곳에 좋은 시설이 들어오기도 한다. 어느 쪽이 먼저인지 자료만으로는 모른다

말할 수 있는 것은 "건물 나이만으로는 설명되지 않는다" 까지다. **263만원을 "위치의 값" 이라고 부르면 안 된다.**

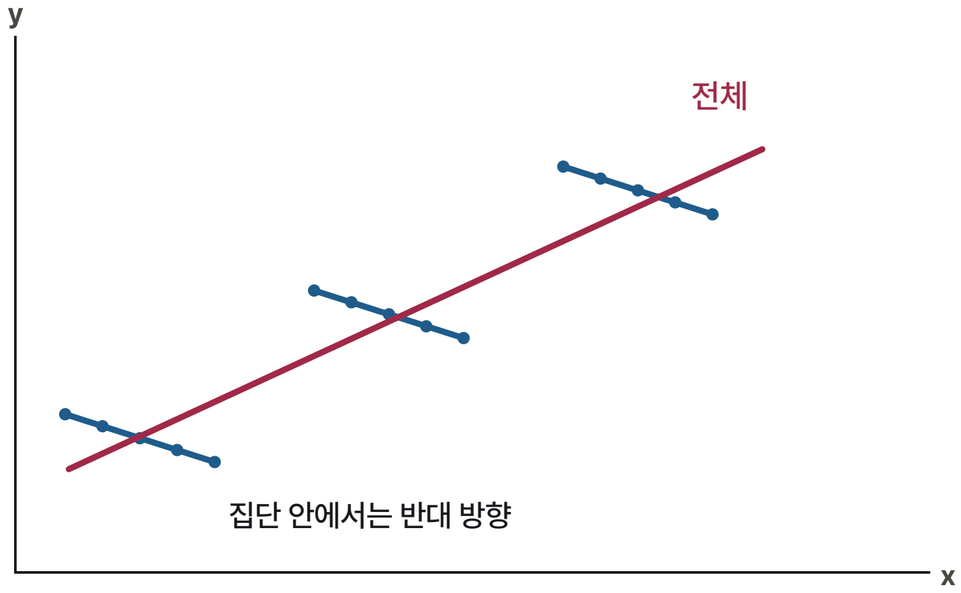
나누면 방향이 뒤집히기도 한다

전체로 보면 **오른쪽 위로** 가는데, 집단마다 나눠 보면 **전부 오른쪽 아래로** 가는 일이 있다.

집단이 서로 다른 위치에 놓여 있어서 **집단 간 차이가 집단 내 관계를 덮어 버린** 것이다.

이것을 **심슨의 역설**이라 한다. 통제해야 할 변수를 빠뜨리면 결론의 **부호까지** 바뀐다.

그래서 "나눠 보면 어떤가" 를 항상 묻는다.



어디까지 말할 수 있나

회귀는 "다른 조건이 같다면" 을 계산해 준다.
다만 식에 넣은 조건에 한해서다

→ 넣지 않은 조건은 계수 안에 그대로 남아 있다.

그래서 결론은 언제나 "...를 통제했을 때" 라는 단서와 함께 쓴다

과제: 아산 원인 분석과 어린이 교통사고 위험지역

1. 아산 의료 취약지역 ② 원인 분석

9주차에 「10만명당 병원이 적다」고 찾은 지역. 왜 그런가

1. 원인 후보를 먼저 적음: 인구밀도, 도시화 정도, 노령인구 비율, 온양 시가지와의 거리
2. 혼란변수를 가림: 병원 수와 지역 특성 둘 다에 영향을 주는가
3. 단계적으로 회귀함: ① 도시화 여부 ② + 인구밀도 ③ + 노령인구 비율
   단계마다 계수가 어떻게 변하는지 표로 정리
4. 네 문장으로 씀: 통제 전 · 통제 후 · 남은 것의 해석 · 단서

n = 12 는 회귀를 돌리기에 매우 작음. 이 회귀를 믿어도 되는지도 AI 에게 묻고 판단을 적음

2. 어린이 교통사고 위험지역

도로교통공단 TAAS 공개 데이터로
어린이 교통사고 위험지역을 분석함

절차는 별도로 배부함

본보기: 배포 자료의 「분석 프롬프트.md」와 「로직 문서 본보기.md」

제출물

두 과제를 각각 별도 파일로 낸다

- `원인분석.md` : 1번의 모형 비교표 + 네 문장 + 로직 문서
- `교통사고분석.md` : 2번의 어린이 교통사고 위험지역 분석 결과

제출기한: 11월 14일(토) 23시 59분 59초

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

2주차와 같은 주소다. 주차 선택에서 **10주차**를 고르고, 학번 열 자리와 이름을 띄어쓰기 없이 적는다.

자료 출처

- **11·12쪽 회귀 결과:** COMPAS 「주택 시장 특성분석」(세종시, SBJ_2102_001) 공개 데이터
  2017~2020 계약분 · 전용 60m² 초과 · 취소 제외 15,486건
  신도시/편입 구분은 지역명이 `동` 으로 끝나는지 `리` 로 끝나는지로 나눴다
- **산출 방법:** `analysis/10-진단적분석2/10-세종회귀.py` (외부 라이브러리 없이 정규방정식을 직접 푼다), 판단 근거는 `analysis/10-진단적분석2/10-세종회귀-로직.md`
- 6·9·15쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr