



2026-2학기 데이터사이언스

11강. 예측적 분석 I

추세와 회귀 예측

2026. 11. 16.

화성시 인구는 계속 늘어날까?

- 9년 동안 56만에서 98만으로 늘었다
- 학교를 몇 개 더 지어야 하는가는 앞으로에 달렸다
- 그런데 "앞으로" 는 자료에 없다

예측적 분석 predictive

과거에서 찾은 규칙을 아직 없는 기간에 밀어 넣는 일

→ 진단과 결정적으로 다르다. 진단은 맞는지 확인할 수 있지만
예측은 그 시점이 와야 확인된다 — 그래서 미리 검증하는 법이 필요하다

오늘 배울 세 가지

방법	쓰는 것	한계
① 추세 외삽	시간 하나만	왜 그런지 모른 채 늘린다
② 홀드아웃 검증	과거의 일부를 숨긴다	예측을 미리 채점하는 유일한 길
③ 설명변수 예측	원인이 될 만한 변수	그 변수도 예측해야 한다

②가 오늘의 중심이다. 검증 없는 예측은 **그럴듯한 이야기**일 뿐이다.

가장 단순한 예측

지금까지의 흐름이 **그대로 이어진다고** 가정하고 선을 연장한다.


선형 — 매달 같은 양만큼 는다

$$\hat{y}_t = a + bt$$

지수 — 매달 같은 비율로 는다

$$\hat{y}_t = a e^{bt}$$

둘의 차이가 멀리 갈수록 벌어진다. 어느 쪽을 고르느냐가 곧 가정이다.



언제 쓸 만하고 언제 위험한가

쓸 만하다	위험하다
가까운 미래 (몇 달~1~2년)	먼 미래 — 오차가 눈덩이처럼 커진다
변화가 완만하고 꾸준할 때	정책·개발 같은 사건이 예정되어 있을 때
대략의 규모만 알면 될 때	결정이 숫자에 민감할 때
다른 방법의 기준선 이 필요할 때	상한이 있는 값 (수용 한계, 포화 상태)

오른쪽 두 번째가 도시 데이터에서 가장 자주 걸린다 — **신도시 입주, 산업단지 준공, 노선 개통**은 추세에 없다.

과거의 일부를 숨겨 미리 채점한다




얼마나 틀렸는지 재는 자 — MAPE

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right|$$

→ 틀린 정도를 **실제값 대비 비율**로 잰다. 단위가 없어 서로 다른 자료끼리도 견줄 수 있다

"MAPE 4%" 는 평균적으로 4%쯤 빗나간다는 뜻이다

화성 인구 — 선형 추세를 채점한다



학습 100개월(2014.01~2022.04)로 만든 선형 추세를 검증 12개월에 적용 — **MAPE 4.12%**

주의 – 검증을 망치는 방법들

이렇게 하면	왜 안 되나
무작위로 떼어 낸다	시계열에서는 앞뒤가 섞인다 . 미래를 보고 과거를 맞추는 셈이라 성적이 부풀려진다 — 반드시 뒤 쪽 을 떼는다
검증 성적을 보고 모형을 고친다	고르고 고치다 보면 검증 구간에 맞춰진다. 그 순간 검증이 아니게 된다
검증 구간이 너무 짧다	운으로 맞을 수 있다. 예측하려는 기간만큼은 떼어 둔다
학습에 미래 정보가 섞여 든다	"연간 평균" 같은 값을 미리 계산해 넣으면 그 안에 검증 구간이 들어 있다

네 가지 모두 결과를 **실제보다 좋게** 만든다. 틀리는 방향이 한쪽이라 더 위험하다.


시간 말고 원인을 넣는다

추세 외삽은 **"왜"를 모른 채** 선을 늘린다. 설명변수를 넣으면 이유가 생긴다.

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots$$

인구라면 **전입·전출·출생·사망**과 **주택 공급량**이 후보다.

인구 예측의 표준 방법인 **코호트 요인법**도 같은 생각이다 — 연령별로 나눠 출생·사망·이동을 각각 적용해 한 해씩 굴린다.



주의 — 설명변수도 미래에는 없다

**"주택 공급량으로 인구를 예측한다" 고 하면
내년 주택 공급량은 어떻게 아는가?**

→ 설명변수를 쓰려면 그것도 예측하거나, 이미 확정된 것이어야 한다.
이미 승인된 인허가 물량처럼 확정된 값이 예측에 가장 쓸모 있다

실습

화성시 인구 기초 예측 — 약 1시간 30분

실습 ① — 데이터와 검증 설계 25분

- 1 COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」(화성시) 를 받는다. **이 과제는 자료가 전부 공개고 46MB 로 작다**
- 2 엑셀 「데이터」 시트에서 월별 총인구를 뽑는다 (112개월)
- 3 모형을 만들기 전에 검증 설계를 먼저 정한다 — 몇 개월을 뺄 것인가, 왜 그만큼인가

프롬프트

"이 엑셀에서 월별 총인구를 뽑아 줘. 마지막 12개월은 검증용으로 떼어 두고, 학습에는 절대 쓰지 마. 떼기 전에 전체 기간과 관측 개수를 먼저 알려 줘."

실습 ② — 추세를 그리고 채점한다 35분

- 1 학습 구간으로 **선형**과 **지수** 추세를 각각 만든다
- 2 검증 12개월의 MAPE 를 구한다. 강의에서 본 값(선형 4.12%)과 맞춰 본다
- 3 실제값과 두 추세선을 한 그래프에 그린다. 검증 구간을 색으로 구분한다
- 4 어느 쪽이 왜 더 크게 빗나가는지 그래프를 보고 설명해 본다

4번이 핵심이다. 지수 추세가 더 나쁜 이유는 **화성 인구의 증가세가 둔화되고 있기 때문**이다 — 그것을 그래프에서 직접 읽어 낸다.

실습 ③ — 앞을 내다보고 단서를 단다 30분

- 1 전체 112개월을 다 써서 다시 적합하고 **24개월 앞**을 예측한다
- 2 예측값을 문장으로 옮긴다 — "2025년 4월 화성 인구는 약 ○○만명"
- 3 그 문장 아래에 단서 세 줄을 붙인다 — 어떤 가정 위에 있나, 무엇이 어긋나면 틀리나, 얼마나 빗나갈 수 있나

제출: 추세 그래프 + 예측값 + 단서 세 줄 + 로직 문서

3번의 마지막 줄이 다음 주의 주제다 — "**얼마나 빗나갈 수 있나**"를 숫자로 내는 법.

가정 과제: 자기 문제정의서 데이터에 시계열이 있다면 같은 검증을 해 본다.

자료 출처

- 9쪽 수치 — COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」
(화성시, SBJ_2307_001) 공개 데이터 · `1.화성시_인구데이터.xlsx`
월별 총인구 112개월 (2014-01 ~ 2023-04) · 561,418 → 978,653명
원 출처는 차세대 주민등록 통합행정시스템 등, 엑셀 상단에 명시되어 있다
- 산출 방법 — `analysis/11-화성인구.py` (외부 라이브러리 없이 xlsx 를 직접 읽고 최소제곱을 푼다),
판단 근거는 `analysis/11-화성인구-로직.md`
- 5·7·11쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr