2026-2학기 데이터사이언스

11강. 예측적 분석 I
추세와 회귀 예측

2026. 11. 16.

화성시 인구는 계속 늘어날까?

- 9년 동안 56만에서 98만으로 늘었다
- 학교를 몇 개 더 지어야 하는가는 앞으로에 달렸다
- 그런데 "앞으로" 는 자료에 없다

예측적 분석 predictive

과거에서 찾은 규칙을 아직 없는 기간에 밀어 넣는 일

→ 진단과 결정적으로 다르다. 진단은 맞는지 확인할 수 있지만
예측은 그 시점이 와야 확인된다 — 그래서 미리 검증하는 법이 필요하다

오늘 배울 세 가지

방법	쓰는 것	한계
① 추세 외삽	시간 하나만	왜 그런지 모른 채 늘린다
② 홀드아웃 검증	과거의 일부를 숨긴다	**예측을 미리 채점하는 유일한 길**
③ 설명변수 예측	원인이 될 만한 변수	그 변수도 **예측해야 한다**

②가 오늘의 중심이다. 검증 없는 예측은 **그럴듯한 이야기**일 뿐이다.

오늘의 실습자료와 자료 정리

화성시 월별 인구와 관련 지표

- **파일:** `11강–화성인구.zip`
- **기간:** 2014년 1월 ~ 2023년 4월, 월별
- **규모:** 112개월 × 109열
- **열:** 월별 · 총인구 · 내국인 · 외국인 ·
  총전입 · 총전출 · 출생자수 · 사망자수 ·
  지가·아파트 가격지수 · 금리·물가 등
- **함께 든 것:** 열 설명(README) · 방법별 프롬프트 ·
  로직 문서 본보기

→ 모형을 만들기 전에 **검증용 기간을 먼저 떼어 둠**

자료: COMPAS「AI기법에 의한 인구예측모델 정확도 비교 분석」
(화성시, SBJ_2307_001)

자료 정리 프롬프트

화성시_인구데이터_2014-2023.xlsx 의 「데이터」 시트를 읽어 줘.
위 네 줄은 제목과 출처이고 5행이 열 이름이야.

「월별」 열은 41640 같은 엑셀 날짜 일련번호야. 2014-01 꼴의 연월로 바꿔 줘.

행 수, 열 수, 기간의 처음과 끝, 열마다 빈 값의 개수를 보여 줘.

연월과 총인구 두 열로 월별 시계열을 만들어 줘.
마지막 12개월은 검증용으로 떼어 두고, 학습에는 절대 쓰지 마.

무엇을 왜 정했는지 로직 문서로 정리해 줘.

확인할 값: 112개월 (2014-01 ~ 2023-04) · 총인구 561,418 → 978,653명
학습 **100개월** (2014-01 ~ 2022-04) · 검증 **12개월** (2022-05 ~ 2023-04)

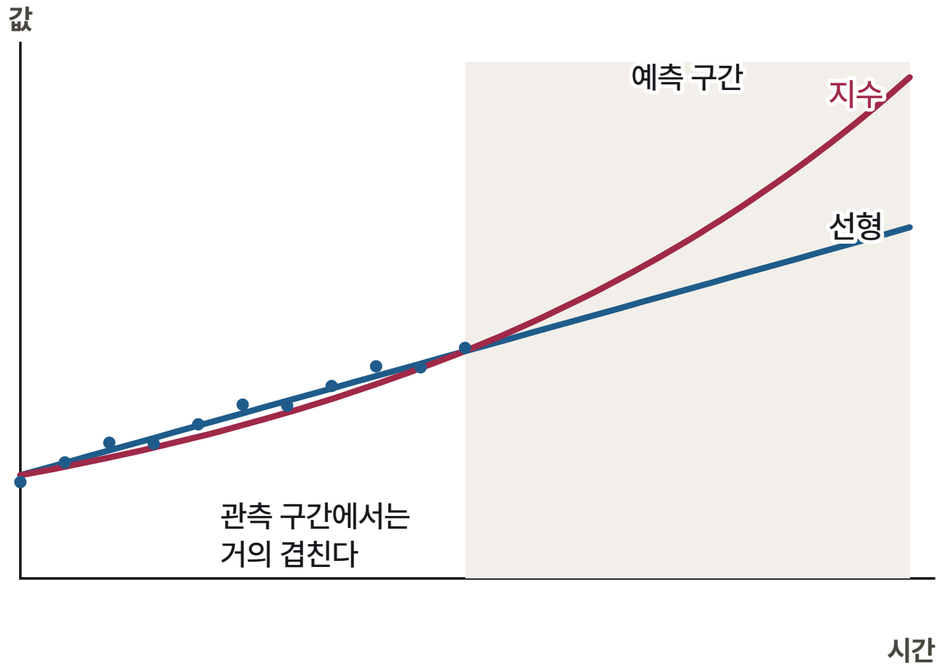
가장 단순한 예측

지금까지의 흐름이 그대로 이어진다고 보고 선을 늘리는 방법

- **추세:** 시간이 지나면서 값이 한 방향으로 움직이는 큰 흐름
- **외삽:** 관측 범위 밖의 값을 범위 안에서 찾은 관계로 추정
- **선형 추세:** 매달 같은 **양**만큼 는다고 보는 꼴 $\hat{y}_t = a + bt$
- **지수 추세:** 매달 같은 **비율**로 는다고 보는 꼴 $\hat{y}_t = a\,e^{bt}$

t 는 시점, a · b 는 자료에서 추정하는 계수

둘의 차이가 멀리 갈수록 벌어진다. **어느 쪽을 고르느냐가 곧 가정이다.**



언제 쓸 만하고 언제 위험한가

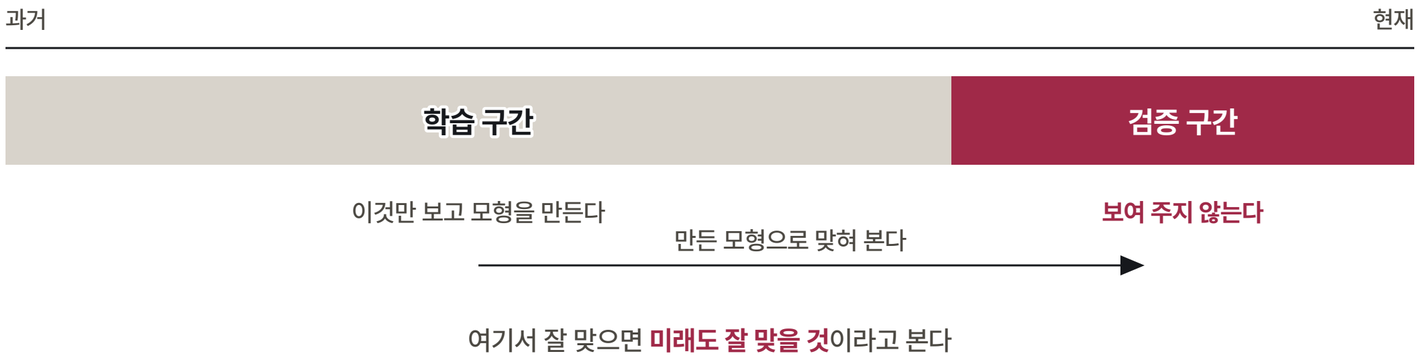
쓸 만하다	위험하다
가까운 미래 (몇 달~1~2년)	먼 미래: 오차가 눈덩이처럼 커진다
변화가 완만하고 꾸준할 때	정책·개발 같은 **사건이 예정되어 있을 때**
대략의 규모만 알면 될 때	결정이 숫자에 민감할 때
다른 방법의 **기준선**이 필요할 때	상한이 있는 값 (수용 한계, 포화 상태)

오른쪽 두 번째가 도시 데이터에서 가장 자주 걸린다 — **신도시 입주, 산업단지 준공, 노선 개통**은 추세에 없다.

과거의 일부를 숨겨 미리 채점한다

자료의 뒤쪽 일부를 떼어 두고, 나머지로 만든 모형이 그 기간을 맞히는지 채점하는 방법

- **학습 구간:** 모형을 만드는 데 쓰는 앞쪽 기간
- **검증 구간:** 모형에게 보여 주지 않고 떼어 둔 뒤쪽 기간. 채점에만 씀
- **학습 오차 · 검증 오차:** 각 구간에서 측정한 예측의 오차. 예측력은 검증 오차로 판단



검증 구간의 답은 이미 알고 있다. **모형에게만 숨기는 것이다.**

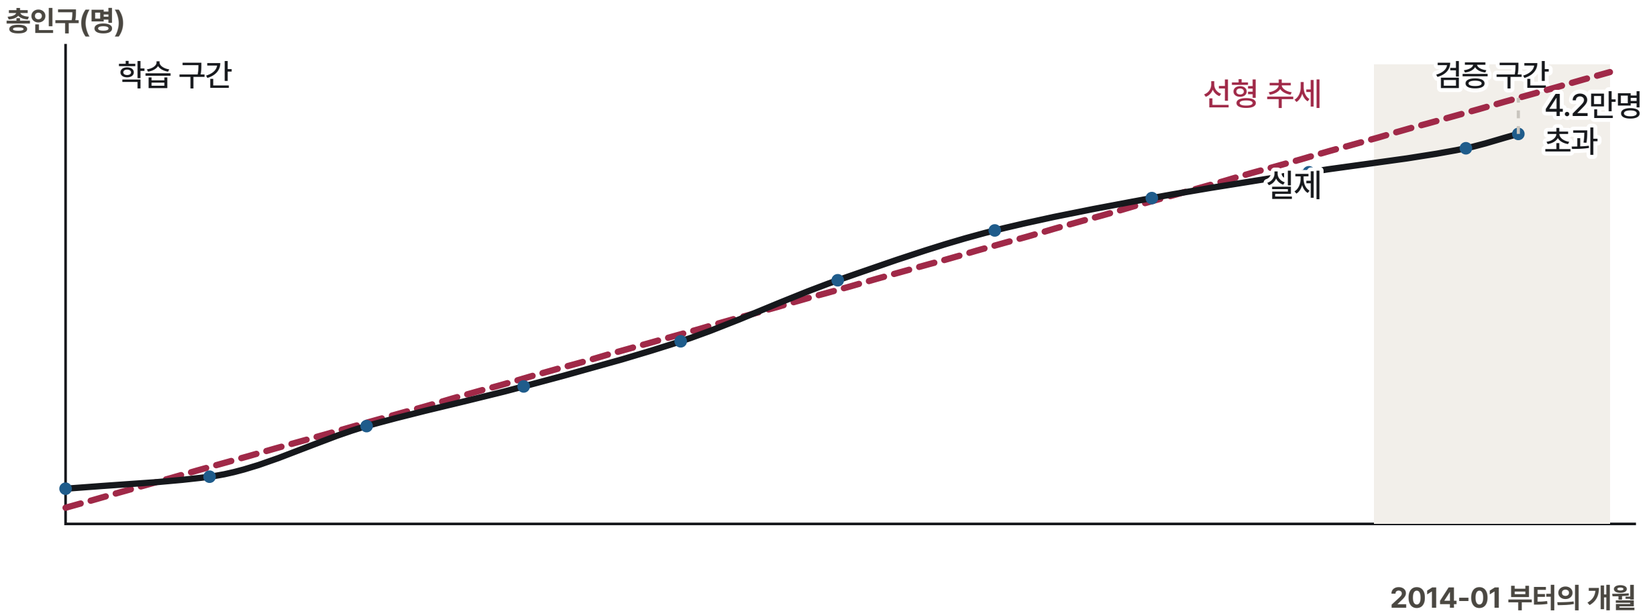
MAPE: 얼마나 틀렸는지 측정하는 지표

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^{n} \left| \frac{\hat{y}_i - y_i}{y_i} \right|$$

- $\hat{y}_i \cdot y_i$: i 번째 시점의 예측값과 실제값
- **n:** 채점하는 시점의 개수. 검증 구간이 12개월이면 12
- **절대백분율오차:** 한 시점에서 빗나간 크기를 실제값으로 나눈 비율 (%)
- **MAPE:** 절대백분율오차의 평균 (평균절대백분율오차)

→ 틀린 정도를 실제값 대비 비율로 측정한다. 단위가 없어 서로 다른 자료끼리도 견줄 수 있다
"MAPE 4%" 는 평균적으로 4%쯤 빗나간다는 뜻이다

화성 인구: 선형 추세를 채점한다



학습 100개월(2014.01~2022.04)로 만든 선형 추세를 검증 12개월에 적용 — **MAPE 4.12%**

주의: 검증을 망치는 방법들

이렇게 하면	왜 안 되나
무작위로 떼어 낸다	시계열에서는 **앞뒤가 섞인다.** 미래를 보고 과거를 맞히는 셈이라 성적이 부풀려진다 — 반드시 **뒤쪽**을 뗀다
검증 성적을 보고 모형을 고친다	고르고 고치다 보면 검증 구간에 맞춰진다. **그 순간 검증이 아니게 된다**
검증 구간이 너무 짧다	운으로 맞을 수 있다. 예측하려는 기간만큼은 떼어 둔다
학습에 미래 정보가 섞여 든다	"연간 평균" 같은 값을 미리 계산해 넣으면 그 안에 검증 구간이 들어 있다

네 가지 모두 결과를 **실제보다 좋게** 만든다. 틀리는 방향이 한쪽이라 더 위험하다.

시간 말고 원인을 넣는다

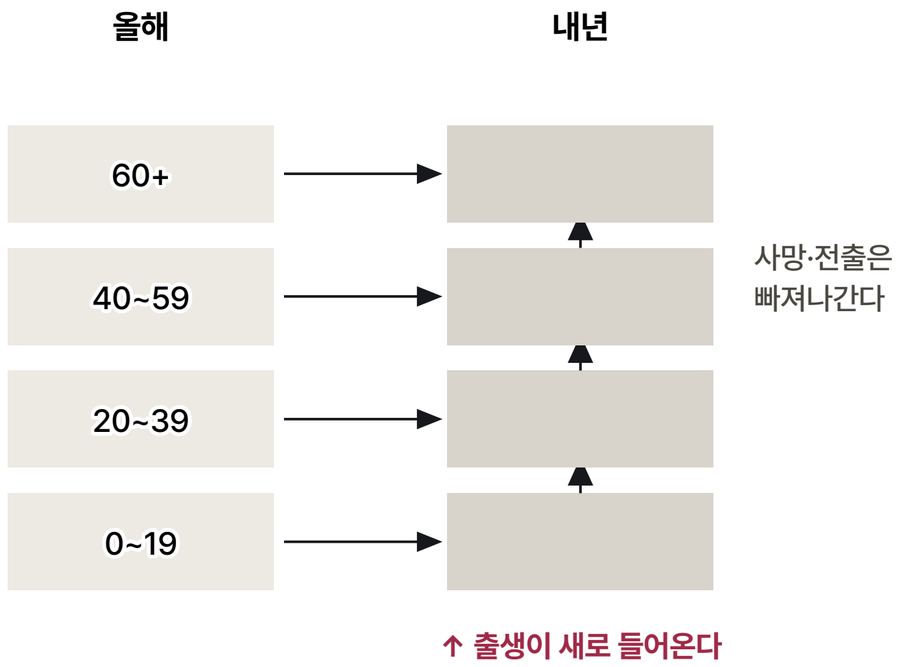
시간 대신 원인이 될 만한 변수로 값을 예측하는 방법

- **종속변수 y:** 예측하려는 값. 여기서는 총인구
- **설명변수 x:** y 를 움직인다고 보는 변수
  인구라면 **전입·전출·출생·사망**과 **주택 공급량**이 후보
- **회귀계수 b:** x 가 한 단위 늘 때 y 가 변하는 양. 자료에서 추정
- **코호트 요인법:** 인구 예측의 표준 방법
  연령별로 나눠 출생·사망·이동을 각각 적용해 한 해씩 굴림

$$\hat{y} = b_0 + b_1 x_1 + b_2 x_2 + \cdots$$

추세 외삽은 **"왜" 를 모른 채** 선을 늘린다.

설명변수를 넣으면 이유가 생긴다.



주의: 설명변수도 미래에는 없다

"주택 공급량으로 인구를 예측한다" 고 하면
내년 주택 공급량은 어떻게 아는가?

→ 설명변수를 쓰려면 그것도 예측하거나, 이미 확정된 것이어야 한다.
이미 승인된 인허가 물량처럼 확정된 값이 예측에 가장 쓸모 있다

과제: 화성 인구를 추세로 예측하고 자기 데이터에 적용한다

1. 화성 인구를 추세로 예측한다

1. 검증 설계를 먼저 정함: 마지막 12개월을 떼고,
   왜 그만큼인지 적음
2. 추세를 만들고 채점함: 학습 구간으로 선형·지수 추세
   검증 MAPE 를 구해 강의의 선형 4.12% 와 맞춰 봄
3. 한 그래프에 그림: 실제값, 두 추세선, 검증 구간(색)
   어느 쪽이 왜 더 빗나가는지 설명
4. 24개월 앞을 예측함: 112개월 전체로 다시 적합
   예측값 문장 아래 **단서 세 줄**: 어떤 가정 위에 있나,
   무엇이 어긋나면 틀리나, 얼마나 빗나갈 수 있나

2. 자기 데이터에 적용해 보고서로 정리한다

자기 문제정의서 데이터의 시계열에 같은 검증을 함

1. 목적을 한 문장으로 적음: 무엇을 얼마나 앞까지 예측하나
2. 검증 구간을 정하고 이유를 적음: 예측하려는 기간만큼 뒤쪽을 뗌
3. 적용하고 결과를 봄: AI 에게 로직을 요구하고 사람이 검증함
4. 판단을 남김: 무엇을 걸러 냈고 무엇을 정했나

단서의 마지막 줄 「얼마나 빗나갈 수 있나」를 숫자로 내는 법이 다음 주 주제

본보기: 배포 자료의 「분석 프롬프트.md」와 「로직 문서 본보기.md」

제출물

두 과제를 각각 별도 파일로 낸다

- `화성인구예측.md` : 1번의 추세 그래프, 예측값, 단서 세 줄, 로직 문서
- `분석보고서.md` : 2번의 자기 데이터에 적용한 결과

제출기한: 11월 21일(토) 23시 59분 59초

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

2주차와 같은 주소다. 주차 선택에서 **11주차**를 고르고, 학번 열 자리와 이름을 띄어쓰기 없이 적는다.

자료 출처

- **10쪽 수치:** COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」
  (화성시, SBJ_2307_001) 공개 데이터 · `1.화성시_인구데이터.xlsx`
  월별 총인구 112개월 (2014-01 ~ 2023-04) · 561,418 → 978,653명
  원 출처는 차세대 주민등록 통합행정시스템 등, 엑셀 상단에 명시되어 있다
- **산출 방법:** `analysis/11-예측적분석/11-화성인구.py` (외부 라이브러리 없이 xlsx 를 직접 읽고 최소제곱을 푼다),
  판단 근거는 `analysis/11-예측적분석/11-화성인구-로직.md`
- 6·8·12쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr