



2026-2학기 데이터사이언스

12강. 예측적 분석 II 머신러닝과 불확실성

2026. 11. 23.

어느 모형의 예측을 믿어야 하나?

- 지난주에 선형 추세가 4.12% 빛나갔다
- 더 복잡한 모형을 쓰면 더 잘 맞을까
- 그리고 "약 100만명" 이라고만 말해도 되는가

오늘 배울 세 가지

방법	답하는 질문	얻는 것
① 과적합과 복잡도	복잡하게 하면 나아지나	복잡도를 고르는 기준
② 머신러닝 개관	회귀와 무엇이 다른가	언제 쓰고 언제 안 쓰나
③ 예측구간	얼마나 빗나갈 수 있나	숫자 하나 대신 범위

③이 이 수업에서 가장 중요하다. 점 하나만 내놓은 예측은 증거로 쓸 수 없다.


잘 맞는 것과 잘 예측하는 것은 다르다

모형을 복잡하게 하면 **학습 자료는 얼마든지** 잘 맞힐 수 있다. 점이 10개면 9차 다항식이 전부를 정확히 지난다.

그런데 그 곡선은 자료의 **규칙이 아니라 우연까지** 따라 그린 것이다.

그래서 학습 오차는 계속 줄어드는데 **검증 오차는 어느 지점부터 도로 커진다.**

그 지점이 **복잡도의 걱정선**이다.



화성 인구 — 네 모형을 채점한다

학습 100개월 (2014.01~2022.04) · 검증 12개월 · 실제 2023-04 = 978,653명

모형	학습 MAPE	검증 MAPE	2023-04 예측
선형	1.38%	4.12%	1,021,018
2차	1.37%	3.10%	1,008,456
3차	0.50%	2.47%	928,321
지수	1.60%	7.83%	1,066,323

모든 모형에서 검증 오차가 학습 오차보다 크다. 3차는 학습에서 0.50%로 가장 잘 맞지만 그것이 예측력의 증거는 아니다.

선형·지수는 **과대추정**(증가세 둔화를 놓쳤다), 3차는 **과소추정**(학습 구간의 굴곡을 따라가다 꺾여 내려갔다). 어느 모형도 "맞다" 고 할 수 없다.

주의 – 복잡도를 올리고 싶어질 때

이런 유혹	왜 위험한가
"차수를 올리니 R ² 이 올랐어요"	R ² 은 학습 성적 이다. 변수를 넣을수록 무조건 오른다
"모형을 여럿 돌려 가장 잘 맞는 걸 골랐어요"	검증 자료로 고르면 그 순간 검증이 아니다 . 고르기용과 채점용을 나눠야 한다
"관측이 112개인데 변수를 20개 넣었어요"	표본이 적으면 복잡한 모형이 우연을 외운다. <u>표본 수가 복잡도의 상한이다</u>
"AI가 알아서 골라 줬어요"	무엇을 기준으로 골랐는지 물어야 한다. 학습 성적으로 골랐다면 과적합된 모형이 뽐힌다

마지막 줄이 이 수업의 자리다. **AI에게 모형 선택 기준을 물어보는 것**이 로직 검증이다.


회귀와 무엇이 다른가

회귀는 **사람이 꼴을 정한다** — "직선이다", "2차식이다" 라고 미리 못 박고 계수만 찾는다.

머신러닝은 **꼴도 자료에서 찾는다**. 나무를 몇 번 가를지, 어디서 가를지를 자료가 정한다.

그래서 복잡한 관계를 잡아내지만, 같은 이유로 과적합에 훨씬 쉽게 빠진다.

검증이 더 중요해지지 **덜** 중요해지지 않는다.




언제 쓰고 언제 쓰지 않나

쓸 만하다	회귀가 낫다
관측이 많다 (수천~수만)	관측이 적다 — 화성 112개월은 적은 편이다
변수가 많고 관계가 뒤엉켜 있다	변수가 몇 개뿐이다
맞히는 것 자체가 목적이다	왜 그런지 설명해야 한다
규칙을 미리 알기 어렵다	이론이 이미 꼴을 알려 준다

정책 근거를 만드는 일에서는 오른쪽 세 번째가 자주 결정적이다. "왜 이 지역인가" 를 설명하지 못하면 예산을 못 받는다.

숫자 하나 대신 범위를 낸다



멀리 갈수록 띠가 넓어진다. 넓어지지 않는 예측구간은 잘못 만든 것이다.

같은 예측을 두 가지 방식으로 쓰면

㉠ "2025년 4월 화성 인구는 102만명이다"

㉡ "선형 추세로 보면 약 102만명이다. 다만 최근 3년의 검증 오차가 4% 수준이므로 98만 ~ 106만으로 보는 편이 안전하다"

→ ㉠은 반박당하면 무너진다. ㉡은 틀릴 수 있다는 것까지 포함해 말한 것이라 무너지지 않는다

주의 — 구간이 담지 못하는 불확실성

종류	구간에 들어가나
자료의 흠어짐	들어간다 — 이것이 예측구간이 재는 것이다
계수를 잘못 켜 정도	들어간다
모형을 잘못 고른 것	들어가지 않는다. 선형이 틀렸다면 선형의 구간도 함께 틀린다
구조가 바뀌는 것	들어가지 않는다. 신도시 입주가 끝나면 추세 자체가 달라진다

아래 둘은 **시나리오**로 다룬다 — "이렇게 되면 이 값, 저렇게 되면 저 값". 다음 주 처방적 분석의 첫 방법이다.

예측을 증거로 쓰는 조건

- ① 학습에 쓰지 않은 기간으로 채점했는가
- ② 복잡도를 검증 오차로 골랐는가
- ③ 점이 아니라 범위로 말했는가
- ④ 무엇이 어긋나면 틀리는지 적었는가

→ 넷 중 하나라도 빠지면 그 예측은 정책 근거로 쓸 수 없다

실습

화성 인구예측모델 비교와 예측구간 — 약 1시간 30분

실습 ① — 네 모형을 채점한다 30분

- 1 지난주 학습/검증 분리를 그대로 쓴다 (마지막 12개월)
- 2 선형·2차·3차·지수 네 모형의 **학습 MAPE**와 **검증 MAPE**를 모두 낸다
- 3 표로 정리하고 강의의 값과 맞춰 본다
- 4 차수를 더 올려 본다 (5차, 8차). 학습 오차와 검증 오차가 각각 어떻게 되는가

4번에서 **4쪽의 그림이 실제로 재현된다**. 학습 오차는 계속 줄고 검증 오차는 어느 지점부터 커진다.

실습 ② — 구간을 만든다 35분

프롬프트

"검증 MAPE 가 가장 낮은 모형으로 24개월 앞을 예측하고, 예측구간도 함께 내 줘.

구간을 어떤 방법으로 어떤 가정 위에서 만들었는지 먼저 설명해 주고, 내가 확인하면 계산해.

그래프에는 실제값·예측선·구간을 함께 그리고, 학습 구간과 예측 구간을 색으로 구분해 줘."

구간 만드는 방법은 여러 가지다. **어떤 방법을 썼는지 모르면 그 구간은 해석할 수 없다.**

멀리 갈수록 넓어지는지 확인한다. 넓어지지 않으면 만드는 방식이 잘못된 것이다.

실습 ③ — 정책 문장으로 쓴다 25분

10쪽의 ㉠ 꼴로 쓴다

- 1 고른 모형과 **고른 이유** (검증 MAPE 를 근거로)
- 2 예측값과 **구간**
- 3 이 예측이 전제하는 가정 — 무엇이 계속된다고 보았나
- 4 무엇이 어긋나면 틀리는가 — 화성이라면 신도시 입주 일정

제출: **모형 비교표 + 구간 그래프 + 정책 문장 네 줄 + 로직 문서**

COMPAS 이 과제의 수상작들은 ARIMA·LSTM 등을 썼다. 분석 결과 탭에서 볼 수 있다 — **자기 결과와 견주어 보면 좋다.**

가정 과제: 자기 프로젝트 예측에도 구간을 붙인다.

자료 출처

- 5쪽 모형 비교 — COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」
(화성시, SBJ_2307_001) 공개 데이터 · 월별 총인구 112개월 (2014-01 ~ 2023-04)
학습 100개월 / 검증 12개월 · MAPE 로 채점
- 산출 방법 — `analysis/11-예측적분석/11-화성인구.py`, 판단 근거는 `analysis/11-예측적분석/11-화성인구-로직.md`
- 10쪽의 "98만 ~ 106만" 은 검증 오차 4% 를 그대로 적용해 본 **예시**다. 정식 예측구간이 아니다 — 실습에서 제대로 만든다
- 4·7·9쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr