2026-2학기 데이터사이언스

12강. 예측적 분석 II
머신러닝과 불확실성

2026. 11. 23.

어느 모형의 예측을 믿어야 하나?

- 지난주에 선형 추세가 4.12% 빗나갔다
- 더 복잡한 모형을 쓰면 더 잘 맞을까
- 그리고 "약 100만명" 이라고만 말해도 되는가

오늘 배울 세 가지

방법	답하는 질문	얻는 것
① 과적합과 복잡도	복잡하게 하면 나아지나	**복잡도를 고르는 기준**
② 머신러닝 개관	회귀와 무엇이 다른가	언제 쓰고 언제 안 쓰나
③ 예측구간	얼마나 빗나갈 수 있나	**숫자 하나 대신 범위**

③이 이 수업에서 가장 중요하다. **점 하나만 내놓은 예측은 증거로 쓸 수 없다.**

오늘의 실습자료와 자료 정리

화성시 월별 인구와 관련 지표

- **파일:** `12강–화성인구.zip` (11강과 같은 자료)
- **기간:** 2014년 1월 ~ 2023년 4월, 월별
- **규모:** 112개월 × 109열
- **쓰는 열:** 월별 · 총인구
- **함께 든 것:** 열 설명(README) · 방법별 프롬프트 · 로직 문서 본보기

→ 지난주와 **같은 분리**로 나눔. 그래야 모형끼리 견줄 수 있음

자료: COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」 (화성시, SBJ_2307_001)

자료 정리 프롬프트

화성시_인구데이터_2014-2023.xlsx 의 「데이터」 시트를 읽어 줘.
위 네 줄은 제목과 출처이고 5행이 열 이름이야.

「월별」 열은 41640 같은 엑셀 날짜 일련번호야. 2014-01 꼴의 연월로 바꿔 줘.

연월과 총인구 두 열로 월별 시계열을 만들어 줘.
마지막 12개월은 검증용으로 떼어 두고, 학습에는 절대 쓰지 마.

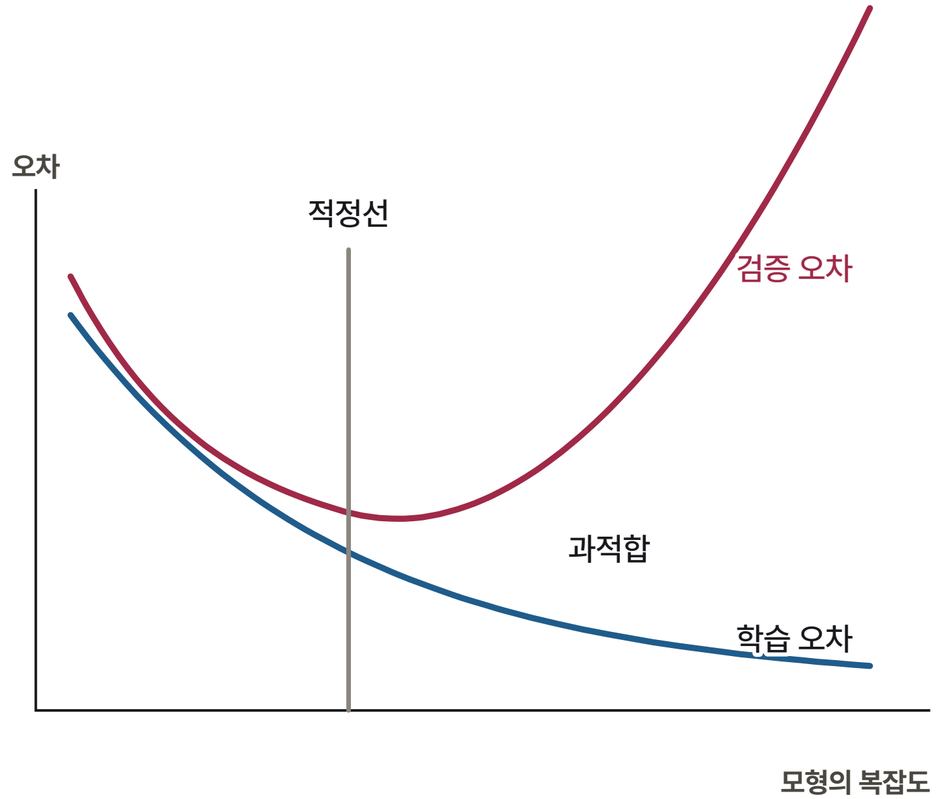
무엇을 왜 정했는지 로직 문서로 정리해 줘.

확인할 값: 112개월 (2014-01 ~ 2023-04) · 총인구 561,418 → 978,653명
학습 **100개월** (2014-01 ~ 2022-04) · 검증 **12개월** (2022-05 ~ 2023-04)

잘 맞히는 것과 잘 예측하는 것은 다르다

과적합: 모형이 자료의 규칙뿐 아니라 우연까지 따라 그려 새 자료에서 크게 빗나가는 것

- **복잡도:** 모형이 자료에 맞춰 조정할 수 있는 정도
  다항식이면 차수, 회귀면 변수의 개수
- **학습 오차:** 모형을 만든 자료에서 측정한 오차
  복잡도를 올리면 계속 줄어듦
- **검증 오차:** 모형이 보지 않은 자료에서 측정한 오차
  어느 지점부터 도로 커짐
- **적정선:** 검증 오차가 가장 작은 복잡도



점이 10개면 9차 다항식이 전부를 정확히 지난다.
규칙이 아니라 우연까지 따라 그린 것이다.

화성 인구: 네 모형을 채점한다

학습 100개월 (2014.01~2022.04) · 검증 12개월 · 실제 2023-04 = 978,653명

모형	학습 MAPE	검증 MAPE	2023-04 예측
선형	1.38%	4.12%	1,021,018
2차	1.37%	3.10%	1,008,456
3차	**0.50%**	2.47%	928,321
지수	1.60%	7.83%	1,066,323

모든 모형에서 검증 오차가 학습 오차보다 크다. 3차는 학습에서 0.50%로 가장 잘 맞지만 그것이 예측력의 증거는 아니다.

선형·지수는 **과대추정**(증가세 둔화를 놓쳤다), 3차는 **과소추정**(학습 구간의 굴곡을 따라가다 꺾여 내려갔다). 어느 모형도 "맞다" 고 할 수 없다.

주의: 복잡도를 올리고 싶어질 때

이런 유혹	왜 위험한가
"차수를 올리니 R^2이 올랐어요"	R^2은 **학습 성적**이다. 변수를 넣을수록 무조건 오른다
"모형을 여럿 돌려 가장 잘 맞는 걸 골랐어요"	검증 자료로 고르면 **그 순간 검증이 아니다.** 고르기용과 채점용을 나눠야 한다
"관측이 112개인데 변수를 20개 넣었어요"	표본이 적으면 복잡한 모형이 우연을 외운다. **표본 수가 복잡도의 상한이다**
"AI가 알아서 골라 줬어요"	무엇을 기준으로 골랐는지 물어야 한다. **학습 성적으로 골랐다면 과적합된 모형이 뽑힌다**

마지막 줄이 이 수업의 자리다. **AI에게 모형 선택 기준을 물어보는 것**이 로직 검증이다.

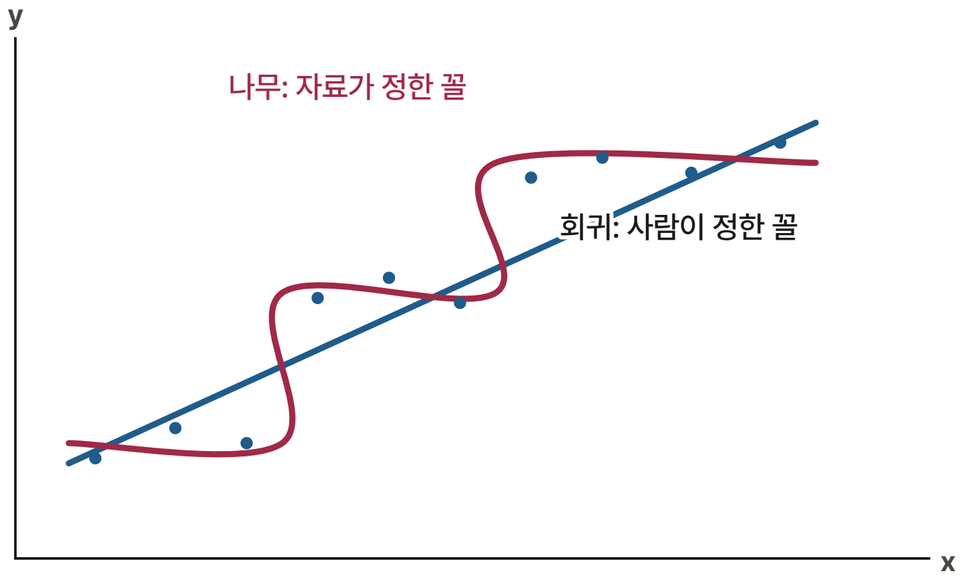
회귀와 무엇이 다른가

머신러닝: 예측의 꼴까지 자료에서 찾는 방법

- **회귀: 사람이 꼴을 정함**. "직선이다", "2차식이다" 라고 미리 못 박고 계수만 찾음
- **머신러닝: 꼴도 자료에서 찾음**
- **의사결정나무:** 변수의 값을 기준으로 자료를 거듭 둘로 갈라 갈린 칸마다 평균을 예측값으로 쓰는 모형
  몇 번, 어디서 가를지를 자료가 정함

그래서 **복잡한 관계를 잡아내지만**,
같은 이유로 **과적합에 훨씬 쉽게 빠진다.**

검증이 더 중요해지지 덜 중요해지지 않는다.



언제 쓰고 언제 쓰지 않나

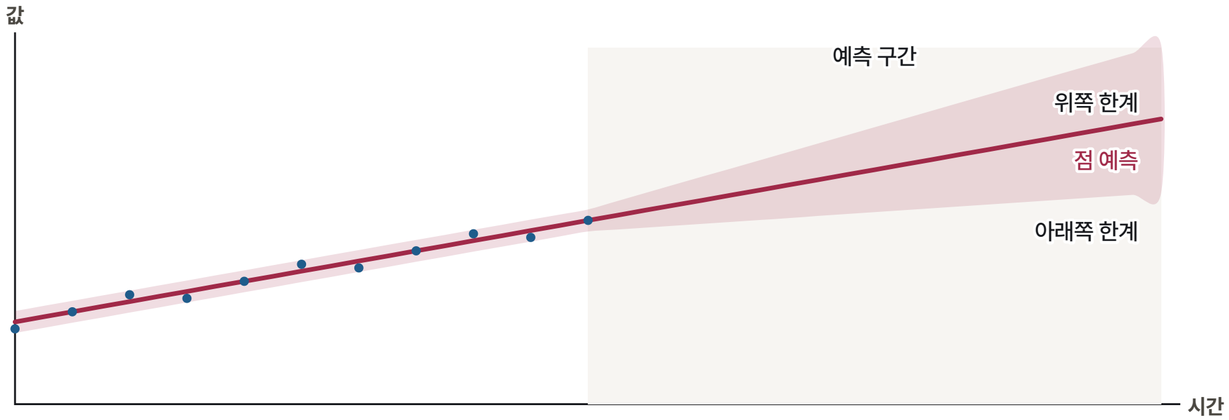
쓸 만하다	회귀가 낫다
관측이 많다 (수천~수만)	관측이 적다: **화성 112개월은 적은 편이다**
변수가 많고 관계가 뒤엉켜 있다	변수가 몇 개뿐이다
맞히는 것 자체가 목적이다	**왜 그런지 설명해야 한다**
규칙을 미리 알기 어렵다	이론이 이미 꼴을 알려 준다

정책 근거를 만드는 일에서는 오른쪽 세 번째가 자주 결정적이다. "왜 이 지역인가" 를 설명하지 못하면 예산을 못 받는다.

숫자 하나 대신 범위를 낸다

예측구간: 새로 관측될 값이 정한 확률로 들어갈 것으로 보는 범위

- **점 예측:** 예측값 하나만 내놓는 것
- **신뢰수준:** 구간이 실제값을 담을 것으로 정한 확률. 흔히 95%
- **신뢰구간과의 차이:** 신뢰구간은 평균·계수의 범위, 예측구간은 값 하나의 범위라 더 넓음



멀리 갈수록 띠가 넓어진다. 넓어지지 않는 예측구간은 잘못 만든 것이다.

같은 예측을 두 가지 방식으로 쓰면

㉠ "2025년 4월 화성 인구는 102만명이다"

㉡ "선형 추세로 보면 약 102만명이다. 다만 최근 3년의 검증 오차가 4% 수준이므로 98만 ~ 106만으로 보는 편이 안전하다"

→ ㉠은 반박당하면 무너진다. ㉡은 틀릴 수 있다는 것까지 포함해 말한 것이라 무너지지 않는다

주의: 구간이 담지 못하는 불확실성

종류	구간에 들어가나
자료의 흩어짐	들어간다. 이것이 예측구간이 측정하는 것이다
계수를 잘못 추정한 정도	들어간다
모형을 잘못 고른 것	**들어가지 않는다. 선형이 틀렸다면 선형의 구간도 함께 틀린다**
구조가 바뀌는 것	**들어가지 않는다. 신도시 입주가 끝나면 추세 자체가 달라진다**

아래 둘은 **시나리오**로 다룬다 — "이렇게 되면 이 값, 저렇게 되면 저 값". 다음 주 처방적 분석의 첫 방법이다.

예측을 증거로 쓰는 조건

① 학습에 쓰지 않은 기간으로 채점했는가
② 복잡도를 검증 오차로 골랐는가
③ 점이 아니라 범위로 말했는가
④ 무엇이 어긋나면 틀리는지 적었는가

→ 넷 중 하나라도 빠지면 그 예측은 정책 근거로 쓸 수 없다

과제: 화성 인구 모형을 비교하고 예측에 구간을 붙인다

1. 화성 인구로 모형을 비교하고 구간을 낸다

1. 네 모형을 채점함: 지난주 분리(마지막 12개월) 그대로
   선형·2차·3차·지수의 학습 MAPE 와 검증 MAPE 를 표로
2. 차수를 더 올려 봄: 5차, 8차에서
   학습 오차와 검증 오차가 각각 어떻게 되나
3. 구간을 만듦: 검증 MAPE 가 가장 낮은 모형으로 24개월 앞
   어떤 방법·가정으로 만들었는지 먼저 설명하게 함
4. 정책 문장 네 줄 (11쪽의 ㄴ 꼴): 고른 모형과 이유 ·
   예측값과 구간 · 전제한 가정 · 무엇이 어긋나면 틀리나

2. 자기 프로젝트 예측에 구간을 붙인다

1. 목적을 한 문장으로 적음: 무엇을 얼마나 앞까지 예측하나
2. 모형을 검증 오차로 고름: 학습 오차로 고르지 않음
3. 예측값에 구간을 붙임: 만든 방법과 가정을 밝힘
4. 판단을 남김: 무엇을 걸러 냈고 무엇을 정했나

COMPAS 이 과제의 수상작들은 ARIMA·LSTM 등을 썼다. 분석 결과 탭에서 볼 수 있다

본보기: 배포 자료의 「분석 프롬프트.md」와 「로직 문서 본보기.md」

제출물

두 과제를 각각 별도 파일로 낸다

- `화성모형비교.md` : 1번의 모형 비교표, 구간 그래프, 정책 문장 네 줄, 로직 문서
- `분석보고서.md` : 2번의 자기 프로젝트 예측과 구간

제출기한: 11월 28일(토) 23시 59분 59초

데이터사이언스 과제 제출 — 한 학기 내내 같은 주소

`docs.google.com/forms/d/e/1FAIpQLSc7AWYdgrGn1gKGoo7VkC6vsDZNXANo-CWokVjY2dm2pucIew/viewform`

2주차와 같은 주소다. 주차 선택에서 **12주차**를 고르고, 학번 열 자리와 이름을 띄어쓰기 없이 적는다.

자료 출처

- **6쪽 모형 비교:** COMPAS 「AI기법에 의한 인구예측모델 정확도 비교 분석」
  (화성시, SBJ_2307_001) 공개 데이터 · 월별 총인구 112개월 (2014-01 ~ 2023-04)
  학습 100개월 / 검증 12개월 · MAPE 로 채점
- **산출 방법:** `analysis/11-예측적분석/11-화성인구.py` , 판단 근거는 `analysis/11-예측적분석/11-화성인구-로직.md`
- 11쪽의 "98만 ~ 106만" 은 검증 오차 4% 를 그대로 적용해 본 **예시**다. 정식 예측구간이 아니다. 과제에서 제대로 만든다
- 5·8·10쪽 그림은 원리를 보이는 개념도다. 실제 자료가 아니다

Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr