



2026-2학기 도시교통통계학

3강. 정규분포와 정규분포로의 근사

2026. 9. 16.

성인 남성의 키는 평균 170cm, 표준편차 6cm 라고 한다

그러면 180cm 이상인 사람은 몇 %인가?

2강에서 배운 평균과 표준편차만으로는 이 물음에 답할 수 없다

오늘 이 질문에 답하는 방법을 배운다

지난 강의 요약 (1)

- 통계학은 복잡한 자료를 정리, 분석, 추론하여 유용한 정보를 얻기 위한 도구이다.
- 우리가 관측하는 대부분의 자료는 실제 관심 대상이 되는 전체 집단인 모집단에서 추출한 표본 자료이며, 표본의 특성을 나타내는 통계량을 통해서 모집단의 특성인 모수를 추정해 볼 수 있다.
- 이와 같이 통계학은 표본을 정리, 요약하는 기술통계학과 표본의 통계량으로 관심 대상인 모집단을 추론하는 추론통계학으로 크게 나눌 수 있다.
- 기술통계학 차원에서 자료를 요약하는 방법은 자료의 분포를 그래프로 그리는 것과 숫자인 통계량으로 표현하는 방법이 있다.
- 자료를 일정한 구간으로 나누고 그 구간 내 자료의 빈도를 기입한 표를 도수분포표라고 하며, 구간별 자료의 빈도를 밀도단위(상대도수/구간길이)로 표현한 그래프를 히스토그램이라고 한다.

지난 강의 요약 (2)

- 자료를 숫자로 요약하는 가장 간단한 방법은 자료가 어떤 지점을 중심으로 분포하고 있는지를 나타내는 중심경향성 통계량을 사용하는 방법이며 대표적인 것이 평균, 중앙값, 최빈값이다.
- 평균은 자료의 총합을 자료 개수로 나눈 것으로서 자료의 무게중심을 의미하며, 중앙값은 자료를 크기 순으로 나열했을 때 50%에 위치한 값을 의미하며, 최빈값은 자료 내에서 빈도가 가장 큰 값을 의미한다.
- 평균은 극단적인 값에 민감하지만 중앙값은 극단적인 값의 영향을 받지 않는다.
- 평균은 자료의 중심경향성을 보여주지만 자료가 중심에서 얼마나 퍼져 있는지, 즉 분산된 정도는 알려주지 않기 때문에 자료의 특성을 명확히 알기 위해서는 표준편차 혹은 분산을 함께 보아야 한다.
- 평균과 표준편차를 알면 자료의 전반적인 분포를 설명할 수 있다.

평균과 표준편차로는 「몇 %인가」를 모른다

2강에서 얻은 것

- 도수분포표와 히스토그램 — 분포를 그림으로
- 평균 · 중앙값 · 최빈값 — 자료의 중심
- 분산 · 표준편차 — 자료가 퍼진 정도
- 왜도 · 첨도 — 늘어지고 뾰족한 정도

그래도 답하지 못하는 것

180cm 이상은 몇 %인가?

중심이 어디인지, 얼마나 퍼졌는지는 안다


특정 구간에 자료가 몇 %나 들어 있는지는 모른다

→ 구간의 비율을 구하려면 분포의 모양을 식으로 알아야 한다

→ 자연에서 가장 자주 나타나는 그 모양이 정규분포다

관측을 늘리면 히스토그램이 곡선이 된다

성인 남성의 키에 대한 히스토그램




50번 관측


→ 관측을 무한히 늘리면 분포가 하나의 매끄러운 곡선에 수렴한다

관측을 늘리면 히스토그램이 곡선이 된다

성인 남성의 키에 대한 히스토그램



50번 관측




5,000번 관측


→ 관측을 무한히 늘리면 분포가 하나의 매끄러운 곡선에 수렴한다

관측을 늘리면 히스토그램이 곡선이 된다


성인 남성의 키에 대한 히스토그램



50번 관측



5,000번 관측



50,000번 관측

→ 관측을 무한히 늘리면 분포가 하나의 매끄러운 곡선에 수렴한다

곡선 아래 넓이가 그 구간의 비율이다

밀도 = 상대빈도 / 구간길이

밀도 * 구간길이 = 상대빈도


= 전체 자료에서 해당 구간이 차지하는 비율

= 해당 구간의 자료가 출현할 확률

= 구간의 면적

= 분포를 나타내는 함수식의 구간 적분 값

→ 넓이를 구하면 그 구간에 자료가 몇 %인지 안다



자료의 분포를 함수식 하나로

도수분포표
(frequency table)

자료를 일정한 계급/구간으로 나누어 해당 구간에 속하는 자료의 빈도를 나타낸 분포표

자료를 무한히 관측하면?

→ 해당 자료의 특정 구간 혹은 값이 출현할 **확률(자료의 빈도)**에 대한 분포를 파악할 수 있음

이를 하나의 함수식으로 근사하여 표현하면?

→ 해당 자료의 특정 구간 혹은 값이 출현할 **확률(자료의 빈도)**에 대한 분포를 언제든지 재현할 수 있음

그 중 자연 현상을 관측하여 만든 자료에서 가장 빈번하게 나타나는 분포를 수식으로 표현한 것

→ **정규분포 (normal distribution)**

정규분포란 무엇인가 (normal distribution)

정규분포의 사례

- 저울의 측정오차
- 키와 몸무게의 분포
- 같은 공정에서 만든 부품의 치수

:


대체로 평균을 중심으로 수렴하고
일부의 오차만 존재하는 경우

평균 μ , 표준편차 σ 인 변수 X 에 대한 정규분포

$$X \sim N(\mu, \sigma^2)$$

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$$

$(-\infty < x < +\infty)$ μ, σ 에 따라 곡선의 형태가 결정




정규분포의 모양은 μ 와 σ 가 정한다

평균 μ , 표준편차 σ 인 변수 X 에 대한 정규분포


$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

$(-\infty < x < +\infty)$

가) 표준편차가 같고 평균값이 다른 경우 ($\mu_1 < \mu_2 < \mu_3$, $\sigma_1 = \sigma_2 = \sigma_3$)



나) 표준편차가 다르고 평균값이 같은 경우 ($\mu_1 = \mu_2 = \mu_3$, $\sigma_1 > \sigma_2 > \sigma_3$)




정규분포의 세 가지 특징

평균 μ , 표준편차 σ 인 변수 X 에 대한 정규분포

$$X \sim N(\mu, \sigma^2)$$

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$$

$(-\infty < x < +\infty)$



1. 평균을 중심으로 좌우 대칭 (symmetric)
2. 종 모양 (bell-shaped)
3. 봉우리가 하나 (single-peaked)




평균과 표준편차에 따라 중심과 퍼진 정도는 달라지지만
전반적인 모양은 그대로이며,
평균 $\pm n$ 표준편차의 비율도 일정함

68 – 95 – 99.7 법칙

정규분포는 모양이 하나이므로, 평균에서 표준편차 몇 배 안에
자료가 몇 %인지가 $\mu \cdot \sigma$ 와 상관없이 늘 같다

- 평균의 $-1SD \sim +1SD$ 안에 약 **68%**
- 평균의 $-2SD \sim +2SD$ 안에 약 **95%**
- 평균의 $-3SD \sim +3SD$ 안에 약 **99.7%**

→ 평균과 표준편차만 알면 구간의 비율을 대략 말할 수 있다



왜 표준화하는가

문제

정규분포는 μ 와 σ 마다 다른 곡선이다 (앞 장에서 본 그대로)

키는 $N(170, 6^2)$, 시험점수는 $N(72, 11^2)$, 잔고는 $N(1, 0.2^2)$...

구간의 넓이를 적어 둔 표를 분포마다 만들 수는 없다

해법

모든 정규분포를 **평균 0, 표준편차 1**인 하나로 옮긴다

넓이는 옮겨도 변하지 않으므로, 표 한 장이면 어떤 정규분포든 읽을 수 있다

이 옮기는 일이 **표준화**다

→ 먼저 자료를 더하고 곱하면 평균과 표준편차가 어떻게 변하는지부터 본다

자료 변환에 따른 평균과 표준편차의 변화

상수 합: 자료에 모두 일정한 상수를 더하면?

- 평균 = 상수만큼 증가
- 표준편차 = 일정

상수 배: 자료에 모두 일정한 상수를 곱하면?

- 평균, 표준편차 = 상수 곱만큼 증가

**Q) 변수 X에 평균만큼 빼고,
1/표준편차만큼 곱하면
변수 X의 평균과 표준편차는 어떻게 변할까?**

변수의 표준화 (standardization)

Q) 변수 X에 평균만큼을 빼고, 1/표준편차만큼을 곱하면 기존 평균과 표준편차는 어떻게 변할까?

〈변수 X의 평균 μ , 표준편차 σ 〉

① 상수 합: 평균은 상수만큼 변화, 표준편차는 일정

$$\rightarrow \text{평균} = \mu - \mu = 0$$

$$\text{표준편차} = \sigma$$

② 상수 배: 평균과 표준편차는 모두 상수 곱만큼 변화

$$\rightarrow \text{평균} = (\mu - \mu) * 1/\sigma = 0$$

$$\text{표준편차} = \sigma * 1/\sigma = 1$$

표준화(standardization)

특정 변수 X에서 평균을 빼고 표준편차로 나누어
평균이 0이고 표준편차가 1인 새로운 변수 Z로 변환하는 과정

$$Z = \frac{X - \mu}{\sigma}$$

이걸 왜 할까?

→ 서로 다른 측정 단위를 지닌 변수를 모두 표준편차 단위로 변환

→ 서로 다른 변수들 간의 비교 용이

표준정규분포 (standard normal distribution)

평균 μ , 표준편차 σ 인 변수 X 에 대한 정규분포

$$X \sim N(\mu, \sigma^2)$$

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$$

$$(-\infty < x < +\infty)$$



평균 0, 표준편차 1인 변수 Z 에 대한 정규분포

= 표준정규분포 (standard normal distribution)


$$Z \sim N(0, 1)$$

$$f(Z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}$$


$$(-\infty < z < +\infty)$$



두 가지의 정규분포표




S10 Standard normal distribution | Learning Lab (rmit.edu.au)



Z Score - Definition and How to Use - Conversion Uplift (conversion-uplift.co.uk)

표준정규분포표 읽는 법

만약 어떤 자료의 분포가 정규분포와 유사한 형태의 분포를 지니고 있다면 그 분포를 정규분포로 간주하고, 표준화를 통해 어떤 구간 내에 속한 숫자의 비율을 구할 수 있다.




z	.00	.01	.02
0.0	.0000	.0040	.0080
0.1	.0398	.0438	.0478
0.2	.0793	.0832	.0871
0.3	.1179	.1217	.1255
0.4	.1554	.1591	.1628
0.5	.1915	.1950	.1985
0.6	.2257	.2291	.2324
0.7	.2580	.2611	.2642
0.8	.2881	.2910	.2939
0.9	.3159	.3186	.3212
1.0	.3413	.3438	.3461
1.1	.3643	.3665	.3686

만약 표준화된 구간 값이 -0.4 ~ 0.7이라면

- 1. 0 ~ 0.7까지의 면적을 표준정규분포표에서 찾고 (0.2580)
- 2. 0 ~ 0.4까지의 면적을 표준정규분포표에서 찾은 뒤 1)과 합함 (0.1554)

예) 평균 50, 표준편차 5 – 40 ~ 60 은 몇 %인가




“평균 50, 표준편차 5”인 분포

→ 40~60 사이에 속한 자료는 대략 몇 %일까?

40 과 60 은 평균 ± 2 표준편차 – 약 95%

$$X \sim N(50, 5^2)$$

$$f(X) = \frac{1}{\sqrt{2\pi} * 5} e^{-\frac{1}{2} \left(\frac{X-50}{5}\right)^2}$$



40 과 60 을 표준편차로 재면

40 = 평균 50 - 2표준편차

60 = 평균 50 + 2표준편차

68 - 95 - 99.7 법칙에서 -2SD ~ +2SD 는 약 95%



→ 40 ~ 60 사이에 **약 95%**의 자료가 들어 있다

연습문제 – 은행 잔고

연습문제) 매일 영업이 끝난 뒤 어느 은행에 남아있는 잔고는 평균이 1조원이고, 표준편차가 0.2조원이다. 이 분포가 정규분포에 잘 근사된다고 할 때, 이 은행의 잔고가 지급준비금인 0.7조원 이하로 떨어질 가능성은?

연습문제 – 은행 잔고


연습문제) 매일 영업이 끝난 뒤 어느 은행에 남아있는 잔고는 평균이 1조원이고, 표준편차가 0.2조원이다. 이 분포가 정규분포에 잘 근사된다고 할 때, 이 은행의 잔고가 지급준비금인 0.7조원 이하로 떨어질 가능성은?



표준정규분포곡선에 해당 구간을 표시

연습문제 – 은행 잔고

연습문제) 매일 영업이 끝난 뒤 어느 은행에 남아있는 잔고는 평균이 1조원이고, 표준편차가 0.2조원이다. 이 분포가 정규분포에 잘 근사된다고 할 때, 이 은행의 잔고가 지급준비금인 0.7조원 이하로 떨어질 가능성은?
(답: 6.68%)




평균이 분포를 대표하지 못할 때

어떤 자료가 정규분포를 잘 따를 경우 평균과 표준편차만 있으면 자료를 거의 100% 묘사할 수 있다
→ 하지만 자료가 정규분포를 안따르면?

자료가 오른쪽으로 치우친(right-skewed) 경우: 최빈값 < 중앙값 < 평균

평균 3,486만원 / 표준편차 1,829만원

→ 평균이 분포를 잘 설명하지 못한다!



연간 가구소득 분포 : 2008년, 한국

백분위	백분위수(만원/년)
1	589.5
10	1484.7
25	2242.8
50	3254.1
75	4438.5
90	5687.3
99	8887.9

백분위수 · 사분위수 · 사분위수 범위

백분위수 (percentile)

하나의 히스토그램을 100개의 균등한 영역으로 나눈 99개의 경계점
(즉, 자료의 1%, 2%, 3%, ..., 99% 지점)


사분위수 (quartile)

백분위수를 대표하는 지점으로서, 제1사분위(제25백분위), 제2사분위(제50백분위 = 중앙값), 제3사분위(제75백분위)

사분위수 범위 (interquartile range, IQR)

제3사분위 - 제1사분위


상자그림의 구성 (boxplot)




어떤 자료의 분포를

“최소값, 제1사분위수, 제2사분위수(중앙값), 제3사분위수, 최대값”의 다섯가지 통계량으로 나타낸 그림


연간 가구소득 분포




상자그림 : KOSPI 지수와 거래소 개별종목의 2008년 주간수익률



늘어짐에 따른 상자그림과 분포곡선



중앙값이 상자 안 어디에 놓이는지가
분포가 어느 쪽으로 늘어졌는지를 말해 준다



오늘 강의 요약 (1)

- 자연현상의 상당 수는 평균을 중심으로 좌우 대칭인 종모양의 정규분포를 따른다.
- 정규분포는 평균과 표준편차에 따라 그 모양과 크기가 달라진다.
- 특정 현상이 정규분포를 따른다면 그 현상의 평균과 표준편차만으로 해당 현상의 발생빈도를 완벽하게 묘사할 수 있다.
- 정규분포 중에서 평균이 0이고 표준편차가 1인 정규분포를 표준정규분포라 한다.
- 어떤 자료에서 평균을 빼고 표준편차로 나눈 것을 자료의 표준화라고 하며, 정규분포를 따르는 자료를 표준화한 값은 표준정규분포를 따른다.

오늘 강의 요약 (2)

- 정규분포를 따르는 자료는 평균을 중심으로 ± 1 표준편차 이내에 약 68%가, ± 2 표준편차 이내에 약 95%가 포함된다.
- 특정 자료가 정규분포와 유사한 분포를 따를 경우 이 분포를 정규분포로 간주하고, 정규분포표를 사용하여 특정 구간 내에 속한 자료의 비중을 계산할 수 있으며 이를 정규분포로의 근사라 한다.
- 만약 특정 자료가 정규분포를 따르지 않을 경우 평균과 표준편차만으로 이 자료의 분포를 명확히 묘사할 수 없으며, 이 경우 자료를 100개의 균등한 영역으로 나눈 지점의 값인 분위수를 사용하는 것이 도움이 된다.
- 분위수를 활용하여 자료의 분포를 나타내는 대표적인 방식으로는 상자그림이 있다.
- 히스토그램이 서로 다른 자료의 분포를 비교하기 어려운 반면, 상자그림은 서로 다른 자료 간 분포를 비교하기 용이하다.

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr