



2026-2학기 도시교통통계학

5강. 회귀분석 (1)

2026. 9. 30.


지난 강의 요약

- 하나의 변수에 대한 분포가 아니라 두 변수 사이의 상호관계를 고려한 분포를 결합분포라고 하며, 두 변수의 결합분포를 나타내기 위해 한 변수를 x축에, 다른 변수를 y축에 표시하여 점으로 나타낸 것을 산포도(scatter plot)이라고 한다.
- 평균과 분산이 동일한 두 변수가 존재하더라도 두 변수 간의 관계는 서로 다를 수 있다.
- 두 변수 간의 관계를 요약한 대표적인 수치는 두 변수 간 선형관계를 나타내는 공분산(covariance)이다.
- 공분산은 자료의 단위에 의존하기 때문에, 서로 다른 선형관계 간의 비교가 어렵다.
- 공분산의 단위를 제거하기 위해 두 변수 간 공분산을 각 변수의 표준편차로 나누어 $-1 \sim 1$ 사이의 값을 갖도록 조정한 통계량을 상관계수라 한다.

지난 강의 요약

- 두 변수 간 관계가 음(-)의 상관관계를 가질 경우 -1 에 가까운 값을, 정(+)의 상관관계를 가질 경우 $+1$ 에 가까운 값이 나타나며, 두 변수 간 선형관계가 존재하지 않을 경우 0 에 가까운 값이 나타난다.
- 상관계수는 두 변수 간 선형관계만을 수치화하기 때문에 선형관계가 아닌 비선형 관계는 나타낼 수 없다.
- 상관계수는 이상치에 민감하다.
- 평균이나 비율로 계산한 상관계수는 이미 변수의 편차가 소거된 상태이기 때문에, 실제 두 변수 간의 선형관계를 왜곡할 여지가 있다.
- 상관관계는 두 변수 간의 선형의 연관성(association)만 나타낼 뿐이며, 인과관계(causality)는 아니다.

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm
- 평균 몸무게: 63.5kg

→ 다른 정보가 없을 때 임의로 한 개인을 선택할 경우 몸무게는 얼마일 것으로 추정할 수 있는가?

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm
- 평균 몸무게: 63.5kg

→ 다른 정보가 없을 때 임의로 한 개인을 선택할 경우 몸무게는 얼마일 것으로 추정할 수 있는가?

: 다른 정보가 없으므로 전체 평균인 63.5kg 수준일 것

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm
- 평균 몸무게: 63.5kg


→ 만약 한 개인의 키가 179.5cm라는 정보가 있다면 그 값은 어떻게 바뀔까?

회귀분석




회귀분석

x변수에 대응하는 y변수의 “부분집합별” 평균값을 추정하는 통계적 방법



상관계수와 회귀분석의 연계



주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, **키의 표준편차: 8.5cm**
- 평균 몸무게: 63.5kg, **몸무게의 표준편차: 11.9kg**
- 상관계수: 0.67

→ 모든 x 에 대해서 부분집합을 구하고 y 의 평균을 내기 어려움

→ 만약 내가 x 와 y 의 상관계수를 알고 있다면 키를 고려한 몸무게의 수준을 더 정확히 추정할 수 있지 않을까?

상관계수의 의미


$$\begin{aligned}
 r &= \frac{\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n-1}}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}} \cdot \sqrt{\frac{\sum (y_i - \bar{y})^2}{n-1}}} \\
 &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \cdot \sqrt{\sum (y_i - \bar{y})^2}} = \frac{Cov_{xy}}{SD_x \cdot SD_y}
 \end{aligned}$$

X가 평균에서 벗어난 정도(편차)의 표준편차 단위 환산 = **X가 1표준편차 단위 변화할 때**

Y가 평균에서 벗어난 정도(편차)의 표준편차 단위 환산 = **Y는 표준편차 단위로 얼마나 변화할까?**

→ 그 변화에 대한 평균값 (그 반대도 성립)

상관계수의 의미



주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, **키의 표준편차: 8.5cm**
- 평균 몸무게: 63.5kg, **몸무게의 표준편차: 11.9kg**
- 상관계수: 0.67


→ 키가 8.5cm 증가할 경우 몸무게는 얼마나 증가할까?

: 키가 1표준편차($1 \times 8.5\text{cm}$) 클 경우

몸무게는 **평균적으로** 0.67표준편차($0.67 \times 11.9\text{kg}$) 클 것


상관계수를 활용한 회귀직선의 기울기 도출

x변수에 대응하는 y변수의 평균값을 추정하는 통계적 방법



주: 실선은 회귀직선이고 점선은 표준편차선이다.

분포를
하나의 직선으로 근사



회귀직선의 기울기

$$= r * \frac{SD_y}{SD_x}$$

→ 상관계수를 y의 단위로 변환하는 것

$$\rightarrow y = a + (r * SD_y / SD_x) * X$$


회귀의 표준오차 (standard error)

추정오차(estimation error) = 잔차(residual) = 실제값 - 추정치

표준오차(standard error): 잔차 제곱합을 자유도(n-2)로 나눈 뒤 제곱근을 취한 것

잔차 제곱의 **평균**에 제곱근을 취한 RMSE 와는 나누는 수만 다르다 (n 대신 n-2)

→ 표준오차가 작을수록 회귀직선이 자료를 잘 요약



$$SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$


자유도가 2만큼 줄어드는 이유

: 추정치 계산 시 회귀직선의 기울기와 절편을 통계량으로 사용하므로

회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것




회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것

$$e_i = Y_i - b_0 - b_1 X_i$$

$$\sum e_i^2 = \sum (Y_i - b_0 - b_1 X_i)^2 \rightarrow \text{이 값을 최소화하는 모수 추정량 } b_0, b_1 = \text{최소제곱추정량}$$



$$SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

표준오차의 최소화 = 잔차제곱합의 최소화

회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것

$$e_i = Y_i - b_0 - b_1 X_i$$

$$\sum e_i^2 = \sum (Y_i - b_0 - b_1 X_i)^2 \quad \rightarrow \text{이 값을 최소화하는 모수 추정량 } b_0, b_1 = \text{최소제곱추정량}$$

$$\frac{\partial \sum e_i^2}{\partial b_0} = -2 \sum (Y_i - b_0 - b_1 X_i) = 0$$

$$\frac{\partial \sum e_i^2}{\partial b_1} = -2 \sum (Y_i - b_0 - b_1 X_i) X_i = 0$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것

$$b_1 = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sum(X_i - \bar{X})^2} = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum(X_i - \bar{X})^2} \cdot \sqrt{\sum(Y_i - \bar{Y})^2}} \times \frac{\sqrt{\sum(Y_i - \bar{Y})^2}}{\sqrt{\sum(X_i - \bar{X})^2}}$$

$$= r \times \frac{SD_y}{SD_x}$$

$$\begin{aligned} & \text{X의 1표준편차 변화에 따른 y의 평균 변화량} = \frac{\frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n-1}}{\sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}}} \times \frac{1}{\sqrt{\frac{\sum(x_i - \bar{x})^2}{n-1}}} \end{aligned}$$

X를 곱해주면
X값의 표준편차 단위로 X를
변환시키는 것과 동일

회귀효과

**평범(평균)으로의 회귀: 측정한 값이 극단값이면,
다음에 측정할 때 평균에 더 가까워지는 현상**

SD선: 기말고사에서도 같은 정도의 운이 반복될 때의 선

중간고사를 잘 본 학생 (오른쪽 띠)


운 좋았던 학생이 많이 섞임 → 기말고사에서 운이 반복된다는 보장이 없음
→ SD선보다 아래

중간고사를 못 본 학생 (왼쪽 띠)

운 나빴던 학생이 많이 섞임 → 나쁜 운도 보통 반복되지 않음
→ SD선보다 위

→ 그래서 회귀직선은 SD선보다 완만함

기울기 = $r \times SDy/SDx$, 상관계수 r 이 +1이 아니기 때문



회귀효과

**평범(평균)으로의 회귀: 측정한 값이 극단값이면,
다음에 측정할 때 평균에 더 가까워지는 현상**

SD선: 기말고사에서도 같은 정도의 운이 반복될 때의 선

중간고사를 잘 본 학생 (오른쪽 띠)


운 좋았던 학생이 많이 섞임 → 기말고사에서 운이 반복된다는 보장이 없음
→ SD선보다 아래

중간고사를 못 본 학생 (왼쪽 띠)

운 나빴던 학생이 많이 섞임 → 나쁜 운도 보통 반복되지 않음
→ SD선보다 위

→ 그래서 회귀직선은 SD선보다 완만함

기울기 = $r \times SDy/SDx$, 상관계수 r 이 +1이 아니기 때문



회귀효과

평범(평균)으로의 회귀: 측정한 값이 극단값이면, 다음에 측정할 때 평균에 더 가까워지는 현상

SD선: 기말고사에서도 같은 정도의 운이 반복될 때의 선

중간고사를 잘 본 학생 (오른쪽 띠)


운 좋았던 학생이 많이 섞임 → 기말고사에서 운이 반복된다는 보장이 없음
→ SD선보다 아래

중간고사를 못 본 학생 (왼쪽 띠)

운 나빴던 학생이 많이 섞임 → 나쁜 운도 보통 반복되지 않음
→ SD선보다 위

→ 그래서 회귀직선은 SD선보다 완만함

기울기 = $r \times SDy/SDx$, 상관계수 r 이 +1이 아니기 때문



회귀분석의 절차

1. **문제제기**: 회귀분석으로 해결가능한 질문 제시
2. **모형설정**: 이론적 토대에 기반 → 두 변수 사이의 선형관계로 가설 설정

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad \begin{array}{l} \beta_0, \beta_1 = \text{회귀모수(계수)}. (\text{알려지지 않은}) \text{ 상수} \\ \varepsilon_i = \text{오차. 확률변수} \end{array}$$

3. **자료수집 및 모수 추정**: 주어진 자료를 활용하여 적절한 추정법(예. 최소제곱법)으로 모수(β_0, β_1)를 추정

$$Y_i = b_0 + b_1 X_i + e_i \quad \begin{array}{l} b_0, b_1 = \text{회귀모수의 추정량. 확률변수} \\ e_i = \text{잔차. 확률변수} \end{array}$$

4. **모형 설명력 및 모수 추정량에 대한 유의성 검정**: 모수 추정량의 표준오차, 추정 통계량, 유의성 검정을 위한 분포의 결정
5. **모형 가정에 대한 검정**: 회귀분석의 사후검정 (7가지 가정에 대한 준수여부 판단)
6. **모형 해석 및 결론 도출**

오늘 강의 요약

- 산포도 상에서 두 변수 x, y 의 관계가 대략적인 선형관계를 따를 경우, x 의 변화를 통해 y 의 변화량을 추정해볼 수 있다.
- x 에 대응하는 y 의 부분집합별 평균을 추정하는 직선을 찾는 통계적 방법을 회귀분석이라 한다.
- 두 변수 x, y 간의 상관계수를 알고 있을 경우, 회귀직선의 기울기는 $r \times (SD_y / SD_x)$ 와 같다.
- 회귀(regression)는 극단적인 값도 평균으로 돌아가는 성질이 있기 때문에 붙여진 이름이다.
- 회귀직선 위의 점은 x 에 대응하는 y 의 평균에 대한 추정치이며, 이 값과 실제 관측값 간의 차이를 추정오차라 한다.
- 추정오차의 표준적인 값을 구하기 위해 추정오차 제곱의 평균값에 제곱근을 씌운 것을 표준오차라 한다.
- 두 변수의 평균을 지나는 무수히 많은 직선 중 표준오차를 최소화하는 직선의 기울기와 절편을 찾는 추정방법을 최소제곱법이라고 하며, 이 때 구한 기울기는 상관계수와 두 변수의 표준편차로 구한 기울기와 같다.

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr