



2026-2학기 도시교통통계학

6강. 회귀분석 (2)

2026. 10. 7.

퀴즈 1 풀이

퀴즈 1 풀이

1. 다음 명제의 참과 거짓을 판별하시오.

(1) 모든 자료에 같은 상수 10을 더하면 평균은 10만큼 커지지만 표준편차는 변하지 않는다. (참, 거짓)

(2) 키를 cm 대신 m 단위로 측정하면 키와 몸무게 사이의 상관계수 값도 달라진다. (참, 거짓)

(3) 두 변수의 상관계수가 0에 가까우면 두 변수 사이에는 아무런 관계도 없다고 말할 수 있다. (참, 거짓)

퀴즈 1 풀이

1. 다음 명제의 참과 거짓을 판별하시오.

(1) 모든 자료에 같은 상수 10을 더하면 평균은 10만큼 커지지만 표준편차는 변하지 않는다. (참, 거짓)

→ 참 — 상수를 더하면 자료 전체가 평행이동할 뿐 흩어진 정도는 같다

(2) 키를 cm 대신 m 단위로 측정하면 키와 몸무게 사이의 상관계수 값도 달라진다. (참, 거짓)

→ 거짓 — 상관계수는 표준단위로 바꾼 값의 평균이라 측정단위와 무관하다

(3) 두 변수의 상관계수가 0에 가까우면 두 변수 사이에는 아무런 관계도 없다고 말할 수 있다. (참, 거짓)

→ 거짓 — 상관계수는 선형관계만 잴다. 비선형 관계가 있어도 0에 가까울 수 있다


퀴즈 1 풀이

2. 같은 과목을 두 반에서 따로 시험을 보았다. A반 점수는 평균 60점, 표준편차 10점, B반 점수는 평균 70점, 표준편차 5점인 정규분포를 따른다.

A반 철수는 75점, B반 영희는 78점을 받았다.

(1) 두 학생의 표준점수(Z)를 각각 구하고, 자기 반 안에서 상대적으로 더 잘한 학생은 누구인지 쓰시오.

(2) A반에서 철수보다 높은 점수를 받은 학생은 대략 몇 %인지 답과 풀이과정을 쓰시오. (단, $P(0 < Z < 1.5) = 0.4332$, $P(0 < Z < 1.6) = 0.4452$)




퀴즈 1 풀이

2. 같은 과목을 두 반에서 따로 시험을 보았다. A반 점수는 평균 60점, 표준편차 10점, B반 점수는 평균 70점, 표준편차 5점인 정규분포를 따른다.

A반 철수는 75점, B반 영희는 78점을 받았다.

(1) 두 학생의 표준점수(Z)를 각각 구하고, 자기 반 안에서 상대적으로 더 잘한 학생은 누구인지 쓰시오.

(2) A반에서 철수보다 높은 점수를 받은 학생은 대략 몇 %인지 답과 풀이과정을 쓰시오. (단, $P(0 < Z < 1.5) = 0.4332$, $P(0 < Z < 1.6) = 0.4452$)



(1) <정규분포를 따르는 자료의 표준화>

$$Z(\text{철수}) = (75 - 60) / 10 = 1.5$$

$$Z(\text{영희}) = (78 - 70) / 5 = 1.6$$

→ 영희가 자기 반에서 더 잘했다


퀴즈 1 풀이

2. 같은 과목을 두 반에서 따로 시험을 보았다. A반 점수는 평균 60점, 표준편차 10점, B반 점수는 평균 70점, 표준편차 5점인 정규분포를 따른다.

A반 철수는 75점, B반 영희는 78점을 받았다.

(1) 두 학생의 표준점수(Z)를 각각 구하고, 자기 반 안에서 상대적으로 더 잘한 학생은 누구인지 쓰시오.

(2) A반에서 철수보다 높은 점수를 받은 학생은 대략 몇 %인지 답과 풀이과정을 쓰시오. (단, $P(0 < Z < 1.5) = 0.4332$, $P(0 < Z < 1.6) = 0.4452$)



(1) <정규분포를 따르는 자료의 표준화>

$$Z(\text{철수}) = (75 - 60) / 10 = 1.5$$

$$Z(\text{영희}) = (78 - 70) / 5 = 1.6$$

→ 영희가 자기 반에서 더 잘했다


$$(2) P(Z > 1.5) = 0.5 - P(0 < Z < 1.5)$$

$$= 0.5 - 0.4332 = 0.0668$$

답: 6.68%


퀴즈 1 풀이

3. 어느 강의의 중간고사(x)와 기말고사(y) 점수는 모두 평균 70점, 표준편차 10점이고, 두 시험 점수 사이의 상관계수는 0.6이다. 중간고사 점수로 기말고사 점수를 예측하는 회귀직선의 기울기를 구하시오.



퀴즈 1 풀이

3. 어느 강의의 중간고사(x)와 기말고사(y) 점수는 모두 평균 70점, 표준편차 10점이고, 두 시험 점수 사이의 상관계수는 0.6이다. 중간고사 점수로 기말고사 점수를 예측하는 회귀직선의 기울기를 구하시오.



$$\text{기울기} = r \times \text{SDy} / \text{SDx}$$

$$= 0.6 \times 10 / 10 = 0.6$$

두 시험의 표준편차가 같으므로
회귀직선의 기울기는 상관계수와 같다


답: 0.6

지난 강의 요약

1. 산포도 상에서 두 변수 x , y 의 관계가 대략적인 선형관계를 따를 경우, x 의 변화를 통해 y 의 변화량을 추정해볼 수 있다.
2. x 에 대응하는 y 의 부분집합별 평균을 추정하는 직선을 찾는 통계적 방법을 회귀분석이라 한다.
3. 두 변수 x , y 간의 상관계수를 알고 있을 경우, 회귀직선의 기울기는 $r \times (SD_y / SD_x)$ 와 같다.
4. 회귀(regression)는 극단적인 값도 평균으로 돌아가는 성질이 있기 때문에 붙여진 이름이다.
5. 회귀직선 위의 점은 x 에 대응하는 y 의 평균에 대한 추정치이며, 이 값과 실제 관측값 간의 차이를 추정오차라 한다.
6. 추정오차의 표준적인 값을 구하기 위해 추정오차 제곱의 평균값에 제곱근을 씌운 것을 표준오차라 한다.
7. 두 변수의 평균을 지나는 무수히 많은 직선 중 표준오차를 최소화하는 직선의 기울기와 절편을 찾는 추정방법을 최소제곱법이라고 하며, 이 때 구한 기울기는 상관계수와 두 변수의 표준편차로 구한 기울기와 같다.

회귀분석



x변수에 대응하는 y변수의 "부분집합별" 평균값을 추정하는 통계적 방법



상관계수를 활용한 회귀직선의 기울기 도출

x변수에 대응하는 y변수의 평균값을 추정하는 통계적 방법

분포를 하나의 직선으로 근사 →



$$\text{회귀직선의 기울기} = r * \frac{SD_y}{SD_x}$$

→ 상관계수를 y의 단위로 변환하는 것

$$\rightarrow y = a + (r * SD_y / SD_x) * X$$

회귀방정식 (regression equation)

x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식

$$Y = b_0 + b_1 X$$
$$b_1 = r * \frac{SD_y}{SD_x} \quad b_0 = \bar{Y} - b_1 \bar{X}$$

종속변수(dependent variable, Y)

추정되는 변수 (궁극적으로 알고자 하는 변수)


설명변수(독립변수)(independent variable, X)

종속변수를 추정하기 위해 활용하는 변수

회귀방정식 (regression equation)

x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식


회귀직선의 기울기와 절편 구하기



30-40세 도시남성 198명의 표본자료

- 평균 교육연수 = 12.5년
- 교육연수 표준편차 = 2년
- 평균 소득 = 163만원
- 소득 표준편차 = 77만원
- 상관계수 = 0.33

$$\text{월소득} = 4.25\text{만원} + 12.7\text{만원/년} \times \text{교육연수}$$



$$\begin{aligned} \text{기울기} &= r \times (\text{SDy} / \text{SDx}) = 12.7\text{만원/년} \\ 12.5\text{년} \times 12.7\text{만원/년} &= 158.75\text{만원} \\ \text{절편} &= 163\text{만원} - 158.75\text{만원} = 4.25\text{만원} \end{aligned}$$

연습문제: 회귀방정식 구하기

x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식

$$Y = b_0 + b_1 X$$
$$b_1 = r * \frac{SD_y}{SD_x} \quad b_0 = \bar{Y} - b_1 \bar{X}$$

회귀직선의 기울기와 절편 구하기: 교육연수(x)로 소득(y)을 추정

도시여성 근로자 108명의 표본자료

- 평균 교육연수 = 11년
- 교육연수 표준편차 = 3.6년
- 평균 소득 = 89만원
- 소득 표준편차 = 60만원
- 상관계수 = 0.43

연습문제: 회귀방정식 구하기

x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식

$$Y = b_0 + b_1 X$$
$$b_1 = r * \frac{SD_y}{SD_x} \quad b_0 = \bar{Y} - b_1 \bar{X}$$

회귀직선의 기울기와 절편 구하기: 교육연수(x)로 소득(y)을 추정

도시여성 근로자 108명의 표본자료

- 평균 교육연수 = 11년
- 교육연수 표준편차 = 3.6년
- 평균 소득 = 89만원
- 소득 표준편차 = 60만원
- 상관계수 = 0.43

$$\text{월소득} = 9.8\text{만원} + 7.2\text{만원/년} * \text{교육연수}$$

$$\text{기울기} = 0.43 * 60\text{만원} / 3.6\text{년} = 7.2\text{만원 /년}$$

$$\text{절편} = 89\text{만원} - 7.2\text{만원/년} * 11\text{년} = 9.8\text{만원}$$

회귀분석의 해석


- **설명변수의 기울기**: x값 1단위 변화와 관련한 y값의 **평균**적인 변화량
- **절편**: x값이 0일 때 y값의 상태

예시) 회귀방정식이 다음과 같을 경우

$$\text{월소득} = 9.8\text{만원} + 7.2\text{만원} * \text{교육연수}$$

- 교육연수가 12년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 12년 = 96.2만원
- 교육연수가 16년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 16년 = 125만원

해석) 교육수준의 1년 증가와 관련해 월 소득은 평균적으로 7.2만원 증가함



회귀분석의 해석


- **설명변수의 기울기**: x값 1단위 변화와 관련한 y값의 **평균**적인 변화량
- **절편**: x값이 0일 때 y값의 상태

예시) 회귀방정식이 다음과 같을 경우

$$\text{월소득} = 9.8\text{만원} + 7.2\text{만원} * \text{교육연수}$$

- 교육연수가 12년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 12년 = 96.2만원
- 교육연수가 16년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 16년 = 125만원

해석) 교육수준의 1년 증가와 관련해 월 소득은 평균적으로 7.2만원 증가함



외부에서 임의로 추출한 개인에게 4년의 추가 교육을 시키면 28.8만원 소득이 증가할까?

회귀분석의 해석


- **설명변수의 기울기**: x값 1단위 변화와 관련한 y값의 **평균**적인 변화량
- **절편**: x값이 0일 때 y값의 상태

예시) 회귀방정식이 다음과 같을 경우

$$\text{월소득} = 9.8\text{만원} + 7.2\text{만원} * \text{교육연수}$$

- 교육연수가 12년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 12년 = 96.2만원
- 교육연수가 16년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 16년 = 125만원

해석) 교육수준의 1년 증가와 관련해 월 소득은 평균적으로 7.2만원 증가함



외부에서 임의로 추출한 개인에게 4년의 추가 교육을 시키면 28.8만원 소득이 증가할까?

→ 혼동요인(설명변수 이외의 개입할 다른 요인)이 존재 (개인의 성향, 나이, 가정환경 등)

혼동요인의 통제

- 실험을 통한 통제
- 제3의 요인을 활용한 집단의 구분: 성별, 연령대 ...
예. 홈런과 사사구 수의 관계 → 규정타석 타자 / 그 외 타자
- 중회귀분석: 성별, 연령을 다른 설명변수(통제변수)로 고려
예. 홈런과 사사구 수의 관계 → 모든 타자를 고려하되 홈런 수 외에 타석 수를 설명변수로 추가

회귀분석의 해석


- **설명변수의 기울기**: x값 1단위 변화와 관련한 y값의 **평균적인** 변화량
- **절편**: x값이 0일 때 y값의 상태

예시) 회귀방정식이 다음과 같을 경우

$$\text{월소득} = 9.8\text{만원} + 7.2\text{만원} * \text{교육연수}$$

- 교육연수가 12년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 12년 = 96.2만원
- 교육연수가 16년인 경우 추정소득 = 9.8만원 + 7.2만원/년 * 16년 = 125만원

해석) 교육수준의 1년 증가와 관련해 월 소득은 평균적으로 7.2만원 증가함



외부에서 임의로 추출한 개인에게 4년의 추가 교육을 시키면 28.8만원 소득이 증가할까?

→ 혼동요인(설명변수 이외의 개입할 다른 요인)이 존재 (개인의 성향, 나이, 가정환경 등)

→ 다른 요인으로부터 완벽하게 통제된 실험에서만 가능 하지만 우리의 분석결과는 단지 표본조사를 통해 얻어낸 관측자료에 불과

→ 실험을 통한 통제가 어렵기 때문에 통계적 통제(statistical control)의 수단인 중회귀분석(multiple regression) 수행

단순회귀와 (다)중회귀

단순회귀(simple regression)

하나의 설명변수(X)와 종속변수(Y) 간의 관계를 분석

$$\text{아파트 가격 (Y)} = a + b * \text{접근성(X)}$$

(다)중회귀(multiple regression)

둘 이상의 설명변수(X1, X2, X3...)와 종속변수(Y) 간의 관계를 분석

$$\text{아파트 가격 (Y)} = a + b1 * \text{접근성(X1)} + b2 * \text{평수(X2)} + b3 * \text{연식(X3)} \dots$$

아파트 가격에 영향을 미치는
다른 요인들을 함께 고려함으로써
접근성이 아파트 가격에 미치는
(가급적) 순수한 영향을 파악



혼동요인을 통제함으로써
관심을 갖는 설명변수가
미치는 영향을 더 잘 설명

회귀분석을 사용할 때 주의사항


- 회귀분석은 변수 간의 선형관계를 파악: 비선형(non-linear) 관계 X
- 선형관계의 존재(즉, 높은 상관계수)만으로 유의미한 결과라고 볼 수 없음

예. 아이스크림 판매량이 증가하면 일사병이 많이 걸린다.

→ 이론적 토대 + 설명 가능여부의 중요성

결정계수 (coefficient of determination)

“회귀직선이 y 의 변화를 설명하는 정도”로서 전체 편차 중에 회귀선이 설명하는 비율을 의미



$$y_i - \bar{y} = [(a + bx_i) - \bar{y}] + [y_i - (a + bx_i)]$$

$$T = R + E$$

$$\sum (y_i - \bar{y})^2 = \sum [(a + bx_i) - \bar{y}]^2 + \sum [y_i - (a + bx_i)]^2$$

$$SST = SSR + SSE$$


(회귀식으로 설명됨) (회귀식으로 설명 안 됨)

- SST(총제곱합): y 의 평균 주위로의 총변동
- SSR(회귀제곱합): 회귀직선에 의해 설명되는 변동
- SSE(잔차(오차)제곱합): 회귀직선에 의해 설명되지 않는 변동

결정계수 (coefficient of determination)

“회귀직선이 y 의 변화를 설명하는 정도”로서 전체 편차 중에 회귀선이 설명하는 비율을 의미

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (0 \leq R^2 \leq 1) \quad \text{1에 가까울수록 높은 설명력 (단순회귀에서는 상관계수의 제곱)}$$



$$y_i - \bar{y} = [(a + bx_i) - \bar{y}] + [y_i - (a + bx_i)]$$

$$T = R + E$$

$$\sum (y_i - \bar{y})^2 = \sum [(a + bx_i) - \bar{y}]^2 + \sum [y_i - (a + bx_i)]^2$$

$$SST = SSR + SSE$$

(회귀식으로 설명됨) (회귀식으로 설명 안 됨)

- SST(총제곱합): y 의 평균 주위로의 총변동
- SSR(회귀제곱합): 회귀직선에 의해 설명되는 변동
- SSE(잔차(오차)제곱합): 회귀직선에 의해 설명되지 않는 변동

조정된 결정계수 (adjusted R2)

“회귀직선이 y의 변화를 설명하는 정도”로서 전체 편차 중에 회귀선이 설명하는 비율을 의미

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$$(0 \leq R^2 \leq 1)$$

1에 가까울수록 높은 설명력 (단순회귀에서는 상관계수의 제곱)

→ 설명변수가 추가되면 SSE는 무조건 감소

→ 결정계수는 계속 증가 (많은 설명변수를 가진 모형이 무조건 유리?!)

$$\text{adj } R^2 = 1 - \frac{SSE/(n - k - 1)}{SST/(n - 1)}$$

n = 표본크기

k = 설명변수의 개수

설명변수가 추가될수록 자유도가 감소하도록 조정

→ 설명변수 추가에 따른 SSE의 감소속도 < 설명변수 추가에 따른 자유도 감소 속도

→ 표준오차가 증가 → 조정된 결정계수는 오히려 감소

→ 설명변수 추가에 따라 SSE가 충분히 많이 감소해야
(즉, 설명변수가 잔차를 크게 줄여야)

회귀직선의 설명력인 조정된 결정계수가 증가

$$cf) SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

회귀분석에 대해 우리가 아직 안 배운 것들

회귀분석을 통해 추정된 기울기와 절편은 표본자료가 바뀌더라도 얼마나 유지될까?

→ 기울기와 절편의 유의성 검정

회귀분석은 어떠한 상황을 만족해야(어떤 조건 하에서만) 신뢰할 만한 분석일까?

→ 회귀분석의 조건과 조건에 위배될 경우에 적합한 다른 방법들

오늘 강의 요약

1. x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식을 회귀방정식이라 한다.
2. 회귀분석에서 추정되는 변수를 종속변수, 종속변수를 추정하기 위해 사용하는 변수를 설명변수(독립변수)라 한다.
3. 회귀방정식에서 설명변수의 기울기는 설명변수 1단위 변화에 따른 종속변수의 평균적 변화량을 의미한다.
4. 하나의 설명변수로 종속변수의 변동을 설명하려는 회귀분석을 단순회귀분석, 둘 이상의 설명변수로 종속변수의 변동을 설명하려는 회귀분석을 (다)중회귀분석이라 한다.
5. 중회귀분석은 종속변수 변동에 영향을 미치는 여러 요인들을 동시에 고려함으로써, 혼동요인을 통제하고 설명변수가 종속변수에 미치는 순수한 효과를 더 잘 파악할 수 있게 한다.
6. 결정계수는 총 변동 중 회귀직선을 통해 설명 가능한 변동의 비중을 의미한다.
7. 회귀분석은 만병통치약이 아니며, 설명변수로 종속변수의 변화를 추정할 때는 이론적 토대가 반드시 필요하다.

Q & A

권규상 Kyusang Kwon
kyusang.kwon@chungbuk.ac.kr