2026-2학기 도시교통통계학

8강. 확률이론 (1)

2026. 10. 21.

중간고사 풀이

중간고사 풀이: 1. 참과 거짓 (1)~(3)

1. 다음 명제의 참과 거짓을 판별하시오. (6점, 각 1점)

(1) 같은 모집단에서 표본을 다시 뽑더라도 표본의 평균(통계량)은 언제나 같은 값이 나온다. (참, 거짓)

(2) 계급구간의 길이가 서로 다른 히스토그램에서 각 막대의 넓이(구간길이×높이)는 그 계급의 상대빈도와 같다. (참, 거짓)

(3) 표본의 표준편차를 구할 때 n 이 아니라 n−1 로 나누는 것은 평균을 먼저 계산하면서 자유도가 하나 줄기 때문이다. (참, 거짓)

중간고사 풀이: 1. 참과 거짓 (1)~(3)

1. 다음 명제의 참과 거짓을 판별하시오. (6점, 각 1점)

(1) 같은 모집단에서 표본을 다시 뽑더라도 표본의 평균(통계량)은 언제나 같은 값이 나온다. (참, 거짓)

→ **거짓: 모수는 하나로 정해져 있으나, 통계량은 표본을 다시 뽑으면 값이 달라진다 (2강)**

(2) 계급구간의 길이가 서로 다른 히스토그램에서 각 막대의 넓이(구간길이×높이)는 그 계급의 상대빈도와 같다. (참, 거짓)

→ **참: 밀도 = 상대빈도 / 구간길이 이므로 밀도 × 구간길이 = 상대빈도 (2강)**

(3) 표본의 표준편차를 구할 때 n 이 아니라 n−1 로 나누는 것은 평균을 먼저 계산하면서 자유도가 하나 줄기 때문이다. (참, 거짓)

→ **참: 평균을 쓰는 순간 값 하나가 묶이므로 마음대로 정할 수 있는 값은 n−1 개다 (2강)**

중간고사 풀이: 1. 참과 거짓 (4)~(6)

(4) 왼쪽으로 늘어진(left-skewed) 분포에서는 일반적으로 평균이 중앙값보다 크다. (참, 거짓)

(5) 상관계수는 이상치(outlier) 하나에 의해서도 값이 크게 달라질 수 있다. (참, 거짓)

(6) 회귀모형에 설명변수를 추가하면 결정계수(R^2)는 줄어들지 않지만, 조정된 결정계수는 줄어들 수 있다. (참, 거짓)

중간고사 풀이: 1. 참과 거짓 (4)~(6)

(4) 왼쪽으로 늘어진(left-skewed) 분포에서는 일반적으로 평균이 중앙값보다 크다. (참, 거짓)

→ **거짓: 왼쪽으로 늘어지면 평균 < 중앙값 < 최빈값 이다. 평균이 긴 꼬리 쪽으로 끌려간다 (2강)**

(5) 상관계수는 이상치(outlier) 하나에 의해서도 값이 크게 달라질 수 있다. (참, 거짓)

→ **참: 상관계수는 이상치에 민감하다 (4강 상관계수의 한계)**

(6) 회귀모형에 설명변수를 추가하면 결정계수(R^2)는 줄어들지 않지만, 조정된 결정계수는 줄어들 수 있다. (참, 거짓)

→ **참: 설명변수가 추가되면 SSE 는 줄거나 같아 R^2 는 줄지 않는다. 조정된 결정계수는 자유도 감소를 반영하므로 줄 수 있다 (6강)**

중간고사 풀이: 2. 빈칸 채우기

2. 다음 문장의 빈칸에 알맞은 용어를 쓰시오. (6점, 각 1점)

(1) 관심 대상이 되는 전체 집단의 특성을 나타내는 값으로, 하나로 정해져 있으나 대개 알 수 없는 값을 (　　)라 한다.

(2) 히스토그램에서 각 계급의 상대빈도를 구간의 길이로 나눈 값을 (　　)라 하며, 이 값이 막대의 높이가 된다.

(3) 제3사분위수에서 제1사분위수를 뺀 값을 (　　)라 한다.

(4) 두 변수의 편차를 곱해 평균한 값으로, 두 변수의 측정단위를 그대로 지니는 통계량을 (　　)이라 한다.

(5) 처음 측정한 값이 극단적이었던 대상이 다음 측정에서는 평균에 더 가까운 값을 보이는 현상을 (　　)라 한다.

(6) 두 변수의 결합분포를 나타내기 위해 한 변수를 x축에, 다른 변수를 y축에 두고 점으로 찍은 그림을 (　　)라 한다.

중간고사 풀이: 2. 빈칸 채우기

2. 다음 문장의 빈칸에 알맞은 용어를 쓰시오. (6점, 각 1점)

(1) 관심 대상이 되는 전체 집단의 특성을 나타내는 값으로, 하나로 정해져 있으나 대개 알 수 없는 값을 (**모수**)라 한다.

(2) 히스토그램에서 각 계급의 상대빈도를 구간의 길이로 나눈 값을 (**밀도**)라 하며, 이 값이 막대의 높이가 된다.

(3) 제3사분위수에서 제1사분위수를 뺀 값을 (**사분위수 범위 (IQR)**)라 한다.

(4) 두 변수의 편차를 곱해 평균한 값으로, 두 변수의 측정단위를 그대로 지니는 통계량을 (**공분산**)이라 한다.

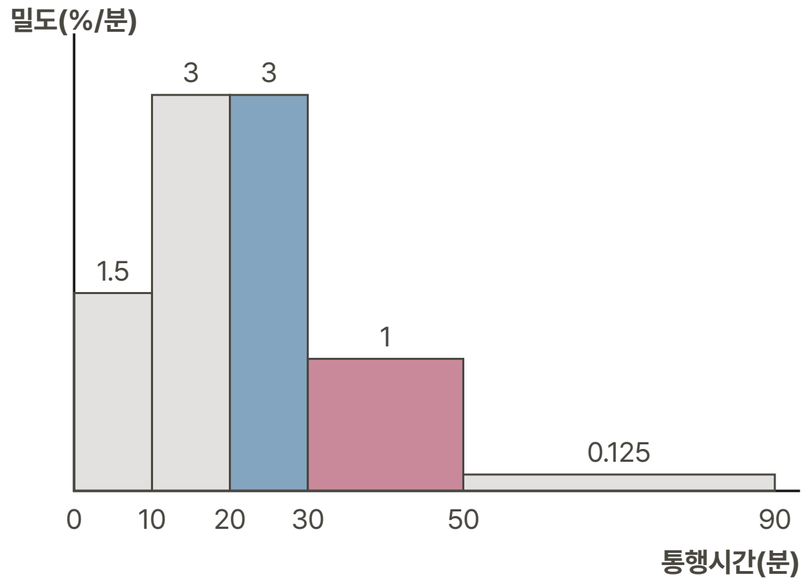
(5) 처음 측정한 값이 극단적이었던 대상이 다음 측정에서는 평균에 더 가까운 값을 보이는 현상을 (**회귀효과 (평균으로의 회귀)**)라 한다.

(6) 두 변수의 결합분포를 나타내기 위해 한 변수를 x축에, 다른 변수를 y축에 두고 점으로 찍은 그림을 (**산포도**)라 한다.

중간고사 풀이: 3. 도수분포표와 히스토그램

3. 청주시 시내버스 승객 200명의 통행시간(분)을 조사하여 아래의 도수분포표를 얻었다. (4점)
(단, 계급구간은 좌측경계는 포함하되 우측경계는 포함하지 않음)

계급(분)	0-10	10-20	20-30	30-50	50-90
빈도(명)	30	60	60	40	10



(1) 30-50분 계급의 밀도 (%/분)

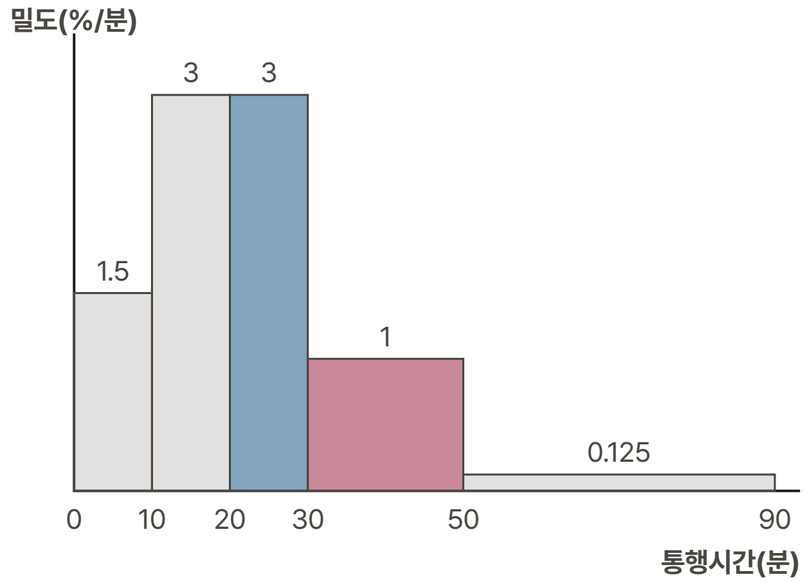
(2) 중앙값이 속한 계급

(3) 평균과 중앙값 중 더 큰 쪽과 그 이유

중간고사 풀이: 3. 도수분포표와 히스토그램

3. 청주시 시내버스 승객 200명의 통행시간(분)을 조사하여 아래의 도수분포표를 얻었다. (4점)
(단, 계급구간은 좌측경계는 포함하되 우측경계는 포함하지 않음)

계급(분)	0-10	10-20	20-30	30-50	50-90
빈도(명)	30	60	60	40	10



(1) 30-50분 계급의 밀도 (%/분)

상대빈도 = 40 / 200 = 20%, 구간길이 = 20분 → 밀도 = 1.0

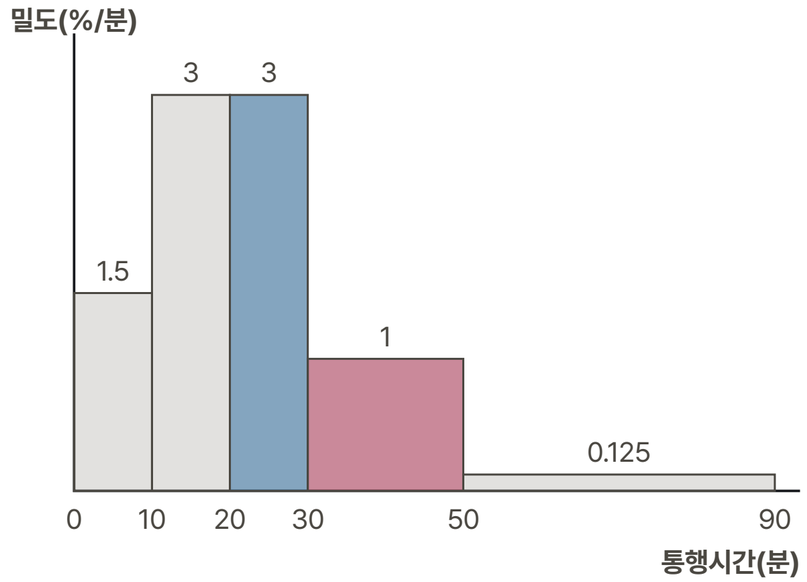
(2) 중앙값이 속한 계급

(3) 평균과 중앙값 중 더 큰 쪽과 그 이유

중간고사 풀이: 3. 도수분포표와 히스토그램

3. 청주시 시내버스 승객 200명의 통행시간(분)을 조사하여 아래의 도수분포표를 얻었다. (4점)
(단, 계급구간은 좌측경계는 포함하되 우측경계는 포함하지 않음)

계급(분)	0-10	10-20	20-30	30-50	50-90
빈도(명)	30	60	60	40	10



(1) 30-50분 계급의 밀도 (%/분)

상대빈도 = 40 / 200 = 20%, 구간길이 = 20분 → 밀도 = 1.0

(2) 중앙값이 속한 계급

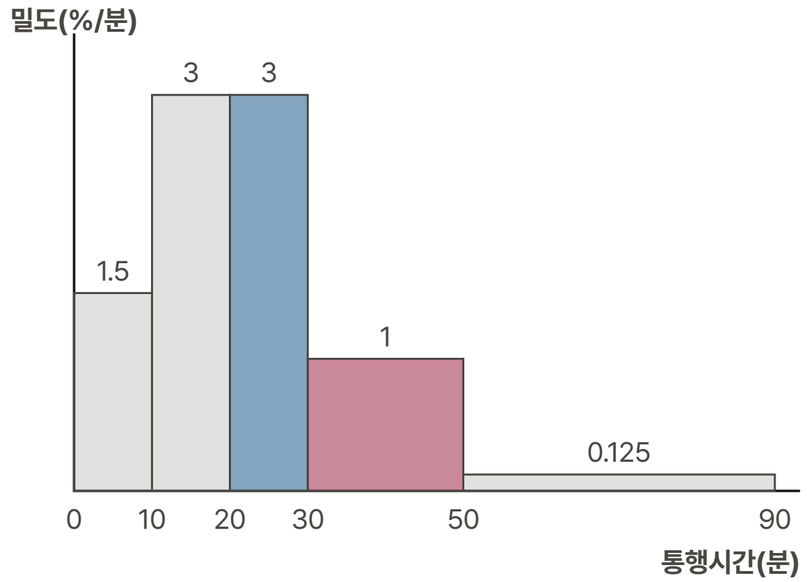
누적빈도 30 → 90 → 150. 중앙값은 100번째와 101번째 값의 평균이므로 20-30분 계급

(3) 평균과 중앙값 중 더 큰 쪽과 그 이유

중간고사 풀이: 3. 도수분포표와 히스토그램

3. 청주시 시내버스 승객 200명의 통행시간(분)을 조사하여 아래의 도수분포표를 얻었다. (4점)
(단, 계급구간은 좌측경계는 포함하되 우측경계는 포함하지 않음)

계급(분)	0-10	10-20	20-30	30-50	50-90
빈도(명)	30	60	60	40	10



(1) 30-50분 계급의 밀도 (%/분)

상대빈도 = 40 / 200 = 20%, 구간길이 = 20분 → 밀도 = 1.0

(2) 중앙값이 속한 계급

누적빈도 30 → 90 → 150. 중앙값은 100번째와 101번째 값의 평균이므로 20-30분 계급

(3) 평균과 중앙값 중 더 큰 쪽과 그 이유

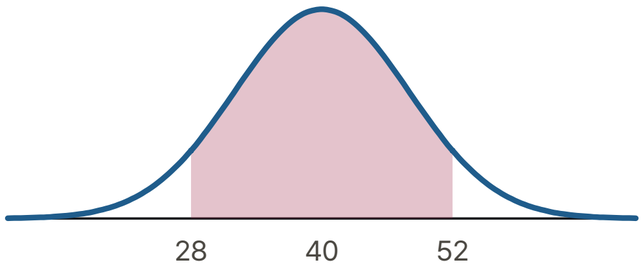
평균: 50-90분 계급까지 오른쪽으로 길게 늘어진(right-skewed) 분포이다. 평균은 극단적인 값의 영향을 받아 긴 꼬리 쪽으로 끌려가므로 중앙값보다 크다

중간고사 풀이: 4. 정규분포

4. 어느 도시 직장인의 출근 통행시간은 평균 40분, 표준편차 8분인 정규분포를 따른다고 한다. (5점)
(1) 출근 통행시간이 28분 이상 52분 이하인 직장인은 대략 몇 %인지 답과 풀이과정을 쓰시오. (2점)
(2) 통행시간이 가장 긴 상위 10%에 속하려면 출근 통행시간이 최소 몇 분이어야 하는지 답과 풀이과정을 쓰시오. (답은 소수점 둘째 자리에서 반올림) (3점)

중간고사 풀이: 4. 정규분포

4. 어느 도시 직장인의 출근 통행시간은 평균 40분, 표준편차 8분인 정규분포를 따른다고 한다. (5점)
(1) 출근 통행시간이 28분 이상 52분 이하인 직장인은 대략 몇 %인지 답과 풀이과정을 쓰시오. (2점)
(2) 통행시간이 가장 긴 상위 10%에 속하려면 출근 통행시간이 최소 몇 분이어야 하는지 답과 풀이과정을 쓰시오. (답은 소수점 둘째 자리에서 반올림) (3점)



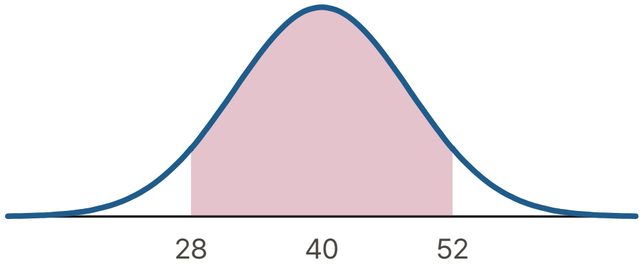
(1) $Z(28) = (28 - 40) / 8 = -1.5$, $Z(52) = 1.5$

$P(-1.5 \le Z \le 1.5) = 2 \times \Phi(1.5) - 1 = 2 \times 0.9332 - 1 = 0.8664$

답: 약 86.64%

중간고사 풀이: 4. 정규분포

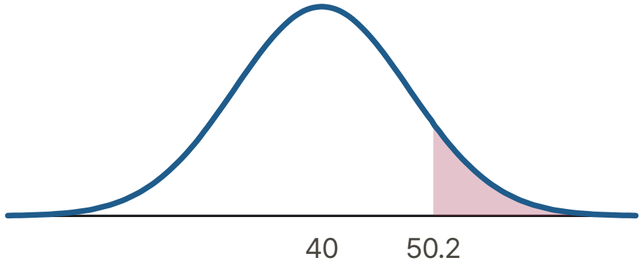
4. 어느 도시 직장인의 출근 통행시간은 평균 40분, 표준편차 8분인 정규분포를 따른다고 한다. (5점)
(1) 출근 통행시간이 28분 이상 52분 이하인 직장인은 대략 몇 %인지 답과 풀이과정을 쓰시오. (2점)
(2) 통행시간이 가장 긴 상위 10%에 속하려면 출근 통행시간이 최소 몇 분이어야 하는지 답과 풀이과정을 쓰시오. (답은 소수점 둘째 자리에서 반올림) (3점)



(1) $Z(28) = (28 - 40) / 8 = -1.5$, $Z(52) = 1.5$

$P(-1.5 \le Z \le 1.5) = 2 \times \Phi(1.5) - 1 = 2 \times 0.9332 - 1 = 0.8664$

답: 약 86.64%



(2) 상위 10% 의 경계는 $\Phi(z) = P(Z \le z) = 0.90$ 이 되는 z

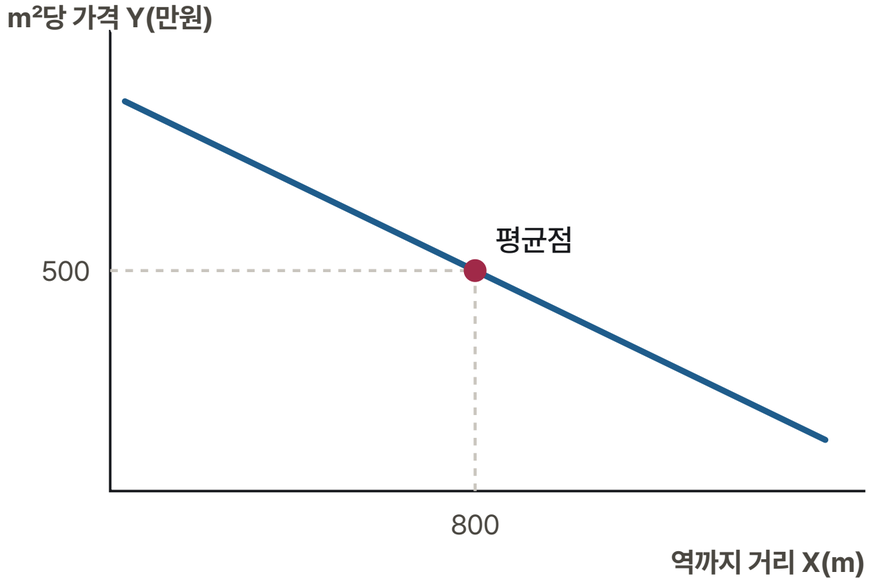
$\Phi(1.28) = 0.8997$, $\Phi(1.29) = 0.9015 \rightarrow z \approx 1.28$

$X = \mu + z\sigma = 40 + 1.28 \times 8 = 50.24$

답: 약 50.2분 (z = 1.29 로 보아 50.3분도 정답)

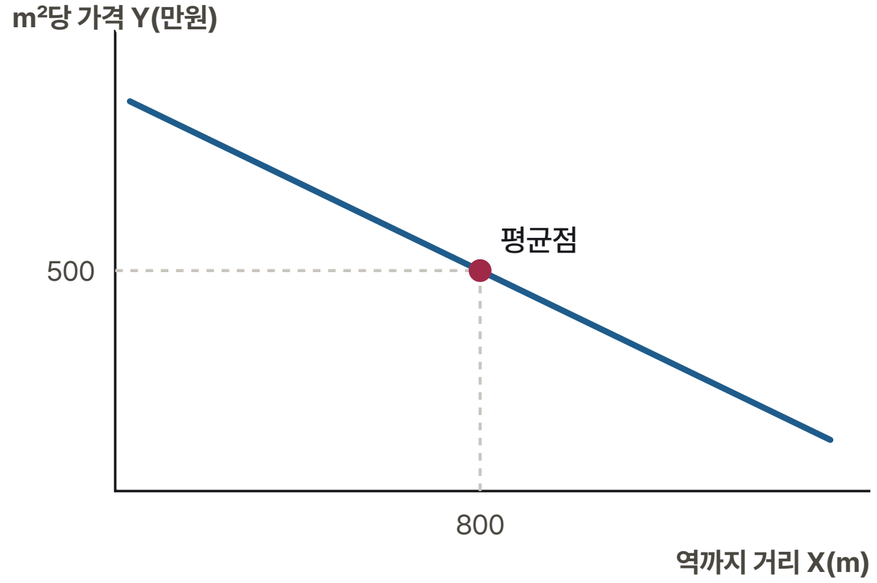
중간고사 풀이: 5. 회귀방정식

5. 어느 도시 아파트의 m²당 가격(Y, 만원)과 가장 가까운 지하철역까지의 거리(X, m)에 대한 요약 통계량은 다음과 같다. (5점)
X 의 평균 800m, 표준편차 200m · Y 의 평균 500만원, 표준편차 80만원 · X 와 Y 의 상관계수 −0.6
(1) 거리(X)로 m²당 가격(Y)을 추정하는 회귀방정식을 구하시오. (3점)
(2) 역에서 600m 떨어진 아파트의 m²당 가격을 추정하시오. (2점)



중간고사 풀이: 5. 회귀방정식

5. 어느 도시 아파트의 m²당 가격(Y, 만원)과 가장 가까운 지하철역까지의 거리(X, m)에 대한 요약 통계량은 다음과 같다. (5점)
X 의 평균 800m, 표준편차 200m · Y 의 평균 500만원, 표준편차 80만원 · X 와 Y 의 상관계수 −0.6
(1) 거리(X)로 m²당 가격(Y)을 추정하는 회귀방정식을 구하시오. (3점)
(2) 역에서 600m 떨어진 아파트의 m²당 가격을 추정하시오. (2점)



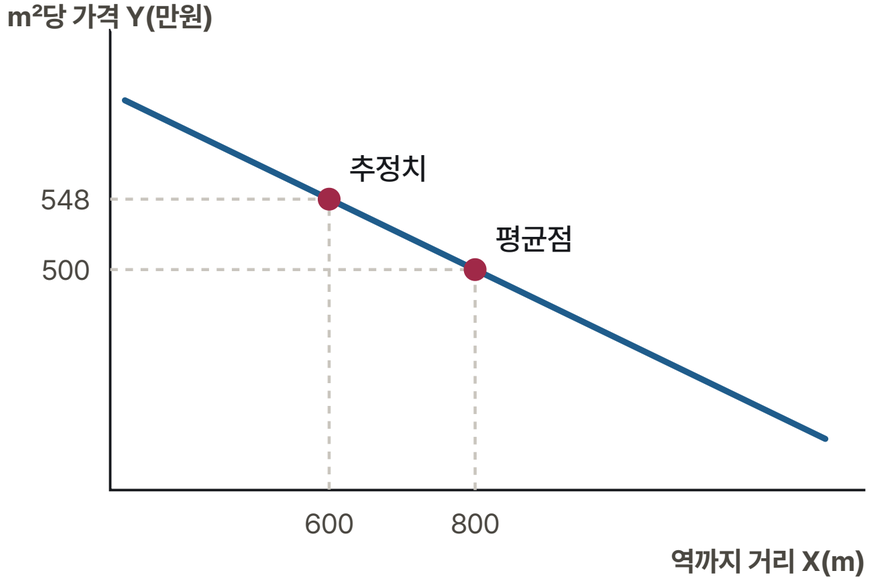
(1) 기울기 $b_1 = r \times SDy / SDx = -0.6 \times 80 / 200 = -0.24$ (만원/m)

절편 $b_0 = \bar{Y} - b_1\bar{X} = 500 - (-0.24 \times 800) = 692$

답: Y = 692 − 0.24X

중간고사 풀이: 5. 회귀방정식

5. 어느 도시 아파트의 m²당 가격(Y, 만원)과 가장 가까운 지하철역까지의 거리(X, m)에 대한 요약 통계량은 다음과 같다. (5점)
X 의 평균 800m, 표준편차 200m · Y 의 평균 500만원, 표준편차 80만원 · X 와 Y 의 상관계수 −0.6
(1) 거리(X)로 m²당 가격(Y)을 추정하는 회귀방정식을 구하시오. (3점)
(2) 역에서 600m 떨어진 아파트의 m²당 가격을 추정하시오. (2점)



(1) 기울기 $b_1 = r \times SDy / SDx = -0.6 \times 80 / 200 = -0.24$ (만원/m)

절편 $b_0 = \bar{Y} - b_1\bar{X} = 500 - (-0.24 \times 800) = 692$

답: $Y = 692 - 0.24X$

(2) $Y = 692 - 0.24 \times 600 = 548$

답: 548만원

중간고사 풀이: 6. 결정계수와 조정된 결정계수

6. 표본 12개 동(n = 12)의 대중교통 이용률(Y)을 설명하는 두 회귀모형을 추정하였다. 총제곱합(SST)은 두 모형 모두 500 이다. (4점)
모형 A: 설명변수 1개 (역까지 거리), SSE = 200 · 모형 B: 설명변수 3개 (역까지 거리, 인구밀도, 가구소득), SSE = 180
(1) 두 모형의 R^2 와 조정된 R^2 를 각각 구하시오. (소수점 셋째 자리에서 반올림) (2점)
(2) 어느 모형을 고르는 것이 적절한지 쓰고, 그 이유를 설명하시오. (2점)

중간고사 풀이: 6. 결정계수와 조정된 결정계수

6. 표본 12개 동(n = 12)의 대중교통 이용률(Y)을 설명하는 두 회귀모형을 추정하였다. 총제곱합(SST)은 두 모형 모두 500 이다. (4점)
모형 A: 설명변수 1개 (역까지 거리), SSE = 200 · 모형 B: 설명변수 3개 (역까지 거리, 인구밀도, 가구소득), SSE = 180
(1) 두 모형의 R^2 와 조정된 R^2 를 각각 구하시오. (소수점 셋째 자리에서 반올림) (2점)
(2) 어느 모형을 고르는 것이 적절한지 쓰고, 그 이유를 설명하시오. (2점)

$R^2 = 1 - SSE / SST$ · 조정된 $R^2 = 1 - [SSE / (n - k - 1)] / [SST / (n - 1)]$

모형	설명변수 k	SSE	자유도 n−k−1	R^2	조정된 R^2
A	1	200	10	0.60	0.56
B	3	180	8	0.64	0.51

중간고사 풀이: 6. 결정계수와 조정된 결정계수

6. 표본 12개 동(n = 12)의 대중교통 이용률(Y)을 설명하는 두 회귀모형을 추정하였다. 총제곱합(SST)은 두 모형 모두 500 이다. (4점)
모형 A: 설명변수 1개 (역까지 거리), SSE = 200 · 모형 B: 설명변수 3개 (역까지 거리, 인구밀도, 가구소득), SSE = 180
(1) 두 모형의 R^2 와 조정된 R^2 를 각각 구하시오. (소수점 셋째 자리에서 반올림) (2점)
(2) 어느 모형을 고르는 것이 적절한지 쓰고, 그 이유를 설명하시오. (2점)

$R^2 = 1 - SSE / SST$ · 조정된 $R^2 = 1 - [SSE / (n - k - 1)] / [SST / (n - 1)]$

모형	설명변수 k	SSE	자유도 n−k−1	R^2	조정된 R^2
A	1	200	10	0.60	0.56
B	3	180	8	0.64	0.51

답: 모형 A

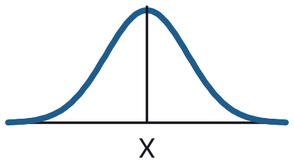
B 는 설명변수를 둘 더했지만 SSE 가 20 만 줄어 R^2 가 0.04 오르는 데 그쳤다. 그 대가로 자유도가 10 에서 8 로 줄어 조정된 R^2 는 0.56 에서 0.51 로 낮아졌다. 설명력을 공정하게 비교하는 조정된 R^2 가 더 큰 A 가 적절하다

자료(표본)요약의 중요성과 확률의 필요성

모집단
(population)

관심의 대상이 되는 전체

모집단 분포



표본추출
(sampling)
: 모집단 분포에 따른
확률로 추출

→ 관심대상의 확률변수화에 방식에 따라
이미 알려진 분포로 표현 가능

→ 모집단 분포를 이미 알려진 분포로 표현하기 위해서는
반드시 알아야 할 필요한 모수가 있음
예. 정규분포(μ, σ)

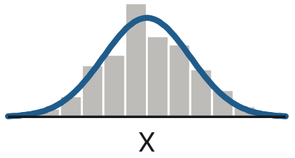
표본
(sample)

모집단의 관측된 일부

표본의 분포

- 요약정리: 히스토그램
- 수학적 근사: 확률질량(밀도)함수

→ 표본은 모집단의 분포를 따름



모수
(parameter)

모집단의 특성(모분포의 요약)

1개 특성
- (모)평균
- (모)분산(표준편차)
- 왜도
- 첨도
- 기타: 중앙값, 최빈값, 분위수 등

2개 이상 특성
- 공분산 → 상관계수
- 회귀계수

추론
(inference)
: 모수추정량은 모수와
얼마만큼 비슷할까?
↓
확률 개념이 필요

통계량
(statistics)

모수추정량

표본의 특성(표본분포의 요약)

1개 특성
- (표본)평균
- (표본)분산(표준편차)
- 왜도
- 첨도
- 기타: 중앙값, 최빈값, 분위수 등

2개 이상 특성
- 공분산 → 상관계수
- 회귀계수

확률(probability)이란?

어떤 사건이 일어날 가능성

- **주관적 견해 (subjective view)**

  그 사건에 대한 주관적 확신의 정도

- **도수이론 (frequency theory)**

  한 시행을 동일한 조건에서 독립적으로 반복했을 때,
  전체 시행횟수에서 그 사건이 일어난 횟수의 비율(상대도수)

확률의 범위

- 절대로 일어날 수 없는 사건의 확률 = 0
- 반드시 일어나는 사건의 확률 = 1

} 확률은 0 ~ 1 사이의 값을 가진다

확률의 표현

- 어떤 사건: A
- A 사건이 일어날 확률: $P(A)$
- A 사건이 일어나지 않을 확률: $P(A^c) = 1 - P(A)$
- A 사건의 여사건(A가 일어나지 않는 사건): A^c

관심을 갖는 사건을 잘 정의하는 것이 중요!

↓

- 어떤 사건 A : 동전의 앞면이 나오는 것
- A 사건이 일어날 확률 $P(A)$: 동전의 앞면이 나올 확률 = ½
- A 사건이 일어나지 않을 확률 $P(A^c) = 1 - P(A)$: 동전의 앞면이 나오지 않을 확률 = 동전의 뒷면이 나올 확률 = 1/2
- A 사건의 여사건 A^c: 동전의 뒷면이 나오는 것

확률의 계산: 도수이론 기반

- 무한 반복시행해서 전체 시행횟수 대비 사건이 발생하는 횟수의 비율을 구함

- 사건의 특성을 보고 가능한 경우를 생각(나열)해서 확률을 계산

확률의 계산



- **무한 반복시행**

  (F, B, F, F, F, B, B ..., F, F, B, B)

  앞면 횟수: 3123980125480125802185021850 1회

  뒷면 횟수: 3123980125480125802185021820 1회

  동전에서 앞면이 나올 확률: ?

- **사건의 특성을 보고 가능한 경우를 생각(나열)**

  동전에서 나올 수 있는 모든 경우의 수: 앞면, 뒷면 (2개)

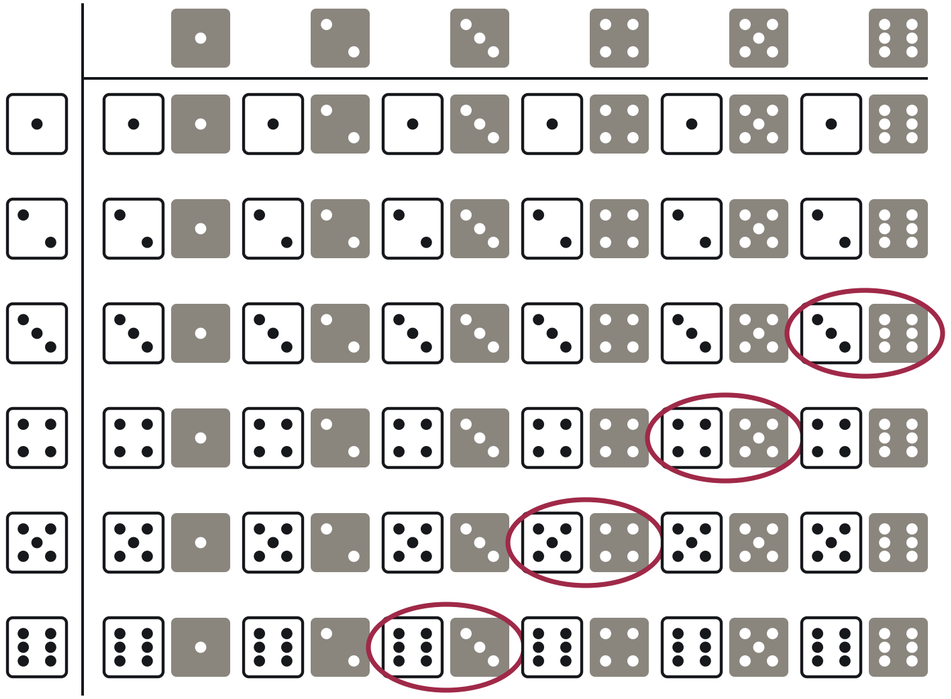
  동전에서 앞면이 나오는 경우의 수: 앞면 (1개)

  동전에서 앞면이 나올 확률: 앞면이 나오는 경우 / 모든 경우 = 1/2

확률의 계산

두 개의 주사위를 던져 9가 나올 확률은?

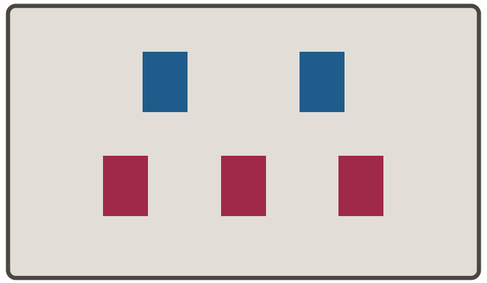
- 모든 경우의 수: 36개
- 9가 나오는 경우의 수: 4개 (6, 3), (3, 6), (4, 5), (5, 4)
- 9가 나올 확률: 4/36 = 1/9



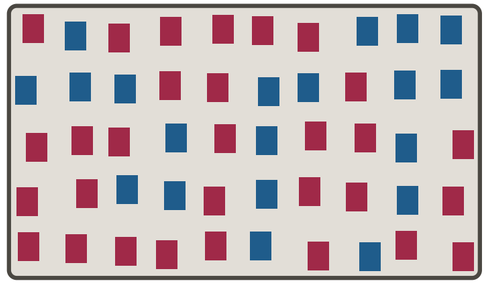
확률의 계산

상자 A와 B에서 **한 장의 카드를 꺼낼 때**
붉은 카드를 꺼낼 확률 P(R)은
A와 B에서 서로 다른가?

- 꺼낸 카드가 붉은 색이라는 사건: R
- R이 발생할 확률: P(R)
- 꺼낸 카드가 붉은 색이 아닐 확률: 1−P(R)



상자 A
(붉은 카드 3장, 푸른 카드 2장)



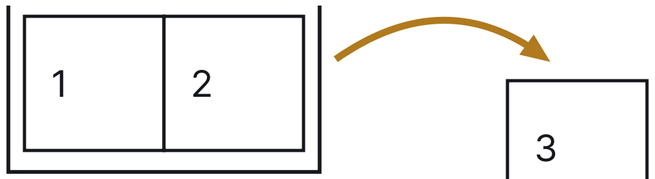
상자 B
(붉은 카드 30장, 푸른 카드 20장)

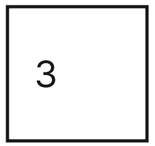
$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{3}{5}$$

복원추출과 비복원추출

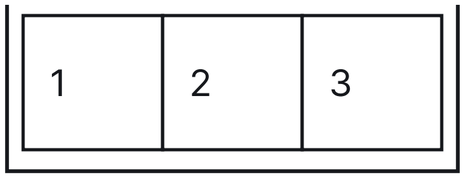
두 장의 카드를 순서대로 꺼내는 경우

첫 번째 추출

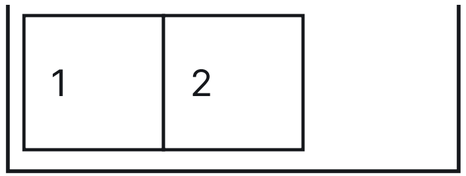




두 번째 추출



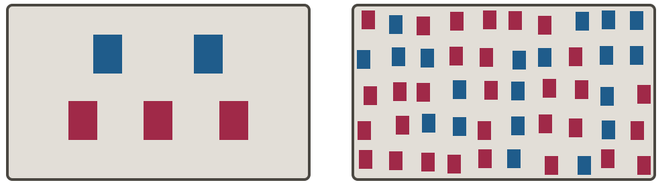
복원 추출



비복원 추출

복원추출과 비복원추출

상자 A와 B에서 **두 장의 카드를 차례로 꺼내는 경우**
두 번째에서 붉은 카드를 꺼낼 확률 P(R)은
A와 B에서 서로 다른가?



상자 A
(붉은 카드 3장, 푸른 카드 2장)

상자 B
(붉은 카드 30장, 푸른 카드 20장)

- 복원추출

  = 시행에 따라 전체카드의 수와 붉은 카드의 수가 변하지 않음

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{3}{5}$$

- 비복원추출 = 시행에 따라 전체 카드의 수와 붉은 카드의 수가 변함

〈상자 A〉

첫번째 시행

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{3}{5}$$

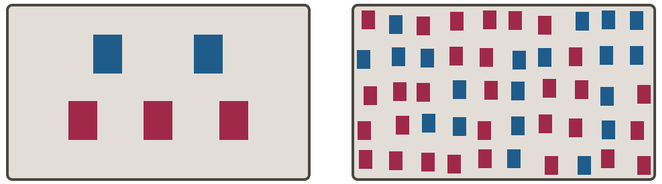
$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{2}{4}$$ **첫번째 시행에서 붉은 카드를 꺼냈을 경우**

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{3}{4}$$ **첫번째 시행에서 파란 카드를 꺼냈을 경우**

→ 첫 장을 본 뒤의 확률 $P(R|\cdot)$ 은 0.5 와 0.75 로 갈린다

복원추출과 비복원추출

상자 A와 B에서 **두 장의 카드를 차례로 꺼내는 경우**
두 번째에서 붉은 카드를 꺼낼 확률 P(R)은
A와 B에서 서로 다른가?



상자 A
(붉은 카드 3장, 푸른 카드 2장)

상자 B
(붉은 카드 30장, 푸른 카드 20장)

- 복원추출

  = 시행에 따라 전체카드의 수와 붉은 카드의 수가 변하지 않음

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{3}{5}$$

- 비복원추출 = 시행에 따라 전체 카드의 수와 붉은 카드의 수가 변함

〈상자 B〉

첫번째 시행

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{30}{50}$$

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{29}{49}$$ **첫번째 시행에서 붉은 카드를 꺼냈을 경우**

$$P(R) = \frac{\text{붉은 카드의 수}}{\text{전체 카드의 수}} = \frac{30}{49}$$ **첫번째 시행에서 파란 카드를 꺼냈을 경우**

→ B 에서는 0.59 와 0.61 로 거의 붙는다. 무조건부 $P(R)$ 은 A·B 모두 3/5 로 같다

표본공간과 사건

- **사건 (event)**

  특정한 실험 혹은 시행에서 관찰 가능한 결과, 표본공간의 부분 집합

- **표본공간 (sample space)**

  특정한 실험 혹은 시행에서 관찰 가능한 모든 결과(근원사건)의 집합

- **확률 (probability)**

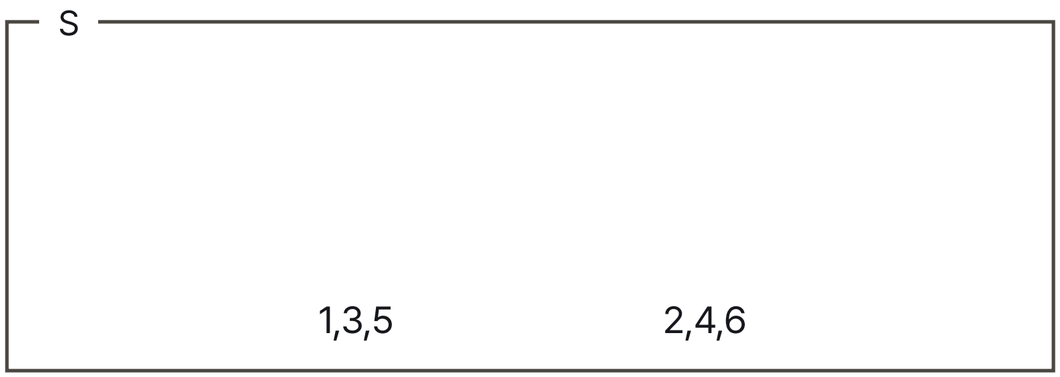
  사건 A의 확률은 표본공간에서 사건 A가 나타나는 경우가 모든 사건의 경우의 수에서 차지하는 비중

표본공간과 사건

- 동전 2회 던지기라는 시행
- 표본공간 S = {HH, HT, TH, TT}



- 주사위 던지기라는 시행
- 표본공간 S = {1,2,3,4,5,6}



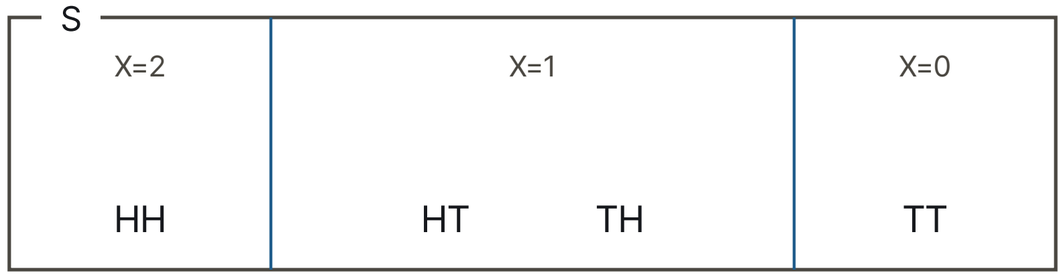
확률변수 (random variable)

표본공간에서 정의되는 각 사건들에 대응하는 실수 값 → 우리가 관심을 갖는 형태로 구성

- 동전 2회 던지기라는 시행
- 표본공간 S = {HH, HT, TH, TT}
- **각 사건을 앞면이 나오는 횟수로 변환한 확률변수**

  HH = 2, HT = 1, TH = 1, TT = 0

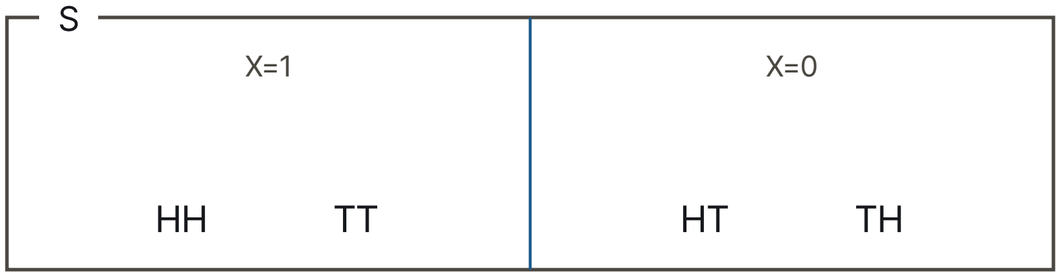
  X = {0, 1, 2}



- 동전 2회 던지기라는 시행
- 표본공간 S = {HH, HT, TH, TT}
- **각 사건을 두 면이 동일한 경우로 변환한 확률변수**

  HH = 1, HT = 0, TH = 0, TT = 1

  X = {0, 1}



확률분포 (probability distribution)

확률변수가 출현할 가능성, 즉 사건이 발생할 가능성에 대한 분포

- 동전 2회 던지기라는 시행
- 표본공간 S = {HH, HT, TH, TT}
- 각 사건을 앞면이 나오는 횟수로 변환한 확률변수
  HH = 2, HT = 1, TH = 1, TT = 0
  X = {0, 1, 2}
- **각 확률변수가 발생할 가능성: P(X)**

S		
X=2 P(X=2) =1/4	X=1 P(X=1) =1/2	X=0 P(X=0) =1/4
HH	HT TH	TT

- 주사위 던지기라는 시행
- 표본공간 S = {1,2,3,4,5,6}
- 각 사건을 홀수와 짝수로 변환한 확률변수
  1 = 1, 2 =0, 3 = 1, 4 = 0, 5 = 1, 6 = 0
  X = {0, 1}
- **각 확률변수가 발생할 가능성: P(X)**

S	
X=1 P(X=1) = 1/2	X=0 P(X=0) = 1/2
1,3,5	2,4,6

이산변수와 연속변수의 확률

- **이산변수**

  주사위를 2개 던져서 나온 눈의 합이라는 사건

  동전을 던져서 앞면이 나올 사건

  → 특정 값에 대한 사건의 확률 계산 가능 (∵ 경우의 수를 셀 수 있으므로)

- **연속변수**

  1~10 사이의 실수 중에서 하나의 수를 뽑는 사건

  → 특정 값에 대한 사건의 확률은 모두 0에 수렴 (∵ 경우의 수를 셀 수 없으므로)

  → 연속사건의 경우 특정 값에 대한 확률이 아닌 특정 구간에 속할 확률을 계산

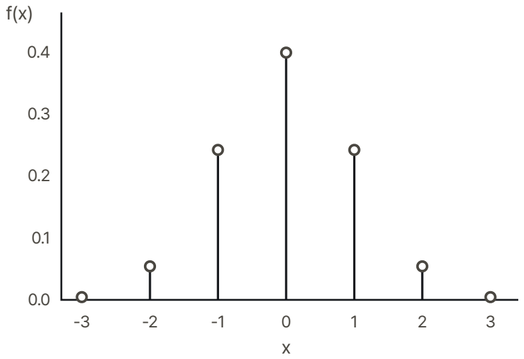
이산변수와 연속변수의 확률을
그래프와 수식으로 나타내면?

히스토그램, 확률질량함수, 확률밀도함수

히스토그램(histogram): 사건확률을 그래프로 나타낸 것

어떤 자료를 계급으로 나눈 도수분포표의 상대도수를 밀도화하여 그래프로 표현한 것

이산변수의 히스토그램



특정 값의 상대빈도 계산 o

→ 특정 값의 상대빈도 계산

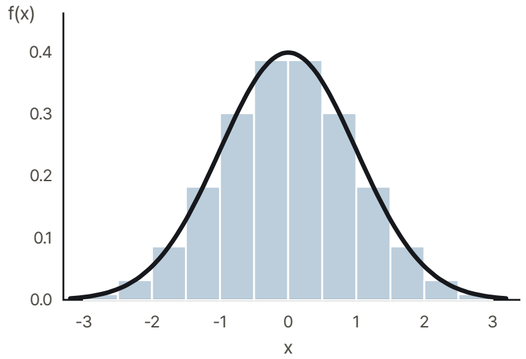
f(x) = 높이 = 밀도

= 상대도수 / 구간길이

= 상대도수 / 1

= 개별 값의 확률

연속변수의 히스토그램



특정 값의 상대빈도 계산 x

→ 구간의 상대빈도 계산

f(x) = 높이 = 밀도

= 상대도수 / 구간길이

→ 밀도 × 구간길이 = 그 구간에 속할 확률

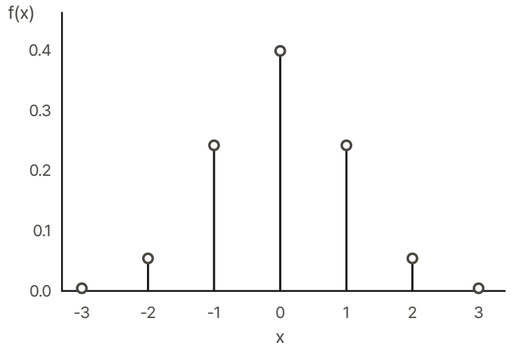
이미지 출처: Continuous and discrete statistical distributions (wasyresearch.com)

히스토그램, 확률질량함수, 확률밀도함수

히스토그램(histogram): 사건확률을 그래프로 나타낸 것

어떤 자료를 계급으로 나눈 도수분포표의 상대도수를 밀도화하여 그래프로 표현한 것

이산변수의 히스토그램



f(x) = 높이 = 밀도

= 상대도수 / 구간길이

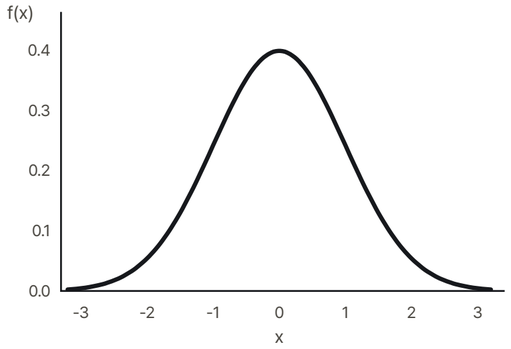
= 상대도수 / 1

= 개별 값의 확률

↓

확률질량함수

연속변수의 히스토그램



f(x) = 높이 = 밀도

= 상대도수 / 구간길이

→ 밀도 × 구간길이 = 그 구간에 속할 확률

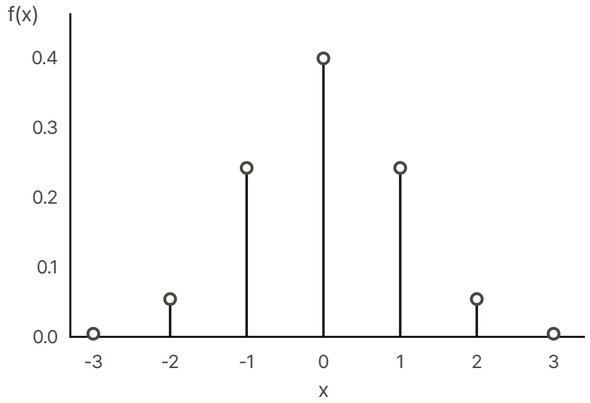
↓

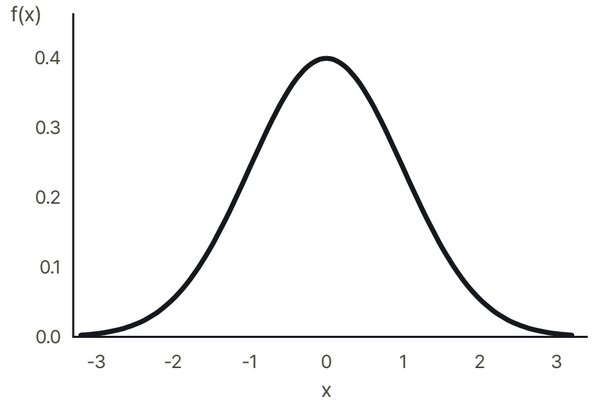
확률밀도함수

이미지 출처: Continuous and discrete statistical distributions (wasyresearch.com)

→ 히스토그램을 밀도로 표현하는 이유: 확률질량함수와 확률밀도함수 모두에 대응하기 위해서!

확률질량함수와 확률밀도함수





이미지 출처: Continuous and discrete statistical distributions (wasyresearch.com)

- **확률질량함수(probability mass function)**

  이산확률변수의 밀도분포를 나타내는 함수로서 특정 확률변수의 함수값 그 자체를 확률로 갖는 함수

- **확률밀도함수(probability density function)**

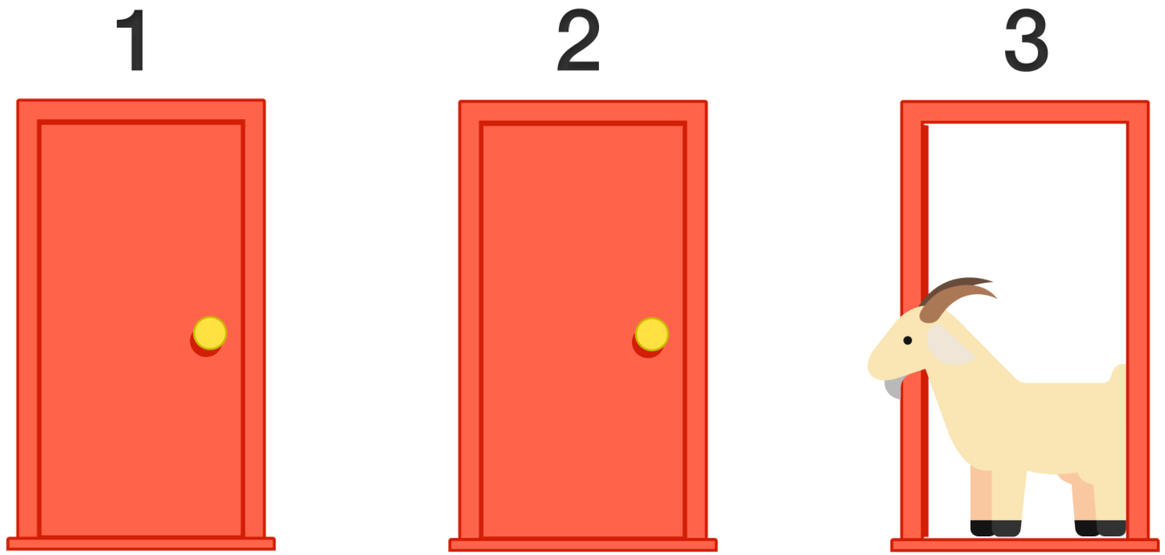
  연속확률변수의 밀도분포를 나타내는 함수로서 특정 확률변수 구간의 면적을 확률로 갖는 함수

오늘 강의 요약

- 자료의 요약 통계량이 동일 모집단의 다른 표본에서도 유사할지를 판단하기 위해 확률개념이 필요하다.
- 확률이란 어떤 사건이 일어날 가능성을 의미한다.
- 확률은 어떤 사건 발생 가능성에 대한 주관적 확신의 정도나, 한 시행을 동일한 조건에서 독립적으로 반복했을 때 전체 시행횟수에서 그 사건이 일어난 횟수의 비율로 나타낸다.
- 확률은 0~1 사이의 값을 가지며, 각 사건의 확률은 시행을 무한 반복하거나 사건의 특성을 보고 개념적으로 계산할 수 있다.
- 사건이란 특정 시행이나 실험에서 관찰가능한 결과를 의미하며, 표본공간은 발생 가능한 모든 결과(근원사건)의 집합을 의미한다.
- 표본공간에서 발생하는 각 사건들에 대응한 실수 값을 확률변수라하며, 각 확률변수가 나타날 가능성에 대한 분포가 바로 확률분포이다.
- 이산확률변수에 대한 확률분포함수를 확률질량함수, 연속확률변수에 대한 확률분포함수를 확률밀도함수라 한다.

몬티홀 문제

Q) 세 개의 문 중 **하나에는 자동차**가, 나머지 **두 개에는 염소**가 있다.
당신이 **문 하나를 선택**하면 사회자가 나머지 **두 개의 문 중에 염소가 있는 문 하나를 연다**.
그리고 열리지 않은 문을 두고 **다시 한번 선택할 수 있는 기회**를 준다.
선택을 **바꿀 것인가, 바꾸지 않을 것인가**?



Q & A

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr