



2026-2학기 도시교통통계학

14강. 도시교통통계학 요약

2026. 12. 2.

통계학이 필요한 이유

자료를 정리, 분석, 추론하여 유용한 정보를 이끌어냄으로써 효과적 · 효율적인 의사결정 지원



숫자는 스스로 말하지 않는다.

학습 목표

**다양한 도시현상을 데이터를 통해 분석하기 위한
기초적인 통계이론의 개념과 그 원리를 이해하는 것**

수식에 매몰되거나 통계 프로그램(SPSS, STATA, R 등)의 활용만을 강조하기 보다
통계이론의 원리 이해에 초점

한 학기 동안의 강의 내용

- 통계학과 자료의 정리: 히스토그램, 평균, 표준편차
- 정규분포와 정규분포로의 근사
- 상관관계
- 회귀분석

기술통계학

- 확률이론
- 대수의 법칙과 중심극한정리
- 표본추출과 추정
- 가설검정

추론통계학

통계학의 분류

기술통계학 (Descriptive Statistics)

주어진 자료를 변수별로 요약하여 자료의 특성을 추출하는 것

추론통계학 (Inferential Statistics)

정리된 자료에 대한 의미를 해석하여 미지의 세계에 대해 추론

자료의 요약: 하나의 변수

히스토그램 · 평균과 중앙값 · 표준편차 · 정규분포로의 근사

자료 요약의 중요성

어떻게 복잡한 자료를 쉽게 이해할 수 있을까?

그래프로 만들기

숫자 하나로 만들기

$X \sim N(170, 5^2)$ / 500개 랜덤추출

자료요약 (1) 그래프로 만들기: 도수분포표와 히스토그램

도수분포표
(frequency table)

자료를 일정한 계급/구간으로 나누어 해당 구간에 속하는 자료의 빈도를 나타낸 분포표


히스토그램
(histogram)

도수분포표를 그래프로 나타낸 것


도수분포표

계급	(절대)빈도	상대빈도	밀도
150-155	0	0	0
155-160	17	0.034	0.0068
160-165	63	0.126	0.0252
165-170	170	0.34	0.0680
170-175	168	0.336	0.0672
175-180	70	0.14	0.0280
180-185	11	0.022	0.0044
185-190	1	0.002	0.0004

히스토그램(절대빈도)



히스토그램(밀도)



자료요약 (1) 그래프로 만들기: 도수분포표와 히스토그램

도수분포표
(frequency table)

자료를 일정한 계급/구간으로 나누어 해당 구간에 속하는 자료의 빈도를 나타낸 분포표

히스토그램
(histogram)

도수분포표를 그래프로 나타낸 것

장점: 자료의 분포와 그 이면의 특징(중심점, 중심점으로부터의 퍼진 정도 등)에 대한 파악 가능

단점: 자료의 세부적인 수치에 대한 정보 상실 (계급으로 묶기 때문)

자료요약 (1) 그래프로 만들기: 히스토그램 그리기

- 1단계** 자료 내에서 최대값과 최소값을 찾는다.
- 2단계** 최대값과 최소값이 포함되도록 자르기 좋은 대강의 범위를 만들고 그 범위 내에서 작은 범위, 즉 계급을 만든다.
(계급 수 산정식: $k = 1 + 3.3 \log_{10} N$, $k = 5 \times \log_{10} N$)
- 3단계** 각 계급 내에 속한 자료의 총 개수를 센다. 이 개수가 바로 도수 혹은 빈도(frequency)이다.
- 4단계** 각 계급의 도수가 전체에서 차지하는 비율을 계산한다.
이 비율이 바로 상대도수 혹은 상대빈도(relative frequency)이며, 상대도수는 전체에서 차지하는 비율이므로 그 합은 반드시 1이다.
- 5단계** 그래프의 x축에 계급을 순서대로 나열하고, 각 계급별로 상대도수의 크기를 고려하여 블록높이를 결정한다.
계급구간별 면적(=계급의 폭x높이)은 상대도수의 크기와 같아야 하며, 이 때 각 계급구간별 높이가 바로 밀도(density)이다.

* 밀도(density): 일정한 단위 당 자료의 비율 (물리학: 밀도(density) = 질량(mass) / 부피)

자료요약 (2) 숫자 하나로 만들기: 평균, 중앙값, 최빈값


평균 (mean)

자료의 총합을 자료의 개수로 나눈 것

→ 히스토그램의 무게 중심*

* 모든 자료와 자신과의 차이인 편차의 합을 0으로 만드는
지점

대칭(symmetric)




중앙값 (median)

전체 자료의 50%에 위치한 값

→ 히스토그램의 면적을 양분하는 값

오른쪽으로 늘어짐
(right-skewed / positive-skewed)




최빈값 (mode)

자료 내에서 빈도가 가장 큰 값

→ 히스토그램의 최대 높이를 갖는 값

왼쪽으로 늘어짐
(left-skewed / negative-skewed)



평균은 극단적인 값의 영향을 받지만, 중앙값은 극단적인 값의 영향을 받지 않음

자료요약 (2) 평균과 불확실성: 표준편차의 중요성

표준편차
(standard deviation)

관측치들이 평균으로부터 얼마나 떨어져 있는지를 나타내는 정도

포트폴리오	수익률
주식수익률 A	0, 1, -3, 3, -1
주식수익률 B	0, 5, -7, 7, -5

A, B의 평균수익률은 모두 0

→ 두 포트폴리오는 같은 특성을 지니고 있다고 볼 수 있는가?

자료를 대표하는 특성으로 평균은 부족하다!

자료요약 (2) 평균과 불확실성: 표준편차의 중요성

표준편차
(standard deviation)

관측치들이 평균으로부터 얼마나 떨어져 있는지를 나타내는 정도

분포를 파악하는 방법

$$s = \sqrt{\frac{\sum (X_i - \bar{X})^2}{n - 1}}$$

- 1 평균으로부터의 편차(= 개별 관측치 - 자료의 평균)를 모두 합해보자**
→ 평균으로부터의 편차의 합은 모든 자료에서 언제나 0이라 분포차이를 구할 수 없음
- 2 평균으로부터의 편차를 제곱하여 합해보자**
→ 편차 제곱의 합은 자료의 개수에 영향 (자료가 많아질수록 제곱합의 크기도 증가)
- 3 평균으로부터의 편차 제곱합을 자료의 개수로 나눠보자**
→ 자료가 하나인 경우에는? → 자유도(degree of freedom)의 문제

* 자유도: 자료 내에서 실질적으로 독립인 값의 개수


자료요약의 중요성

자료를 잘 요약하면 복잡한 정보를 쉽게 파악할 수 있다.

자료를 잘 요약하면 자료의 대표값과 대표값을 중심으로 퍼진 정도를 알 수 있고,
이를 통해 자료를 이미 알려진 분포에 근사함으로써 예측도 할 수 있다.

정규분포의 근사 (normal approximation)

만약 어떤 확률변수가 정규분포와 유사한 형태의 분포를 지니고 있다면 그 분포를 정규분포로 간주하고, 표준화를 통해 어떤 구간 내에 속한 숫자의 비율을 구할 수 있다.



정규분포: 다음 특징을 지니면서 아래의 식을 따르는 분포

1. 평균을 중심으로 좌우 대칭 (symmetric)
2. 종 모양 (bell-shaped)
3. 봉우리가 하나 (single-peaked)

$$X \sim N(\mu, \sigma^2)$$

$$f(X) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{X-\mu}{\sigma}\right)^2}$$

$$(-\infty < x < +\infty)$$


“평균 50, 표준편차 5”인 분포

→ 40~60 사이에 속한 자료는 대략 몇 %일까?

정규분포의 근사 (normal approximation)

만약 어떤 확률변수가 정규분포와 유사한 형태의 분포를 지니고 있다면 그 분포를 정규분포로 간주하고, 표준화를 통해 어떤 구간 내에 속한 숫자의 비율을 구할 수 있다.

$$X \sim N(50, 5^2) \quad f(X) = \frac{1}{\sqrt{2\pi} * 5} e^{-\frac{1}{2} \left(\frac{X-50}{5} \right)^2}$$



40 = 평균 50 - 2표준편차

60 = 평균 50 + 2표준편차


자료가 정규분포와 유사할 경우

- 평균의 -1SD ~ +1SD 구간 내에 약 68% 자료가 포함
- 평균의 -2SD ~ +2SD 구간 내에 약 95% 자료가 포함
- 평균의 -3SD ~ +3SD 구간 내에 약 99.7% 자료가 포함

정규분포의 근사 (normal approximation)

만약 어떤 확률변수가 정규분포와 유사한 형태의 분포를 지니고 있다면 그 분포를 정규분포로 간주하고, 표준화를 통해 어떤 구간 내에 속한 숫자의 비율을 구할 수 있다.

$$X \sim N(50, 5^2) \quad f(X) = \frac{1}{\sqrt{2\pi} * 5} e^{-\frac{1}{2} \left(\frac{X-50}{5}\right)^2}$$



정규분포곡선 아래 구간의 면적(= 그 구간 내에 속한 자료의 비율 = 그 구간의 값이 나올 확률)을 구하는 법

1. (표준)정규분포곡선을 구간에 대하여 적분
2. 구간의 값을 표준화한 뒤 표준정규분포표를 통해 면적을 도출



자료의 요약: 두 개의 변수

결합분포와 산포도 · 공분산과 상관계수 · 회귀분석

결합분포와 산포도

결합분포(joint distribution): 하나의 변수에 대한 분포가 아니라 두 변수 사이의 상호관계를 고려한 분포

→ 산포도(scatter plot): 두 변수의 결합분포를 나타내기 위해 한 변수를 x축에, 다른 변수를 y축에 표시하여 점으로 나타낸 것




산포도에서 우리가 알 수 있는 값

- x의 평균과 표준편차
- y의 평균과 표준편차

→ x와 y는 평균과 표준편차를 통해 각각 요약 가능

→ 이것만으로 충분할까?

결합분포와 산포도



(a), (b) 모두 x , y 의 평균과 표준편차는 동일, 하지만 x , y 의 결합분포 특성은 다름

→ (a)와 (b)의 차이를 반영할 수 있도록 x 와 y 의 결합분포는 어떻게 요약할까?

공분산

두 변수의 선형관계를 나타내는 통계량

$$ax+by=c$$

$$Cov_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{(n - 1)}$$

표본 공분산의 자유도는 $n-1$
($\because \bar{x}, \bar{y}$ 가 주어져 있을 때 $\bar{y}$ 를 알더라도 $\bar{x}$ 를 구하기 위해서는 $n-1$ 개의 표본이 필요하므로)

- **공분산(Covariance)**: 하나의 변수에 대한 편차곱의 평균, 즉 분산(variance)를 두 변수에 대한 편차곱의 평균으로 바꾼 것
→ 공분산이 (+)이면 양의 관계, (-)이면 음의 관계
- **공분산의 한계**: 서로 다른 관계들의 강도를 상호 비교하기 어려움
 1. 측정단위를 그대로 지님: x가 키(cm)이고 y가 몸무게(kg)일 경우 공분산은 cm*kg이라는 단위를 지님
 2. 값의 한계가 없음: 측정단위에 따라서 값이 크게 변하며 한계가 없음→ 해결방법: 공분산을 두 변수의 표준편차로 나누어 표준단위로 변환하자!

상관계수

두 변수 간 선형관계의 방향과 강도를 측정단위와 무관하게 $-1 \sim +1$ 의 값으로 나타내는 통계량

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y}) / (n - 1)}{\sqrt{\sum (x_i - \bar{x})^2 / (n - 1)} \cdot \sqrt{\sum (y_i - \bar{y})^2 / (n - 1)}} = \frac{Cov_{xy}}{SD_x \cdot SD_y}$$


- 상관계수의 범위: $-1 \leq r \leq +1$

(1 또는 -1: 완전한 양의 상관 또는 음의 상관)

→ 모든 점들이 하나의 선 위에 위치


- 상관계수의 의미

두 변수의 결합분포가 하나의 선 주위로 밀집된 정도



주: 각각의 산포도는 가로, 세로 모두 평균 3, 표준편차 1의 동일한 값을 갖는다. 각각의 산포도에는 50개씩의 점이 찍혀 있다.

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, 키의 표준편차: 8.5cm
- 평균 몸무게: 63.5kg, 몸무게의 표준편차: 11.9kg
- 상관계수: 0.67

→ 다른 정보가 없을 때 임의로 한 개인을 선택할 경우 몸무게는 얼마일 것으로 추정할 수 있는가?

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, 키의 표준편차: 8.5cm
- 평균 몸무게: 63.5kg, 몸무게의 표준편차: 11.9kg
- 상관계수: 0.67

→ 다른 정보가 없을 때 임의로 한 개인을 선택할 경우 몸무게는 얼마일 것으로 추정할 수 있는가?

: 다른 정보가 없으므로 전체 평균인 63.5kg 수준일 것

회귀분석의 의미




주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, 키의 표준편차: 8.5cm
- 평균 몸무게: 63.5kg, 몸무게의 표준편차: 11.9kg
- 상관계수: 0.67


→ 만약 한 개인의 키가 179.5cm라는 정보가 있다면 그 값은 어떻게 바뀔까?

회귀분석




회귀분석

x변수에 대응하는 y변수의 “부분집합별” 평균값을 추정하는 통계적 방법



상관계수와 회귀분석의 연계



주: 실선은 회귀직선이고 점선은 표준편차선이다.

• 평균 키: 167.5cm, **키의 표준편차: 8.5cm**

• 평균 몸무게: 63.5kg, **몸무게의 표준편차: 11.9kg**

• 상관계수: 0.67

→ 모든 x에 대해서 부분집합을 구하고 y의 평균을 내기 어려움

→ 만약 한 개인의 키가 176cm라는 정보가 있을 경우

→ 상관계수를 통해 키를 고려한 몸무게의 수준을 더 정확히 추정할 수 있지 않을까?

상관계수의 의미의 재검토


$$\begin{aligned}
 r &= \frac{\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n-1}}{\sqrt{\frac{\sum (x_i - \bar{x})^2}{n-1}} \cdot \sqrt{\frac{\sum (y_i - \bar{y})^2}{n-1}}} \\
 &= \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \cdot \sqrt{\sum (y_i - \bar{y})^2}} = \frac{Cov_{xy}}{SD_x \cdot SD_y}
 \end{aligned}$$

X가 평균에서 벗어난 정도(편차)의 표준편차 단위 환산 = **X가 1표준편차 단위 변화할 때**

Y가 평균에서 벗어난 정도(편차)의 표준편차 단위 환산 = **Y는 표준편차 단위로 얼마나 변화할까?**

→ 그 변화에 대한 평균값 (그 반대도 성립)

상관계수의 의미



주: 실선은 회귀직선이고 점선은 표준편차선이다.

- 평균 키: 167.5cm, **키의 표준편차: 8.5cm**
- 평균 몸무게: 63.5kg, **몸무게의 표준편차: 11.9kg**
- 상관계수: 0.67


→ 키가 8.5cm 증가할 경우 몸무게는 얼마나 증가할까?

: 키가 1표준편차($1 \times 8.5\text{cm}$) 클 경우

몸무게는 **평균적으로** 0.67표준편차($0.67 \times 11.9\text{kg}$) 클 것


상관계수를 활용한 회귀직선의 기울기 도출

x변수에 대응하는 y변수의 평균값을 추정하는 통계적 방법



주: 실선은 회귀직선이고 점선은 표준편차선이다.

분포를 하나의 직선으로 근사



회귀직선의 기울기

$$= r * \frac{SD_y}{SD_x}$$

→ 상관계수를 y의 단위로 변환하는 것

$$\rightarrow y = a + (r * SD_y / SD_x) * X$$

회귀방정식 (regression equation)

x변수에 대응하는 y변수의 평균값을 추정하는 회귀직선을 나타내는 방정식

$$Y = \beta_0 + \beta_1 X$$

$$\beta_1 = r * \frac{SD_y}{SD_x}$$

x 표준편차 단위 변화에 따른 y의 평균 변화량
x값의 표준편차 단위로의 변환

종속변수(dependent variable, Y)

추정되는 변수 (궁극적으로 알고자 하는 변수)

설명변수(독립변수)(independent variable, X)

종속변수를 추정하기 위해 활용하는 변수


회귀의 표준오차 (standard error)

추정오차(estimation error) = 잔차(residual) = 실제값 - 추정치

표준오차(standard error): 잔차 제곱합을 자유도(n-2)로 나눈 뒤 제곱근을 취한 것

잔차 제곱의 **평균**에 제곱근을 취한 RMSE 와는 나누는 수만 다르다 (n 대신 n-2)

→ 표준오차가 작을수록 회귀직선이 자료를 잘 요약



$$SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

자유도가 2만큼 줄어드는 이유

: 추정치 계산 시 회귀직선의 기울기와 절편을 통계량으로 사용하므로


회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것

$$e_i = Y_i - b_0 - b_1 X_i$$

$$\sum e_i^2 = \sum (Y_i - b_0 - b_1 X_i)^2 \rightarrow \text{이 값을 최소화하는 모수 추정량 } b_0, b_1 = \text{최소제곱추정량}$$



$$SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

표준오차의 최소화 = 잔차제곱합의 최소화

회귀분석의 기울기와 절편의 추정: 최소제곱법

회귀직선의 **기울기와 절편을 추정**하기 위한 방법으로

산포도 상의 점들을 지나는 **수많은 직선 중 RMSE로 측정된 표준오차(잔차제곱합의 평균 제곱근)를 최소화하는 직선**을 찾는 것

$$e_i = Y_i - b_0 - b_1 X_i$$

$$\sum e_i^2 = \sum (Y_i - b_0 - b_1 X_i)^2 \quad \rightarrow \text{이 값을 최소화하는 모수 추정량 } b_0, b_1 = \text{최소제곱추정량}$$

$$\frac{\partial \sum e_i^2}{\partial b_0} = \sum -2(Y_i - b_0 - b_1 X_i) = 0$$

$$\frac{\partial \sum e_i^2}{\partial b_1} = \sum -2(Y_i - b_0 - b_1 X_i)X_i = 0$$


$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

결정계수 (coefficient of determination)

“회귀직선이 y 의 변화를 설명하는 정도”로서 전체 편차 중에 회귀선이 설명하는 비율을 의미

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST} \quad (0 \leq R^2 \leq 1) \quad \text{1에 가까울수록 높은 설명력 (단순회귀에서는 상관계수의 제곱)}$$



$$y_i - \bar{y} = [(a + bx_i) - \bar{y}] + [y_i - (a + bx_i)]$$

$$T = R + E$$

$$\sum (y_i - \bar{y})^2 = \sum [(a + bx_i) - \bar{y}]^2 + \sum [y_i - (a + bx_i)]^2$$

$$SST = SSR + SSE$$

- SST(총제곱합): y 의 평균 주위로의 총변동
- SSR(회귀제곱합): 회귀직선에 의해 설명되는 변동
- SSE(잔차(오차)제곱합): 회귀직선에 의해 설명되지 않는 변동

조정된 결정계수 (adjusted R2)

“회귀직선이 y의 변화를 설명하는 정도”로서 전체 편차 중에 회귀선이 설명하는 비율을 의미

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

$(0 \leq R^2 \leq 1)$

1에 가까울수록 높은 설명력 (단순회귀에서는 상관계수의 제곱)

→ 설명변수가 추가되면 SSE는 무조건 감소

→ 결정계수는 계속 증가 (많은 설명변수를 가진 모형이 무조건 유리?!)

$$\text{adj } R^2 = 1 - \frac{SSE/(n - k - 1)}{SST/(n - 1)}$$

n = 표본크기

k = 설명변수의 개수

설명변수가 추가될수록 자유도가 감소하도록 조정

→ 설명변수 추가에 따른 SSE의 감소속도 < 설명변수 추가에 따른 자유도 감소 속도

→ 표준오차가 증가 → 조정된 결정계수는 오히려 감소

→ 설명변수 추가에 따라 SSE가 충분히 많이 감소해야
(즉, 설명변수가 잔차를 크게 줄여야)

회귀직선의 설명력인 조정된 결정계수가 증가

$$cf) SE = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

회귀분석을 사용할 때 주의사항

- 회귀분석은 변수 간의 선형관계를 파악: 비선형(non-linear) 관계 X
- 선형관계의 존재(즉, 높은 상관계수)만으로 유의미한 결과라고 볼 수 없음

예. 아이스크림 판매량이 증가하면 일사병이 많이 걸린다.


→ 이론적 토대 + 설명 가능여부의 중요성

자료 요약을 넘어 추론으로: 확률이론

표본공간과 사건 · 확률변수와 확률분포 · 덧셈법칙과 곱셈법칙 · 베이즈 정리

자료(표본)요약의 중요성과 확률의 필요성

- 기술통계학은 모집단으로부터 추출된 표본의 값을 그래프(히스토그램, boxplot) 혹은 숫자(통계량)으로 요약한다.
- 그래프를 잘 그리거나 통계량을 잘 만들면 표본의 분포와 특성을 알 수 있다.
- 그런데 하나의 표본에서 도출된 결과가 다른 표본에서도 똑같이 나타날지는 확신할 수 없다.**
- 따라서 한 표본에서 도출한 결과가 다른 표본에서 얼마만큼 차이가 날지, 궁극적으로 모집단의 모수와 얼마나 비슷한지를 알려면 **확률의 개념이 필요하다.**



확률(probability)이란?

어떤 사건이 일어날 가능성

- 주관적 견해 (subjective view)

그 사건에 대한 주관적 확신의 정도

- 도수이론 (frequency theory)

한 시행을 동일한 조건에서 독립적으로 반복했을 때,
전체 시행횟수에서 그 사건이 일어난 횟수의 비율(상대도수)

확률의 범위

- 절대로 일어날 수 없는 사건의 확률 = 0

- 반드시 일어나는 사건의 확률 = 1

확률은 0 ~ 1 사이의 값을 가진다

- 어떤 사건: A
- A 사건이 아닌 사건 (A의 여사건): A^c
- A 사건이 일어날 확률: $P(A)$
- 사건이 일어나지 않을 확률: $P(A^c) = 1 - P(A)$

표본공간과 사건

- **사건 (event)**

특정한 실험 혹은 시행에서 관찰 가능한 결과, 표본공간의 부분 집합

- **표본공간 (sample space)**


특정한 실험 혹은 시행에서 관찰 가능한 모든 결과(근원사건)의 집합

- **확률 (probability)**


사건 A의 확률은 표본공간에서 사건 A가 나타나는 경우가 모든 사건의 경우의 수에서 차지하는 비중

표본공간과 사건

- 동전 2회 던지기라는 시행
- 표본공간 $S = \{HH, HT, TH, TT\}$



- 주사위 던지기라는 시행
- 표본공간 $S = \{1,2,3,4,5,6\}$



확률변수 (random variable)

표본공간에서 정의되는 각 사건들에 대응하는 실수 값 → 우리가 관심을 갖는 형태로 구성

- 동전 2회 던지기라는 시행
 - 표본공간 $S = \{HH, HT, TH, TT\}$
 - **각 사건을 앞면이 나오는 횟수로 변환한 확률변수**
 $HH = 2, HT = 1, TH = 1, TT = 0$
 $X = \{0, 1, 2\}$
- 동전 2회 던지기라는 시행
 - 표본공간 $S = \{HH, HT, TH, TT\}$
 - **각 사건을 두 면이 동일한 경우로 변환한 확률변수**
 $HH = 1, HT = 0, TH = 0, TT = 1$
 $X = \{0, 1\}$

S			
X=2		X=1	
X=0			
HH	HT	TH	TT

S			
X=1		X=0	
HH	TT	HT	TH

확률분포 (probability distribution)

확률변수가 출현할 가능성, 즉 사건이 발생할 가능성에 대한 분포

- 동전 2회 던지기라는 시행
 - 표본공간 $S = \{HH, HT, TH, TT\}$
 - 각 사건을 앞면이 나오는 횟수로 변환한 확률변수
 $HH = 2, HT = 1, TH = 1, TT = 0$
 $X = \{0, 1, 2\}$
 - **각 확률변수가 발생할 가능성: $P(X)$**
- 주사위 던지기라는 시행
 - 표본공간 $S = \{1,2,3,4,5,6\}$
 - 각 사건을 홀수와 짝수로 변환한 확률변수
 $1 = 1, 2 = 0, 3 = 1, 4 = 0, 5 = 1, 6 = 0$
 $X = \{0, 1\}$
 - **각 확률변수가 발생할 가능성: $P(X)$**


S		
X=2 P(X=2) =1/4	X=1 P(X=1) =1/2	
HH	HT	TH
	X=0 P(X=0) =1/4	
	TT	

S	
X=1 P(X=1) = 1/2	X=0 P(X=0) = 1/2
1,3,5	2,4,6


상호배반 (mutually exclusive) 사건

한 사건이 발생할 때 다른 사건이 일어날 수 없는 경우 두 사건 간의 관계


Q) 사건 A의 상호배반 사건은? **A의 여사건**



- 동전의 앞면과 뒷면



- 주사위의 홀수가 나오는 사건과 6이 나오는 사건




확률의 덧셈법칙

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

- $P(A), P(B)$: A가 발생할 확률, B가 발생할 확률
→ 주변확률/비조건부확률 (marginal probability)
- $P(A \cap B)$: A와 B가 동시에 발생할 확률 (A 그리고 B가 함께 일어날 확률)
→ 결합확률 (joint probability)
- $P(A \cup B)$: A와 B 중 적어도 하나의 사건이 일어날 확률 (A 또는 B가 일어날 확률)

조건부확률

$P(A|B)$ = B가 일어났다는 것을 알고 있을 때 A가 일어날 확률



- 1. B가 일어났다는 것을 알았을 때 A가 일어날 확률은
- 2. B가 일어날 확률의 합에서
- 3. A와 B가 함께 일어날 확률이 차지하는 비중

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

확률의 곱셈법칙

$$P(A \cap B) = P(A) \times P(B|A) = P(B) \times P(A|B)$$

- $P(A), P(B)$: A가 발생할 확률, B가 발생할 확률
→ 주변확률/비조건부확률 (marginal probability)
- $P(A \cap B)$: A와 B가 동시에 발생할 확률 (A 그리고 B가 함께 일어날 확률)
→ 결합확률 (joint probability)
- $P(A|B)$: B가 발생했다는 조건 하에서 A가 발생할 확률
→ 조건부확률 (conditional probability)

독립 (independent)과 종속 (dependent) 사건

- 독립 (independent) : 한 사건이 발생할 때 **다른 사건이 일어날 확률이 변하지 않는 경우** 두 사건 간의 관계
- 종속 (dependent) : 한 사건이 발생할 때 **다른 사건이 일어날 확률이 바뀌는 경우** 두 사건 간의 관계

→ 복원추출은 매 추출이 독립, 비복원추출은 종속

두 사건이 독립일 경우

$$P(B|A) = P(B), P(A|B) = P(A)$$

따라서 두 사건이 모두 일어날 확률은

$$P(A \cap B) = P(A) \times P(B|A) = P(A) \times P(B)$$

만약 두 사건이 종속이라면

두 사건의 결합확률을 계산하기 위해서

반드시 두 사건의 조건부확률을 알아야 한다!

덧셈법칙과 곱셈법칙

- **덧셈법칙**: 두 사건 중 적어도 하나의 사건이 일어날 확률과 관련

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

→ 두 사건이 상호배반일 경우 $P(A \cap B) = 0$


- **곱셈법칙**: 두 사건이 함께 일어날 확률과 관련

$$P(A \cap B) = P(A) \times P(B|A)$$

→ 두 사건이 독립일 경우 $P(B|A) = P(B)$

조건부확률의 심화

$P(A|B)$ = B가 일어났다는 것을 알고 있을 때 A가 일어날 확률



1. B가 일어났다는 것을 알았을 때 A가 일어날 확률은
2. B가 일어났을 때 A가 일어날 확률과
B가 일어났을 때 A가 일어나지 않을 확률의 합에서
3. A와 B가 함께 일어날 확률이 차지하는 비중

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A \cap B)}{P(A \cap B) + P(A^c \cap B)}$$

조건부확률의 심화

B가 일어났다는 것을 알고 있을 때 A가 일어날 확률

$$\begin{aligned} P(A|B) &= \frac{P(A \cap B)}{P(B)} = \frac{P(A \cap B)}{P(A \cap B) + P(A^c \cap B)} \\ &= \frac{P(A)P(B|A)}{P(A)P(B|A) + P(A^c)P(B|A^c)} \end{aligned}$$

확률의 곱셈법칙

B가 발생했다는 정보가 있을 때 A가 발생할 확률

(B의 발생이 A가 발생한 상황에서 나타난 경우)

(B의 발생이 A가 발생한 상황에서 나타난 것인지

혹은 B의 발생이 A가 발생하지 않은 상황에서 나타난 것인지)

베이즈 정리 (Bayes' theorem)

사전에 설정한 (주관적 견해의) 확률을 새롭게 주어진 정보를 활용해서 업데이트 시켜 미지의 세계를 추론하는 것

$$P(A|B) = \frac{P(A)P(B|A)}{P(A)P(B|A) + P(A^c)P(B|A^c)}$$

Q) 사지선다로 낸 회귀분석 문제를 맞췄을 때(B) 알고 풀었을(A) 확률은?

- 회귀분석을 알았다는 사건: A
- 회귀분석 문제를 맞췄다는 사건: B
- 회귀분석을 알 확률: $P(A)$ → 시험을 보기 전에는 모름 → 교수의 주관적 견해로 확률을 매김 → 사전확률 (prior probability)
- 문제를 맞췄다는 것을 알았을 때 회귀분석을 알 확률: $P(A|B)$ → B라는 새로운 정보를 가지고 P(A)를 업데이트한 확률
→ 사후확률 (posterior probability)

$$P(A) = 1/2$$

$$P(B|A) = 1$$

$$P(A^c) = 1 - P(A) = 1/2$$

$$P(B|A^c) = 1/4 (\because \text{사지선다})$$

$$P(A|B) = \frac{P(A)P(B|A)}{P(A)P(B|A) + P(A^c)P(B|A^c)} = \frac{0.5 * 1}{0.5 * 1 + 0.5 * 0.25} = 0.8$$

확률변수와 확률분포

기대값과 분산 · 확률변수의 조합 · 대수의 법칙 · 중심극한정리

확률변수와 확률분포

확률변수

표본공간에서 정의되는 각 사건들에 대응하는 실수 값
→ 우리가 관심을 갖는 형태로 구성

확률분포

확률변수가 출현할 가능성, 즉 사건이 발생할 가능성에 대한 분포
→ 이산확률분포, 연속확률분포

확률변수의 의미

우리가 관심을 갖는 사건을 숫자로 표현한 것

- 성공/실패(1, 0): **베르누이 확률변수**
- 성공횟수: **이항확률변수**
- 성공확률이 매우 낮은 경우의 성공횟수: **포아송확률변수**
- 특정 횟수까지 성공하는데 걸린 시행횟수(실패횟수): **음이항확률변수**
- 성공횟수를 반복해서 연속된 수로 늘린 경우: **정규확률변수**

확률변수의 기대값, 분산, 표준오차

기대값

특정한 확률분포를 따르는 확률변수가 가질 것으로 기대되는 값

$$\rightarrow E(X) = \mu$$

분산

확률변수와 기대값 간의 차이, 즉 편차의 제곱합이 가질 것으로 기대되는 값


$$\rightarrow VAR(X) = E[(X - \mu)^2]$$

표준오차

실현된 값이 기대값과 차이가 나는 정도의 표준적인 크기 = 기대값으로 나타낸 표준편차 = $\sqrt{\text{분산}}$

확률변수의 기대값, 분산, 표준오차

Q) 5가 한 장, 1이 세 장 들어있는 상자에서 하나의 카드를 추출할 때 기대값, 분산, 표준오차는?



- **기대값** = $\sum \text{값} * \text{값의 확률} = 1 * 3/4 + 5 * 1/4 = 2 = \text{상자에 들어있는 값의 평균}$
- **분산** = $\sum (\text{값} - \text{기대값})^2 * \text{값의 확률} = (-1)^2 \times \left(\frac{3}{4}\right) + 3^2 \times \left(\frac{1}{4}\right) = 3 = \text{편차 제곱합의 평균}$
- **표준오차** = $\sqrt{\sum (\text{값} - \text{기대값})^2 * \text{값의 확률}} = \sqrt{3} = \text{분산의 제곱근}$

기대값 및 분산과 관련한 유용한 공식

X, Y : 확률변수, c : 상수, $g(), h()$: 함수

$$E(c) = c$$

$$E[c g(X, Y)] = c E[g(X, Y)]$$

$$E[g(X, Y) + h(X, Y)] = E[g(X, Y)] + E[h(X, Y)]$$

$$E[g_x(X) \cdot h_y(Y)] = E[g_x(X)] \cdot E[h_y(Y)]$$

(X, Y 가 서로 독립일 때)

$$E(X + Y) = E(X) + E(Y)$$

$$E(aX + b) = a E(X) + b$$

$$E(XY) = E(X) \cdot E(Y)$$

(X, Y 가 서로 독립일 때)

$$\begin{aligned} Var(X) &= E[(X - E(X))^2] = E[X^2 - 2XE(X) + E(X)^2] \\ &= E(X^2) - 2E(X)E(X) + E(X)^2 = E(X^2) - E(X)^2 \end{aligned}$$

$$Var(X + Y) = Var(X) + Var(Y) + 2 Cov(X, Y)$$

만약 X, Y 가 독립이라면

$$Var(X + Y) = Var(X) + Var(Y)$$

$$Var(aX + b) = a^2 Var(X)$$

확률변수의 조합

특정 확률변수를 더하거나 곱하는 등 조합하면 새로운 확률변수와 새로운 확률분포를 만들 수 있다.

베르누이 확률분포

어떤 시행에 따른 사건의 결과가 p 의 확률로 성공과 실패, 즉 1과 0의 확률변수가 따르는 확률분포

이항분포

n 번 시행한 베르누이 확률변수의 결과를 모두 합하여 새롭게 만든 확률변수가 따르는 분포

정규분포

베르누이 확률변수를 합한 이항 확률변수에서 시행횟수(n)을 크게 늘렸을 때 그 값이 따르는 분포

카이제곱분포

n 개의 표준정규확률변수를 제공한 결과를 모두 합하여 새롭게 만든 확률변수가 따르는 분포

확률변수 합으로 만든 새로운 확률변수의 특징

제곱근 법칙 (square root law) → 대수의 법칙(평균의 법칙)의 근거

특정 확률분포를 따르는 확률변수(X)를 합하여 만든 새로운 확률변수($Y=X_1+X_2+\dots+X_n$)의 표준편차는 처음 확률변수가 갖는 표준편차($SD(X)$)와 확률변수를 합한 횟수(n)의 제곱근 간의 곱으로 표현

(확률변수 X의 표준편차) $\times \sqrt{\text{합한 회수}}$

$$Var(Y) = Var(X_1 + X_2 + X_3 \cdots + X_n) = Var(X_1) + Var(X_2) + \cdots + Var(X_n) = n Var(X)$$

($\because$ X는 독립이므로)

→ 합한 횟수가 10이면 합의 표준편차 = 처음 확률변수의 표준편차

만약 확률변수 Y가 합이 아니라 평균이라면?

즉, $Y = (X_1+X_2+\dots+X_n)/n$

확률변수 평균으로 만든 새로운 확률변수의 특징

제곱근 법칙 (square root law) → 대수의 법칙(평균의 법칙)의 근거

특정 확률분포를 따르는 확률변수(X)의 합을 평균하여 만든 새로운 확률변수($Y = (X_1 + X_2 + \dots + X_n)/n$)의 표준편차는 처음 확률변수가 갖는 표준편차($SD(X)$)를 확률변수를 합한 횟수(n)의 제곱근으로 나눈 값으로 표현

$$\begin{aligned}
 & \frac{\text{확률변수 } X \text{의 표준편차}}{\sqrt{\text{합한 회수}}} \\
 Var(Y) &= Var\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \frac{1}{n^2} [Var(X_1) + Var(X_2) + \dots + Var(X_n)] \\
 &= \frac{1}{n^2} n Var(X) = Var(X)/n \\
 & \quad (\because X \text{는 독립이므로})
 \end{aligned}$$

→ 합한 횟수가 10이면 평균의 표준편차 = 처음 확률변수의 표준편차

확률변수의 합과 평균을 통한 새로운 조합의 특징: 대수의 법칙(평균의 법칙)

어떤 확률분포를 따르는지에 상관없이
특정 확률변수를 여러 번 합하거나 혹은 평균한 값을 새로운 확률변수로 가질 경우
새로운 확률변수의 표준편차는
기존 확률변수가 지닌 표준편차의 n 배만큼 증가하는 것이 아니라 $\sqrt{n}$ 에 비례하거나 반비례한다.

→ Why?

합하면 극단적인 값이 출현할 경우의 수는 매우 적지만, 중간 값이 출현할 경우의 수는 커지기 때문에
합할수록 값의 표준편차가 합한 횟수의 속도만큼 늘어나지 않음

확률변수의 합과 평균을 통한 새로운 조합의 특징: 중심극한정리

어떤 확률분포를 따르는지에 상관없이

특정 확률변수를 충분히 많은 수까지 더하거나 이를 평균한 값을 새로운 확률변수로 만들면,
그 확률변수는 정규분포에 수렴하는 특성이 있다.

이를 중심극한정리(central limit theorem)라 한다.

단, 정규분포로 수렴해가는 속도는 초기 확률분포에 따라 다르다. (초기 확률분포가 정규분포와 닮을 경우 n 이 작아도 성립)

- 확률변수의 X 의 확률분포 $f(x)$ 는 알려지지 않은 확률분포
- $f(x)$ 로부터 $X_1, X_2, X_3, \dots, X_n$ 과 같이 확률변수를 N 번 더함
- X 를 N 번 더한 값을 갖는 새로운 확률변수: $Y = X_1 + X_2 + X_3 + \dots + X_n$
- N 이 충분히 크다면 새로운 확률변수 $Y \sim N(\mu_x, N\sigma_x^2)$


대수의 법칙과 중심극한정리가 중요한 이유

- 모집단의 모수를 추정하기 위해서 추출한 각 표본은 그 값이 정해지지 않을 경우 여전히 확률변수
- → 표본의 평균이라는 통계량은 확률변수를 평균한 새로운 확률변수
- → 따라서 표본의 평균은 대수의 법칙과 중심극한정리가 적용되는 확률변수임
- → 대수의 법칙과 중심극한정리를 활용하면 표본평균의 분포를 추론할 수 있음
- → 분포를 추론하면 어떤 구간에서 표본평균이 더 빈번하게 출현할지 알 수 있음
- → 표본평균이 모평균과 차이가 날 가능성의 정도, 즉 불확실성의 정도를 알 수 있음

표본통계량: 확률변수의 조합으로 만들어진 새로운 확률변수

모집단에서 추출한 표본으로 만들어진 표본통계량(예. 표본평균) 또한 그 값이 확정되지 않았으므로 확률변수이다.

- 표본통계량(확률변수)으로서 표본평균 $\bar{X}$ 의 기대값



$$E(\bar{X}) = E\left(\frac{x_1 + x_2 + \cdots + x_n}{n}\right) = \frac{E(X) + E(X) + \cdots + E(X)}{n}$$

$$= \frac{nE(X)}{n} = E(X) = \mu$$

→ 표본평균은 모평균에 대한 불편추정량(unbiased estimator)이다.


* 불편의성(unbiasedness)

추정량의 기대값이 추정하려는 모수와 정확하게 일치하는지의 여부

표본통계량: 확률변수의 조합으로 만들어진 새로운 확률변수

모집단에서 추출한 표본으로 만들어진 표본통계량(예. 표본평균) 또한 그 값이 확정되지 않았으므로 확률변수이다.

- 표본통계량(확률변수)으로서 표본평균 $\bar{X}$ 의 분산



$$Var(\bar{X}) = Var\left(\frac{x_1 + x_2 + \cdots + x_n}{n}\right) = \frac{1}{n^2} [Var(x_1) + Var(x_2) + \cdots + Var(x_n)]$$

$$= \frac{1}{n^2} n Var(X) = Var(X)/n = \sigma^2/n$$

→ 표본평균의 분산은 모집단의 분산에 비례하고 표본개수에 반비례한다.

(∵ 확률변수들의 평균을 새로운 확률변수로 할 경우 대수의 법칙이 성립)


→ 표본평균의 분산에 대한 제곱근 = 표본평균의 표준오차

→ 표본평균이 모평균에 비해 얼마나 떨어져 있을지를 나타냄

표본통계량: 확률변수의 조합으로 만들어진 새로운 확률변수

모집단에서 추출한 표본으로 만들어진 표본통계량(예. 표본평균) 또한 그 값이 확정되지 않았으므로 확률변수이다.

- 표본통계량(확률변수)으로서 표본평균의 분포



$\bar{X}$ 의 평균 = μ

$\bar{X}$ 의 분산 = σ^2/n

만약 n 이 충분히 크다면

X 의 확률분포인 $f(x)$ 에 상관없이

$\bar{X}$ 는 정규분포에 근사

→ 중심극한정리


$$\bar{X} \sim N(\mu, \sigma^2/n)$$

통계적 추론: 추정과 가설검정

점추정과 구간추정 · 가설검정의 절차 · 제1종 오류와 제2종 오류

통계적 추론


모집단에서 임의의 표본을 추출하여 이를 바탕으로 모집단의 특성을 찾아내는 통계적 과정



- **추정:** 표본을 이용하여 만든 **표본통계량을 모수추정량**으로 삼아 **모집단의 모수를 예측**하는 방법
- **가설검정:** 모집단(모수)에 대한 **예상결론**을 세우고 그 타당성을 확인하여 **예상결론을 채택 또는 기각**하는 것

통계적 추론

모집단에서 임의의 표본을 추출하여 이를 바탕으로 모집단의 특성을 찾아내는 통계적 과정



- **추정:** 표본을 이용하여 만든 **표본통계량**을 **모수추정량**으로 삼아 **모집단의 모수를 예측**하는 방법
- **가설검정:** 모집단(모수)에 대한 **예상결론**을 세우고 그 타당성을 확인하여 **예상결론을 채택 또는 기각**하는 것

추정 (estimation)


표본을 이용하여 만든 표본통계량을 모수추정량으로 삼아 모집단의 모수를 예측하는 방법

- **점추정 (point estimation):** 모수추정치를 모수에 대한 추정 값으로 삼는 것
- **구간추정 (interval estimation):** 모수추정치를 중심으로 표준오차를 활용하여 모수가 포함될 일정구간을 추정

추정 (estimation)


표본을 이용하여 만든 표본통계량을 모수추정량으로 삼아 모집단의 모수를 예측하는 방법

〈표본평균을 활용한 모평균의 구간추정 절차〉



t-분포표 보는 법

α df	0.4	0.25	0.1	0.05	0.025	0.01	0.005	0.0025	0.001	0.0005
1	0.325	1.000	3.078	6.314	12.706	31.821	63.657	127.32	318.31	636.62
2	0.289	0.816	1.886	2.920	4.303	6.965	9.925	14.089	22.327	31.599
3	0.277	0.765	1.638	2.353	3.182	4.541	5.841	7.453	10.215	12.924
4	0.271	0.741	1.533	2.132	2.776	3.747	4.604	5.598	7.173	8.610
5	0.267	0.727	1.476	2.015	2.571	3.365	4.032	4.773	5.893	6.869
6	0.265	0.718	1.440	1.943	2.447	3.143	3.707	4.317	5.208	5.959
7	0.263	0.711	1.415	1.895	2.365	2.998	3.499	4.029	4.785	5.408
8	0.262	0.706	1.397	1.860	2.306	2.896	3.355	3.833	4.501	5.041
9	0.261	0.703	1.383	1.833	2.262	2.821	3.250	3.690	4.297	4.781
10	0.260	0.700	1.372	1.812	2.228	2.764	3.169	3.581	4.144	4.587
11	0.260	0.697	1.363	1.796	2.201	2.718	3.106	3.497	4.025	4.437
12	0.259	0.695	1.356	1.782	2.179	2.681	3.055	3.428	3.930	4.318
13	0.259	0.694	1.350	1.771	2.160	2.650	3.012	3.372	3.852	4.221
14	0.258	0.692	1.345	1.761	2.145	2.624	2.977	3.326	3.787	4.140
15	0.258	0.691	1.341	1.753	2.131	2.602	2.947	3.286	3.733	4.073
16	0.258	0.690	1.337	1.746	2.120	2.583	2.921	3.252	3.686	4.015
17	0.257	0.689	1.333	1.740	2.110	2.567	2.898	3.222	3.646	3.965
18	0.257	0.688	1.330	1.734	2.101	2.552	2.878	3.197	3.610	3.922
19	0.257	0.688	1.328	1.729	2.093	2.539	2.861	3.174	3.579	3.883
20	0.257	0.687	1.325	1.725	2.086	2.528	2.845	3.153	3.552	3.850
21	0.257	0.686	1.323	1.721	2.080	2.518	2.831	3.135	3.527	3.819
22	0.256	0.686	1.321	1.717	2.074	2.508	2.819	3.119	3.505	3.792
23	0.256	0.685	1.319	1.714	2.069	2.500	2.807	3.104	3.485	3.768
24	0.256	0.685	1.318	1.711	2.064	2.492	2.797	3.091	3.467	3.745
25	0.256	0.684	1.316	1.708	2.060	2.485	2.787	3.078	3.450	3.725
26	0.256	0.684	1.315	1.706	2.056	2.479	2.779	3.067	3.435	3.707
27	0.256	0.684	1.314	1.703	2.052	2.473	2.771	3.057	3.421	3.690
28	0.256	0.683	1.313	1.701	2.048	2.467	2.763	3.047	3.408	3.674
29	0.256	0.683	1.311	1.699	2.045	2.462	2.756	3.038	3.396	3.659
30	0.256	0.683	1.310	1.697	2.042	2.457	2.750	3.030	3.385	3.646
40	0.255	0.681	1.303	1.684	2.021	2.423	2.704	2.971	3.307	3.551
60	0.254	0.679	1.296	1.671	2.000	2.390	2.660	2.915	3.232	3.460
120	0.254	0.677	1.289	1.658	1.980	2.358	2.617	2.860	3.160	3.373
∞	0.253	0.674	1.282	1.645	1.960	2.326	2.576	2.807	3.090	3.291




- 1. 표본수를 통해 자유도(df)를 파악한다.
- 2. "구하려는 T값 ~ ∞사이의 값이 나타날 확률"인 α를 정한다.
- 3. 특정 자유도(행)에서 찾으려는 α(열)에 해당하는 T값을 찾는다.

가설검정 (hypothesis test)

표본통계량이 귀무가설 하의 분포에서 도출되었다고 가정한 상태에서
실제 통계치 이상으로 극단적인 값이 귀무가설 하에서 나올 확률을 계산하여 귀무가설을 검증하는 것

1. 귀무가설과 대립가설을 설정: 연구자가 입증하려는 가설을 대립가설로, 그 반대를 귀무가설로 설정
2. 표본통계량이 갖게 될 표준오차를 유추
3. 표본통계량이 따르는 분포를 유추
4. 가설검정 실시: 표본통계량의 분포를 고려하여 검정통계량으로 변환한 뒤 해당 값이 출현할 확률을 계산
5. 의사결정: 대립가설에 대한 증거가 충분하면 귀무가설을 기각, 충분하지 않으면 기각하지 않음



가설검정 용어

귀무가설
(null hypothesis): H_0

버릴 것을 예상하는 가설, 차이는 우연이다.

대립가설
(alternative hypothesis): H_1

우리가 증명하고자 하는 가설, 차이는 실질적이다.

유의수준
(significance level)

귀무가설이 옳다는 가정 하에서 귀무가설의 기각여부를 결정하는데 사용할 기준 확률

임계치 (critical value) /
기각역(rejection region)

유의수준 하에서 귀무가설을 기각하게 하는 임계 값 및 그 구간(기각역)

유의확률
(p-value)


귀무가설이 옳다는 가정 하에서 관측된 검정통계량 이상으로 극단적인 값이 나올 확률

가설검정 (hypothesis test) 방식 선택 절차

〈단일 표본의 평균 검정〉

귀무가설(H0): 평균은 μ 일 것이다.

대립가설(H1): 평균은 μ 가 아닐 것이다(양측) / 평균은 μ 보다 크거나(우측 기각역) μ 보다 작을 것(좌측 기각역)이다(단측)




가설검정 (hypothesis test) 방식 선택 절차

〈두 표본의 평균 검정〉


귀무가설(H0): 두 집단의 평균에는 차이가 없을 것이다. ($\mu_1 = \mu_2 \rightarrow \mu_1 - \mu_2 = 0$)

대립가설(H1): 두 집단의 평균에는 유의미한 차이가 존재할 것이다(양측) ($\mu_1 \neq \mu_2 \rightarrow \mu_1 - \mu_2 \neq 0$)



가설검정 (hypothesis test): 회귀분석의 유의성 검정

Q) 회귀계수 b_1 은 실질적인 의미가 있는가?



1. 가설설정

귀무가설: 회귀계수는 유의미하지 않다 ($b_1 = 0$)

대립가설: 회귀계수는 유의미하다 ($b_1 \neq 0$)

2. 표본통계량 설정: 회귀계수 b_1

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

3. 표본통계량의 표준오차

- 오차의 분산 σ^2 을 알 때: $Var(b_1) = \frac{\sigma^2}{\sum (X_i - \bar{X})^2}$

- 오차의 분산 σ^2 을 모를 때: $Var(b_1) = \frac{S^2}{\sum (X_i - \bar{X})^2}$

$$S = \sqrt{\frac{\sum (y_i - \hat{y}_i)^2}{n - 2}}$$

4. 검정통계량 분포: 대개 오차의 분산을 모르므로 t-검정


$$T(n - 2) = (b_1 - 0) / SE(b_1)$$

가설검정에서의 오류

검정결과	실제상황	
	귀무가설이 옳은 경우	귀무가설이 옳지 않는 경우
귀무가설을 기각안함	옳은 결정	제2종 오류
귀무가설을 기각함	제1종 오류	옳은 결정

- **제1종 오류:** 귀무가설이 옳은데도 귀무가설을 기각하는 경우
→ 제1종 오류의 확률 = 유의수준
- **제2종 오류:** 귀무가설이 옳지 않은데도 귀무가설을 기각하지 않는 경우
→ 1-제2종 오류의 확률 = 검정력

가설검정에서의 오류



- **제1종 오류:** 귀무가설이 옳은데도 귀무가설을 기각하는 경우
→ 제1종 오류의 확률 = 유의수준
- **제2종 오류:** 귀무가설이 옳지 않은데도 귀무가설을 기각하지 않는 경우
→ 1-제2종 오류의 확률 = 검정력

통계적 추론에서 분포의 중요성

**추정(estimation)이나 가설검정(hypothesis test)은
검정하기 위한 통계량의 분포를 명확히 추론하는데서 출발한다.**

(분포형태(정규분포, t분포, 카이제곱분포 등), 기댓값, 표준오차)

검정통계량의 분포에서

내가 관측한 값이 희귀하면 귀무가설은 옳지 않고,
내가 관측한 값이 평범하면 귀무가설을 유지하는 것이 낫다.

한 학기 동안의 강의 내용

- 통계학과 자료의 정리: 히스토그램, 평균, 표준편차
- 정규분포와 정규분포로의 근사
- 상관관계
- 회귀분석

기술통계학

- 확률이론
- 대수의 법칙과 중심극한정리
- 표본추출과 추정
- 가설검정

추론통계학

통계학은 자료를 정리, 분석, 추론하여 유용한 정보를 얻기 위한 언어이자 도구

한 학기 동안 고생 많았습니다!

권규상 Kyusang Kwon

kyusang.kwon@chungbuk.ac.kr